

Chương 1: Cơ sở về Ngôn ngữ Tự nhiên

Chương 1: Cơ sở về Ngôn ngữ Tự nhiên

- Giới thiệu tổng quan chương
- Mục tiêu: Hiểu được ngôn ngữ tự nhiên, cú pháp, ngữ nghĩa, văn phạm, kho ngữ liệu, và xử lý ngôn ngữ tự nhiên

Ngôn ngữ

► Khái niệm

- Là hệ thống các **ký hiệu** (chữ cái) được kết hợp tuân theo các **quy tắc** (ngữ pháp) để truyền tải ngữ nghĩa
- Là phương tiện để giao tiếp

Ngôn ngữ

► Khái niệm

- Là hệ thống các **ký hiệu** (chữ cái) được kết hợp tuân theo các **quy tắc** (ngữ pháp) để truyền tải ngữ nghĩa
- Là phương tiện để giao tiếp

► Ngôn ngữ được thiết kế bởi con người

- Ngôn ngữ hình thức (formal language)
 - Tập **các xâu** (string) tuân theo các **quy tắc** (rule, grammar) nhất định
 - **Ví dụ:** Tập các xâu trên bảng chữ cái (alphabet) $\{0,1\}$ có số lượng số 0 và số lượng số 1 bằng nhau
- Các ngôn ngữ lập trình (programming language)

► Ngôn ngữ tự nhiên (natural language)

- Ngôn ngữ được **con người sử dụng hàng ngày**

Ngôn ngữ tự nhiên


- Ngôn ngữ tự nhiên là phương tiện giao tiếp của con người.
- Đặc trưng: linh hoạt, mơ hồ, giàu ngữ cảnh.

1.1. Đặc trưng ngôn ngữ tự nhiên

- Tính mơ hồ (ambiguity)
- Tính đa nghĩa (polysemy)
- Tính ngữ cảnh

1.2. Cú pháp

- Cú pháp mô tả cấu trúc của câu trong ngôn ngữ.
- Đơn vị từ, cụm từ, mệnh đề.



1.2.1. Từ

- Đơn vị nhỏ nhất trong ngôn ngữ.
- Phân loại: từ đơn, từ ghép, từ loại.
- Phân chia giữa các từ tùy thuộc vào ngôn ngữ
 - Tiếng Anh: sử dụng khoảng trắng
 - Tiếng Việt: khoảng trắng phân tách cả âm tiết và từ (từ đơn/từ ghép)

Ví dụ phân tích từ

- ‘Tôi yêu NLP’ → ['Tôi', 'yêu', 'NLP']
- “Học sinh học sinh học” → ['Học sinh', 'học', 'sinh học']
- Đây được gọi là quá trình tách từ (Tokenization)

1.2.2. Cụm từ

- - Cụm danh từ: 'một chiếc xe đẹp'
- - Cụm động từ: 'đang học bài'

Phân loại cụm từ

- NP - Noun Phrase
- VP - Verb Phrase
- PP - Prepositional Phrase

1.2.3. Mệnh đề


- Mệnh đề gồm chủ ngữ và vị ngữ.
- Ví dụ: 'Tôi đang học' là một mệnh đề.

Các loại mệnh đề

- - Mệnh đề đơn
- - Mệnh đề phức
- - Mệnh đề ghép

1.2.4. Văn phạm

- Văn phạm (*theo nghĩa thông thường*) là các cú pháp đối với từng ngôn ngữ tự nhiên, là tập các quy tắc cấu tạo từ, và quy tắc liên kết các từ lại thành một câu.



Cây phân tích cú pháp trong văn phạm tiếng Việt

1.2.4. Văn phạm hình thức


- Văn phạm hình thức là một hệ thống sinh các từ của một ngôn ngữ, được định nghĩa như sau:

Văn phạm $G = \langle V_N, V_T, P, \sigma \rangle$

- V_N : tập các ký hiệu chưa kết thúc
- V_T : tập các ký hiệu kết thúc
- P : tập các luật viết lại (luật sản xuất)
- σ : ký hiệu khởi tạo (ký hiệu ban đầu)

Các lớp văn phạm

- Dựa vào đặc điểm của tập quy tắc mà người ta chia các văn phạm thành các nhóm khác nhau. Noam Chomsky đã phân loại văn phạm thành bốn nhóm dưới đây:
 - Loại 0: Văn phạm không hạn chế (Unrestricted Grammar-UG) (hay văn phạm ngữ cấu, văn phạm tổng quát),
 - Loại 1: Văn phạm cảm ngữ cảnh (Context Sensitive Grammar-CSG),
 - Loại 2: Văn phạm phi ngữ cảnh (Context Free Grammar-CFG),
 - Loại 3: Văn phạm chính quy. (Regular Grammar-RG)



Văn phạm phù hợp cho NLP

- ▶ ✗ Văn phạm chính quy (=ngôn ngữ chính quy)
 - Không sinh được ngôn ngữ tự nhiên
- ▶ ✗ Văn phạm cảm ngữ cảnh
- ▶ ✗ Văn phạm loại 0
 - Cần nhiều thời gian để đánh giá xem một văn phạm có thể sinh ra được một xâu hay không
- ▶ ○ Văn phạm phi ngữ cảnh
 - Đủ mạnh để sinh ngôn ngữ tự nhiên
 - Tồn tại các thuật toán phân tích cú pháp hiệu quả

Context Free Grammar (CFG)

- CFG- Đây là loại văn phạm phổ biến nhất được dùng trong NLP để phân tích cú pháp
 - Nó đủ mạnh để mô hình hóa hầu hết cấu trúc câu trong ngôn ngữ tự nhiên.
 - Có nhiều thuật toán phân tích cú pháp hiệu quả (Earley parser, CYK parser).
 - Có thể mở rộng thành PCFG để gán xác suất cho từng quy tắc, phục vụ các mô hình thống kê.
- $S \rightarrow NP VP$
- $NP \rightarrow Det N$
- $VP \rightarrow V NP$
- $Det \rightarrow 'the'$
- $N \rightarrow 'dog'$
- $V \rightarrow 'sees'$

Regular Grammar - RG

- Văn phạm chính quy (RG) thường dùng cho các bước tiền xử lý như phân tách từ, nhận dạng mẫu đơn giản.
- Ứng dụng chính trong NLP: Tokenization, regex, POS tagging đơn giản

1.3. Ngữ nghĩa

- Ngữ nghĩa mô tả ý nghĩa của từ, cụm, câu.
- Bao gồm từ vựng và ngữ nghĩa hình thức.

1.3.1. Quan hệ ngữ nghĩa

- Đồng nghĩa: đẹp $\sim$ xinh
- Trái nghĩa: cao – thấp
- Bao hàm: hoa $\supset$ hoa hồng

Đa nghĩa và mơ hồ

- Ví dụ:
 - từ 'lá' có thể mang nhiều nghĩa tùy ngữ cảnh: lá cây, lá bài
 - từ 'đi' có thể mang nhiều nghĩa tùy ngữ cảnh: đi lại, từ trần

1.3.2. Biểu diễn ngữ nghĩa

- Logic hình thức: FOL (First-Order Logic)
- Vector: Word2Vec, GloVe
- Frame-based

Frame: MUA_BÁN

Buyer: Nam

Goods: cuốn_sách

Seller: hiệu_sách

Time: hôm_qua

Ví dụ biểu diễn vector

- 'king' - 'man' + 'woman' $\approx$ 'queen'
- Áp dụng trong Word2Vec

1.4 Kho ngữ liệu

- ▶ Thuật ngữ tiếng Anh
 - Corpus (số nhiều là Corpora)
- ▶ Kho ngữ liệu văn bản
 - Tập hợp các văn bản viết
 - Báo, tạp chí, tiểu thuyết, từ điển, v.v
- ▶ Kho ngữ liệu tiếng nói
 - Tập hợp các đoạn tiếng nói
 - Hội thoại, phỏng vấn, bài nói chuyện, diễn văn, v.v

Từ số lượng tới chất lượng

❑ Trước kia

- Khó thu thập dữ liệu dưới dạng máy có thể đọc được
- Cần xem xét đến số lượng (amount) của kho ngữ liệu

❑ Ngày nay

- Các văn bản điện tử khá phổ biến
 - Bài báo, báo cáo, trang web, blog
 - Cần quan tâm tới chất lượng dữ liệu
- Điều quan trọng là xem xét xem kho ngữ liệu nên chứa các loại thông tin nào
- Kho ngữ liệu được gán nhãn

Kho ngữ liệu được gán nhãn

- ❑ Kho ngữ liệu được gán một số thông tin thêm
 - Khác với văn bản thô (plain text)
- ❑ Các loại kho ngữ liệu được gán nhãn chính
 - Kho ngữ liệu được gán nhãn từ loại (POS tagged corpus)
 - Từ loại của từng từ
 - Kho ngữ liệu được gán nhãn cú pháp
 - Cây cú pháp mức câu
 - Cây phụ thuộc (dependency tree)

Kho ngữ liệu được gán nhãn

- Kho ngữ liệu ngữ nghĩa
 - Ý nghĩa của các từ
- Kho ngữ liệu song ngữ
 - Tập các câu dịch của nhiều ngôn ngữ khác nhau
 - Tôi ăn sáng rồi đến trường .
 - I had breakfast and left for school .
 - Có giống hàng giữa các câu (alignment between sentences)
 - Có giống hàng giữa các cụm
 - Có giống hàng giữa các từ

Ví dụ kho ngữ liệu đã gán nhãn

☐ Kho ngữ liệu gán nhãn từ loại (POS tagged corpus)

- **Brown corpus**
 - Gồm 1 triệu từ tiếng Anh
- **British National Corpus (BNC)**
 - 100 triệu từ tiếng Anh
- **Viet Treebank**
 - Khoảng 20 nghìn câu

☐ Kho ngữ liệu gán nhãn cú pháp

- **Penn Treebank**
 - 1.1 triệu từ tiếng Anh
 - POS, Cây cú pháp
- **Kyoto corpus**
 - 1 triệu từ tiếng Nhật
 - POS, Cây phụ thuộc
- **Viet Treebank**
 - Khoảng 10 nghìn câu

Truy cập kho ngữ liệu

- Công cụ: NLTK, spaCy, HuggingFace,...
- Định dạng: CoNLL, JSON, XML

Truy cập với NLTK

- `import nltk`
- `nltk.download('wordnet')`
- `from nltk.corpus import wordnet`
`as wn`

Truy cập với NLTK

```
[1] import nltk
# Chạy một lần để tải bộ từ điển WordNet
nltk.download('wordnet')
```



↗ [nltk_data] Downloading package wordnet to /root/nltk_data...
True

```
▶ from nltk.corpus import wordnet as wn
# Lấy tất cả các synsets (nghĩa) của từ "city"
synsets = wn.synsets('city')
print(f"Số nghĩa của từ 'city': {len(synsets)}")

for i, syn in enumerate(synsets):
    print(f"\nNghĩa thứ {i+1}:")
    print(f"  - Tên synset: {syn.name()}")
    print(f"  - Định nghĩa: {syn.definition()}")
    print(f"  - Ví dụ: {syn.examples()}")
```

↗ Số nghĩa của từ 'city': 3

Nghĩa thứ 1:

- Tên synset: city.n.01
- Định nghĩa: a large and densely populated urban area; may include several independent administrative districts
- Ví dụ: ['Ancient Troy was a great city']

Nghĩa thứ 2:

- Tên synset: city.n.02
- Định nghĩa: an incorporated administrative district established by state charter
- Ví dụ: ['the city raised the tax rate']

Truy cập với Spacy



```
▶ import spacy

#download English model
nlp = spacy.load("en_core_web_sm")

doc = nlp("This is a sample sentence.")

for token in doc:
    print(token.text, token.pos_, token.dep_)
```

⇒ This PRON nsubj
is AUX ROOT
a DET det
sample NOUN compound
sentence NOUN attr
. PUNCT punct

Truy cập với Stanford NLP / Stanza

```
[7] pip install stanza
```



Show hidden output



```
[8] import stanza
```

```
# download English model
stanza.download('en')
nlp = stanza.Pipeline('en')


doc = nlp("This is a sample sentence.")
print(doc.sentences[0].print_dependencies())
```

```
INFO:stanza:Done loading processors!
('This', 5, 'nsubj')
('is', 5, 'cop')
('a', 5, 'det')
('sample', 5, 'compound')
('sentence', 0, 'root')
('.', 5, 'punct')
None
```

1.5. Giới thiệu NLP

- Là lĩnh vực kết hợp CS, ngôn ngữ học, AI
- Mục tiêu: tự động xử lý ngôn ngữ con người

The History of NLP



NLP Tasks

WORD TAGGING	SENTENCE PARSING	TEXT CLASSIFICATION	TEXT GENERATION	TEXT PAIR MATCHING
Tokenization	Constituency parsing	Sentiment analysis	Generative text modeling	Semantic textual similarity
Named entity recognition (NER)	Semantic labeling	Intent detection	Machine translation	Natural language inference (NLI)
Part-of-speech tagging	Dependency parsing	Topic classification	Summarization	Relation extraction
Lemmatization/ Stemming	Coreference parsing	Fake news detection	Personalized dialogue systems	
Word sense disambiguation	Clause boundary detection	Email classification	Report generation	
Keyword extraction		Customer feedback analysis	Question answering (QA)	

1.5.1. Các bài toán cơ bản

- POS Tagging
- Named Entity Recognition
- Parsing
- Classification
- Machine Translation


Một số bài toán nâng cao

- Summarization
- Question Answering
- Chatbot
- Sentiment Analysis

1.5.2. Ứng dụng NLP

- Google Translate
- Siri, ChatGPT
- Phân tích mạng xã hội
- Phân loại bình luận
- V,V...

Applications of Natural Language Processing



NLP trong tiếng Việt

- Công cụ: Underthesea, VnCoreNLP, PhoBERT
- Kho dữ liệu: VLSP, UIT-VSFC

Thách thức trong NLP

- Mơ hồ ngữ nghĩa
- Thiếu dữ liệu
- Phụ thuộc ngữ cảnh

Tổng kết

- Ngôn ngữ tự nhiên, cú pháp, ngữ nghĩa, văn phạm
- Tổng quan kho ngữ liệu
- Xử lý ngôn ngữ tự nhiên (NLP), bài toán NLP và ứng dụng của NLP