Học viện Công nghệ Bưu chính Viễn thông
Khoa Công nghệ Thông tin 1

Nhập môn học sâu

Giải tích

TS. NGUYỄN XUÂN ĐỨC

Nội dung

- Đạo hàm
- Luật chuỗi (chain rule)
- Xác suất và thống kê

Giải tích

Đạo hàm và vi phân

- Giả sử ta có hàm $f: R \mapsto R$, đạo hàm của f được định nghĩa là:

$$f(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}$$

Nếu $f'(a)$ tồn tại, f được gọi là khả vi (differentiable) tại a

- Ký hiệu biểu diễn đạo hàm:

$$f'(x) = y' = \frac{dy}{dx} = \frac{df}{dx} = \frac{d}{dx} f(x)$$

Đạo hàm riêng

- Cho $y = f(x_1, x_2, \dots, x_n)$ là một hàm với n biến. Đạo hàm riêng của y theo tham số x_i là

$$\frac{\partial y}{\partial x_i} = \lim_{h \to 0} \frac{f(x_1, \dots, x_i + h, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}$$

- Ta coi $x_1,\dots,x_{i-1},x_{i+1},\dots,x_n$ là các hằng số và tính đạo hàm của y theo x_i

Gradient

- Giả sử đầu vào của hàm $f: R^n \mapsto R$ là một vector n chiều $x = [x_1, x_2, \dots, x_n]^\top$ và đầu ra là một số. Gradient của hàm f(x) theo x là một vector gồm n đạo hàm riêng:

$$\nabla_x f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n}\right]^\top$$

- Biểu thức $\nabla_x f(x)$ thường được viết gọn thành $\nabla f(x)$ nếu không sợ nhầm lẫn

Gradient descent

- Hàm mất mát phụ thuộc vào tham số của mô hình và gián tiếp đánh giá hiệu quả của mô hình
  - Cực tiểu hóa hàm mất mát tương đương với cực đại tính hiệu quả mô hình
- Gradient descent là thuật toán tối ưu tuần tự để tìm giá trị cực tiểu của một hàm số
  - Di chuyển về hướng ngược lại của giá trị gradient của hàm số tại điểm hiện tại

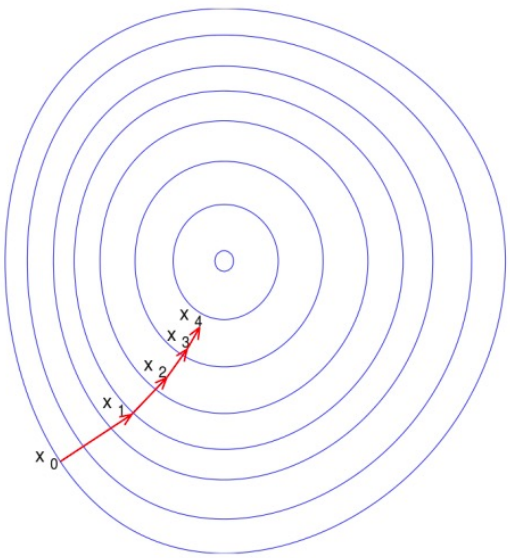

Cập nhật gradient

- Xét hàm số $f(\theta)$, thuật toán cập nhật gradient được biểu diễn như sau:

$$\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} f(\theta)$$

với mọi tham số θ_j

- Bước nhảy được điều khiển bởi tham số tốc độ học α
- Gradient Descent Visualizer

Stochastic Gradient Descent

- Theo lý thuyết, mỗi bước cập nhật cần duyệt qua tất cả mẫu huấn luyện một lần → **batch gradient descent**
- Một cách tiếp cận khác là **minibatch stochastic gradient descent**, khi chỉ dùng một tập nhỏ dữ liệu huấn luyện tại mỗi bước cập nhật gradient
- Trường hợp đặc biệt, chỉ sử dụng *một* mẫu trong mỗi bước cập nhật được gọi là **stochastic gradient descent**

Hàm lồi

- Nếu hàm số có tính lồi (convex) thì thuật toán gradient descent sẽ hội tụ về điểm cực tiểu toàn cục (global minimum)
- Nếu hàm số không lồi, thuật toán sẽ hội tụ về điểm cực tiểu cục bộ (local minima)

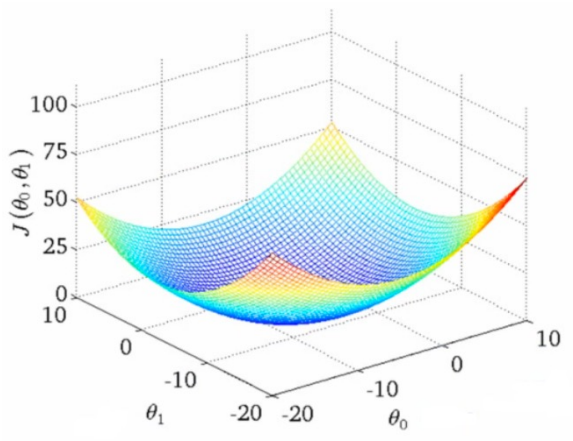

Hàm lồi

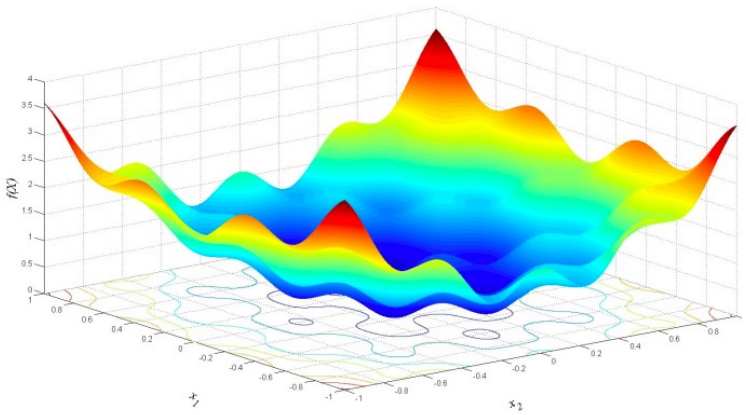

Hàm không lồi

Quy tắc chuỗi (chain rule)

- Tính toán gradient có thể khó khăn vì các hàm nhiều biến thường là hàm hợp, không dễ để áp dụng quy tắc tính vi phân
- Giả sử hai hàm $y = f(u)$ và $u = g(x)$ đều khả vi, quy tắc dây chuyền được mô tả

$$\frac{dy}{dx} = \frac{dy}{du}\frac{du}{dx}$$

- Trường hợp tổng quát với hàm nhiều biến, giả sử $y = f(u_1, u_2, \dots, u_m)$ và $u = g(x_1, x_2, \dots, x_n)$. Quy tắc dây chuyền cho ta:

$$\frac{dy}{dx_i} = \frac{dy}{du_1}\frac{du_1}{dx_i} + \frac{dy}{du_2}\frac{du_2}{dx_i} + \cdots + \frac{dy}{du_m}\frac{du_m}{dx_i}$$

Xác suất thống kê

Xác suất

- Giả sử, ta tung một đồng xu và muốn biết cơ hội để thấy được mặt ngửa (hoặc sấp). Nếu đồng xu công bằng, thì xác suất thấy mặt ngửa là ½
- Với đồng xu bất kỳ, ta có thể ước lượng P(ngửa) bằng cách tung đồng xu và lấy mẫu kết quả, sau đó lấy số lần xuất hiện mặt ngửa chia cho tổng số lần tung
- Theo luật số lớn, số lần tung càng lớn thì ước lượng càng gần với xác suất thực

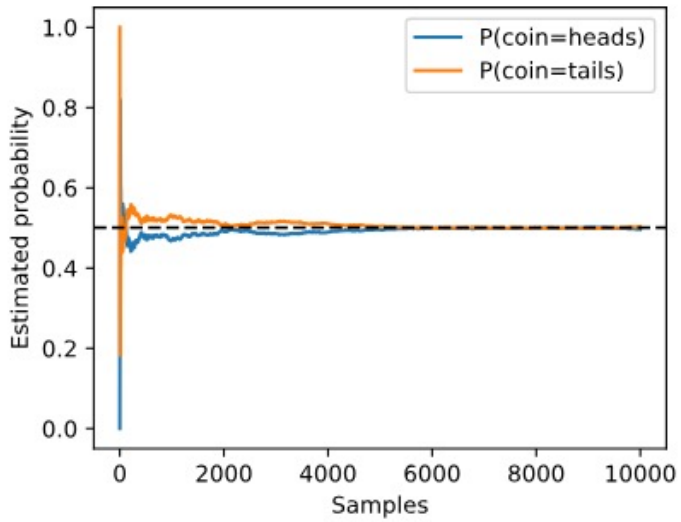

Biến ngẫu nhiên

- Biến ngẫu nhiên: biểu diễn một đại lượng và nhận giá trị thuộc một tập các giá trị khả dĩ
- Ví dụ: khi tung đồng xu, sự kiện "trông thấy mặt ngửa" có xác suất P(X=ngửa)
- Xác suất mà biến ngẫu nhiên nhận giá trị trong một khoảng: $P(1 \leq X \leq 3)$
- Với biến ngẫu nhiên liên tục, ví dụ như chiều cao của một người, ta sử dụng khái niệm *mật độ xác suất* (pdf): $P(X \in (a, b]) = \int_a^b p(x)dx$

Xác suất với nhiều biến ngẫu nhiên

- Xác suất đồng thời: xác suất để cả A=a và B=b đều xảy ra ký hiệu là $P(A = a, B = b)$
- Xác suất có điều kiện: xác suất để B=b với điều kiện A=a đã xảy ra được ký hiệu là $P(B = b|A = a)$
- Định lý Bayes: $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$
- Phép biên hóa: $P(B) = \sum_A P(A, B)$

Kỳ vọng và phương sai

- Kỳ vọng (expected value) của một biến ngẫu nhiên X là:

$$E[X] = \sum_{x} xP(X = x)$$

- Độ lệch của một biến ngẫu nhiên X so với kỳ vọng của nó được gọi là phương sai (variance):

$$Var[X] = E[(X - E[X])^2] = E[X^2] - E[X]^2$$

- Độ lệch chuẩn (standard deviation) bằng căn bậc hai của phương sai

Bias-variance tradeoff

- Định nghĩa: $y = f(x) + \varepsilon$, trong đó f là mô hình được học từ dữ liệu x
- Lỗi bình phương (MSE) của một giá trị x_0 trong tập test:

$$E\left(y_0 - \hat{f}(x_0)\right)^2 = Var\left(\hat{f}(x_0)\right) + \left[Bias\left(\hat{f}(x_0)\right)\right]^2 + Var(\varepsilon)$$

trong đó
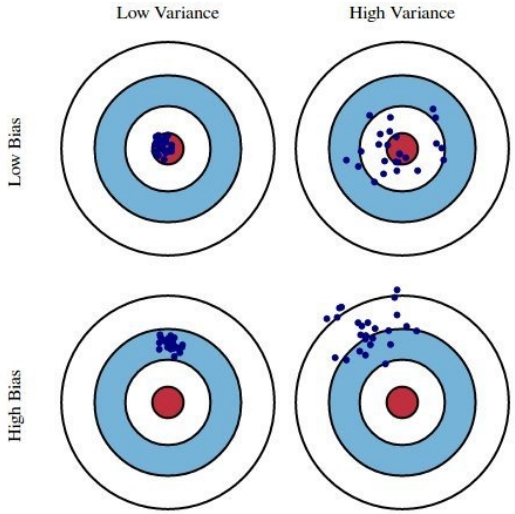
- Var ước lượng sự thay đổi của $\hat{f}$ khi tập train thay đổi
- Bias ước lượng lỗi khi mô hình bài toán phức tạp bằng thuật toán đơn giản