Tìm kiếm thông tin từ văn bản luật Việt Nam

Vũ Công Tuấn Dương – B22DCKH024

Khoa CNTT1 – PTIT

Ngày 22 tháng 4 năm 2026

Mục lục

1. Giới thiệu
2. Cơ sở lý thuyết
   - Tiền xử lý
   - Chỉ mục ngược
   - TF-IDF
   - BM25
   - Các thước đo đánh giá
   - Elasticsearch
3. Thực nghiệm và đánh giá kết quả
4. Tài liệu tham khảo

1 Giới thiệu

2 Cơ sở lý thuyết

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

Mục tiêu đề tài

- Cài đặt và so sánh các phương pháp truy xuất thông tin:
  - Mô hình Boolean
  - Mô hình không gian vector (VSM) sử dụng TF-IDF
  - Mô hình BM25
- Sử dụng **Elasticsearch** làm baseline để so sánh
- Dữ liệu: Văn bản luật Việt Nam
- Xây dựng giao diện demo với Streamlit

1 Giới thiệu

2 Cơ sở lý thuyết
- Tiền xử lý
- Chỉ mục ngược
- TF-IDF
- BM25
- Các thước đo đánh giá
- Elasticsearch

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

1 Giới thiệu

2 Cơ sở lý thuyết
- Tiền xử lý
- Chỉ mục ngược
- TF-IDF
- BM25
- Các thước đo đánh giá
- Elasticsearch

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

Tại sao cần tiền xử lý tiếng Việt?

Đặc thù tiếng Việt:

- Từ ghép không có dấu cách: *trách nhiệm*, *phạm tội*
- Cùng một từ, nhiều cách viết: *Việt Nam*, *ViệtNam*
- Từ dừng phổ biến: *là*, *của*, *và*...

Các bước tiền xử lý:

1. Chuẩn hóa Unicode (NFC)
2. Tách từ (tokenization)
3. Loại bỏ từ dừng
4. Chuyển về chữ thường

Tiền xử lý - Ví dụ

Văn bản gốc:

Người phạm tội sẽ bị truy cứu trách nhiệm hình sự

Thuế GTGT của hàng hóa nhập khẩu

Sau khi xử lý:

người_phạm_tội truy_cứu trách_nhiệm hình_sự

thuế_gtgt hàng_hóa nhập_khẩu

Kết quả: Các từ ghép được giữ nguyên, loại bỏ từ dừng

1 Giới thiệu

2 Cơ sở lý thuyết
- Tiền xử lý
- Chỉ mục ngược
- TF-IDF
- BM25
- Các thước đo đánh giá
- Elasticsearch

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

Chỉ mục ngược (Inverted Index)

Định nghĩa: Cấu trúc dữ liệu ánh xạ từ **term** → danh sách tài liệu chứa term đó

Hai thành phần chính:

- **Dictionary:** Tập hợp các từ duy nhất trong corpus
- **Postings List:** Danh sách (docID, term frequency) cho mỗi từ

Ưu điểm: Tra cứu $O(1)$ thay vì duyệt toàn bộ 222,981 tài liệu

Chỉ mục ngược - Ví dụ

Term	Postings List
thu_gtgt	(Doc10, 5), (Doc25, 2), (Doc58, 3)
người_phạm_tội	(Doc1, 1), (Doc22, 3), (Doc33, 2)
hợp_đồng	(Doc5, 4), (Doc12, 1), (Doc89, 2)
trách_nhiệm	(Doc15, 2), (Doc30, 1), (Doc42, 3)

Truy vấn "thu_gtgt AND hợp_đồng": Lấy giao của Doc10, Doc25, Doc58 và Doc5, Doc12, Doc89

1 Giới thiệu

2 Cơ sở lý thuyết
- Tiền xử lý
- Chỉ mục ngược
- TF-IDF
- BM25
- Các thước đo đánh giá
- Elasticsearch

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

TF-IDF

Đánh giá tầm quan trọng của từ dựa trên [3]:

- **TF (Term Frequency):** Tần suất xuất hiện của từ trong văn bản
- **IDF (Inverse Document Frequency):** Mức độ hiếm của từ trong tập tài liệu

$$TF(t, d) = \frac{\text{Số lần xuất hiện của } t \text{ trong } d}{\text{Tổng số từ trong } d}$$

$$IDF(t, D) = \log\left(\frac{\text{Tổng số văn bản}}{\text{Số văn bản chứa } t}\right)$$

$$TF\text{-}IDF(t, d, D) = TF(t, d) \times IDF(t, D)$$

TF-IDF – Thuật toán tính điểm

Input: Truy vấn Q, tài liệu D, chỉ mục ngược
Output: Điểm TF-IDF

1. $score \leftarrow 0$
2. **for** mỗi từ $t \in Q$ **do**
3. $\quad tf \leftarrow$ số lần t xuất hiện trong D
4. $\quad idf \leftarrow \log\left(\frac{N+1}{n_t+1}\right) + 1$
5. $\quad tf_normalized \leftarrow 1 + \log(tf)$
6. $\quad score \leftarrow score + tf_normalized \times idf$
7. **end for**
8. **return** $score$

Tối ưu: Chỉ tính TF-IDF cho các tài liệu ứng viên từ chỉ mục ngược

1 Giới thiệu

2 Cơ sở lý thuyết
- Tiền xử lý
- Chỉ mục ngược
- TF-IDF
- BM25
- Các thước đo đánh giá
- Elasticsearch

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

BM25

Biến thể nâng cao của TF-IDF [3], dựa trên mô hình xác suất:

$$\text{score}(D, Q) = \sum_{i=1}^{n} IDF(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot (1 - b + b \cdot \frac{|D|}{\text{avgdl}})}$$

- k_1: Kiểm soát TF saturation $(1.2 - 2.0)$
- b: Chuẩn hóa độ dài tài liệu (0.75)
- Ưu điểm: Xử lý tốt độ bão hòa TF và chuẩn hóa độ dài

BM25 – Thuật toán tính điểm

Input: Truy vấn Q, chỉ mục ngược
Output: Top N tài liệu có điểm cao nhất

1. $k_1 \leftarrow 1.5,\ b \leftarrow 0.75$
2. **Lấy candidates:** $C \leftarrow \bigcup_{q_i \in Q}$ các tài liệu chứa q_i
3. **for** mỗi $D \in C$ **do**
4. $\quad score \leftarrow 0$
5. $\quad$ **for** mỗi $q_i \in Q$ **do**
6. $\quad\quad f \leftarrow$ số lần q_i xuất hiện trong D
7. $\quad\quad n_q \leftarrow$ số tài liệu chứa q_i
8. $\quad\quad idf \leftarrow \ln\left(\frac{N-n_q+0.5}{n_q+0.5}+1\right)$
9. $\quad\quad num \leftarrow f \times (k_1+1)$
10. $\quad\quad den \leftarrow f + k_1 \times (1-b+b \times \frac{|D|}{avgdl})$
11. $\quad\quad score \leftarrow score + idf \times \frac{num}{den}$
12. $\quad$ **end for**
13. Lưu $(D, score)$

1 Giới thiệu

2 Cơ sở lý thuyết
- Tiền xử lý
- Chỉ mục ngược
- TF-IDF
- BM25
- Các thước đo đánh giá
- Elasticsearch

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

Precision@K, Recall@K, F1@K

Precision@K: Tỷ lệ tài liệu liên quan trong k kết quả đầu tiên:

$$\mathrm{P@}k = \frac{\#\{\text{tài liệu liên quan trong } k \text{ kết quả}\}}{k}$$

Recall@K: Tỷ lệ tài liệu liên quan tìm được so với tổng số:

$$\mathrm{R@}k = \frac{\#\{\text{tài liệu liên quan trong } k \text{ kết quả}\}}{\#\{\text{tổng tài liệu liên quan}\}}$$

F1@K: Trung bình điều hòa:

$$F1@k = 2 \cdot \frac{P@k \cdot R@k}{P@k + R@k}$$

Mean Reciprocal Rank (MRR)

Tập trung vào vị trí của tài liệu liên quan **đầu tiên**:

$$RR_i = \frac{1}{rank_i}, \quad MRR = \frac{1}{N}\sum_{i=1}^{N}\frac{1}{rank_i}$$

- Ưu tiên vị trí dẫn đầu (vị trí 1: 1 điểm, vị trí 2: 0.5 điểm)
- Phù hợp với hệ thống chỉ cần tìm thấy một kết quả đúng

Mean Average Precision (MAP)

Tính đến cả thứ hạng và độ chính xác:

$$AP = \sum_{k=1}^{n} P(k) \cdot \Delta r(k)$$

Trong đó:

- $P(k) = \frac{\#\text{relevant trong top } k}{k}$: Precisionk
- $\Delta r(k) = \frac{1}{|R|}$ nếu tài liệu tại k là relevant, $= 0$ nếu không

$$MAP = \frac{1}{N} \sum_{i=1}^{N} AP_i$$

- Chỉ số phổ biến nhất trong đánh giá IR
- Đánh giá toàn diện hơn MRR

1 Giới thiệu

2 Cơ sở lý thuyết
- Tiền xử lý
- Chỉ mục ngược
- TF-IDF
- BM25
- Các thước đo đánh giá
- Elasticsearch

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

Elasticsearch - Tổng quan

- Công cụ tìm kiếm phân tán, mã nguồn mở (Apache License)
- Dựa trên Apache Lucene
- CSDL NoSQL, lưu trữ tài liệu dạng JSON
- Sử dụng BM25 làm thước đo mặc định

Elasticsearch - Truy vấn

- **Match Query:** Tìm kiếm toàn văn với phân tích token
- **Term Query:** Kết quả khớp chính xác
- **Bool Query:** Kết hợp must, should, must_not

1 Giới thiệu

2 Cơ sở lý thuyết

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

Tập dữ liệu

- Nguồn: Bộ dữ liệu văn bản pháp luật Việt Nam trên HuggingFace [5]
- **Corpus:** 222,981 tài liệu (các điều, khoản luật)
- **Train:** 9,541 câu hỏi
- **Test:** 3,184 câu hỏi
- Sử dụng 2,000 mẫu đầu tiên để đánh giá (giới hạn phần cứng, thời gian chạy)

Cấu trúc tập dữ liệu

Cột	Kiểu	Mô tả
`qid`	int	ID câu hỏi
`question`	string	Câu hỏi
`cid`	list	ID văn bản liên quan
`context_list`	list	Nội dung liên quan

Tiền xử lý và xây dựng chỉ mục

- Sử dụng `underthesea` [1] để chuẩn hóa và tách từ
- Token có 2 từ trở lên được nối bằng dấu "_"
- Loại bỏ từ dừng bằng danh sách từ Github [2]

Elasticsearch - 2 cách tiếp cận:

- **Chỉ mục mặc định:** Analyzer chuẩn của ES (tiếng Anh)
- **Chỉ mục đã xử lý:** Tách từ tiếng Việt bằng `underthesea`

Mapping: `content (text)` cho full-text, `content.keyword` cho exact match

Các phương pháp truy xuất

5 phương pháp được cài đặt và đánh giá:

1. **Boolean**: Truy vấn với toán tử AND, OR, NOT
2. **VSM**: Mô hình không gian vector với TF-IDF
3. **BM25**: Mô hình xác suất với TF saturation
4. **Elasticsearch (Thường)**: Analyzer mặc định
5. **Elasticsearch (Đã xử lý)**: Tách từ trước bằng underthesea

Kết quả tổng quan

Phương pháp	P@1	P@5	P@10	R@10	F1@10	MRR	MAP
ES (Xử lý)	**0.4132**	**0.1349**	**0.0771**	**0.7708**	**0.1401**	**0.5284**	**0.5284**
BM25	0.4120	0.1358	0.0770	0.7695	0.1399	0.5269	0.5269
ES (Thường)	0.4012	0.1339	0.0737	0.7372	0.1340	0.5136	0.5136
VSM	0.2195	0.0963	0.0627	0.6270	0.1140	0.3353	0.3353
Boolean	0.1305	0.0541	0.0306	0.3060	0.0556	0.1900	0.1900

Kết quả chi tiết - BM25

K	Precision@K	Recall@K	F1@K
1	0.4120	0.4120	0.4120
2	0.2685	0.5370	0.3580
3	0.2033	0.6100	0.3050
5	0.1358	0.6790	0.2263
10	0.0769	0.7695	0.1399

Kết quả chi tiết - ES (Đã xử lý)

K	Precision@K	Recall@K	F1@K
1	0.4132	0.4132	0.4132
2	0.2716	0.5432	0.3621
3	0.2043	0.6128	0.3064
5	0.1349	0.6744	0.2248
10	0.0771	0.7708	0.1401

Nhận xét

- **BM25 vs ES (xử lý):** Hiệu suất gần tương đương (MRR chênh 0.0015)
- **ES xử lý vs ES thường:** Tiền xử lý tách từ tiếng Việt giúp cải thiện kết quả
- **BM25 vs VSM:** BM25 vượt trội nhờ độ bão hòa TF và chuẩn hóa độ dài
- **Boolean:** Hiệu suất thấp nhất, không có xếp hạng
- **Xu hướng:** P@K giảm, R@K tăng khi K tăng

Giao diện demo

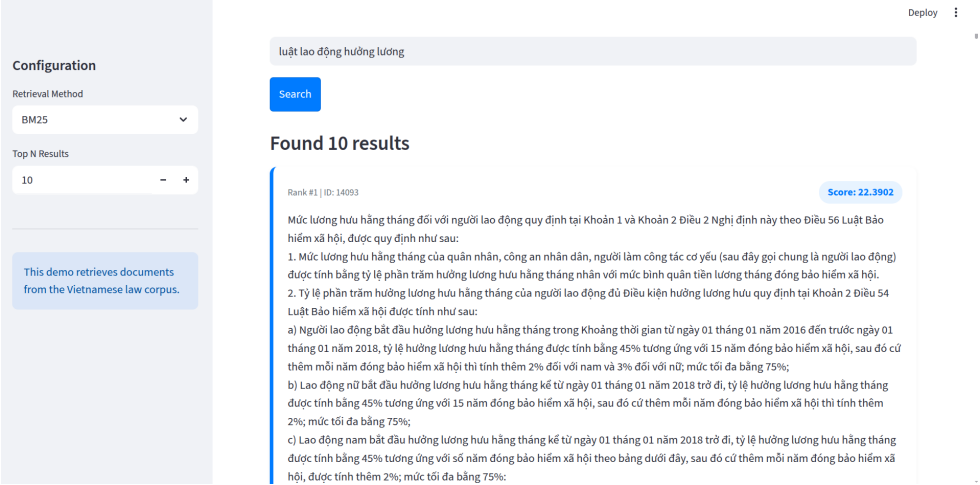

Kết luận

- Đã cài đặt và so sánh thành công 5 phương pháp truy xuất
- **BM25** và **ES (đã xử lý)** cho kết quả tốt nhất
- Tiền xử lý văn bản (tách từ tiếng Việt) quan trọng
- Xây dựng giao diện demo hoàn chỉnh với Streamlit [4]

Cảm ơn thầy đã lắng nghe!

1 Giới thiệu

2 Cơ sở lý thuyết

3 Thực nghiệm và đánh giá kết quả

4 Tài liệu tham khảo

Tài liệu tham khảo

[1] Vu Anh.
underthesea: Vietnamese nlp toolkit.
https://github.com/undertheseanlp/underthesea, 2020.

[2] Van-Duyet Le.
Vietnamese stopwords.
https://github.com/stopwords/vietnamese-stopwords/blob/master/vietnamese-stopwords.txt.

[3] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze.
Introduction to Information Retrieval.
Cambridge University Press, Cambridge, UK, 2008.

[4] Snowflake.
Streamlit.
https://streamlit.io/, 2024.

[5] YulTC.
Vietnamese legal documents.
https://huggingface.co/datasets/YuITC/Vietnamese-Legal-Documents/tree/main.