

ĐỀ CƯƠNG ÔN TẬP MÔN XỬ LÝ NGÔN NGỮ TỰ NHIÊN

Hình thức: Tự luận

Thời gian: 90ph

Cấu trúc: 2 câu hỏi lý thuyết + 2 câu bài tập

Lý thuyết: (4đ – CLO1)

1. NLP là gì? Kể tên 3 ứng dụng phổ biến của NLP trong đời sống hiện nay.
2. Tại sao sự nhập nhằng lại là thách thức lớn nhất của NLP? Cho ví dụ về nhập nhằng từ vựng trong tiếng Việt.
3. Gán nhãn từ loại (POS Tagging) là gì? Tại sao cần gán nhãn từ loại? Nêu ít nhất 01 ứng dụng thực tế của POS Tagging.
4. Mô hình Markov ẩn bao gồm những thành phần nào khi áp dụng cho bài toán POS tagging? Mô tả ý nghĩa của từng thành phần.
5. Phân biệt các từ lớp mở (open class) với lớp đóng (closed class). Tại sao sự phân chia này quan trọng trong POS tagging?
6. Tại sao backpointer là cần thiết cho thuật toán Viterbi? Nếu bỏ backpointer đi, thuật toán có thể tính được xác suất cao nhất không?
7. Trong thực tế, HMM gặp vấn đề với “unknown words” (từ không xuất hiện trong tập huấn luyện). Phân tích nguyên nhân tại sao unknown words gây ra vấn đề nghiêm trọng trong HMM và đề xuất phương pháp xử lý.
8. Mô hình N-gram là gì? Công thức tính xác suất của một câu sử dụng bigram, trigram.
9. Phát biểu giả thuyết Markov bậc n trong mô hình ngôn ngữ N-gram. Tại sao giả thuyết này lại quan trọng?
10. Giải thích cơ chế của phương pháp làm trơn Laplace (Add-one smoothing). Tại sao phương pháp này đôi khi lại “quá tay” đối với tập dữ liệu lớn?
11. Định nghĩa chỉ số perplexity (PP). Mối quan hệ giữa xác suất của tập kiểm tra và perplexity là gì?
12. Phân biệt đánh giá trong (intrinsic evaluation) và đánh giá ngoài (extrinsic evaluation) đối với một mô hình ngôn ngữ
13. Tại sao trong thực tế, các xác suất của mô hình ngôn ngữ thường được tính toán và lưu trữ dưới dạng Log-probability thay vì xác suất thô?
14. Giải thích sự khác biệt giữa các đặc trưng sau: (1) Term Frequency, (2) TF-IDF
15. Phân tích quan điểm là gì? Lấy 03 ứng dụng thực tế sử dụng phân tích quan điểm

16. So sánh hai phương pháp trích xuất đặc trưng: Count Vectorization và TF-IDF. Khi nào nên dùng TF-IDF thay vì Count?
17. Bạn đang xây dựng mô hình phân loại quan điểm cho các bình luận đánh giá sản phẩm. Hãy liệt kê ít nhất 03 kỹ thuật tiền xử lý cơ bản và 03 loại đặc trưng có thể dùng.
18. Trình bày định nghĩa văn phạm phi ngữ cảnh và liệt kê đầy đủ 5 thành phần cấu thành.
19. Phân biệt hai hướng tiếp cận chính trong phân tích cú pháp: constituency parsing và dependency parsing về đặc điểm đầu vào/đầu ra và nêu ít nhất hai điểm khác biệt cốt lõi giữa hai hướng.
20. So sánh chiến lược top-down và bottom-up trong phân tích cú pháp về hướng tìm kiếm, điểm mạnh/yếu và khả năng xử lý văn phạm đệ quy trái. Thuật toán CKY thuộc chiến lược nào và tại sao nó khắc phục được nhược điểm của các chiến lược đơn thuần?
21. Phân biệt hai chế độ hoạt động CKY recognition và CKY parsing về mục tiêu, thông tin lưu trữ trong bảng và cách khai thác kết quả. Trong bài toán thực tế, khi nào ưu tiên dùng Recognition, khi nào cần Parsing?
22. Giải thích thuật toán word2vec. Trong word2vec, một từ sẽ có một vec tơ biểu diễn duy nhất hay có nhiều vec tơ phụ thuộc ngữ cảnh khác nhau?
23. Ngữ nghĩa từ vựng nghiên cứu những vấn đề gì? Phân biệt khái niệm “nghĩa của từ” (word sense) với “từ” (word form).
24. Trình bày định nghĩa và đặc điểm của bốn hiện tượng quan hệ nghĩa cơ bản: đồng âm, đa nghĩa, đồng nghĩa và trái nghĩa. Lấy một ví dụ cho mỗi hiện tượng.
25. Trình bày định nghĩa bài toán nhận dạng thực thể đặt tên (NER): đầu vào, đầu ra, các loại thực thể phổ biến và nhãn tương ứng.
26. Trích xuất thông tin (IE) là gì? Nêu sự khác biệt cơ bản về mục tiêu và đầu ra giữa trích xuất thông tin và truy xuất thông tin (IR).
27. Trình bày định nghĩa bài toán hỏi đáp tự động. Lấy ví dụ 3 dạng câu hỏi, trả lời tương ứng.
28. Mô tả kiến trúc hai giai đoạn Retriever-Reader. Nêu rõ đầu vào, đầu ra và nhiệm vụ của từng thành phần.
29. Trình bày các đặc điểm chính của bộ dữ liệu SQuAD (Stanford Question Answering Dataset): quy mô, nguồn gốc, định dạng câu trả lời, số câu trả lời mẫu cho mỗi câu hỏi và hạn chế của bộ dữ liệu này.
30. Trình bày ba bước cơ bản của một hệ thống Naive RAG: Indexing, Retrieval và Generation. Ở mỗi bước, nêu rõ đầu vào, đầu ra và kỹ thuật chính được sử dụng.

Bài tập: (6đ – CLO2)

1. Cho corpus huấn luyện gồm 4 câu:

<s> she/PRO likes/VERB fish/NOUN </s>

<s> he/PRO eats/VERB rice/NOUN </s>

<s> she/PRO eats/VERB fish/NOUN </s>

<s> he/PRO likes/VERB rice/NOUN </s>

a) Tính ma trận chuyển trạng thái A (bao gồm trạng thái <s> và </s>).

b) Tính ma trận phát xạ B cho các từ: she, he, likes, eats, fish, rice.

c) Tính xác suất để chuỗi từ “he likes rice” đi kèm với chuỗi nhãn “PRO VERB NOUN”.

d) Sử dụng thuật toán Viterbi để tìm chuỗi nhãn tối ưu cho câu: “she eats rice”. Tính xác suất của chuỗi nhãn tối ưu này.

2. Cho corpus huấn luyện gồm 4 câu:

<s> em yêu học NLP </s>

<s> anh học NLP rất vui </s>

<s> em học rất chăm </s>

<s> anh yêu NLP </s>

Cho tập từ vựng $V = \{\text{em, yêu, học, NLP, anh, rất, vui, chăm, </s>}\}$.

a) Xây dựng mô hình ngôn ngữ unigram và bigram (không làm trơn)?

b) Tính xác suất câu test $P(<s> \text{anh chăm học} </s>)$ bằng mô hình bigram không làm trơn.

Kết quả có vấn đề gì không? Giải thích.

c) Xây dựng mô hình ngôn ngữ unigram (làm trơn Laplace)?

d) Tính xác suất câu test $P(<s> \text{anh chăm học} </s>)$ bằng mô hình bigram đã làm trơn.

e) Tính perplexity của mô hình bigram sau khi làm trơn trên câu test: “anh chăm học”.

3. Cho tập dữ liệu huấn luyện:

Positive: “good quality product” | “great value and quality”

Negative: “bad product poor value” | “very poor quality”

Và câu test: “great quality product”

a) Tính TF-IDF của từ “quality” trong document D1 = “good quality product”, với corpus gồm cả 4 documents trên.

b) Sử dụng thuật toán Naive Bayes (có Laplace smoothing) để phân loại câu test.

c) Nếu câu test là “not a great quality product”, mô hình Naive Bayes có xu hướng phân loại sai không? Tại sao? Đề xuất một kỹ thuật tiền xử lý để cải thiện.

4. Cho văn phạm CFG sau:

$S \rightarrow NP VP \mid VP$

$NP \rightarrow Det N \mid NP PP \mid N$

$VP \rightarrow V \mid V NP \mid VP PP$

$PP \rightarrow P NP$

$Det \rightarrow \text{“một”} \mid \text{“con”}$

$N \rightarrow \text{“mèo”} \mid \text{“chuột”} \mid \text{“bẫy”}$

$V \rightarrow \text{“bắt”} \mid \text{“thấy”}$

$P \rightarrow \text{“trong”}$

a) Vẽ cây cú pháp cho câu: “con mèo bắt con chuột trong bẫy”. Nếu có hiện tượng nhập nhằng, hãy chỉ ra và vẽ cây cú pháp thứ hai tương ứng.

b) Chuyển văn phạm con sau sang dạng CNF (thực hiện đầy đủ các bước):

$S \rightarrow VP \mid NP VP$

$VP \rightarrow V NP \mid V NP PP \mid \varepsilon$

$PP \rightarrow P NP$

c) Với văn phạm CNF rút gọn sau và câu “mèo bắt chuột” ($w_1=\text{mèo}$, $w_2=\text{bắt}$, $w_3=\text{chuột}$):

$S \rightarrow NP VP$

$NP \rightarrow N$

$VP \rightarrow V NP$

$N \rightarrow \text{“mèo”} \mid \text{“chuột”}$

$V \rightarrow \text{“bắt”}$

Điền đầy đủ bảng CKY 3×3 và kết luận câu có đúng ngữ pháp không.

d) Cho thêm xác suất PCFG:

$P(VP \rightarrow V NP) = 0.7,$

$P(VP \rightarrow VP PP) = 0.3,$

$P(PP \rightarrow P NP) = 1.0,$

$P(NP \rightarrow NP PP) = 0.25.$

Nếu câu “con mèo bắt chuột trong bẫy” có 2 cây cú pháp thì bộ phân tích sẽ ưu tiên cách hiểu nào. Tại sao?

5. Cho ma trận đồng xuất hiện (cửa sổ ngữ cảnh ± 2) của ba từ trong một corpus về kinh tế và địa lý:

Từ	market	price	trade	river	mountain	forest
stock	15	12	8	0	0	1
peak	2	3	1	4	14	6
bond	10	9	11	0	0	0

a) Biểu diễn vector raw count cho từ “stock” và “bond”. Tính cosine similarity giữa hai vector này. Nhận xét về mối quan hệ ngữ nghĩa của chúng.

b) Tính cosine similarity giữa “stock” và “peak”. So sánh với kết quả câu (a) và giải thích tại sao “stock” và “bond” gần nhau hơn về mặt vector không gian.

c) Từ “peak” có thể mang hai nghĩa: (1) đỉnh núi, (2) đỉnh cao/cao điểm (như “peak performance”). Đây là hiện tượng gì trong ngữ nghĩa từ vựng? Một mô hình Word2Vec sẽ biểu diễn từ “peak” bằng bao nhiêu vector? Tại sao đây là hạn chế?

d) Nếu có sẵn các vector đã huấn luyện:

$V(\text{Hà Nội}) = [0.8, 1.2, -0.5]$,

$V(\text{Việt Nam}) = [0.6, 1.0, -0.3]$,

$V(\text{Tokyo}) = [0.9, -0.5, 1.1]$.

Hãy ước tính vector của từ “Nhật Bản” theo công thức tương tự hóa.

6. Cho đoạn văn bản sau:

“Ngày 08 tháng 4 năm 2026, tại Hà Nội, đồng chí Vũ Hải Quân được phê chuẩn giữ chức Bộ trưởng Bộ Khoa học và Công nghệ nhiệm kỳ 2026-2031.”

a) Thực hiện gán nhãn NER theo lược đồ BIO với tập nhãn {B-PER, I-PER, B-ORG, I-ORG, B-LOC, I-LOC, B-DATE, I-DATE, O}. Trình bày kết quả dưới dạng bảng token-nhãn.

b) Một hệ thống NER được đánh giá trên tập test với kết quả sau:

Loại thực thể	Gold	Dự đoán	Đúng
PER	40	35	32
ORG	30	28	22
LOC	30	32	27

Tính Precision, Recall và F1 theo micro-average cho toàn hệ thống. Loại thực thể nào có hiệu suất thấp nhất theo F1? Đề xuất một nguyên nhân có thể giải thích điều đó.

7. “Học viện Công nghệ Bưu chính Viễn thông (PTIT) được thành lập năm 1997, trực thuộc Bộ Thông tin và Truyền thông. PTIT có hai cơ sở chính tại Hà Nội và Thành phố Hồ Chí Minh, đào tạo các ngành Công nghệ thông tin, Điện tử viễn thông và Kinh tế.”

Câu hỏi: “PTIT được thành lập năm nào?”

Hệ thống dự đoán câu trả lời là: “năm 1997”.

Các đáp án mẫu (ground truth) là:

Ref 1: “1997”

Ref 2: “năm 1997”

Ref 3: “được thành lập năm 1997”

Tính Exact Match (EM) và F1 token-level cho câu trả lời dự đoán (lấy max trên 3 đáp án mẫu). Trình bày chi tiết cách tính F1 với từng đáp án mẫu.