Học viện
Công nghệ Bưu chính Viễn thông

KHOA TRÍ TUỆ NHÂN TẠO
Faculty of Artificial Intelligence

Bài 1. Giới thiệu về xử lý ngôn ngữ tự nhiên

Giảng viên: ThS. Võ Ngọc Bích Uyên

Nội dung

- Giới thiệu môn học
- Giới thiệu về xử lý ngôn ngữ tự nhiên (NLP) và ứng dụng
- Lược sử phát triển của NLP
- Nhập nhằng

Giới thiệu môn học

- Giảng viên:
  - ThS. Võ Ngọc Bích Uyên
  - Email: uyenvnb@ptit.edu.vn
- Điểm thành phần:
  - Điểm quá trình: 40%
    - Điểm danh: 10%
    - Kiểm tra: 10%
    - Bài tập lớn: 20%
  - Điểm cuối kỳ: 60%

Mục tiêu môn học

Học về phân tích ngôn ngữ tự nhiên:

- Những vấn đề chính
- Những giải pháp chính

Mục tiêu cuối khóa

- Biết cách đánh giá bài toán NLP
- Biết cách chọn giải pháp và cách áp dụng
- Lập trình Python để giải quyết bài toán NLP
- Biết nguồn thông tin để tìm hiểu thêm
- Đọc bài báo nghiên cứu

Giáo trình

- *Speech and Language Processing*, Daniel Jurasky & James H. Martin, second edition, printed by Prentice Hall, 2009.
- *Foundation of Statistical Natural Language Processing*, Christopher D. Manning & Hinrich Schutze, 2001.
- *Neural Network Methods in Natural Language Processing - Synthesis Lectures on Human Language Technologies,* Yoav Goldberg, 2017.

Giới thiệu về xử lý ngôn ngữ tự nhiên

NLP trong công nghiệp

Thị trường NLP

Thị trường NLP toàn cầu dự đoán tăng trưởng từ $24.1 tỷ năm 2023 lên đến $158.04 tỷ năm 2032, với tốc độ tăng trưởng 23.2% mỗi năm

Động lực thúc đẩy: sự phát triển của phần cứng máy tính, dữ liệu và thuật toán.

Khó khăn:

- Khả năng hiểu ngữ cảnh còn hạn chế
- Nghiên cứu hiện tại tập trung nhiều vào tiếng Anh và những ngôn ngữ phổ biến

Cơ hội mới:

- AI tạo sinh (GPT) cho phép sinh văn bản giống con người hơn, mở ra nhiều ứng dụng trong marketing, báo chí, chatbot, …

Tương tác với máy tính

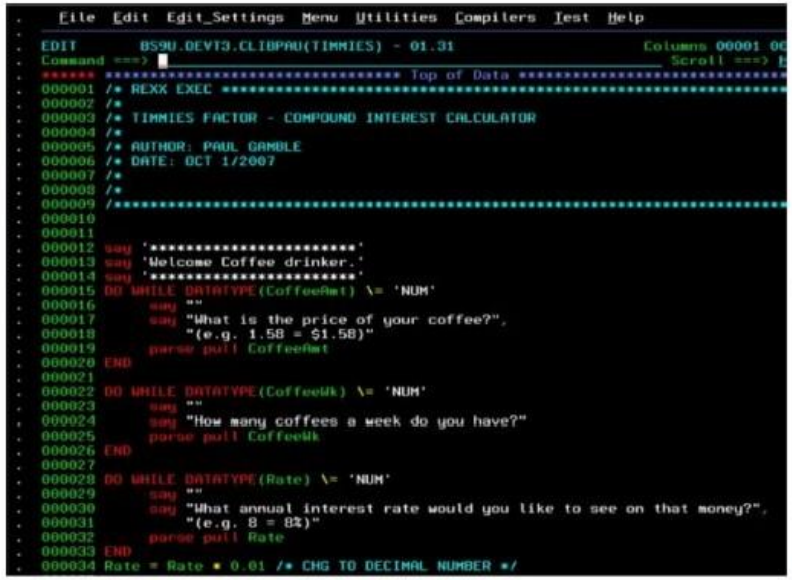

~50-70s ~80s today

Trợ lý ảo

Trợ lý ảo cần có khả năng:

- Nhận diện giọng nói
- Phân tích ngôn ngữ
- Xử lý hội thoại
- Trích xuất thông tin
- Text to speech

Google now, Alexa, Siri, Cortana, Vivi

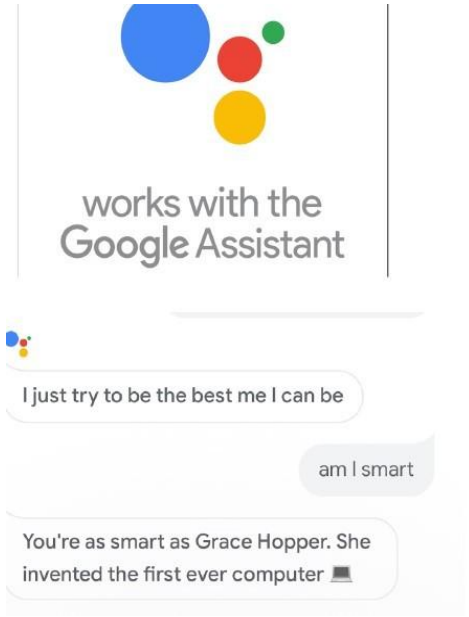

Ứng dụng LLM

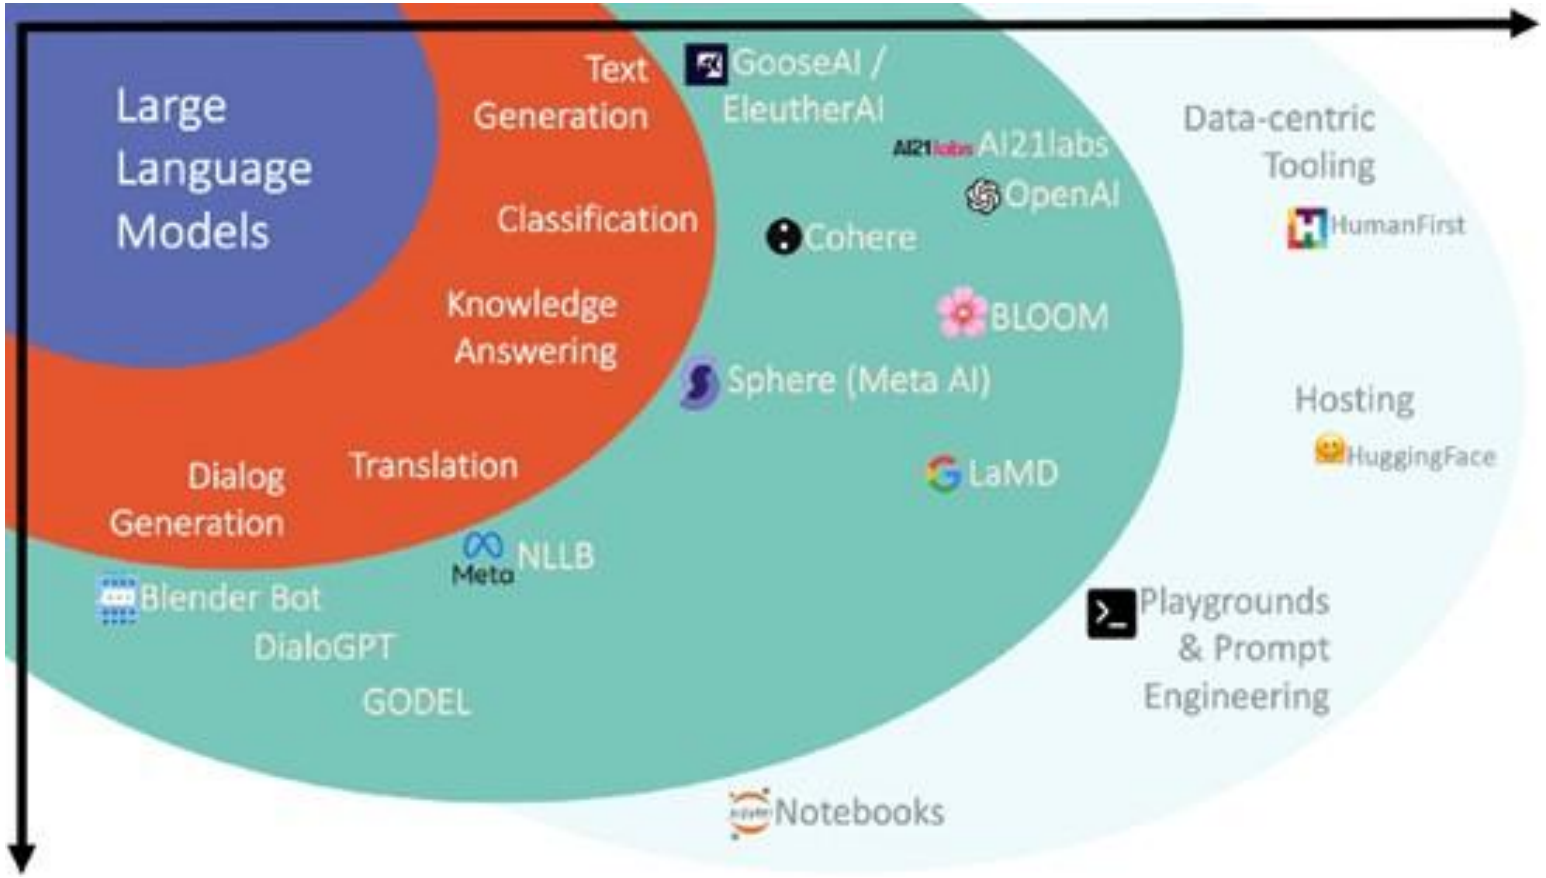
Large Language Models
Text Generation
Classification
Knowledge Answering
Translation
Dialog Generation
GooseAI / EleutherAI
AI21labs
OpenAI
Cohere
BLOOM
Sphere (Meta AI)
LaMD
NLLB
Meta
Blender Bot
DialoGPT
GODEL
Data-centric Tooling
HumanFirst
Hosting
HuggingFace
Playgrounds & Prompt Engineering
Notebooks

ChatGPT

- **ChatGPT (Chat Generative Pre-trained Transformer)** là chatbot được phát hành bởi OpenAI vào tháng 11/2022
- Generative Pre-trained Transformer 3 (GPT-3) là mô hình ngôn ngữ tự hồi quy (autoregressive) sử dụng học sâu để sinh ra đoạn văn giống con người. Với một đoạn prompt đầu vào, mô hình sẽ viết tiếp đoạn văn.
- Mô hình được sử dụng là transformer với ngữ cảnh có độ dài 2048 token và 175 tỷ tham số (yêu cầu 800 GB lưu trữ).
- ChatGPT có thể trả lời lưu loát các câu hỏi trên mọi lĩnh vực. Đồng thời, ChatGPT có thể viết code, làm thơ, soạn nhạc, viết thư, thiết kế và sửa lỗi lập trình.
- ChatGPT đã vượt qua 10 triệu người dùng chỉ 40 ngày sau khi được phát hành, vượt qua các kỷ lục của các ứng dụng trước đó (sau đó là 100 triệu người dùng sau 2 tháng).

Google Translate

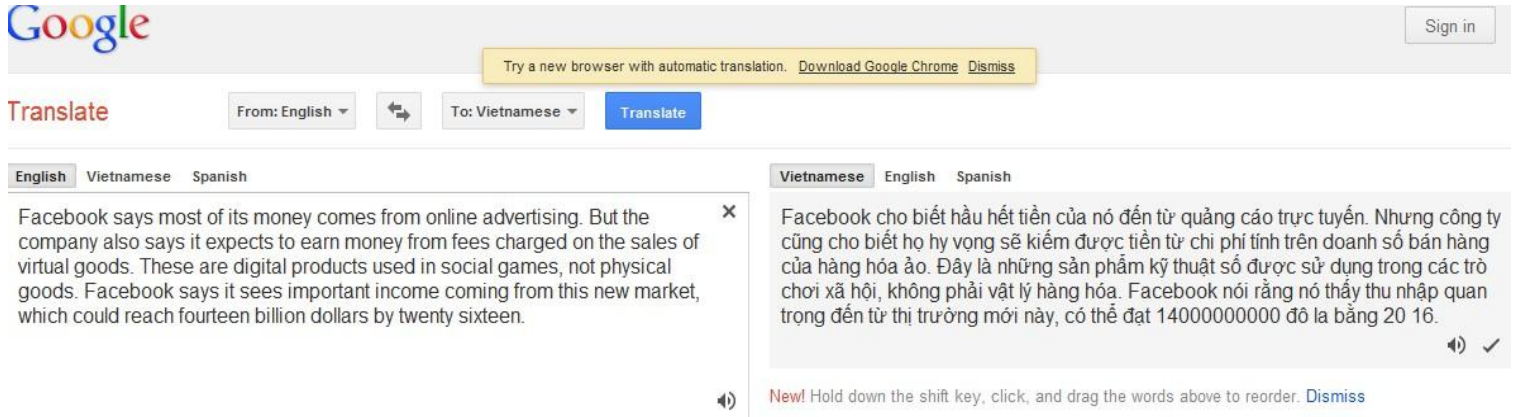

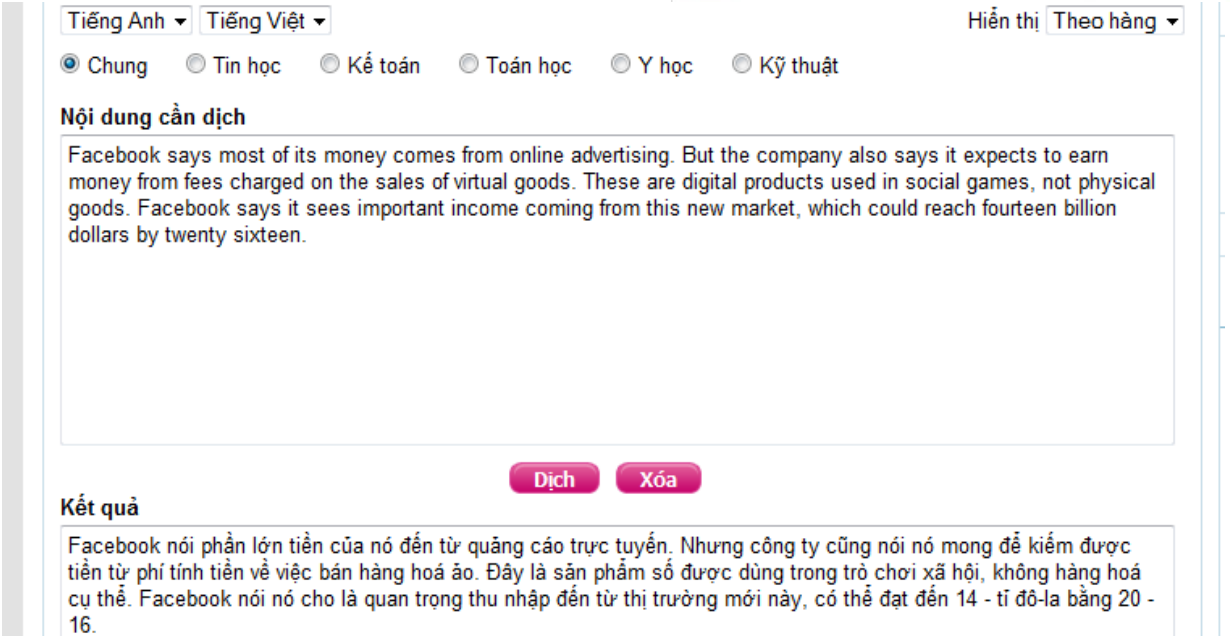

Watson - IBM 2011

- IBM xây dựng một hệ thống máy tính chiến thắng chương trình Jeopardy vào năm 2011.
- Hệ thống hỏi đáp được xây dựng trên 200 triệu trang văn bản, bách khoa toàn thư, từ điển và các cơ sở dữ liệu.

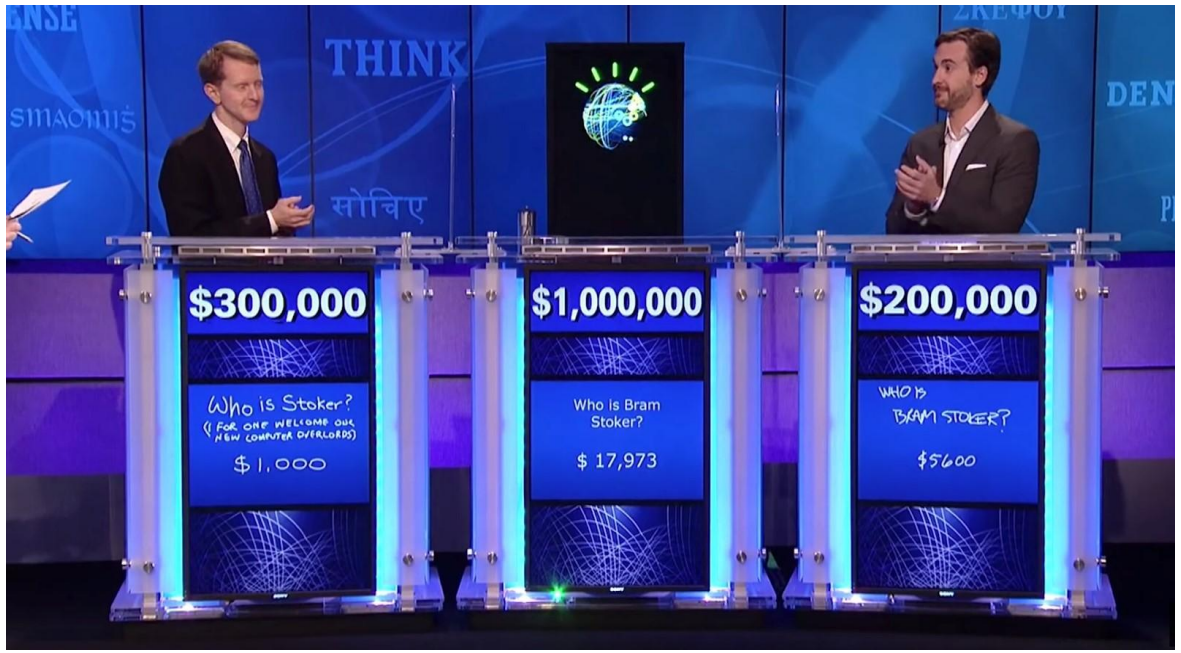

Sơ đồ tri thức (Knowledge Graph)

Mục tiêu: thay vì tìm kiếm văn bản bằng từ khóa, cải thiện bằng cách xây dựng sơ đồ quan hệ giữa các đối tượng

- dễ dàng hơn với người dùng điện thoại

Sơ đồ tri thức của Google:

- Mở rộng thêm từ FreeBase
- Dữ liệu được tổng hợp từ Wikipedia, báo chí, truyện,...
- Cập nhật thủ công

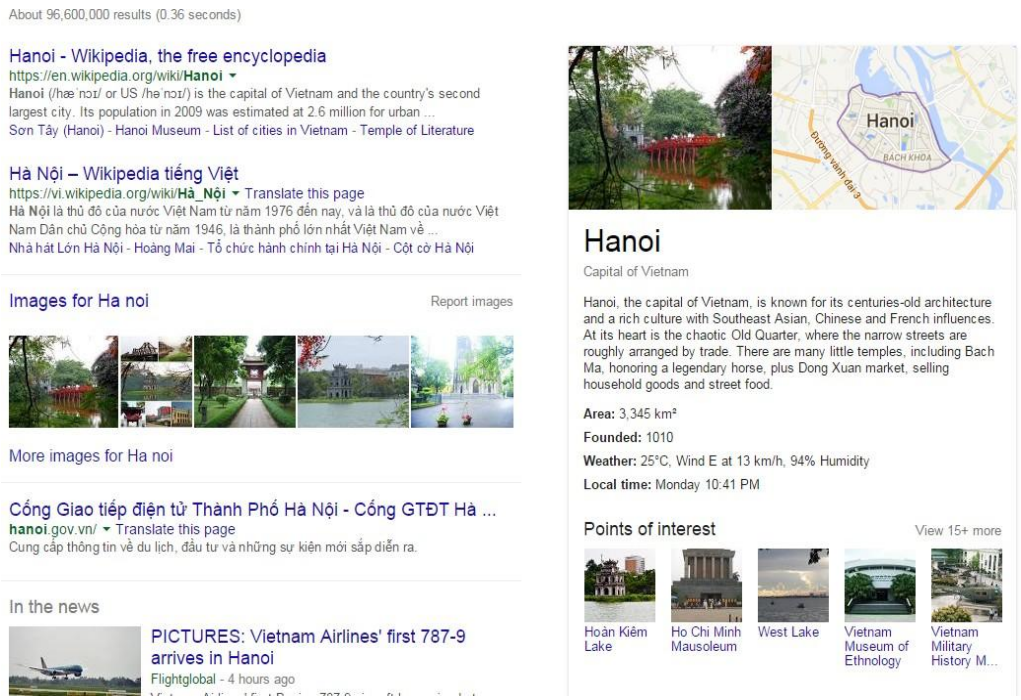

Sơ đồ tri thức

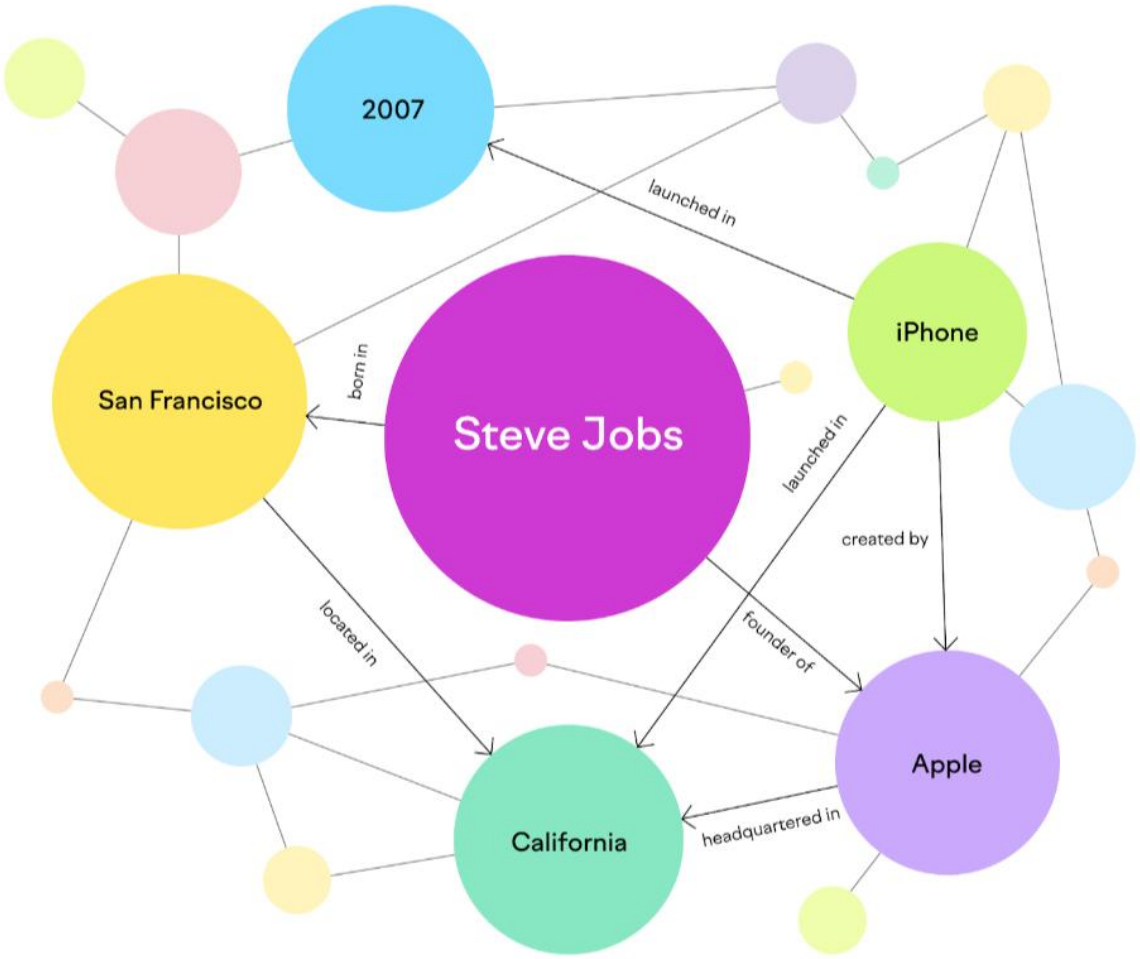

Phương pháp học máy trong NLP

Paradigm	Engineering	Task Relation
a. Fully Supervised Learning (Non-Neural Network)	Features (e.g. word identity, part-of-speech, sentence length)	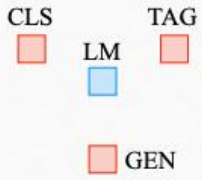
b. Fully Supervised Learning (Neural Network)	Architecture (e.g. convolutional, recurrent, self-attentional)	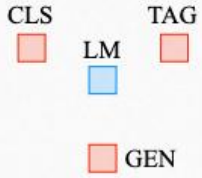
c. Pre-train, Fine-tune	Objective (e.g. masked language modeling, next sentence prediction)	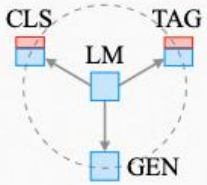
d. Pre-train, Prompt, Predict	Prompt (e.g. cloze, prefix)	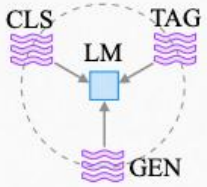

Ứng dụng quan trọng

- Ngôn ngữ học tính toán (mô phỏng khả năng của con người cho xử lý ngôn ngữ)
- Trích xuất thông tin
- Hỏi đáp, chatbot (VD: Google, Zalo)
- Dịch máy
- Tổng hợp văn bản
- Phân tích ý kiến và quan điểm
- Phân tích mạng xã hội
- Nhận biết thông tin sai lệch
- Ứng dụng dựa trên LLM (ChatGPT, Gemini,…)

Nghề nghiệp cho NLP

- Công nghiệp (VinAI, VinBigData, Viettel, FPT, …)
- Chính phủ
- Trường đại học

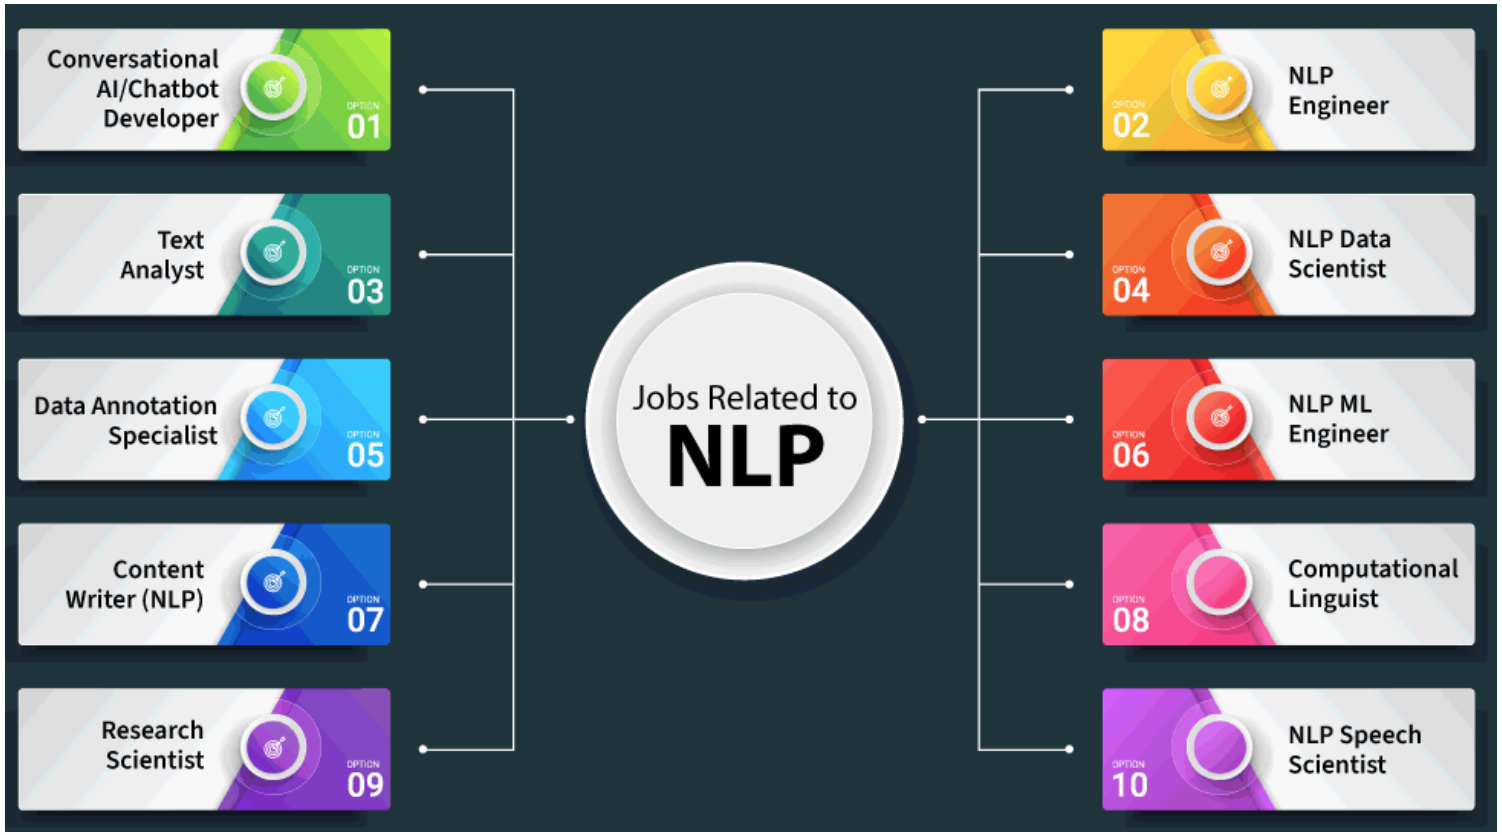

NLP là gì?

- Xử lý ngôn ngữ tự nhiên (Natural Language Processing: NLP) là một nhánh nghiên cứu của trí tuệ nhân tạo và ngôn ngữ học tính toán. Ngành học nghiên cứu về vấn đề sinh ngôn ngữ tự động và hiểu ngôn ngữ con người.
- Hệ thông sinh ngôn ngữ tự nhiên (Natural Language Generation: NLG) chuyển đổi thông tin từ cơ sở dữ liệu sang ngôn ngữ giống như con người. Hệ thống hiểu ngôn ngữ tự nhiên (Natural Language Understanding: NLU) chuyển đổi từ ngôn ngữ con người sang biểu diễn dễ dàng hơn cho chương trình máy tính xử lý.

NLP là gì?

Máy tính sử dụng ngôn ngữ tự nhiên làm đầu vào và đầu ra

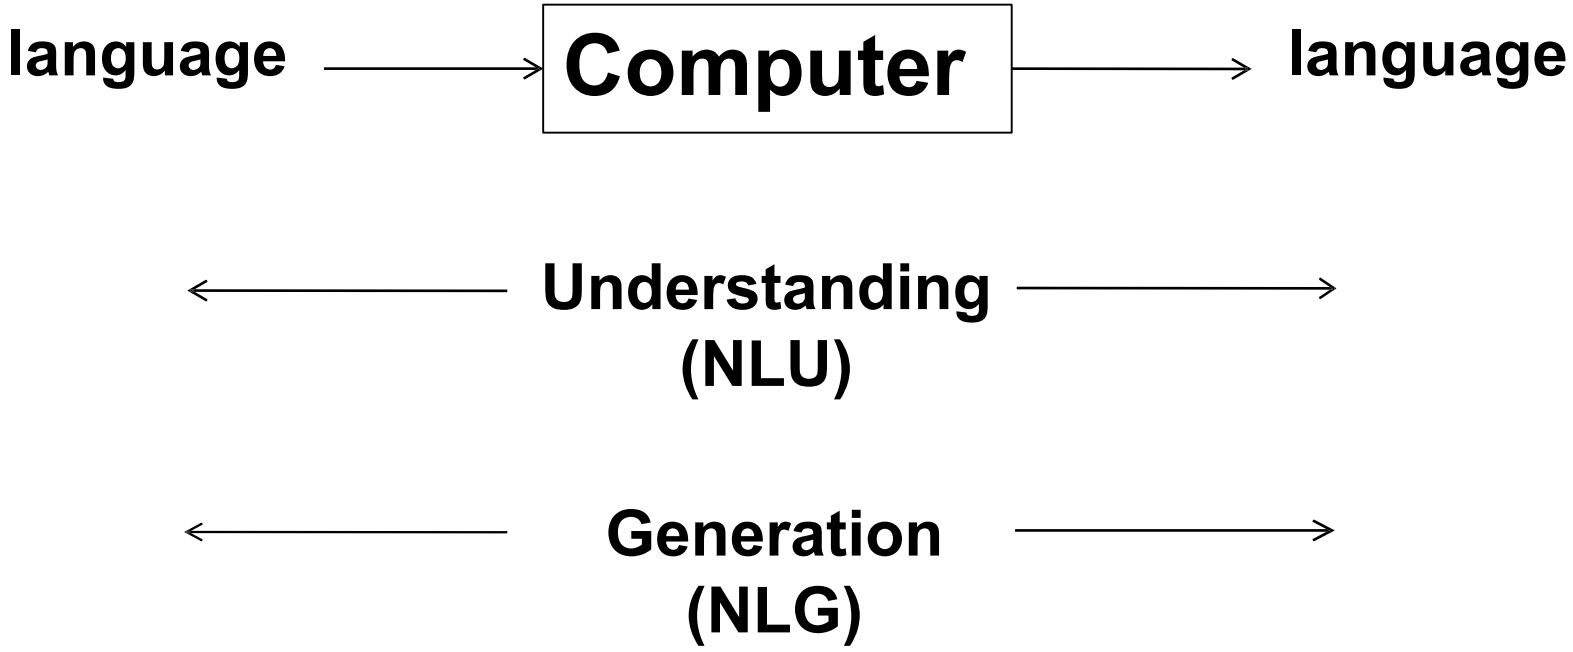

NLP và ngôn ngữ học tính toán

NLP phát triển các chương trình giải quyết những vấn đề thực tế của ngôn ngữ:

- Nhận diện giọng nói tự động
- Dịch máy
- Phân tích quan điểm
- Trích xuất thông tin từ văn bản

Computational linguistics (CL) tập trung vào sử dụng công nghệ để hỗ trợ support/implement linguistics:

- làm sao để hiểu được ngôn ngữ?
- làm sao để sinh ngôn ngữ?
- làm sao để học ngôn ngữ?

Các mức độ hiểu biết ngôn ngữ

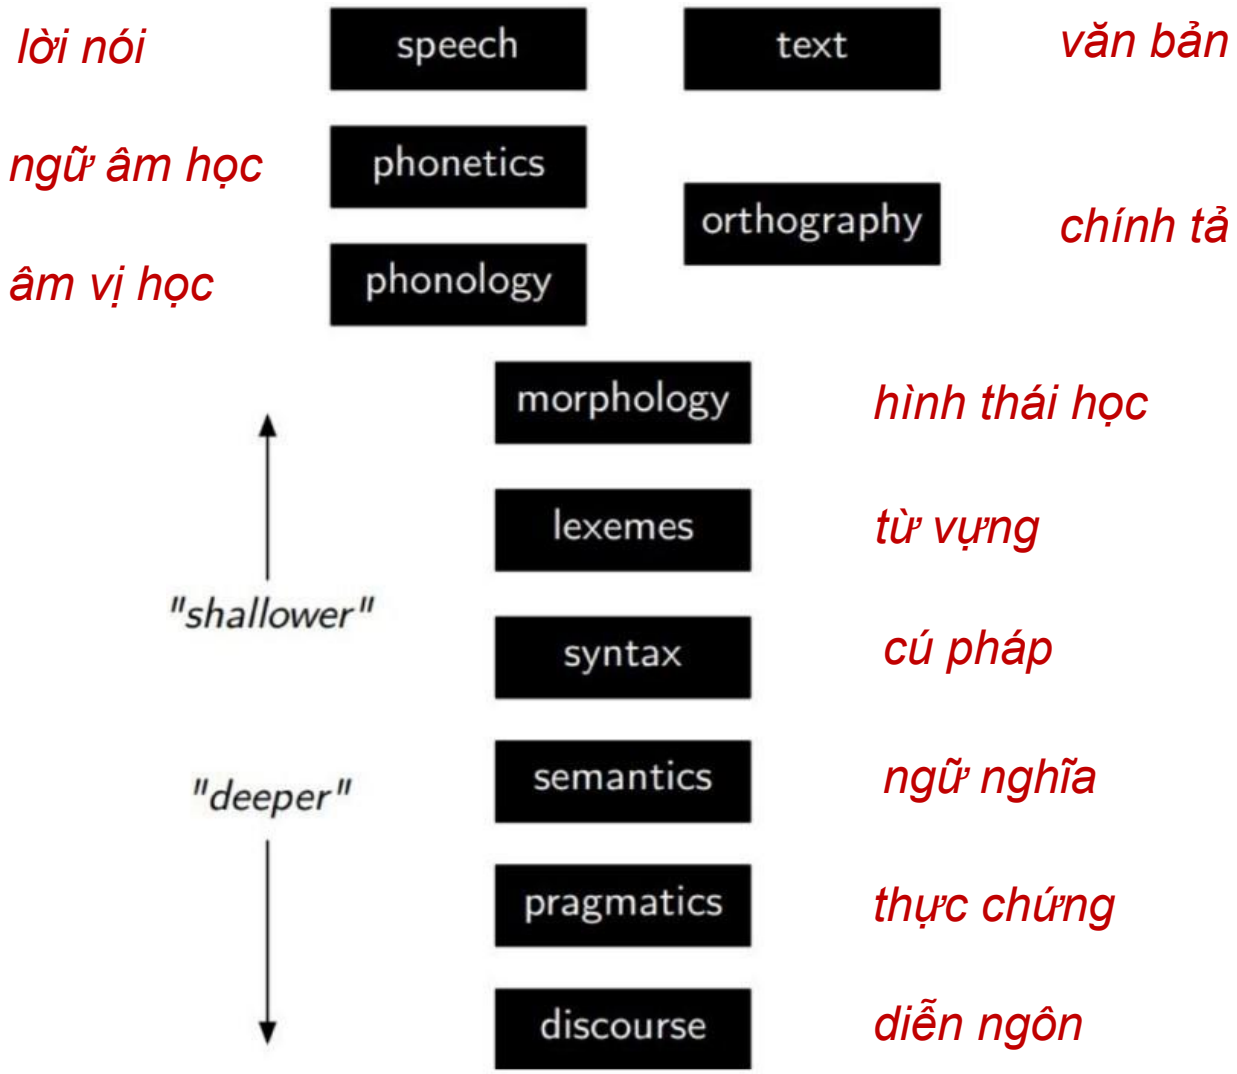

Phonetics và phonology

- Phonetics (ngữ âm học) tìm hiểu về cách con người tạo ra, truyền tải và nghe các âm thanh
- Phonology (âm vị học) tìm hiểu về hệ thống âm thanh được sử dụng nhằm truyền tải ý nghĩa trong ngôn ngữ

Morphology

- Hình thái học tìm hiểu về cấu trúc của từ
- Hình thái của một từ có cấu trúc phân cấp
  - Ví dụ: re+vital+ize+ation
- Hậu tố thường giúp xác định từ loại

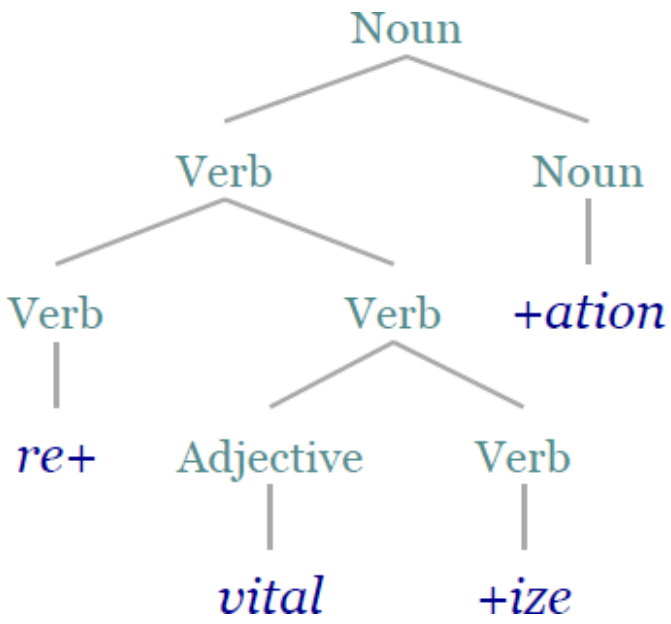

Syntax

- Cú pháp tìm hiểu cách từ được tổng hợp để tạo thành cụm từ và câu.
- Phân tích cú pháp giúp xác định “ai làm gì với ai”, một bước quan trọng để hiểu một câu.

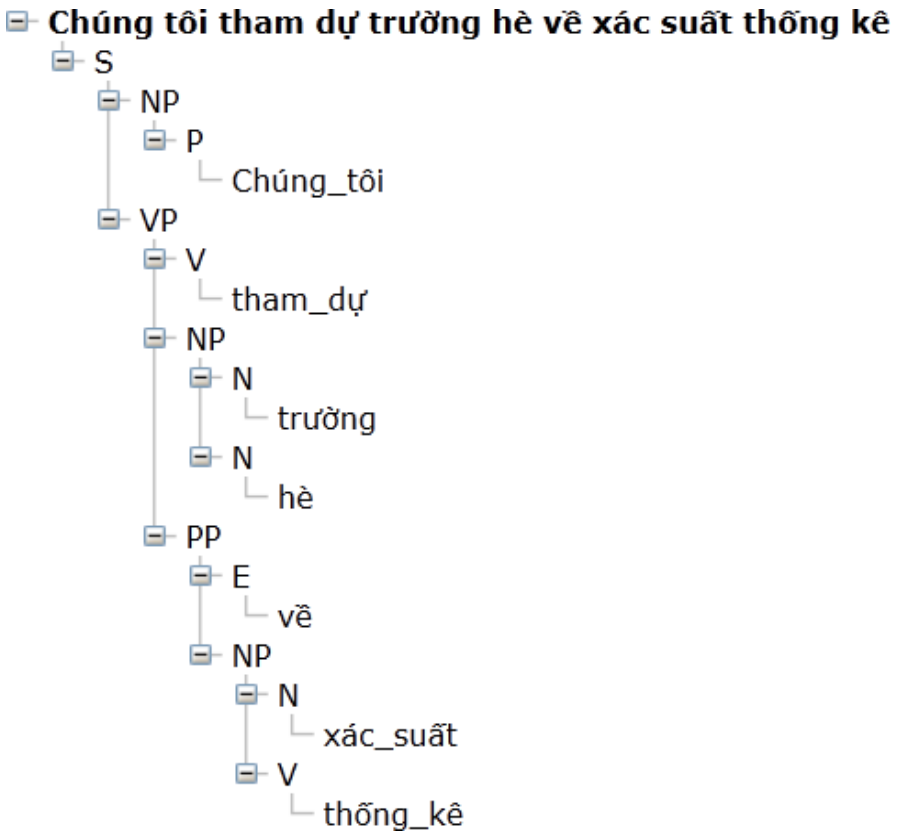

Semantics và pragmatics

Ngữ nghĩa (semantics): tìm hiểu về ý nghĩa của từ, cụm từ và câu

- VD: I have a dinner in/for an hour

Ngữ dụng (pragmatics): tìm hiểu về mối quan hệ giữa ngôn ngữ và ngữ cảnh tạo nên cấu trúc của ngôn ngữ

- VD: Cậu học sinh đi học đạt điểm cao, cậu hãnh diện về khoe mẹ: “Mẹ ơi, hôm nay cô giáo cho con 10 điểm”. “Đưa mẹ xem nào. Con của mẹ giỏi nhỉ”
- VD: Cậu học sinh trốn học đi chơi, về đến nhà cậu bị mẹ phát hiện: “Hôm nay con dám trốn học đi chơi à? Con của mẹ giỏi nhỉ?”

Lexicon

Mỗi ngôn ngữ có một từ điển (lexicon) riêng cho từng hình vị (morpheme):

- cách phát âm (phonology),
- tính chất phân phối (morphology and syntax),
- ý nghĩa (semantics)
- ngữ dụng (pragmatics)

Từ điển tương tác với mọi mức độ của ngôn ngữ học

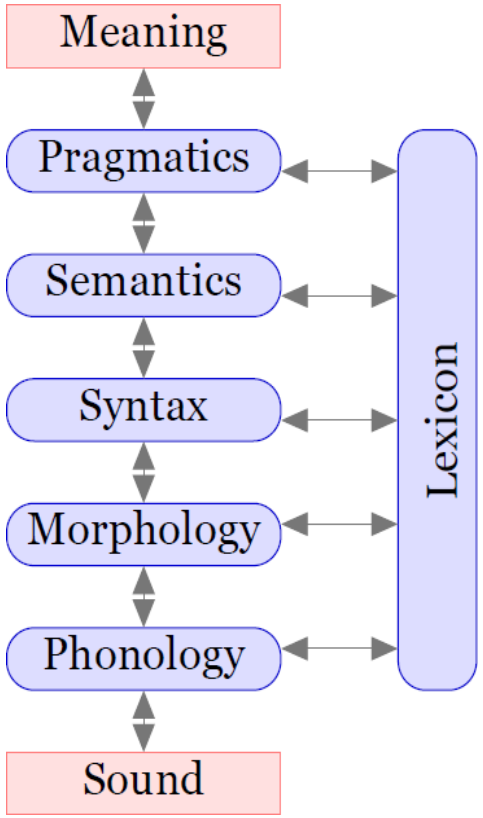

Lược sử phát triển của NLP

1950s -> 1980s

Rule-based
Approach + experts

Các hệ thống dựa trên quy tắc ngôn ngữ và từ điển với sự tham gia của chuyên gia

Late 1980s -> 2000s

Applying
Statistical ML

Chuyển sang NLP thống kê và sử dụng học máy trên dữ liệu lớn

Late 2010s ->

Applying DL:
Representation learning

Áp dụng học sâu và học biểu diễn, bao gồm các kiến trúc mô hình lớn

Lược sử phát triển của NLP

Ví dụ về dịch máy (Machine Translation)

Giai đoạn 1: Rule Based Machine Translation (RBMT)

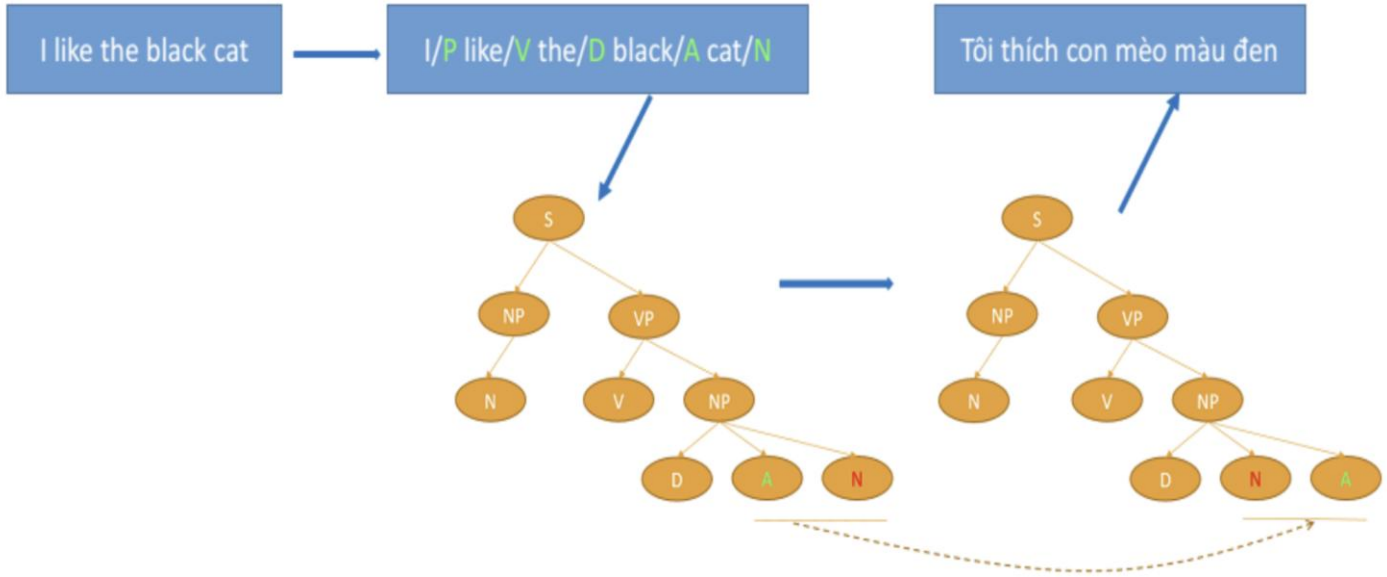

Lược sử phát triển của NLP

Ví dụ về dịch máy (Machine Translation)

Giai đoạn 2: Statistical Machine Translation (SMT)

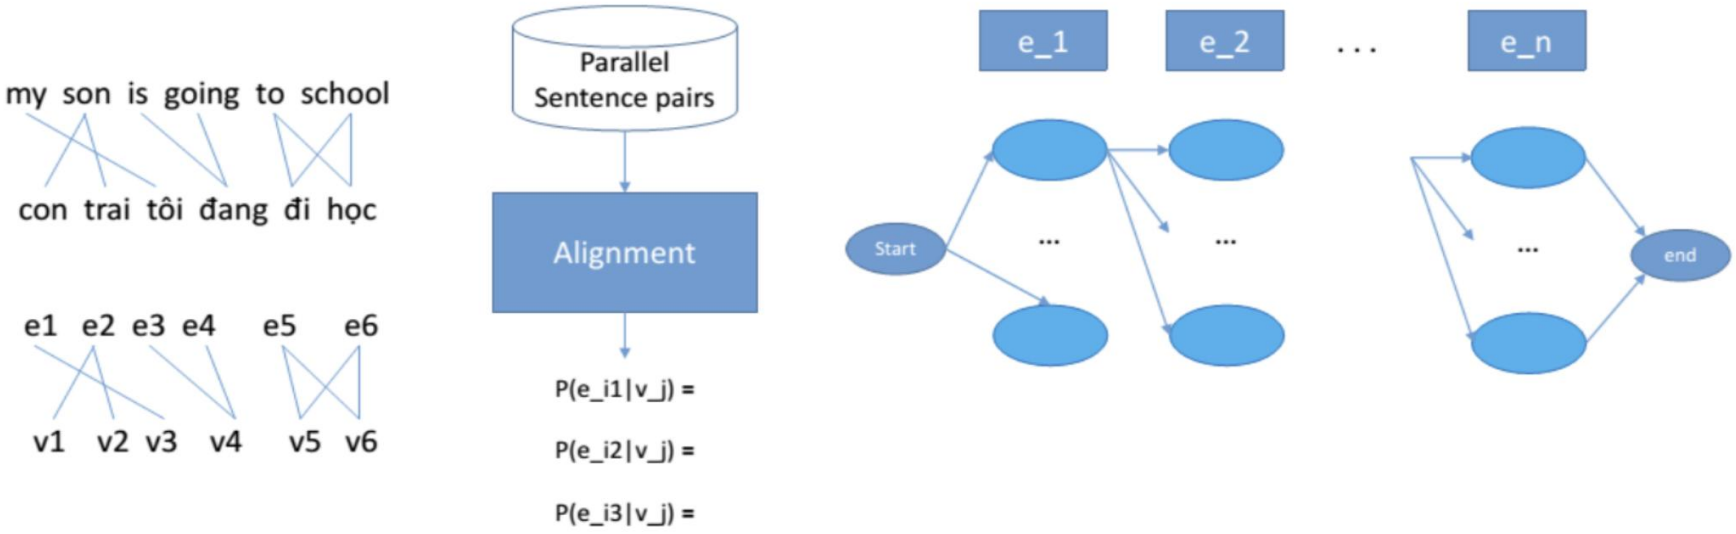

Lược sử phát triển của NLP

Ví dụ về dịch máy (Machine Translation)

Giai đoạn 3: Neural Machine Translation (NMT)

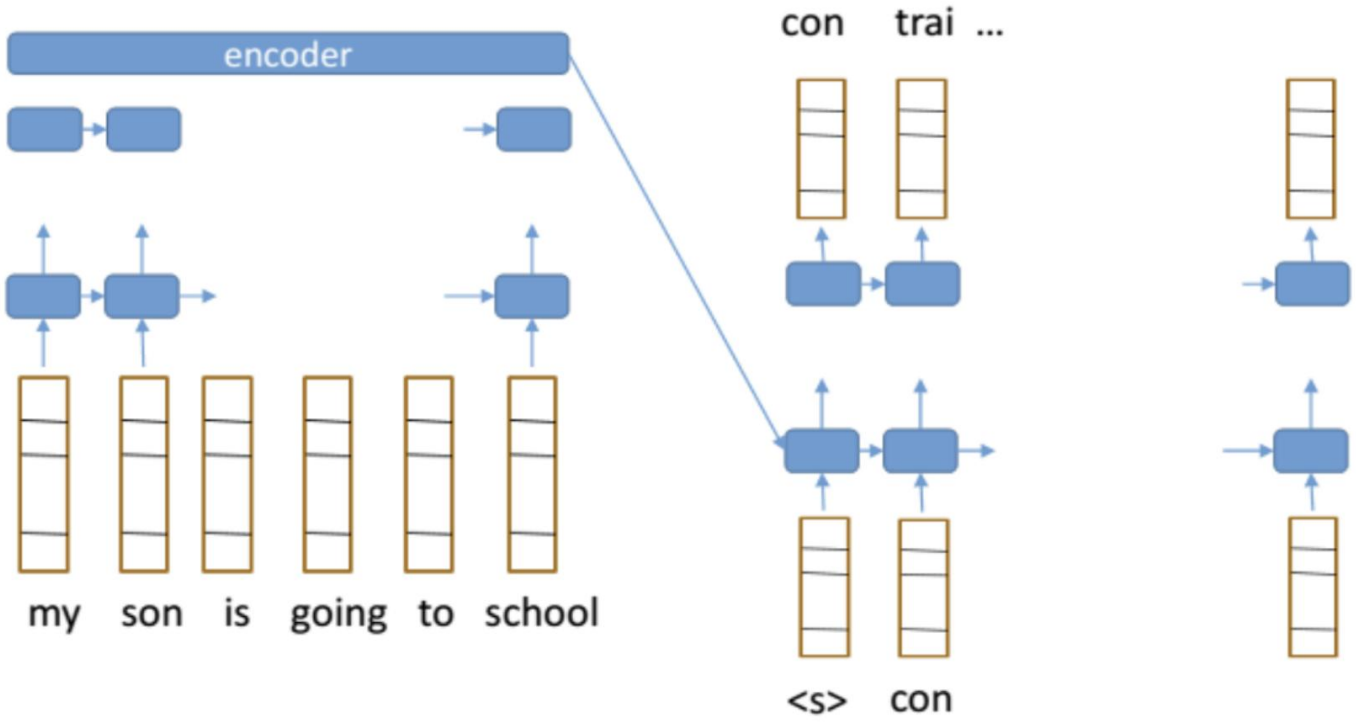

Yếu tố thúc đẩy NLP

Công cụ để quản lý sự ”bùng nổ thông tin“

- trích xuất thông tin và quản lý lượng lớn dữ liệu văn bản
- NLP thường là công cụ miễn phí được gắn kèm cùng sản phẩm
- VD: nhận diện giọng nói, dịch máy, phân cụm văn bản,...

Tính toán trên điện thoại và thiết bị cầm tay

- tìm kiếm/trích xuất văn bản không hoạt động quá tốt trên thiết bị nhỏ
- chúng ta muốn tương tác với máy tính một cách thông minh

Yếu tố thay đổi NLP

- Năng lực tính toán của máy móc
- Sự phát triển của web và mạng xã hội
- Thuật toán học máy hiện đại
- Sự hiểu biết về ngôn ngữ trong bối cảnh xã hội

Xử lý ngôn ngữ tự nhiên

Ứng dụng

- Dịch máy
- Trích chọn thông tin
- Hỏi đáp
- Hệ thống hội thoại
- Trích xuất thông tin
- Tổng hợp thông tin
- Phân tích quan điểm

Công nghệ chính

- Mô hình ngôn ngữ
- Part-of-speech tagging
- Phân tích cú pháp
- Nhận dạng thực thể
- Word sense disambiguation
- Phân tích vai trò ngữ nghĩa

Tại sao NLP lại khó?

- Nhập nhằng
- Tính thưa
- Hầu hết ứng dụng NLP có thể xem là bài toán dự đoán
  - Có thể giải quyết bằng học máy
- Tập nhãn thường là tập các câu khả dĩ
  - vô hạn (hoặc rất lớn)
- Dữ liệu huấn luyện cho học có giám sát thường không có sẵn
  - Giải pháp: Học không giám sát/bán giám sát
- Khó khăn về thuật toán
  - lượng từ vựng lớn (50K từ)
  - dữ liệu lớn (GB hoặc TB)

Nhập nhằng mức từ

Một câu có thể có n khả năng tách từ, nhưng chỉ 1 trong chúng là đúng.

Giải pháp đơn giản: lấy chuỗi âm tiết dài nhất bắt đầu từ vị trí hiện tại và có trong từ điển từ.

Vấn đề: chồng chéo từ

- Học_sinh học_sinh học.
- Học_sinh học sinh_học.

Liệt kê tất cả các khả năng có thể và thiết kế một giải pháp để lựa chọn cái tốt nhất.

Nhập nhằng trong gán nhãn từ loại

Con ngựa đá con ngựa đá.

- Con_ngựa đá con_ngựa đá.
  DT ĐgT DT

Ông già đi nhanh quá.

- Ông già đi nhanh quá.
  ĐaT TT PT TT trạng_từ
- Ông_già đi nhanh quá.
  DT ĐgT TT trạng_từ

Nhập nhằng ở nhiều mức độ

Mức độ âm thanh:

- "… a computer that understands you like your mother"
- "… a computer that understands you lie cured mother"

Mức độ cú pháp:

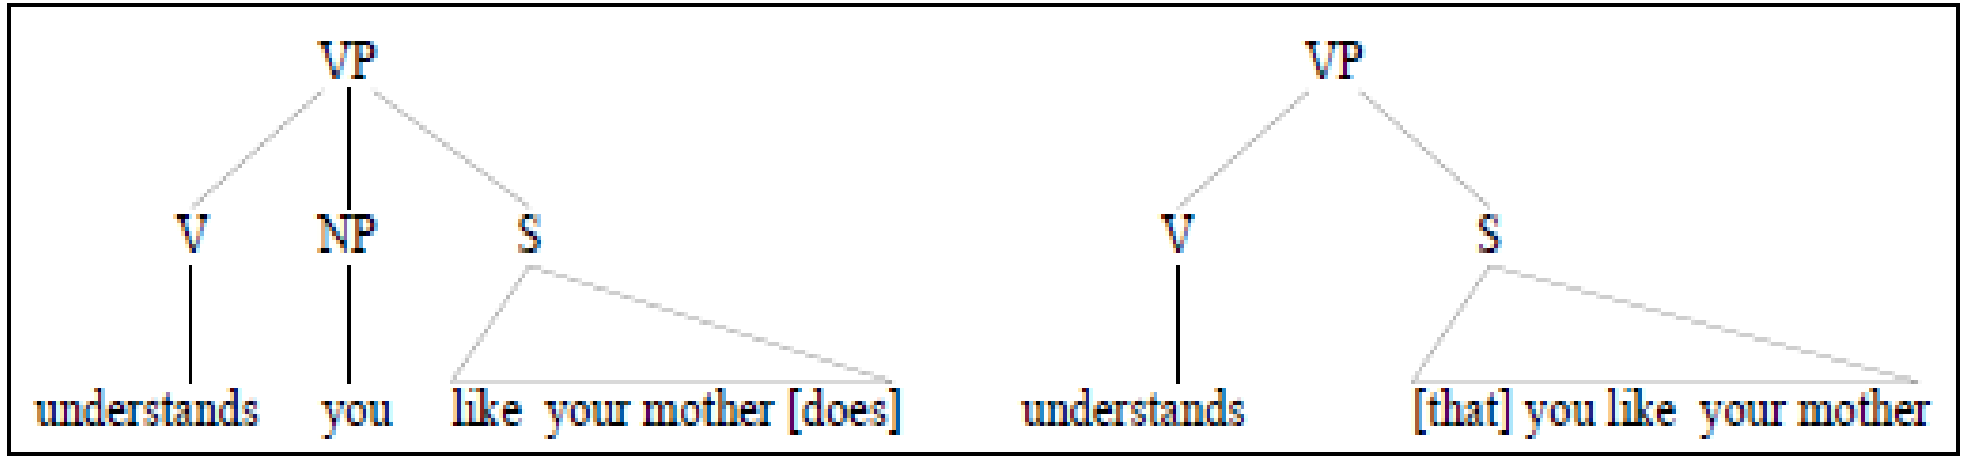

Nhập nhằng ở nhiều mức độ

Mức độ từ vựng

- I walked to the bank ...
  - of the river.
  - to get money.
- I work for John Hancock ...
  - and he is a good boss.
  - which is a good company.

Xử lý nhập nhằng

Làm sao để mô hình xử lý nhập nhằng?

- Phương pháp không xác suất (bộ phân tích cú pháp CKY) trả về tất cả các phân tích khả dĩ.
- Phương pháp xác suất (HMMs cho POS tagging, PCFGs cho cú pháp) và thuật toán (Viterbi, probabilistic CKY) đưa ra kết quả tốt nhất có thể (câu trả lời có xác suất cao nhất).

Tuy nhiên, các phương pháp chỉ tốt nếu tính xác suất được mô hình chính xác. Làm sao để mô hình xác suất đủ tốt?

Corpus

Kho văn bản (Corpus) là tập hợp các văn bản

- Thường được chú thích
- Hoặc chỉ đơn thuần là văn bản

Ví dụ

- Penn Treebank: 1M từ của báo WSJ
- Canadian Hansards: 10M+ từ của câu tiếng Pháp/Anh
- Yelp reviews
- VLSP Corpus (Vietnamese)

NLP thống kê

- Giống như hầu hết các thuật toán AI, thuật toán trong NLP thường là thống kê
- Thường tốt hơn phương pháp dùng luật
- Xác suất/thống kê được học từ dữ liệu
- Thường yêu cầu rất nhiều dữ liệu

Tính thưa thớt

Dữ liệu thưa thớt theo Zip's law: $word\ freq \propto \frac{1}{word\ rank}$

Ví dụ: tần suất của các từ khác nhau trong tập văn bản

any word		nouns	
Frequency	Token	Frequency	Token
1,698,599	the	124,598	European
849,256	of	104,325	Mr
793,731	to	92,195	Commission
640,257	and	66,781	President
508,560	in	62,867	Parliament
407,638	that	57,804	Union
400,467	is	53,683	report
394,778	a	53,547	Council
263,040	I	45,842	States

Tính thưa thớt

Sắp xếp từ theo tần suất xuất hiện

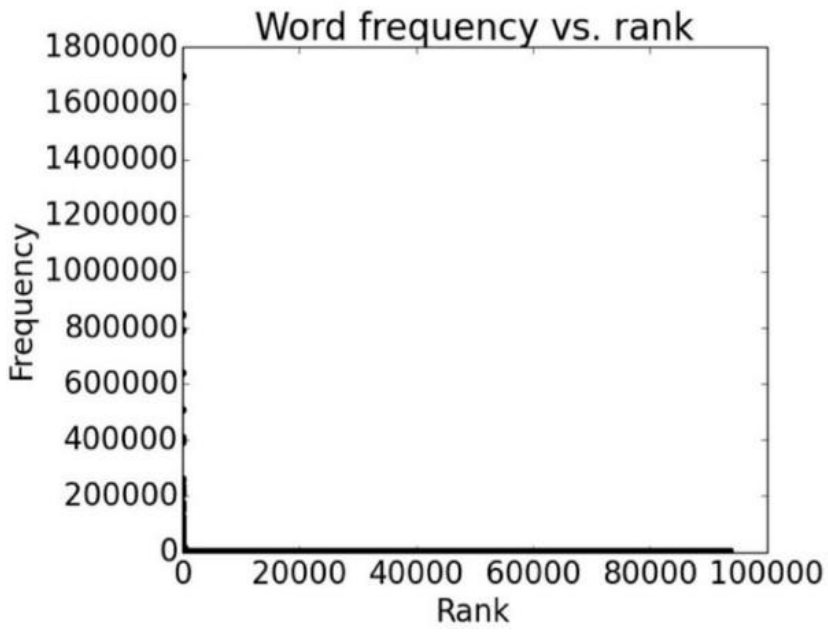

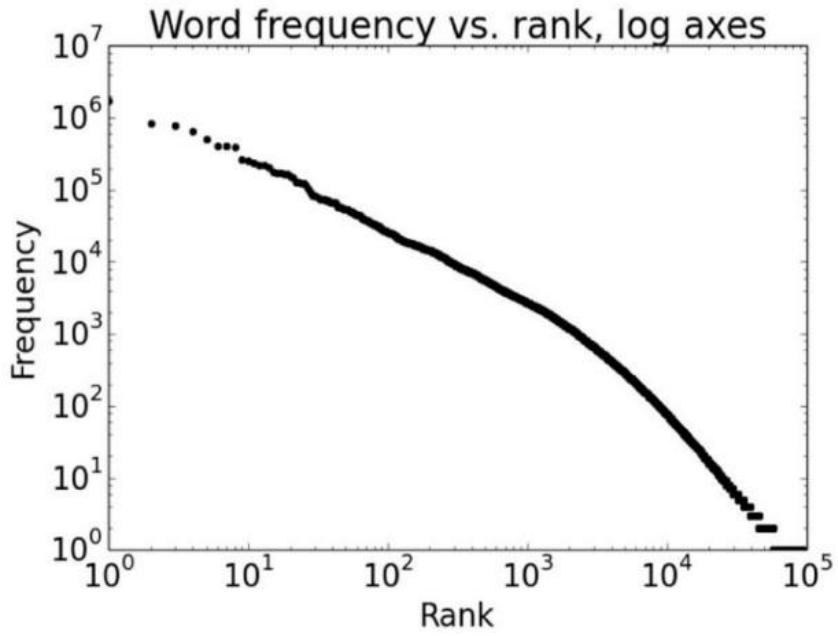

Tính thưa thớt

- Kể cả với tập dữ liệu lớn, sẽ có rất nhiều từ ít xuất hiện.
- Chúng ta cần ước lượng xác suất cho những từ ít hoặc không bao giờ xuất hiện.

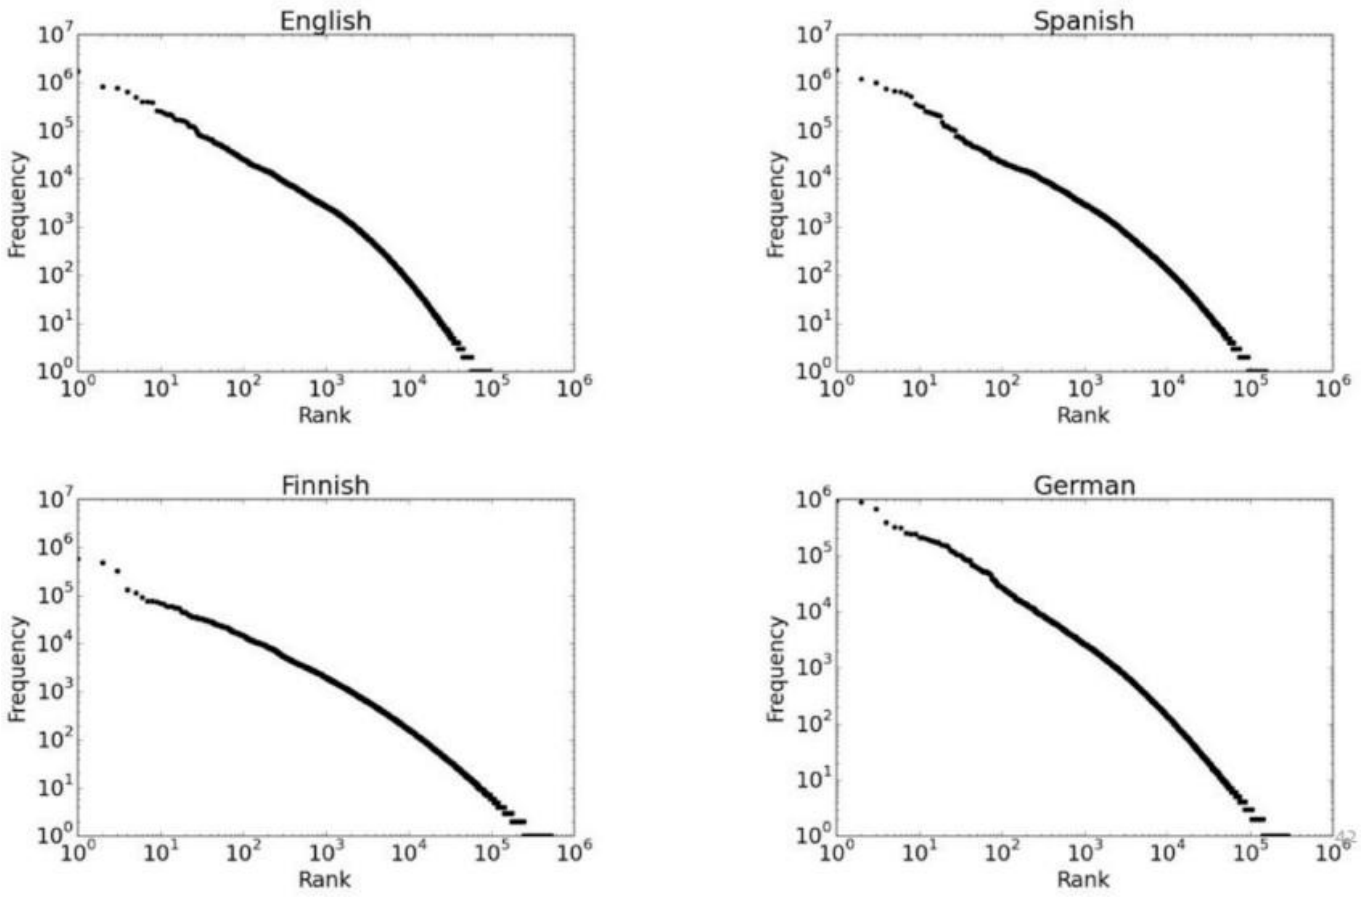

Lĩnh vực gắn liền với NLP

- Học máy
- Ngôn ngữ học
- Khoa học nhận thức (Cognitive science)
- Lý thuyết thông tin
- Khoa học dữ liệu
- Tâm lý học
- Kinh tế
- Giáo dục

Các chủ đề

- Từ và câu
- Phân lớp văn bản
- Mô hình ngôn ngữ xác suất
- Vector ngữ nghĩa và word embeddings
- Gán nhãn câu: POS tagging, NER
- HMM, RNN & LSTM, cơ chế Attention, Transformer, mô hình tiền huấn luyện
- Phân tích cú pháp
- Ứng dụng
  - Dịch máy, hỏi đáp, hệ thống hội thoại