Học viện
Công nghệ Bưu chính Viễn thông

KHOA TRÍ TUỆ NHÂN TẠO
Faculty of Artificial Intelligence

Bài 6.2: Mô hình Sequence-to-Sequence

Giảng viên: ThS. Võ Ngọc Bích Uyên

Nội dung

- Dịch máy (Machine Translation)
- Mô hình Sequence-to-sequence (Seq2seq)
- Mô hình Seq2seq với cơ chế Attention (cơ chế chú ý)

Machine Translation

Machine translation

Dịch máy (Machine Translation - MT) là tác vụ dịch một câu x từ một ngôn ngữ (ngôn ngữ nguồn) sang một câu y ở một ngôn ngữ khác (ngôn ngữ đích)

x: *L'homme est né libre, et partout il est dans les fers*

↓

y: *Man is born free, but everywhere he is in chains*

Lịch sử của dịch máy: 1950s

- Nghiên cứu dịch máy bắt đầu vào đầu những năm 1950 trên các máy tính có sức mạnh tính toán kém hơn cả máy tính bỏ túi của học sinh trung học ngày nay.
- Diễn ra đồng thời với các nghiên cứu nền tảng về ngôn ngữ hình thức, xác suất và lý thuyết thông tin.
- Dịch máy được quân đội tài trợ mạnh mẽ, nhưng về cơ bản chỉ là các hệ thống dựa trên quy tắc đơn giản thực hiện việc thay thế từng từ.
- Tuy nhiên, ngôn ngữ con người phức tạp hơn thế và có nhiều sự khác biệt giữa các ngôn ngữ.
- Sự hiểu biết về cú pháp, ngữ nghĩa và ngữ dụng của ngôn ngữ tự nhiên khi đó còn rất hạn chế.
- Bài toán này nhanh chóng tỏ ra là bất khả thi!

1990s-2010s: Dịch máy thống kê

Ý tưởng: Học một mô hình xác suất từ dữ liệu.

Giả sử chúng ta đang dịch tiếng Pháp → tiếng Anh. Cho trước câu tiếng Pháp x, chúng ta muốn tìm câu tiếng Anh y tốt nhất:

$$argmax_y P(y|x)$$

Sử dụng Định lý Bayes để chia vấn đề này thành hai thành phần cần học riêng biệt:

$$argmax_y P(x|y)P(y)$$

Mô hình dịch: Mô hình hóa cách dịch các từ và cụm từ. Được học từ dữ liệu song ngữ (parallel data).

Mô hình ngôn ngữ: Mô hình hóa cách viết tiếng Anh chuẩn. Được học từ dữ liệu đơn ngữ (monolingual data).

1990s-2010s: Dịch máy thống kê

- Dịch máy Thống kê (SMT) từng là một lĩnh vực nghiên cứu khổng lồ; các hệ thống tốt nhất cực kỳ phức tạp.
- Hàng trăm chi tiết quan trọng: Các hệ thống có nhiều thành phần con được thiết kế riêng biệt.
- Cần rất nhiều nỗ lực trích xuất đặc trưng (feature engineering): Cần thiết kế các đặc trưng để nắm bắt các hiện tượng ngôn ngữ cụ thể.
- Đòi hỏi biên soạn và duy trì các tài nguyên bổ sung như bảng các cụm từ tương đương.
- Tốn rất nhiều công sức con người để bảo trì: Phải lặp lại các công việc này cho mỗi cặp ngôn ngữ!

Neural Machine Translation (NMT)

- Dịch máy Nơ-ron (NMT) là phương pháp thực hiện dịch máy chỉ bằng một mạng nơ-ron từ đầu đến cuối (end-to-end) duy nhất.
- Kiến trúc mạng nơ-ron này được gọi là mô hình sequence-to-sequence (hay còn gọi là seq2seq) và nó bao gồm hai mạng RNN.
  - **Mạng RNN mã hóa (Encoder RNN)** tạo ra một bản mã hóa (encoding) của câu nguồn. Bản mã hóa này cung cấp trạng thái ẩn ban đầu cho mạng RNN giải mã.
  - **Mạng RNN giải mã (Decoder RNN)** là một mô hình ngôn ngữ có nhiệm vụ tạo ra câu đích, dựa trên điều kiện là bản mã hóa. (Lưu ý: Đầu ra của bộ giải mã được đưa vào làm đầu vào cho bước dự đoán tiếp theo)

Sequence-to-sequence (Seq2seq) model

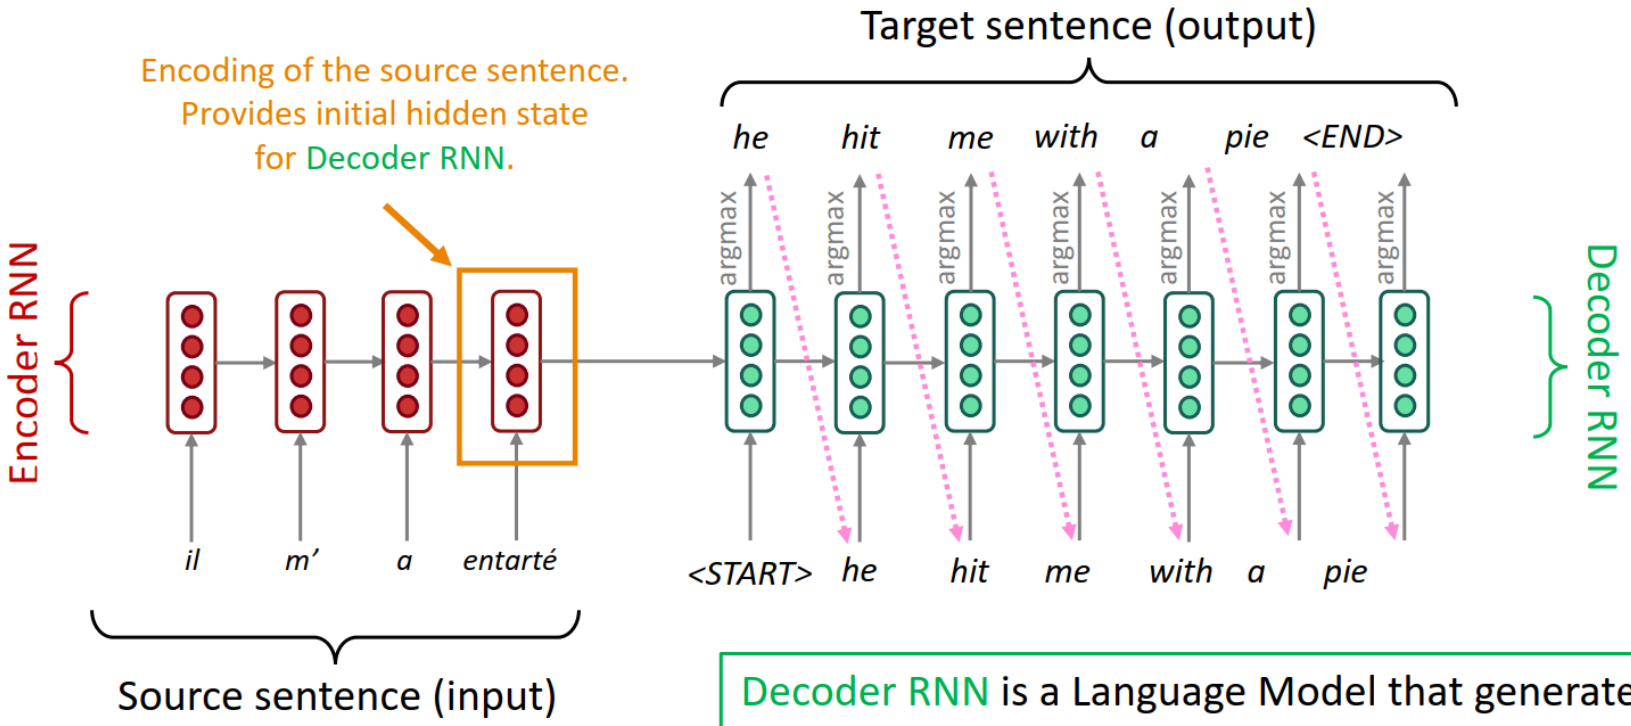

Decoder RNN is a Language Model that generates target sentence, *conditioned on encoding*.

Encoder RNN produces an encoding of the source sentence.

Note: This diagram shows **test time** behavior: decoder output is fed in ·····→ as next step's input

Seq2seq model

- Khái niệm chung ở đây là mô hình bộ mã hóa - bộ giải mã (encoder-decoder model).
  - Một mạng nơ-ron nhận đầu vào và tạo ra một biểu diễn nơ-ron.
  - Một mạng khác tạo ra đầu ra dựa trên biểu diễn nơ-ron đó.
  - Nếu đầu vào và đầu ra đều là chuỗi, chúng ta gọi nó là mô hình seq2seq.
- Mô hình seq2seq không chỉ hữu ích cho tác vụ dịch máy. Nhiều tác vụ NLP có thể được diễn đạt dưới dạng sequence-to-sequence:
  - Tóm tắt văn bản (Văn bản dài → Văn bản ngắn).
  - Hội thoại (Các câu nói trước → Câu nói tiếp theo).
  - Phân tích cú pháp (Văn bản đầu vào → Chuỗi phân tích cú pháp).
  - Tạo mã code (Ngôn ngữ tự nhiên → Mã Python).

Neural Machine Translation (NMT)

- Mô hình seq2seq là một ví dụ về Mô hình ngôn ngữ có điều kiện (Conditional Language Model).
    - Là mô hình ngôn ngữ vì bộ giải mã đang dự đoán từ tiếp theo của câu đích y.
    - Có điều kiện vì các dự đoán của nó phụ thuộc vào câu nguồn x.
- NMT tính toán trực tiếp $P(y|x)$:

$$P(y|x) = P(y_1|x)P(y_2|y_1,x) \dots P(y_T|y_1,\dots,y_{T\text{-}1},x)$$

- Làm thế nào để huấn luyện hệ thống NMT? → thu thập một tập ngữ liệu song ngữ lớn

Hiện nay cũng có các nghiên cứu về "NMT không giám sát", tăng cường dữ liệu,...

Huấn luyện hệ thống NMT

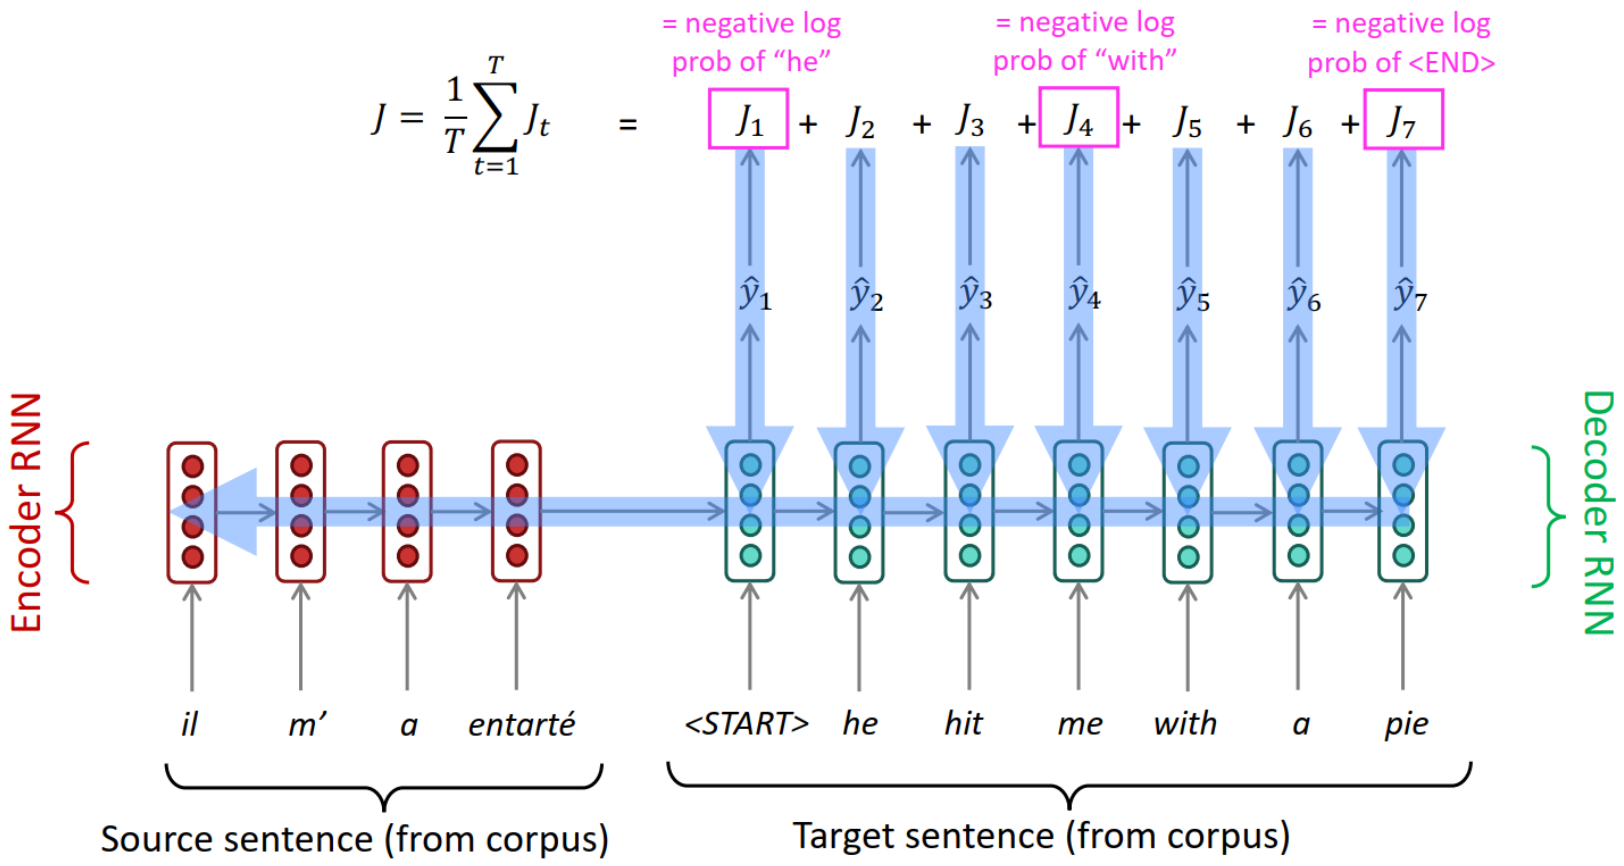

Seq2seq is optimized as a **single system.** Backpropagation operates "*end-to-end*".

Multi-layer deep encoder-decoder machine translation net

[Sutskever et al. 2014; Luong et al. 2015]

The hidden states from RNN layer *i* are the inputs to RNN layer *i*+1

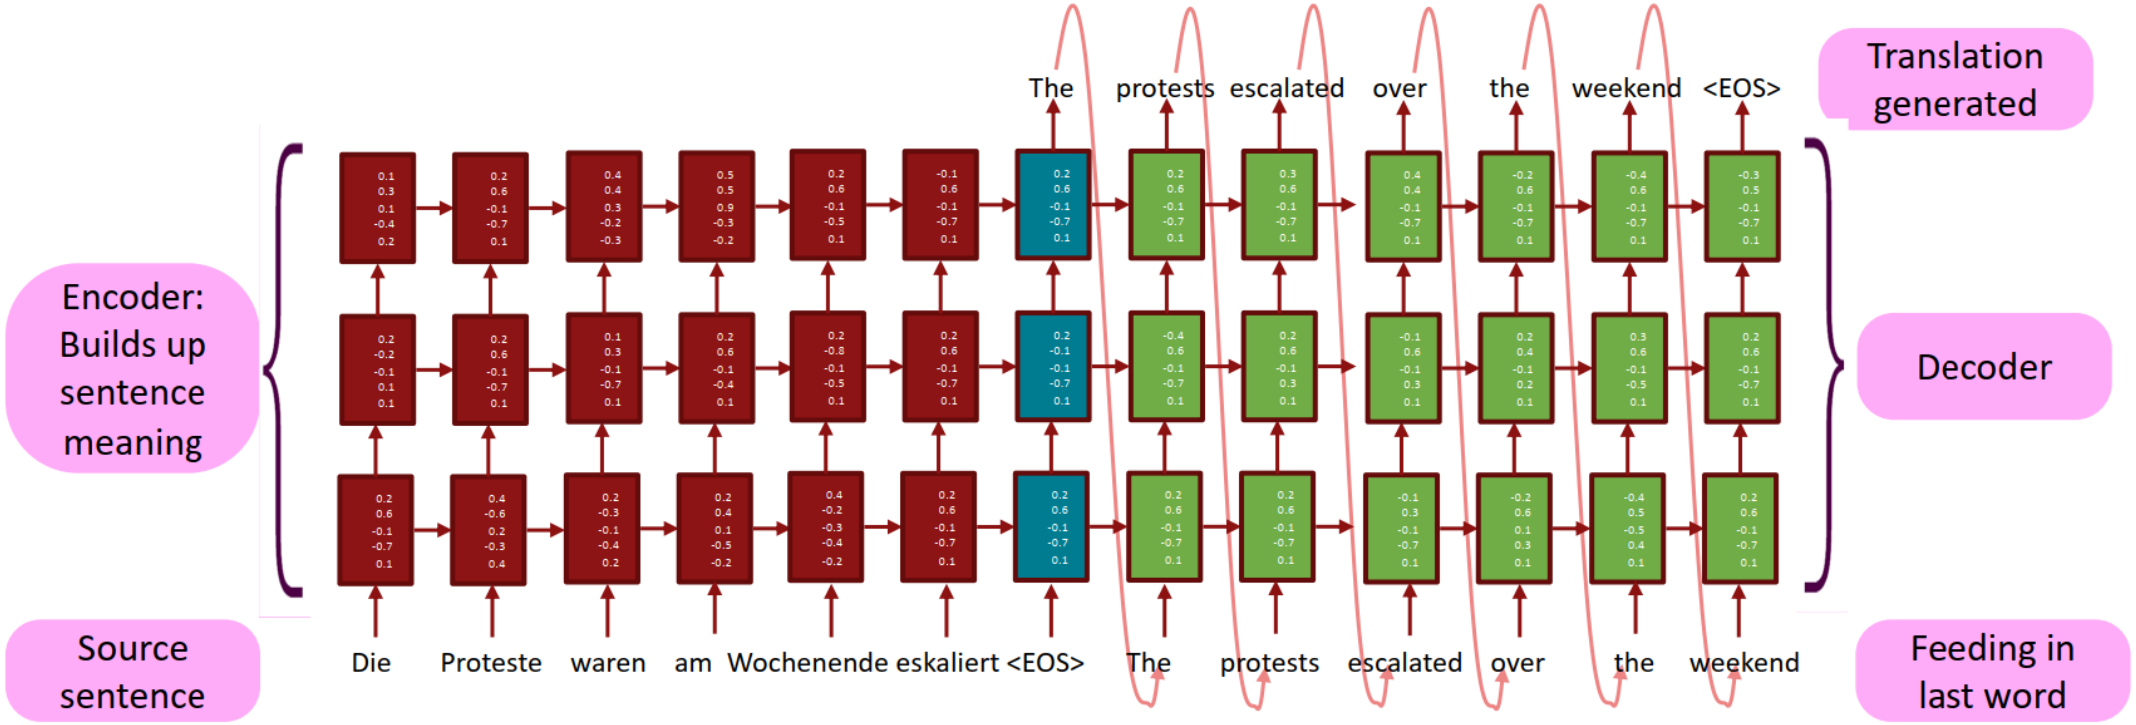

NMT: Thành công của NLP Deep Learning

NMT đi từ một thử nghiệm nghiên cứu vào năm 2014 trở thành phương pháp tiêu chuẩn hàng đầu vào năm 2016.

2014: Bài báo về seq2seq đầu tiên được xuất bản [Sutskever et al. 2014].

2016: Google Translate chuyển từ SMT sang NMT – và đến năm 2018 thì tất cả mọi người đều sử dụng.

Microsoft SYSTRAN beyond language Google facebook

Baidu 百度 網易 NETEASE www.163.com Tencent 腾讯 搜狗搜索

Các hệ thống SMT, được xây dựng bởi hàng trăm kỹ sư trong nhiều năm, đã bị vượt mặt bởi các hệ thống NMT chỉ do các nhóm kỹ sư nhỏ huấn luyện trong vài tháng

NMT so với SMT

- **Ưu điểm:**
  - Hiệu suất tốt hơn, trôi chảy hơn, sử dụng ngữ cảnh và độ tương đồng cụm từ tốt hơn.
  - Là một mạng nơ-ron duy nhất được tối ưu hóa từ đầu đến cuối, không cần tối ưu từng thành phần con.
  - Đòi hỏi ít nỗ lực con người hơn (không cần trích xuất đặc trưng, dùng cùng một phương pháp cho mọi cặp ngôn ngữ).
- **Nhược điểm:**
  - NMT ít có khả năng diễn giải hơn (less interpretable) và khó gỡ lỗi (debug).
  - NMT rất khó kiểm soát (ví dụ: khó đưa ra các quy tắc dịch thuật cụ thể, dẫn đến lo ngại về độ an toàn).

Cách đánh giá hệ thống Dịch máy (MT)

- BLEU (Bilingual Evaluation Understudy): So sánh bản dịch máy với một hoặc nhiều bản dịch của con người và tính điểm tương đồng dựa trên:
    - Độ chính xác n-gram (thường lên đến 3 hoặc 4-grams).
    - Hình phạt (penalty) nếu bản dịch quá ngắn.
- BLEU hữu ích nhưng không hoàn hảo: Có nhiều cách hợp lệ để dịch một câu. Một bản dịch tốt có thể nhận điểm BLEU thấp nếu nó có ít n-gram trùng khớp với câu của người dịch.

Seq2seq: vấn đề nút thắt cổ chai

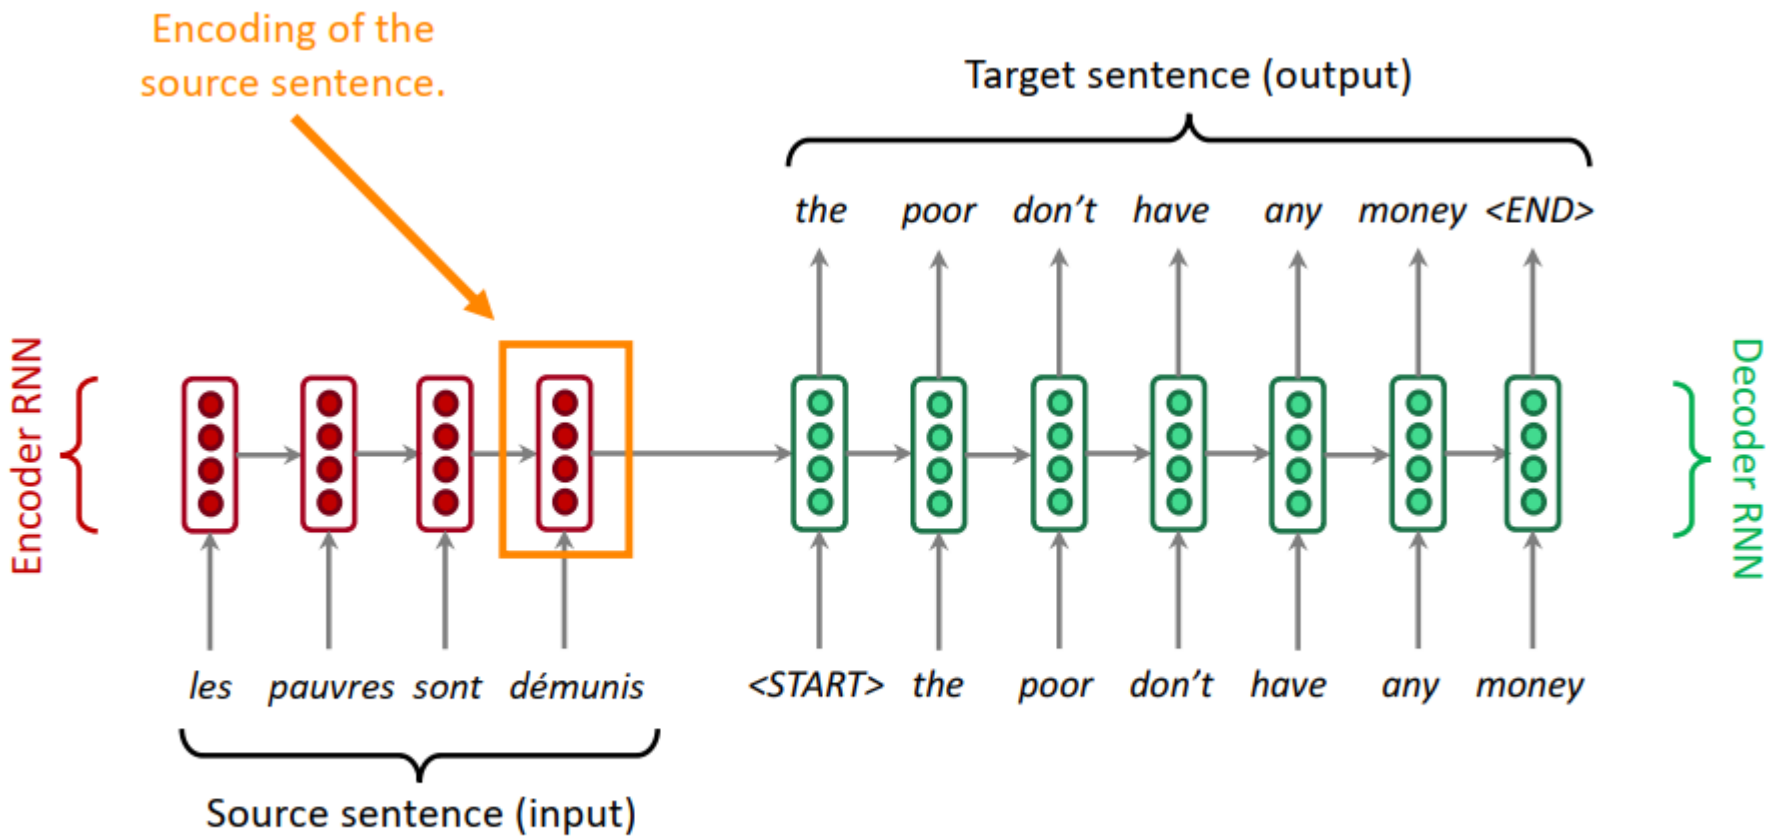

Problems with this architecture?

Seq2seq: vấn đề nút thắt cổ chai

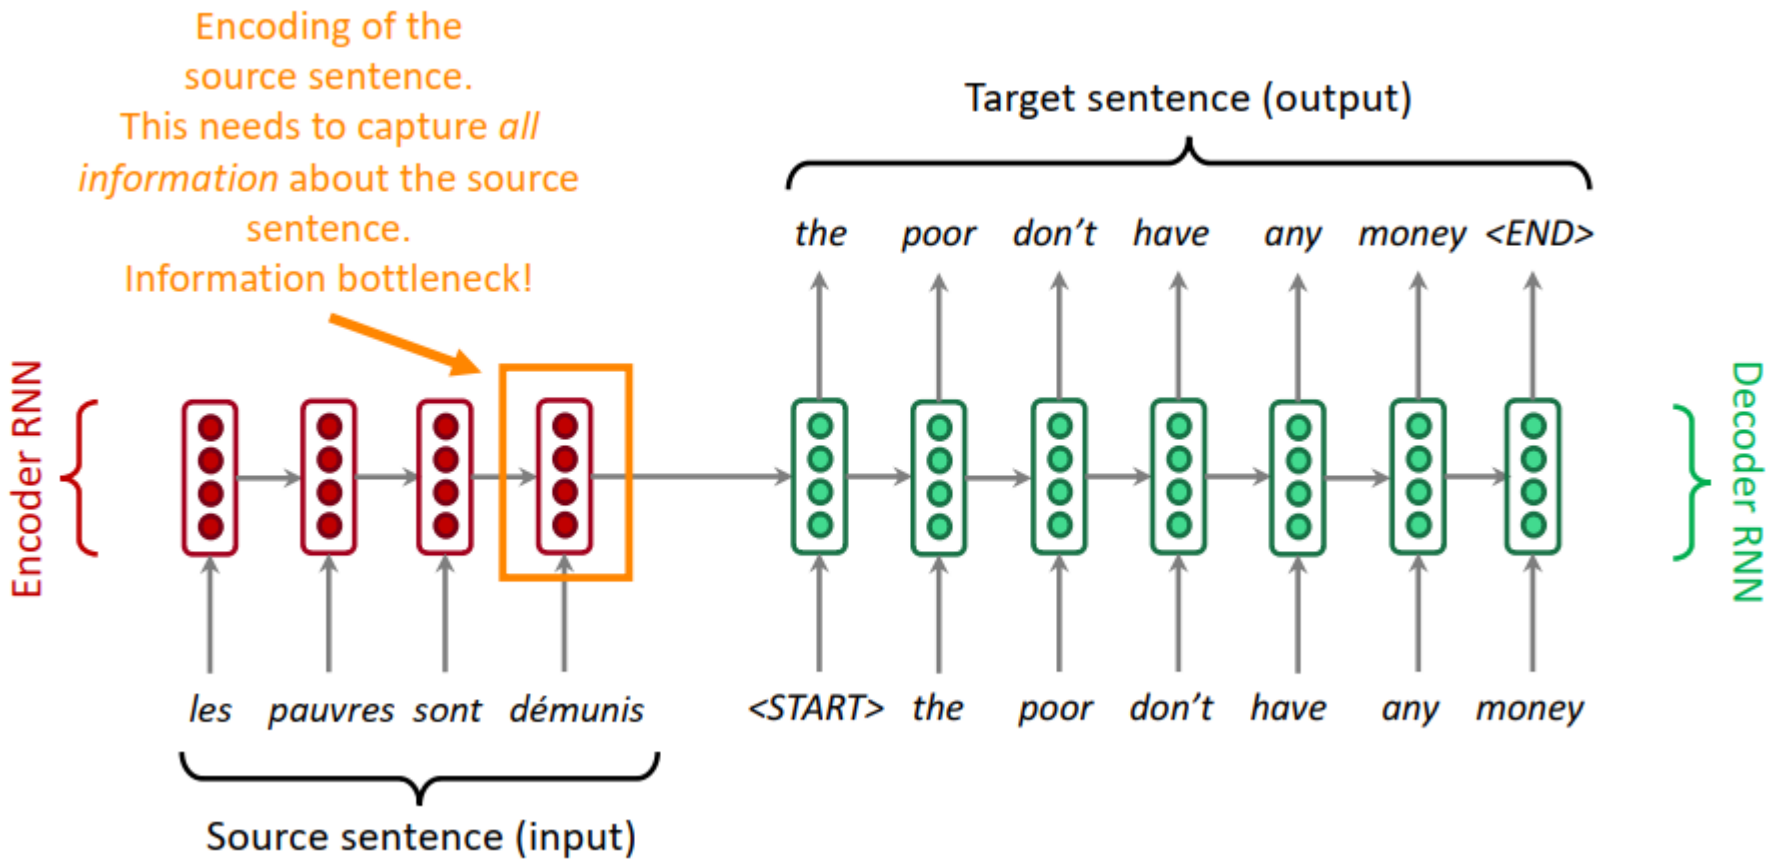

Attention

- Attention là giải pháp cho vấn đề nút thắt cổ chai.
- **Ý tưởng:** Ở mỗi bước của bộ decoder, sử dụng kết nối trực tiếp (direct connection) đến bộ encoder để tập trung vào một phần cụ thể của chuỗi nguồn.

Seq2seq with attention

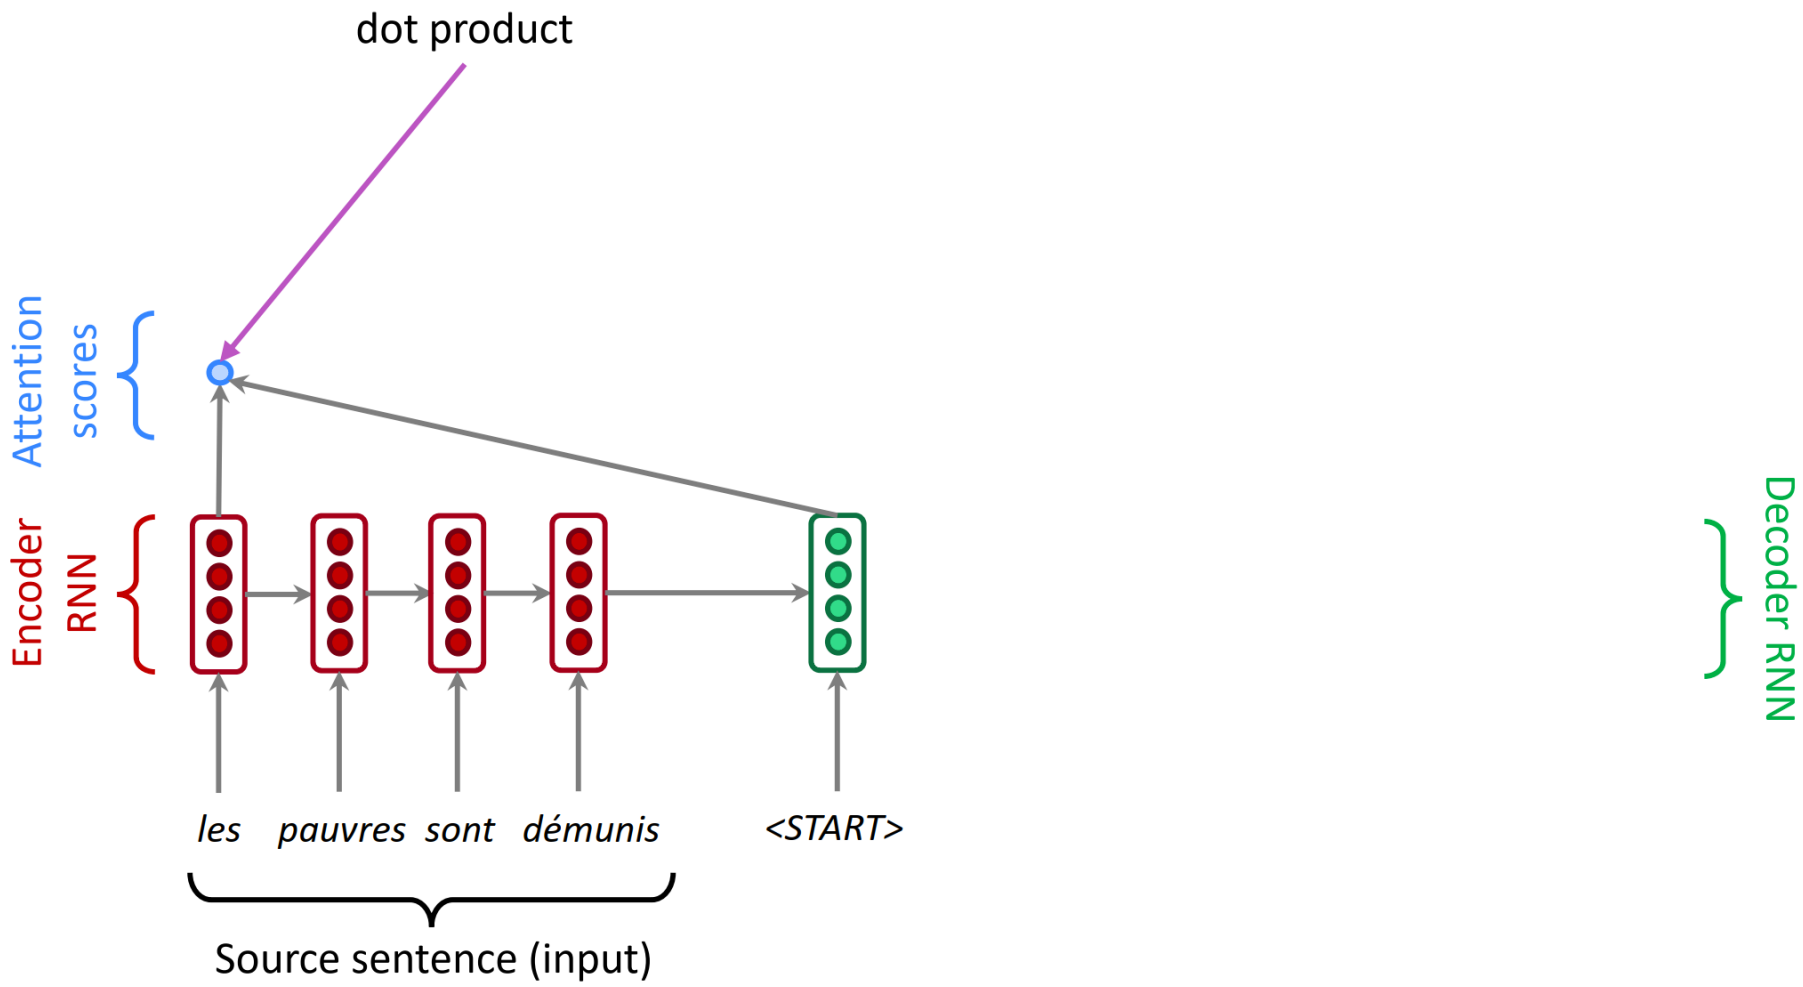

Seq2seq with attention

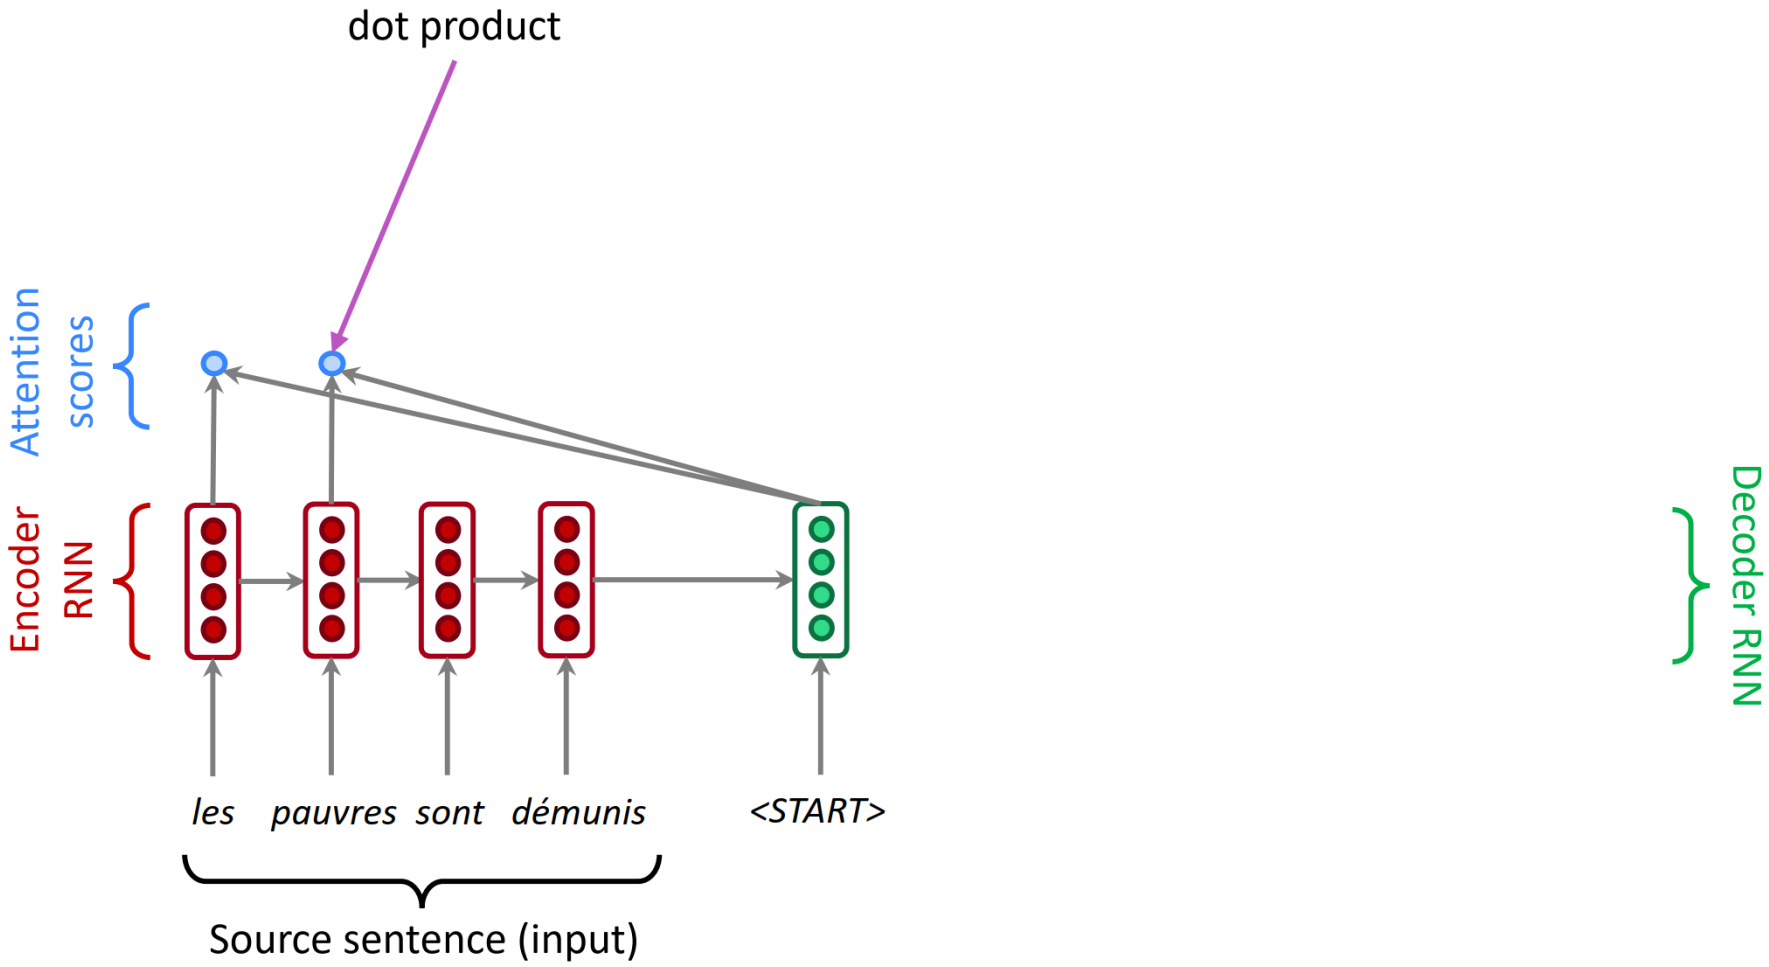

Seq2seq with attention

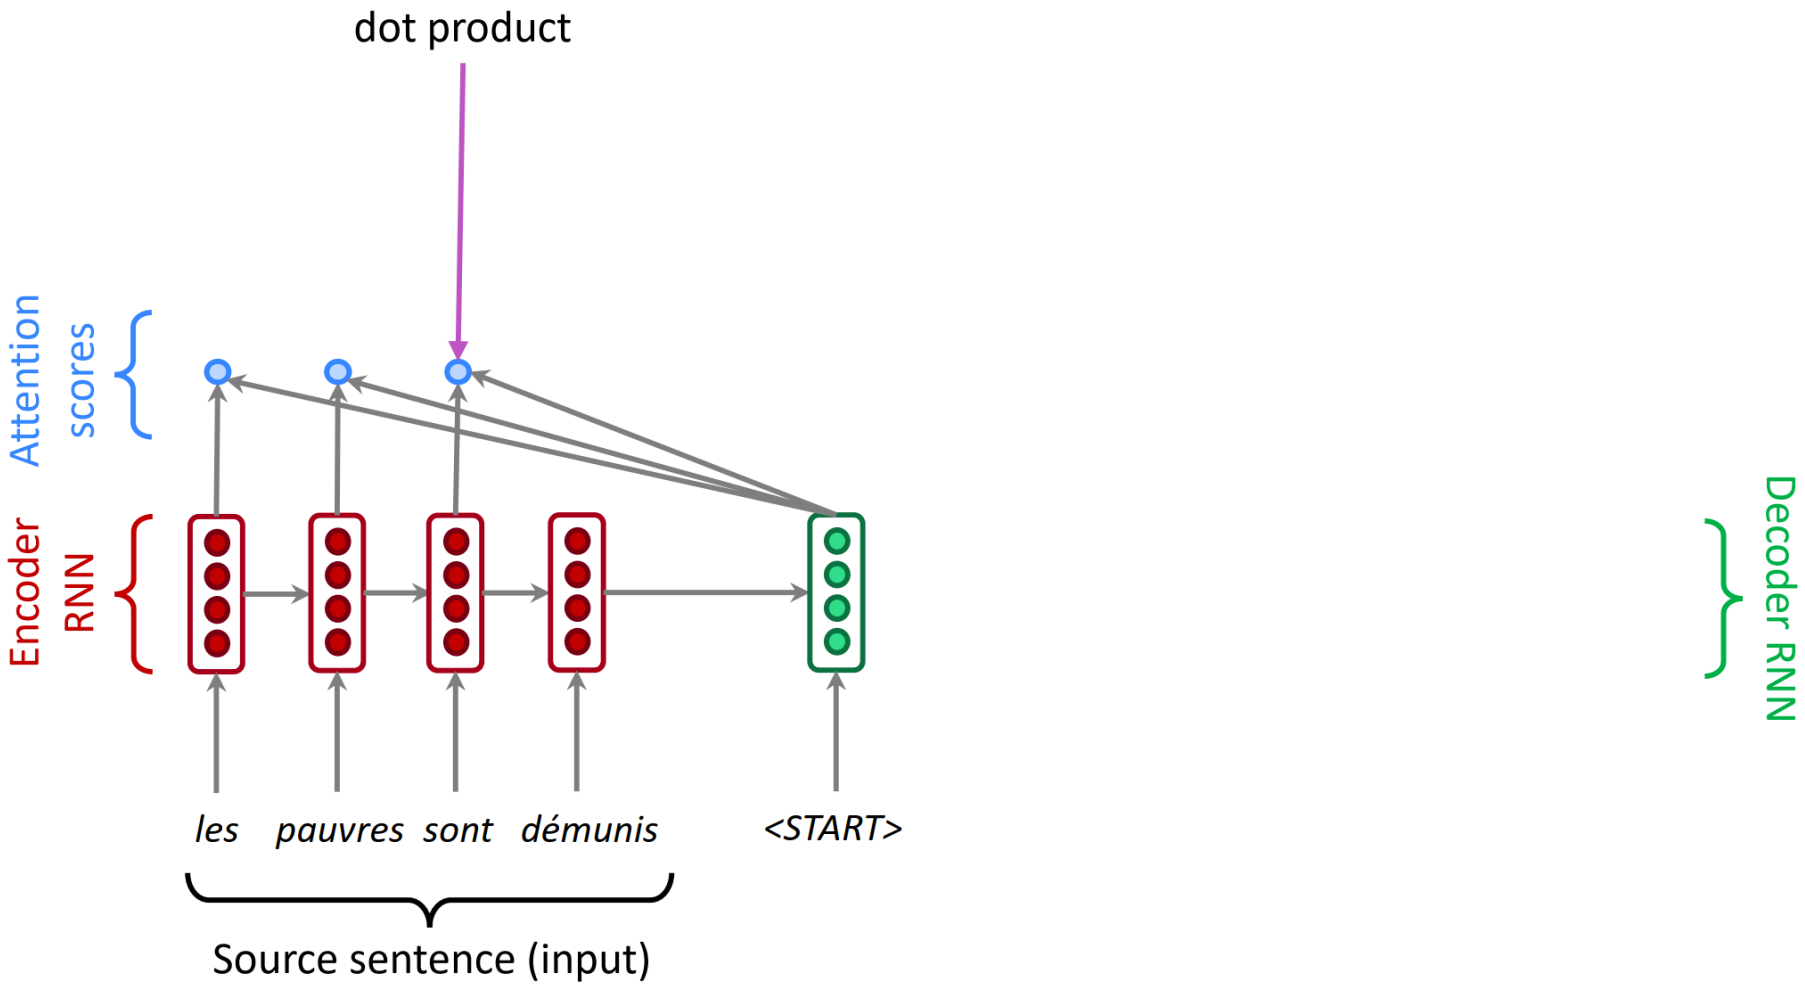

Seq2seq with attention

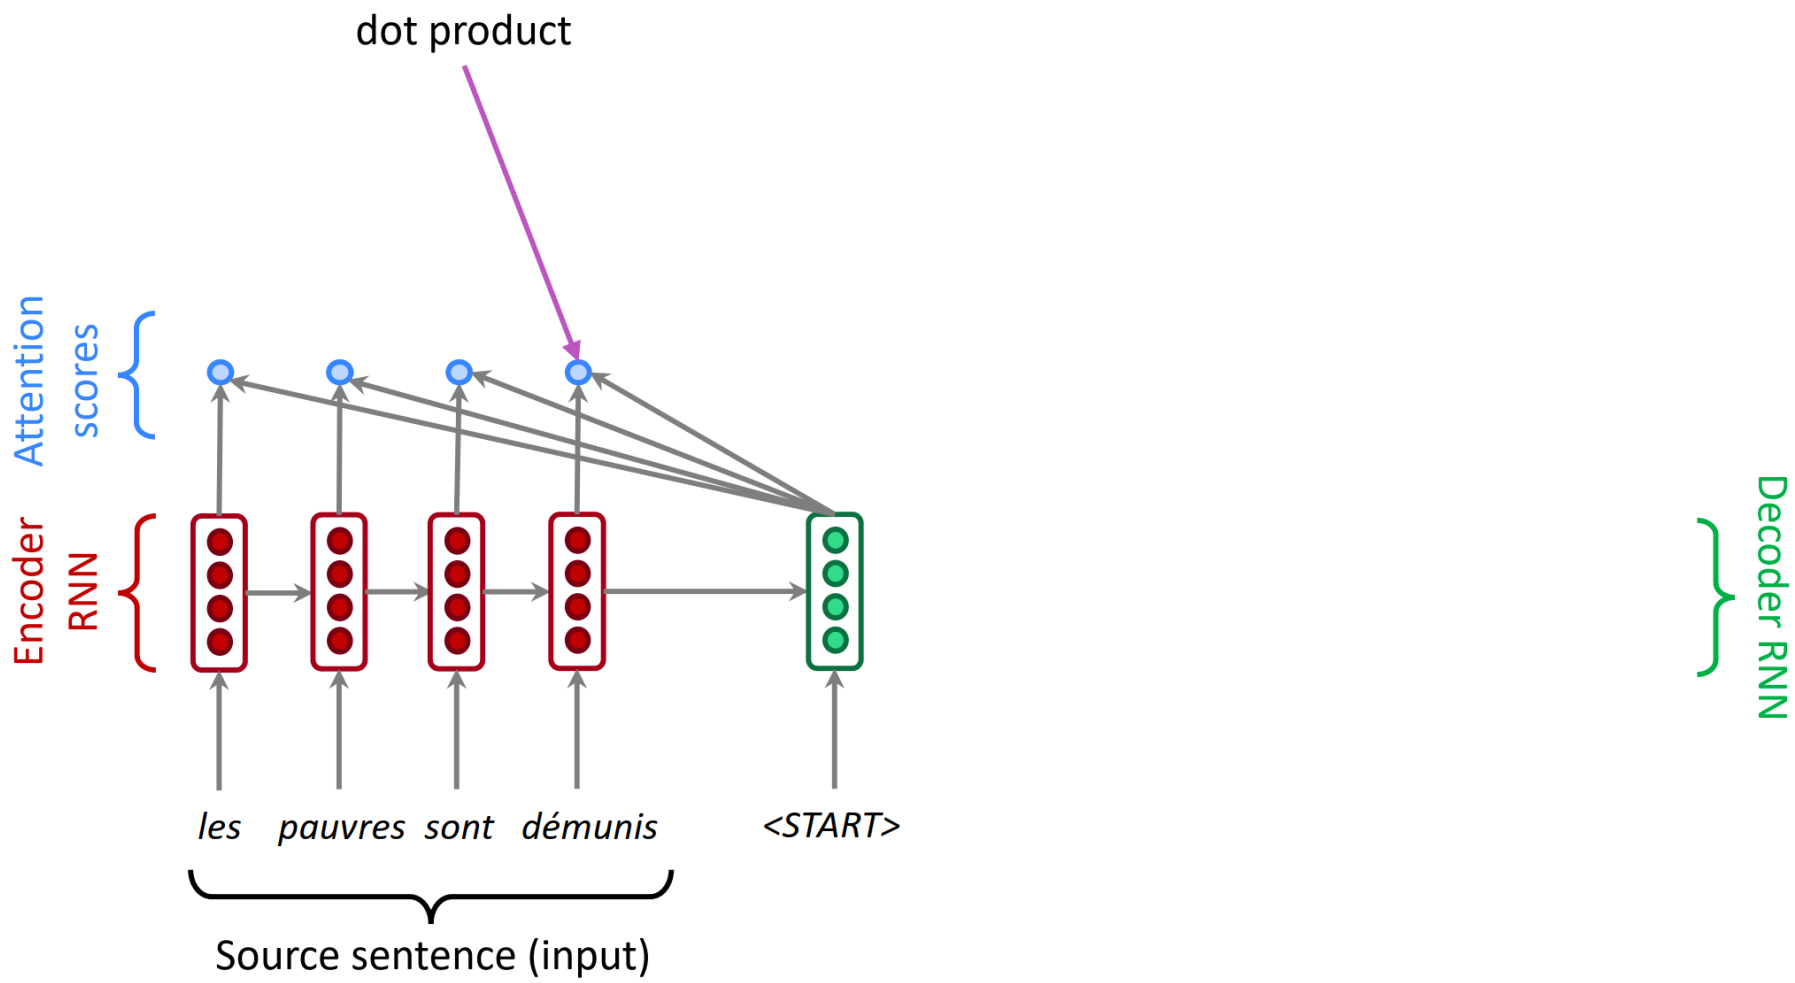

Seq2seq with attention

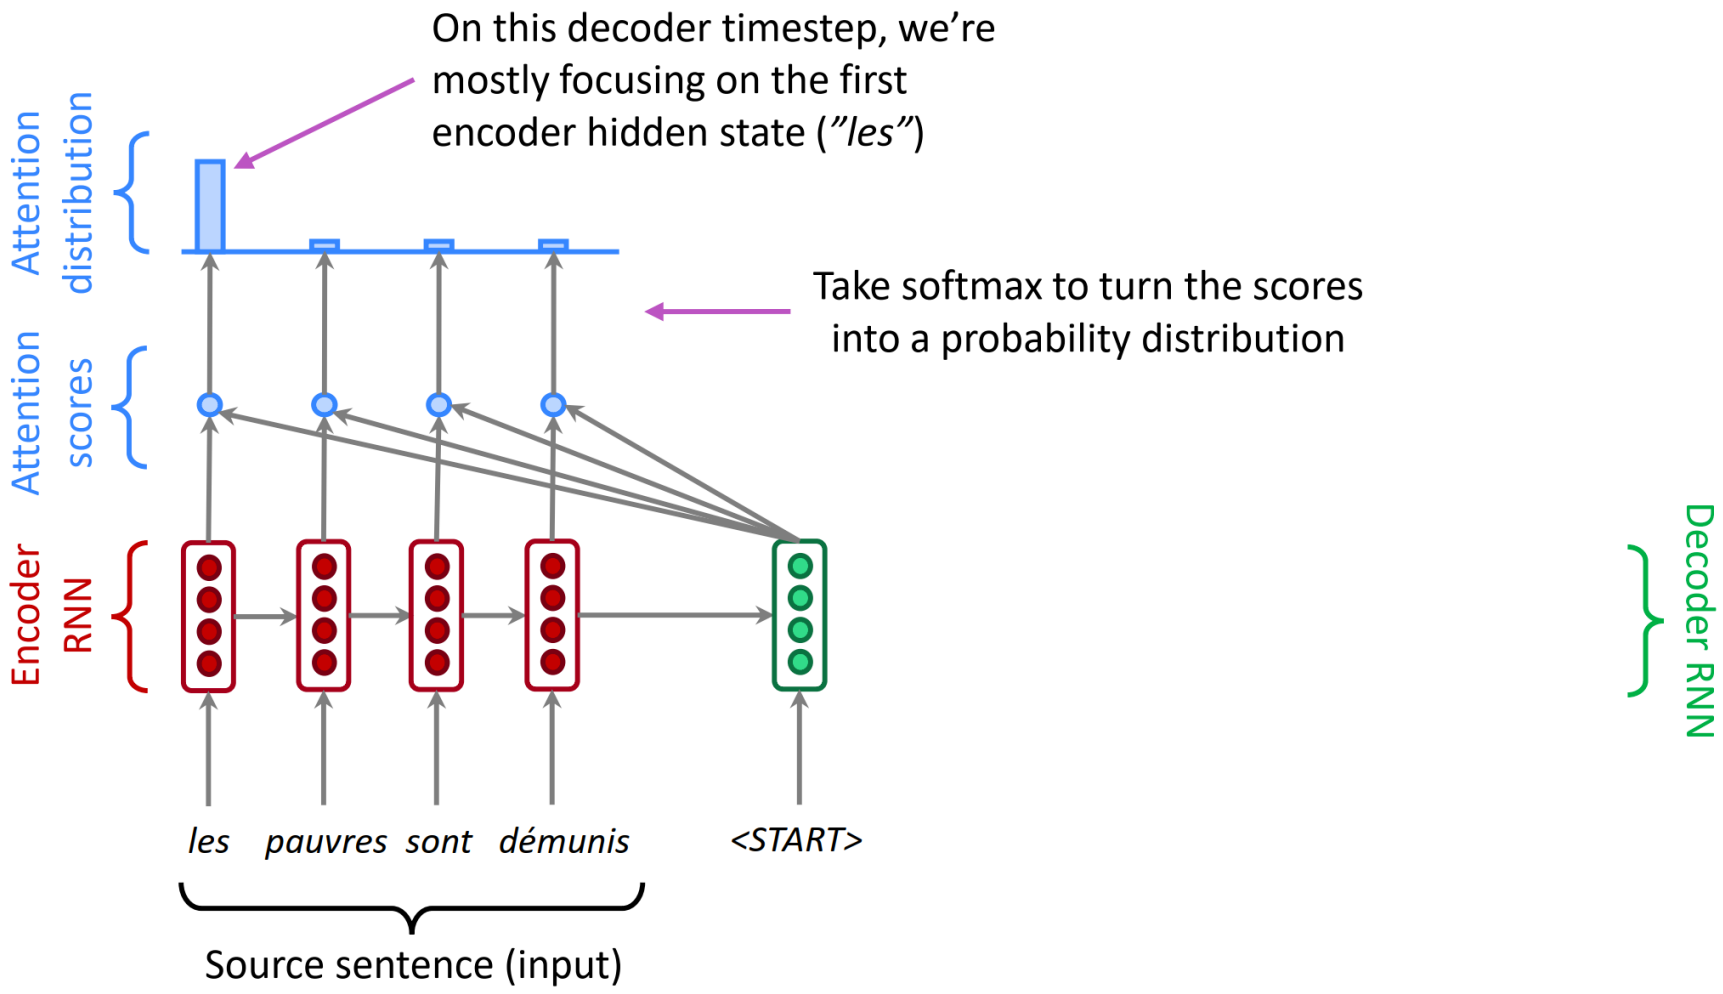

Seq2seq with attention

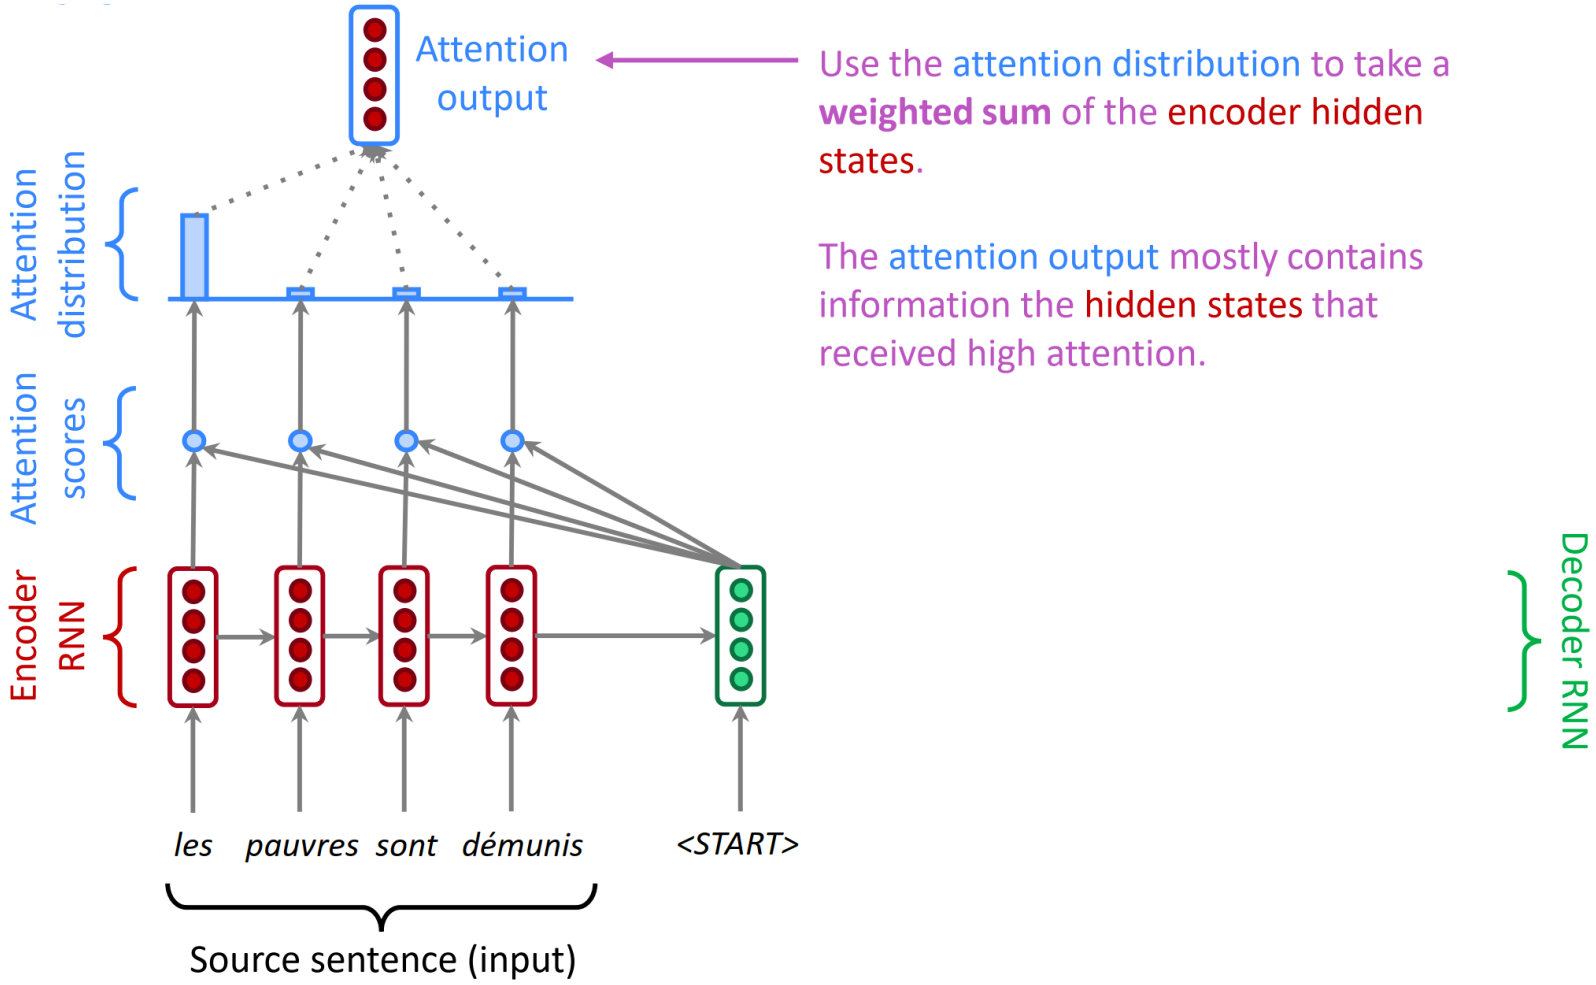

Use the attention distribution to take a **weighted sum** of the encoder hidden states.

The attention output mostly contains information the hidden states that received high attention.

Seq2seq with attention

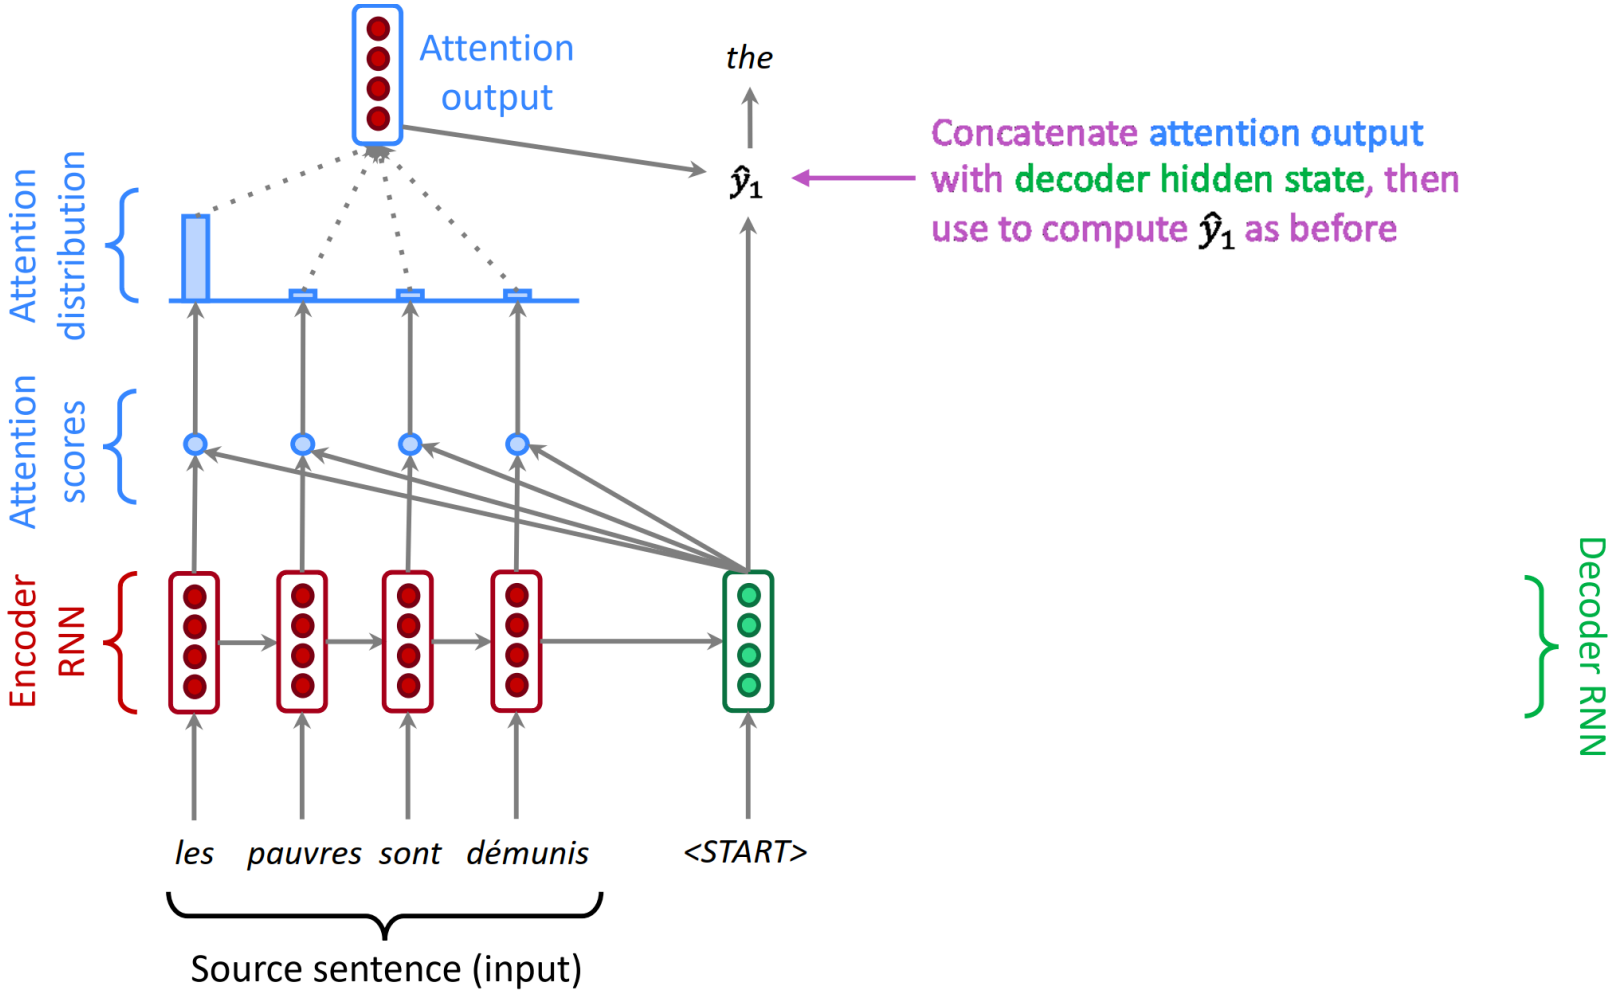

Seq2seq with attention

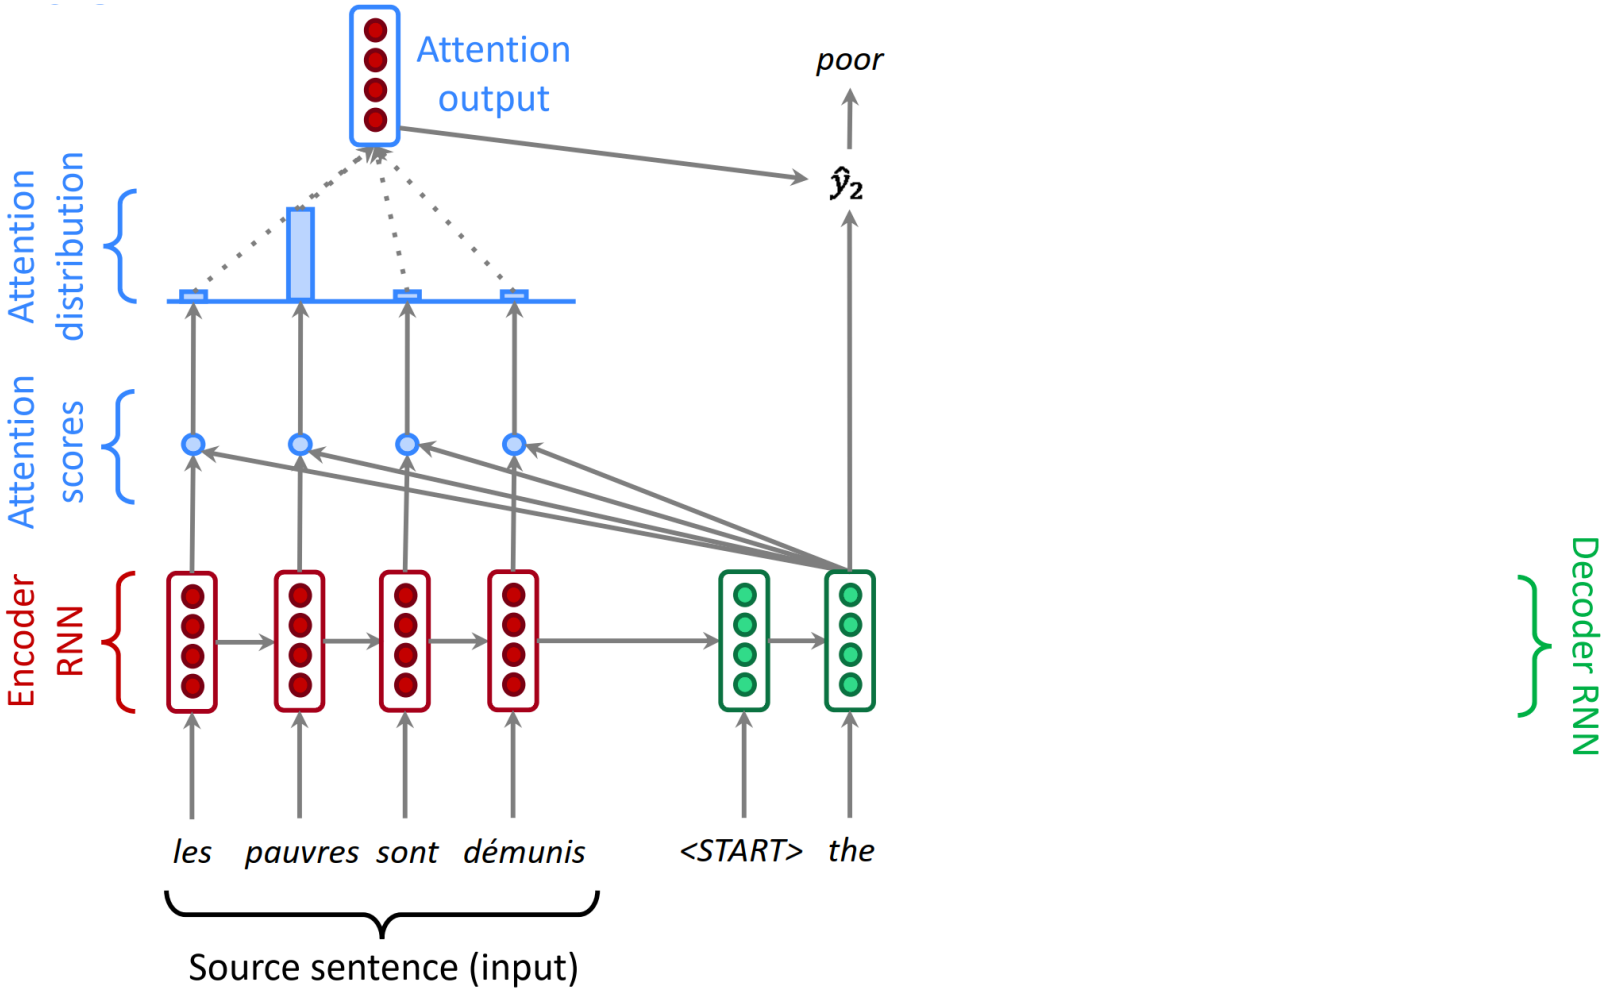

Seq2seq with attention

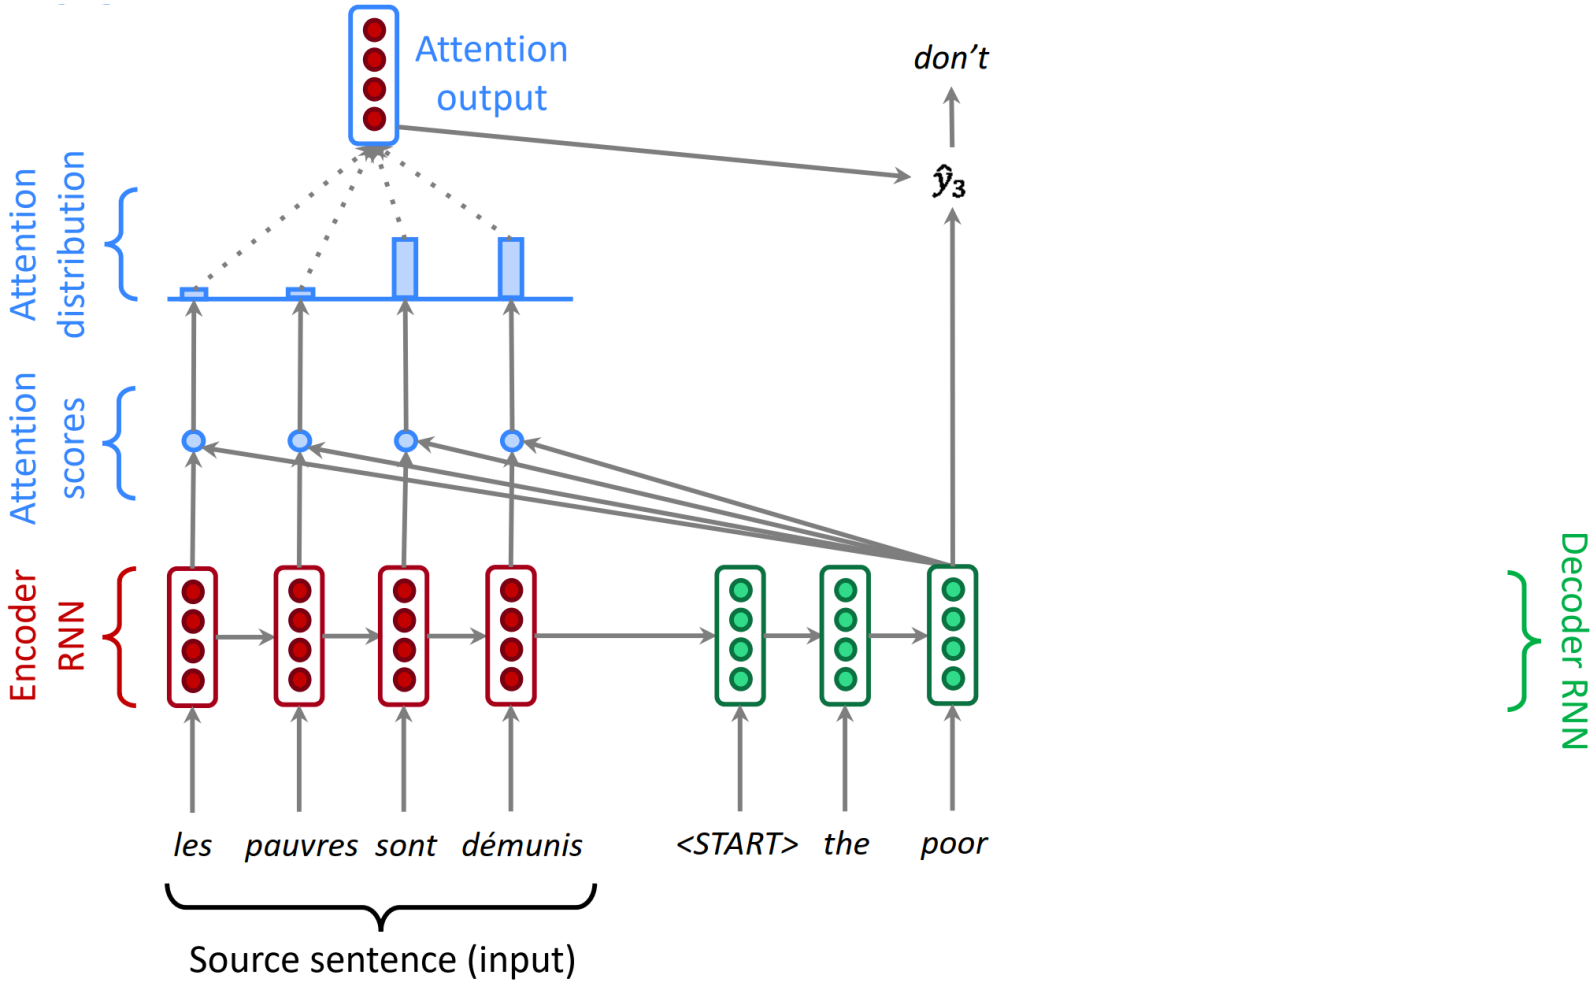

Seq2seq with attention

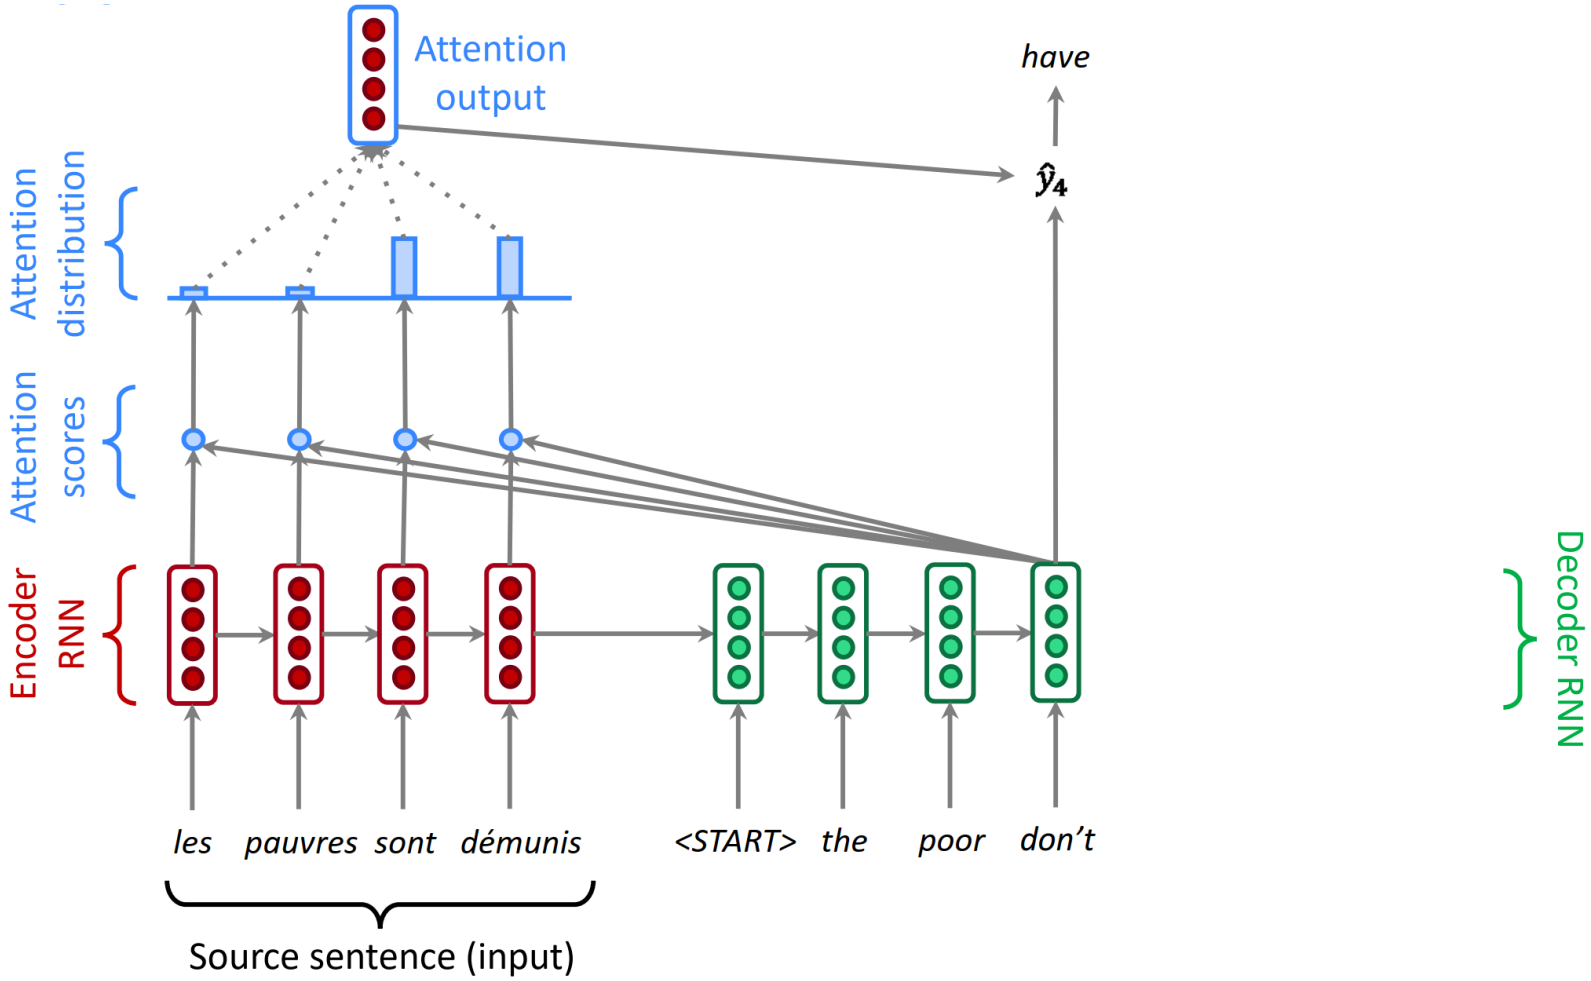

Seq2seq with attention

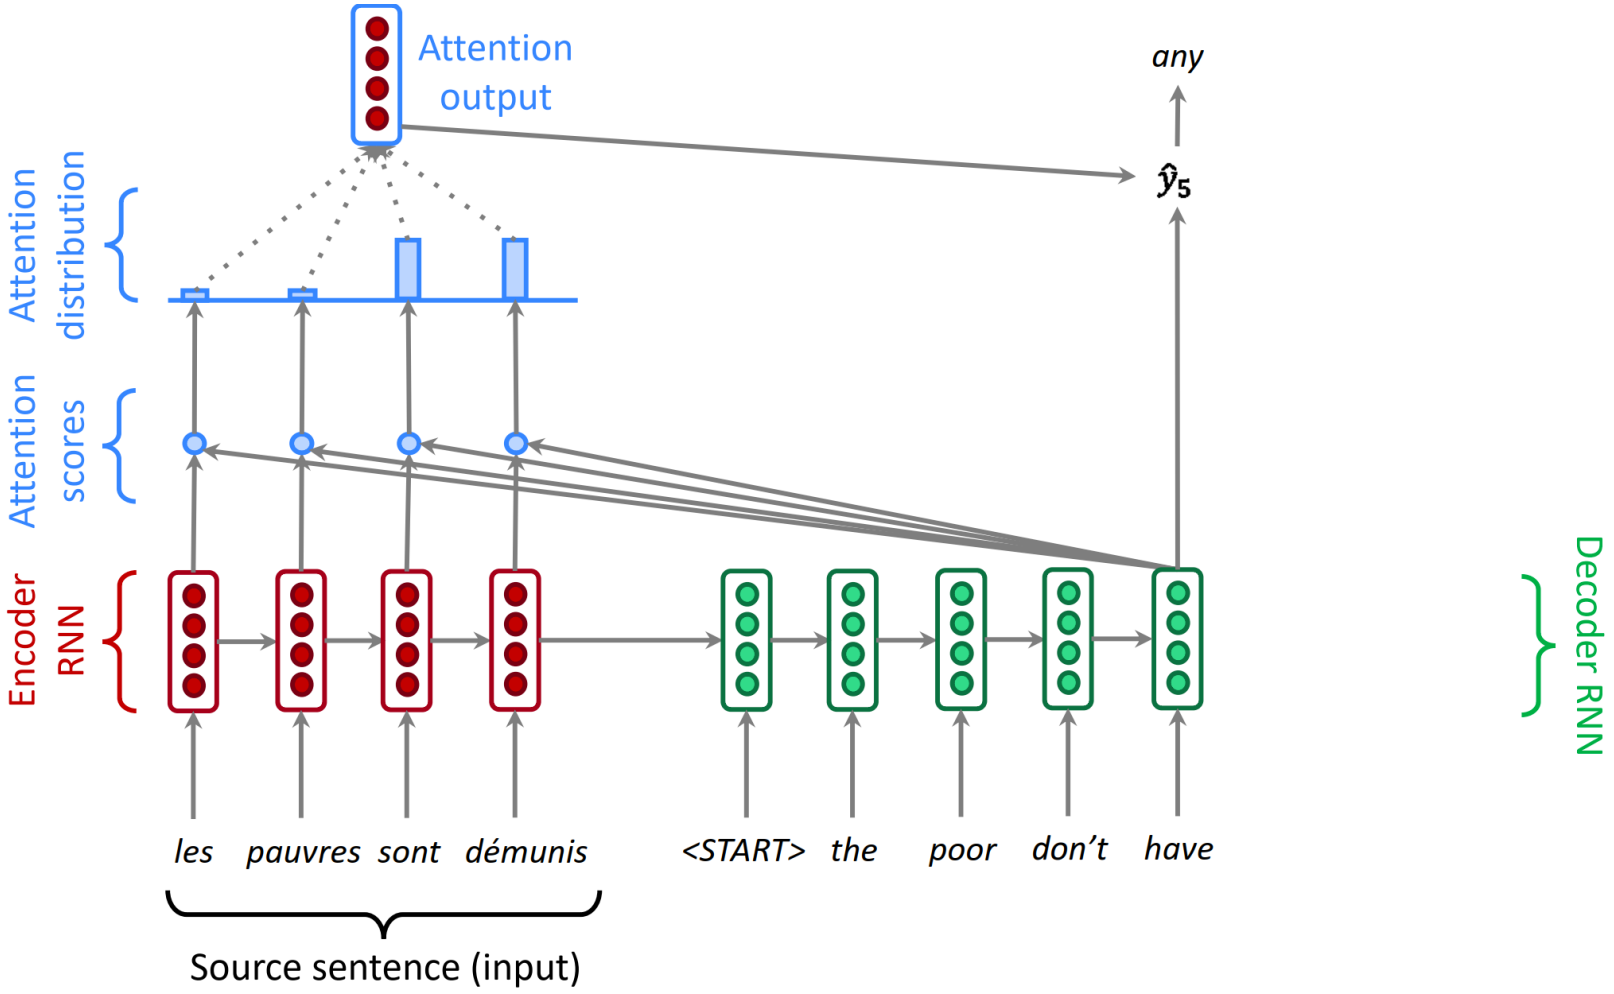

Seq2seq with attention

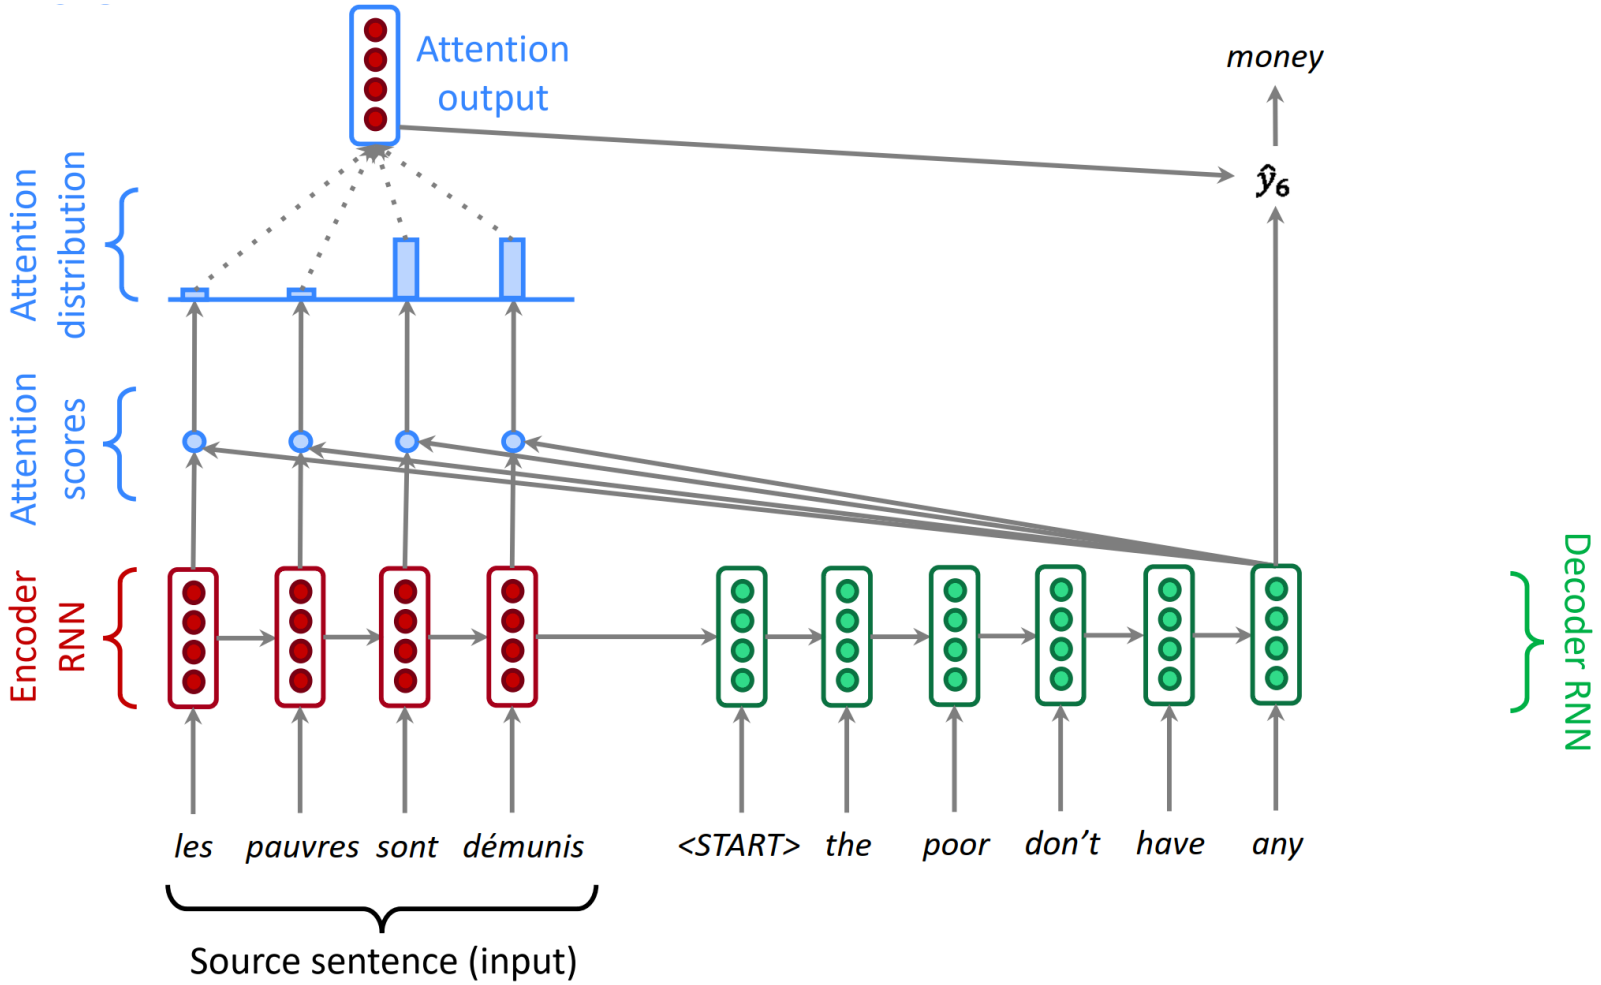

NMT by jointly learn to align and translate

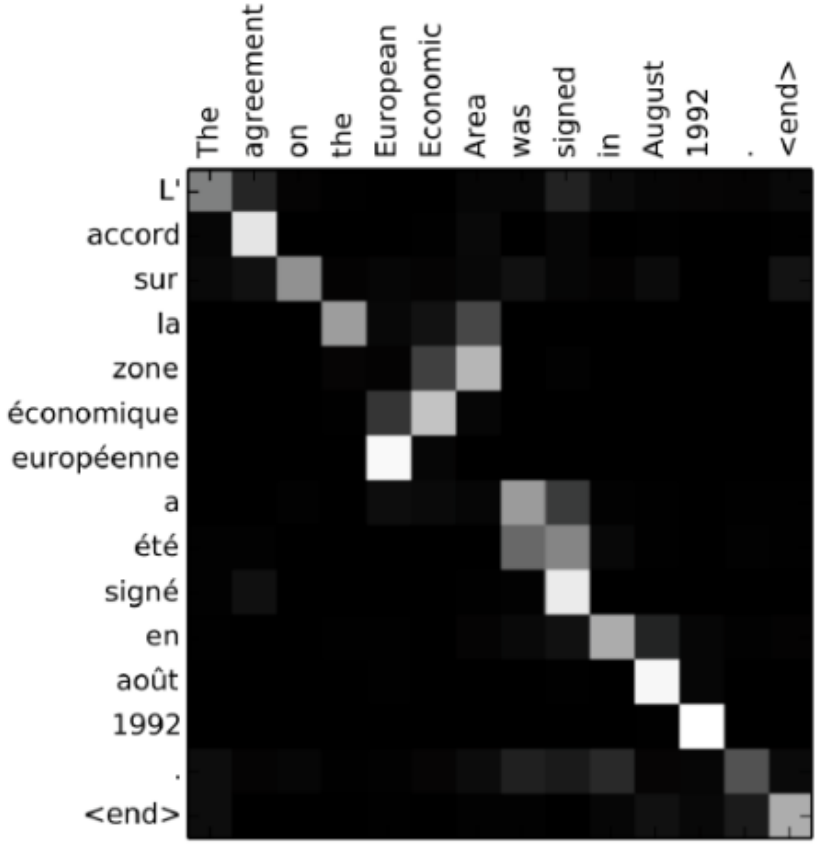

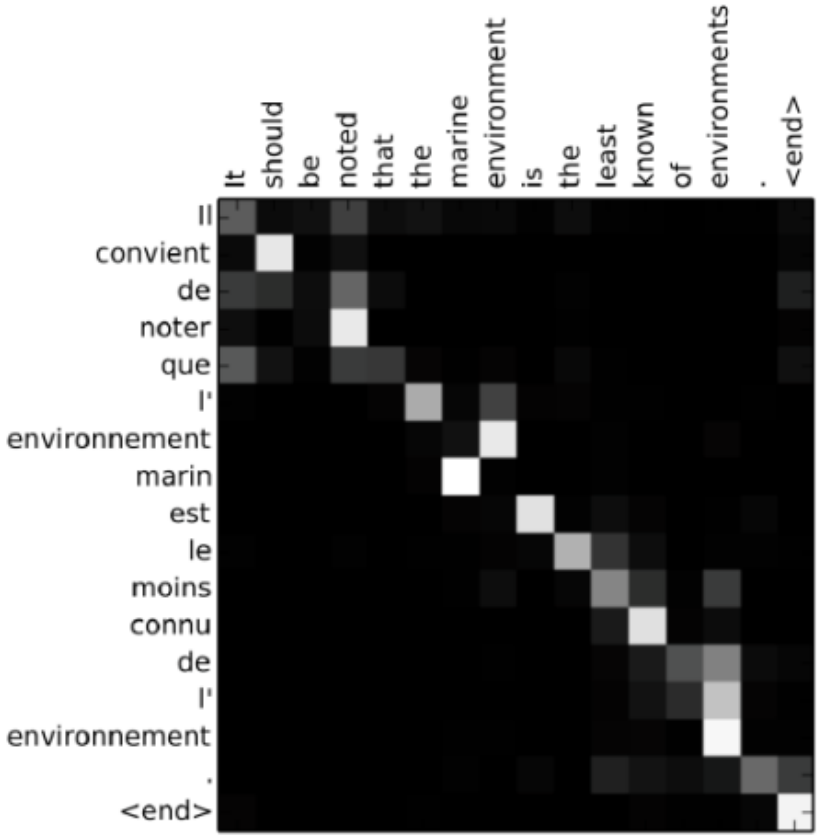

Source: Bahdanau et al., ICLR 2015, https://arxiv.org/abs/1409.0473

NMT by jointly learn to align and translate

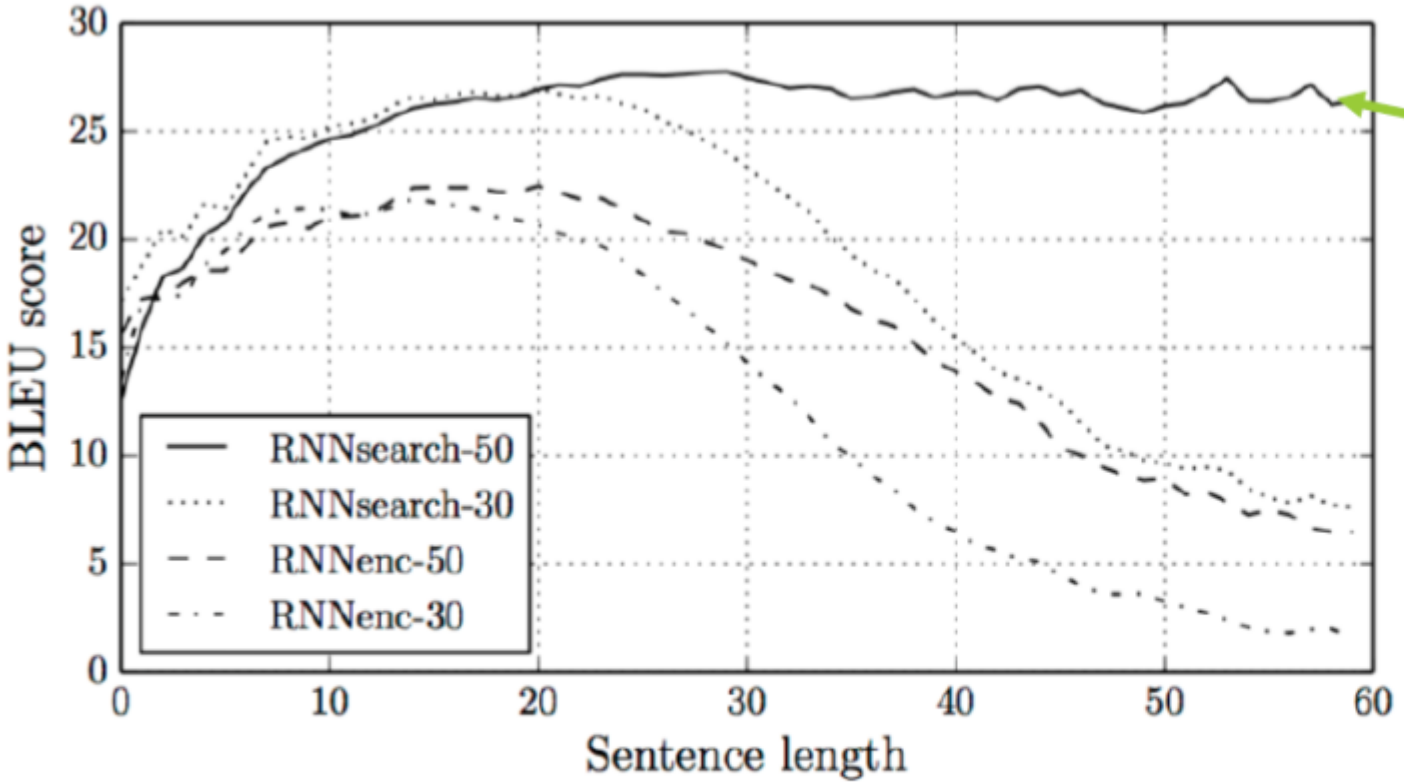

No performance drop for long sentences!

Source: Bahdanau et al., ICLR 2015, https://arxiv.org/abs/1409.0473

Attention: công thức

- Cho các trạng thái ẩn của bộ mã hóa encoder (**values**) $h_1, \dots, h_N \in R^h$
- Ở bước t, trạng thái ẩn của bộ giải mã decoder (**query**) là $s_t \in R^h$
- Tính điểm chú ý e^t tại bước này:

$$e^t = [s_t^T h_1, \dots, s_t^T h_N] \in R^N$$

There are multiple ways to compute attention scores

- Dùng softmax lấy phân phối chú ý α^t tại bước này (đây là phân bố xác suất và có tổng bằng 1)

$$\alpha^t = softmax(e^t) \in R^N$$

- Tính đầu ra attention a_t (tổng có trọng số):

$$a_t = \sum_{i=1}^{N} \alpha_i^t h_i \in R^h$$

- Nối đầu ra: $[a_t; s_t] \in R^{2h}$

Các hàm tính điểm Attention

- q là truy vấn (query); k là khóa (key)
- Multi-layer Perceptron (Bahdanau et al. 2015): Linh hoạt, tốt với dữ liệu lớn.

$$a(q,k) = w_2^T tanh(W_1[q;k])$$

- Bilinear (Luong et al. 2015)

$$a(q,k) = q^T W k$$

- Dot Product (Luong et al. 2015)

$$a(q,k) = q^T k$$

Ưu điểm của Attention

- Cải thiện đáng kể hiệu suất của NMT (giúp bộ giải mã tập trung vào đúng phần cần thiết).
- Mang lại mô hình giống con người hơn (nhìn lại câu nguồn khi dịch thay vì phải nhớ toàn bộ).
- Giải quyết vấn đề nút thắt cổ chai và giảm thiểu vanishing gradient.
- Cung cấp khả năng diễn giải: Có thể xem bộ giải mã đang tập trung vào đâu để lấy ma trận căn chỉnh (alignment).

Các cột mốc phát triển

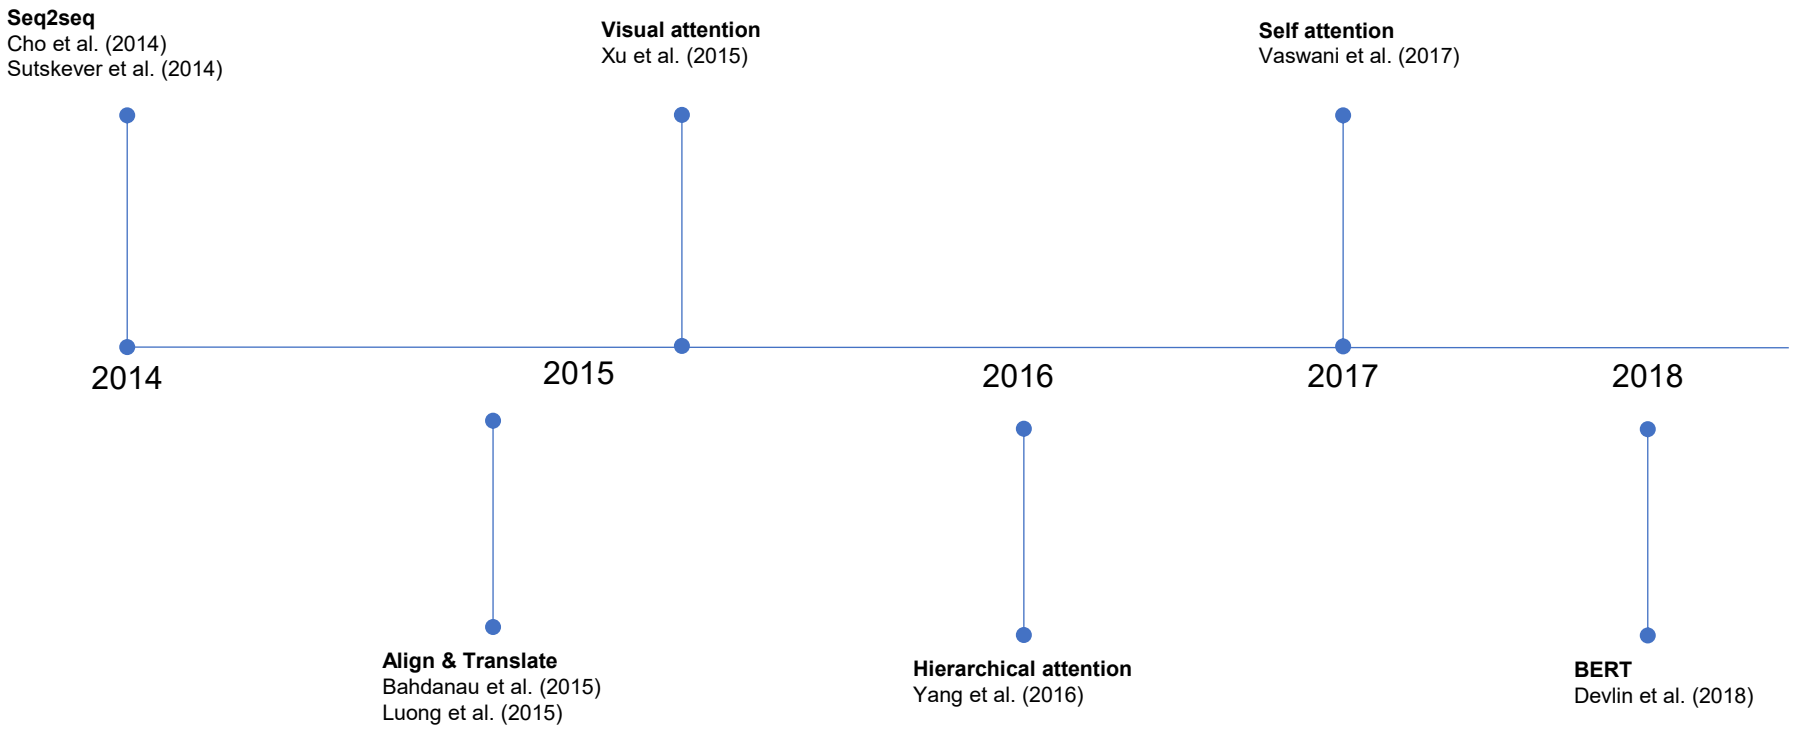

Attention là một kỹ thuật DL tổng quát

- Attention giúp cải thiện đáng kể mô hình seq2seq trong Dịch máy. Ngoài ra, còn có thể được áp dụng trong nhiều kiến trúc khác nhau (không chỉ seq2seq) và cho nhiều tác vụ khác nhau.
- Định nghĩa tổng quát về Attention:
  - Cho một tập hợp các vector giá trị (values) và một vector truy vấn (query).
  - Attention là kỹ thuật tính toán một tổng có trọng số (weighted sum) của các values dựa trên sự tương quan với query.
  - Ví dụ: Trong mô hình seq2seq + attention, mỗi trạng thái ẩn của bộ giải mã (query) sẽ "chú ý" đến toàn bộ các trạng thái ẩn của bộ mã hóa (values).

Attention là một kỹ thuật DL tổng quát

Bản chất và ý nghĩa:

- Tóm tắt có chọn lọc: Tổng có trọng số đóng vai trò là một bản tóm tắt thông tin từ các values, trong đó query đóng vai trò quyết định thông tin nào cần được tập trung vào.
- Biểu diễn kích thước cố định: Attention là phương pháp để thu được một biểu diễn có kích thước cố định từ một tập hợp các biểu diễn có kích thước bất kỳ (values), phụ thuộc vào một biểu diễn khác (query).

Bài toán MT đã được giải quyết?

Dù đã có những bước tiến lớn, nhiều thách thức vẫn còn tồn tại:

- Từ ngoài từ điển (OOV): Các từ mới hoặc từ hiếm không có trong tập huấn luyện.
- Sự khác biệt về miền (domain mismatch): Dữ liệu huấn luyện và dữ liệu thực tế không tương đồng về ngữ cảnh/chuyên môn.
- Duy trì ngữ cảnh: Khó khăn trong việc giữ được tính nhất quán khi xử lý các văn bản dài.
- Cặp ngôn ngữ ít dữ liệu (low-resource): Dễ dẫn đến hiện tượng "ảo giác" (hallucinations) – máy tự tạo ra nội dung nghe có vẻ hợp lý nhưng sai sự thật.

Tính linh hoạt của Seq2Seq

Mô hình Seq2Seq không chỉ hữu ích trong Dịch máy mà còn là nền tảng cho nhiều tác vụ NLP khác:

- Tóm tắt văn bản (Văn bản dài → Văn bản rút gọn)
- Hệ thống hội thoại (Câu hội thoại trước → Câu phản hồi tiếp theo)
- Phân tích cú pháp (Văn bản đầu vào → Chuỗi cấu trúc cú pháp)
- Sinh mã nguồn (Ngôn ngữ tự nhiên → Mã Python/C++)
- Nhận dạng chữ viết (OCR) (Hình ảnh ký tự → Chuỗi văn bản)
- Nhận dạng giọng nói (ASR) (Chuỗi tín hiệu âm thanh → Chuỗi văn bản)

Decoding strategies

Tốt hơn greedy decoding?

- Giải mã tham lam (Greedy decoding): Không thể hoàn tác các quyết định sai lầm trong quá khứ

  les pauvres sont démunis (the poor don’t have any money)

  → the ____

  → the poor ____

  → the poor are ____

- Giải pháp tốt hơn: **Beam Search** – Khám phá nhiều giả thuyết cùng lúc và chọn giải pháp tốt nhất.

Beam search với k=2

Giữ lại k=2 từ với xác suất cao nhất

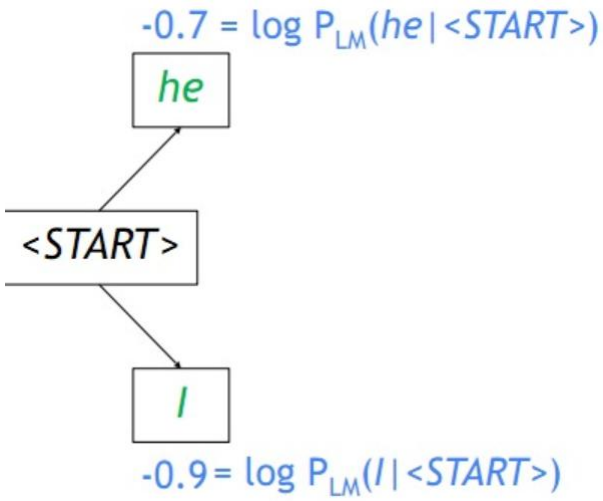

Beam search với k=2

Với mỗi giả thuyết, tìm k giả thuyết có khả năng xảy ra cao nhất tiếp theo.

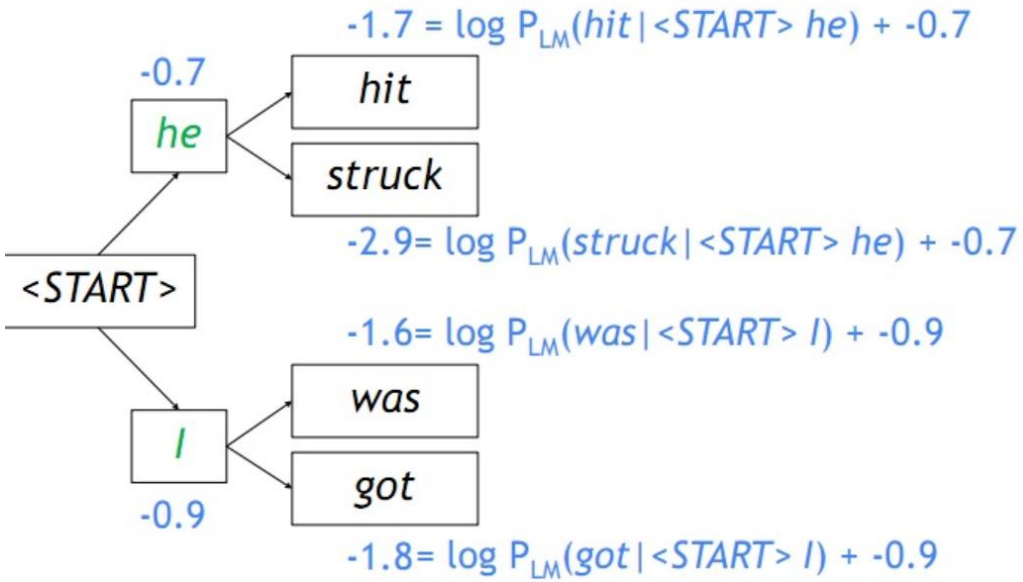

Beam search với k=2

Trong k^2 giả thuyết mới, giữ lại k giả thuyết có khả năng xảy ra cao nhất tiếp theo.

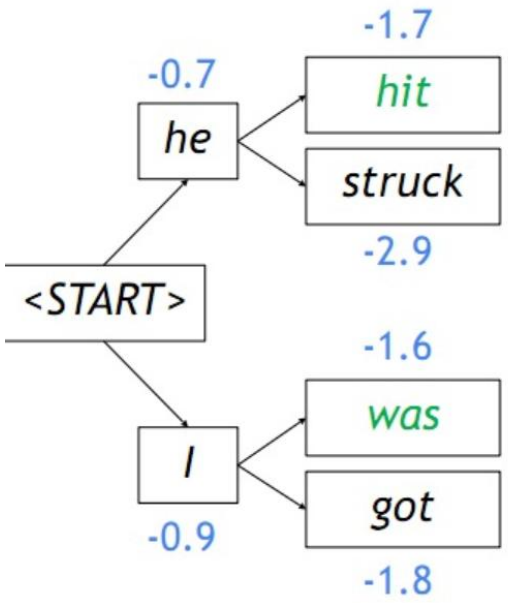

Beam search với k=2

Với mỗi giả thuyết tiếp tục tìm kiếm k giả thuyết có khả năng xảy ra cao nhất tiếp theo.

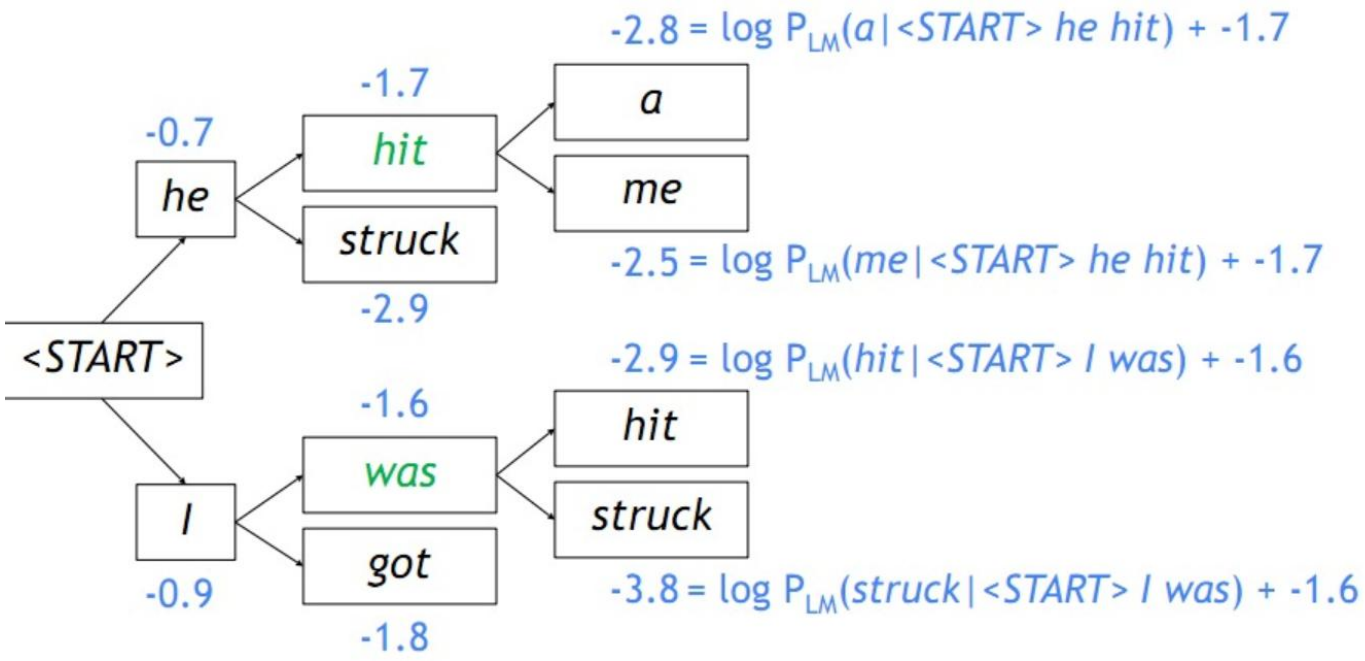

Beam search với k=2

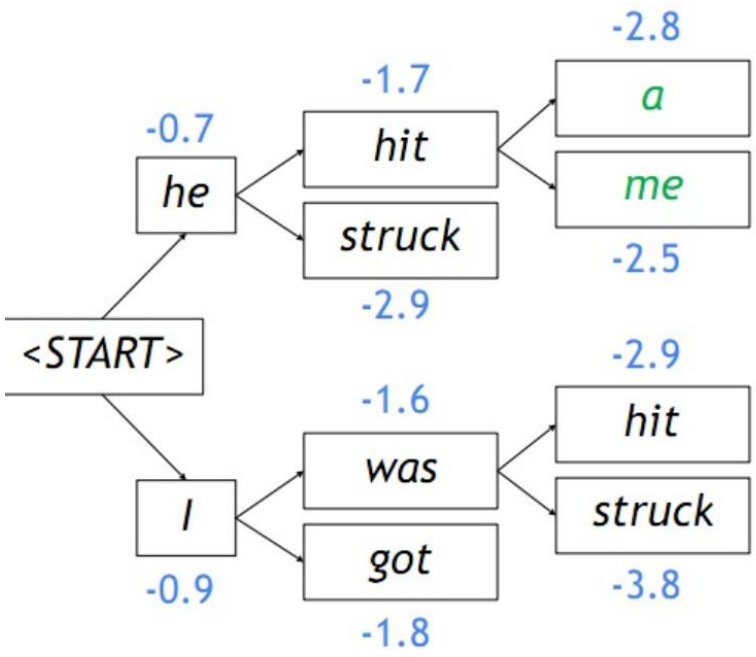

Beam search với k=2

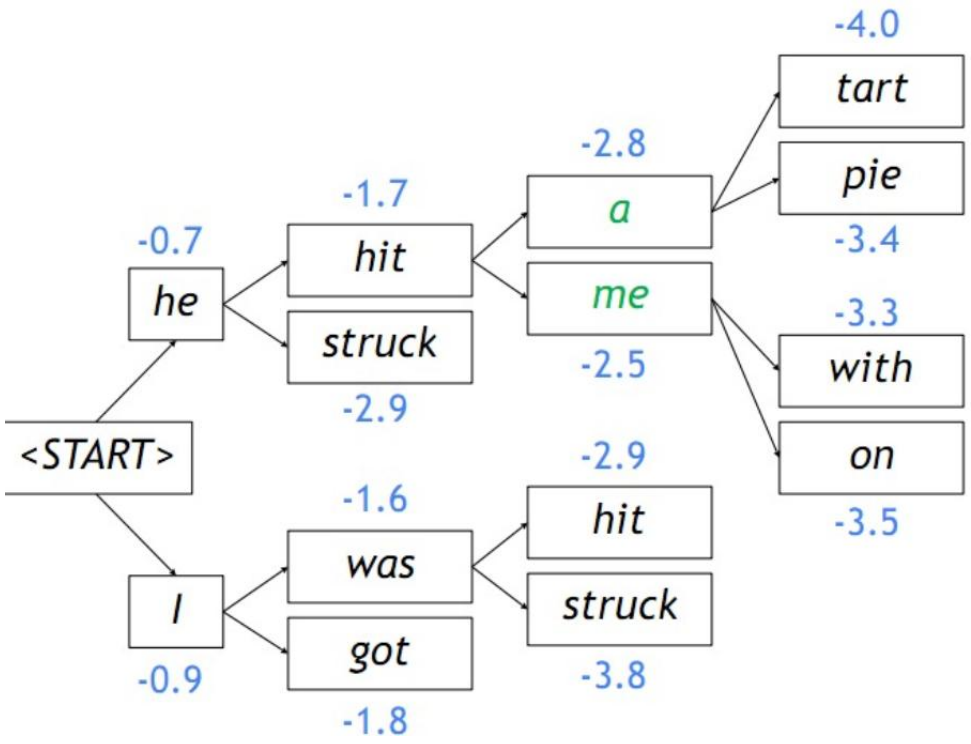

Beam search với k=2

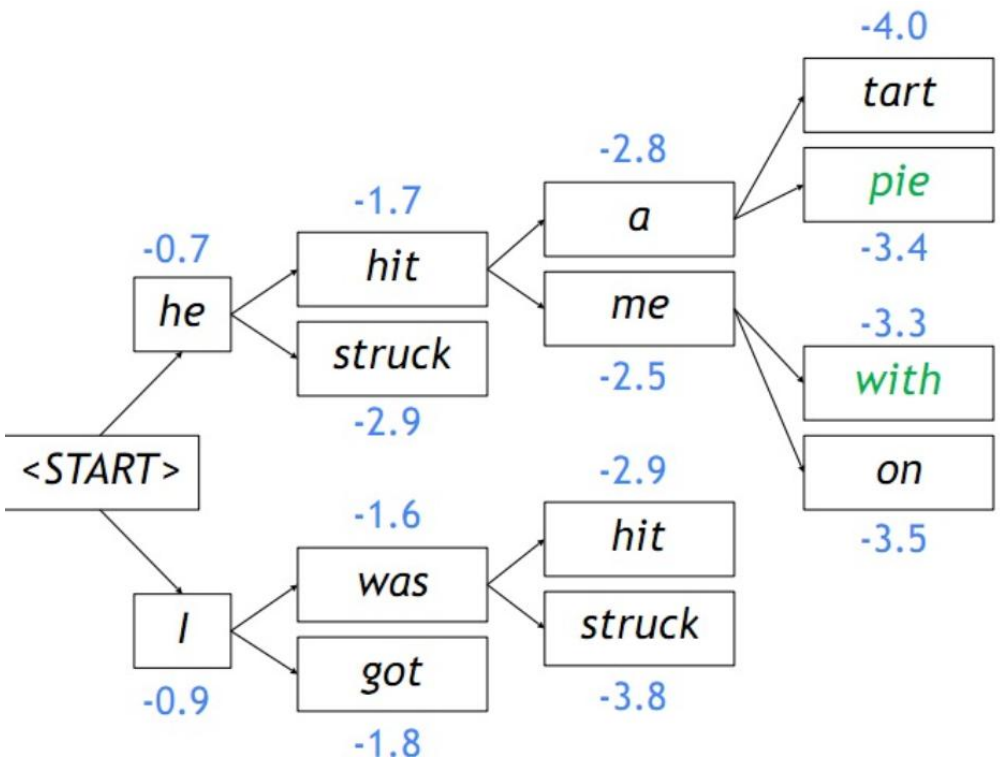

Beam search với k=2

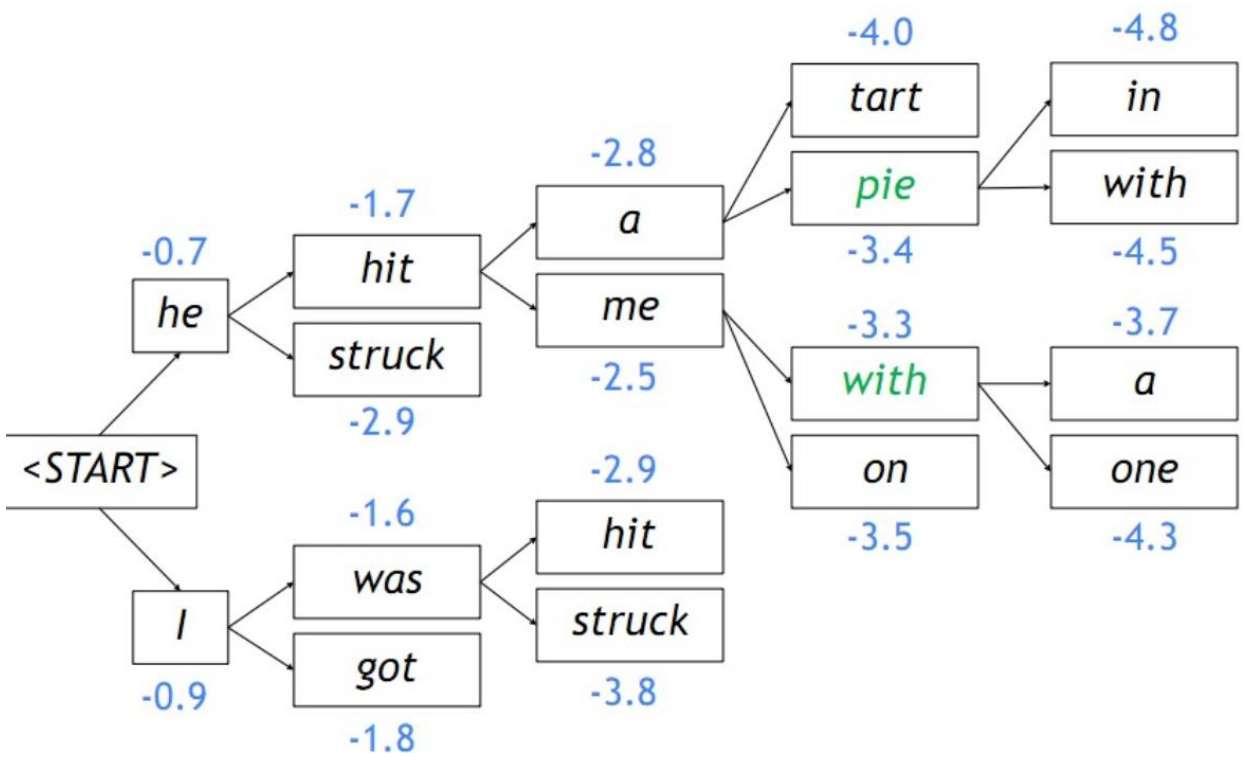

Beam search với k=2

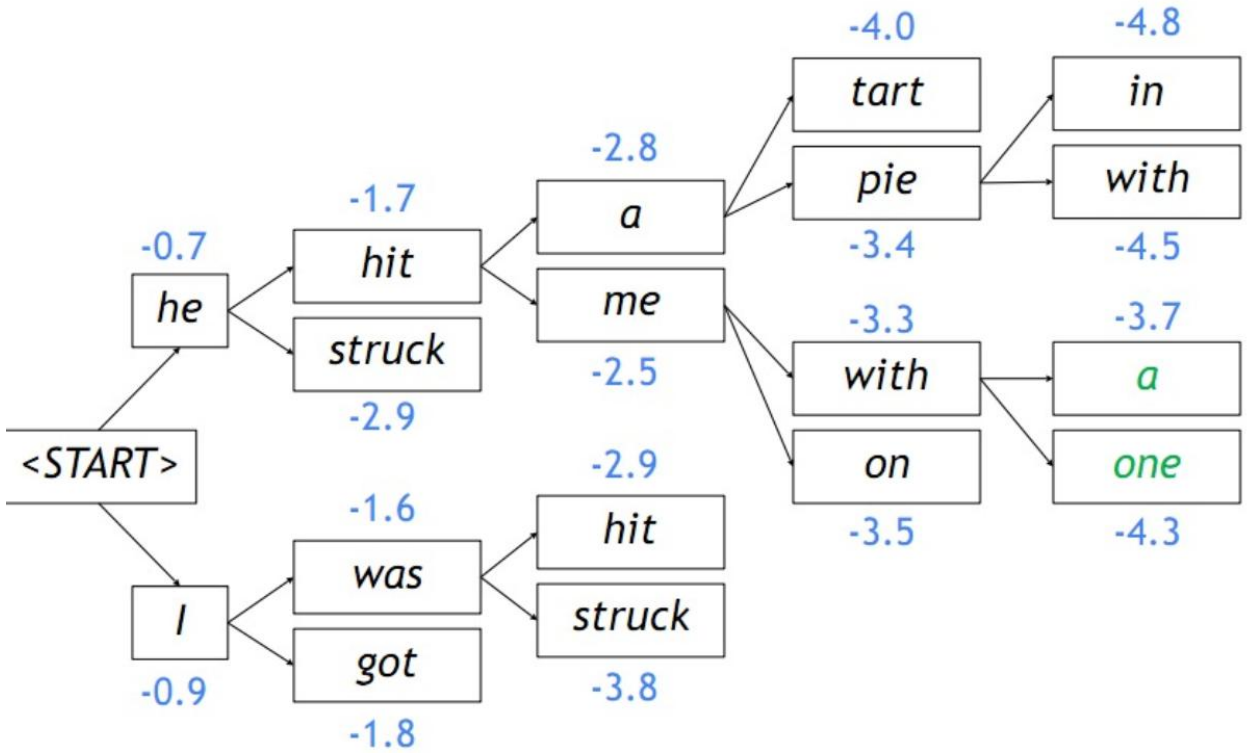

Beam search với k=2

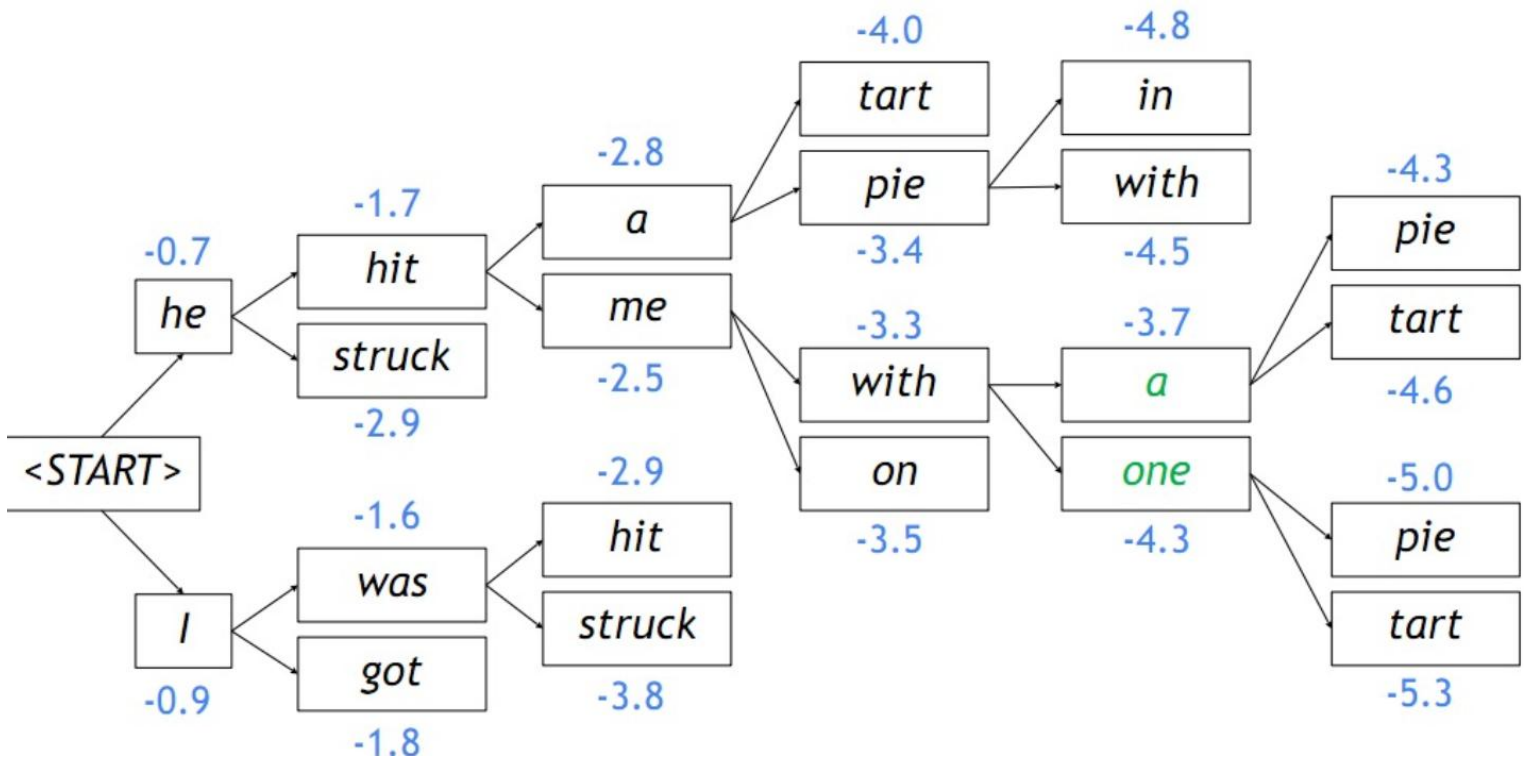

Beam search với k=2

Giữ lại chuỗi có xác suất lớn nhất.

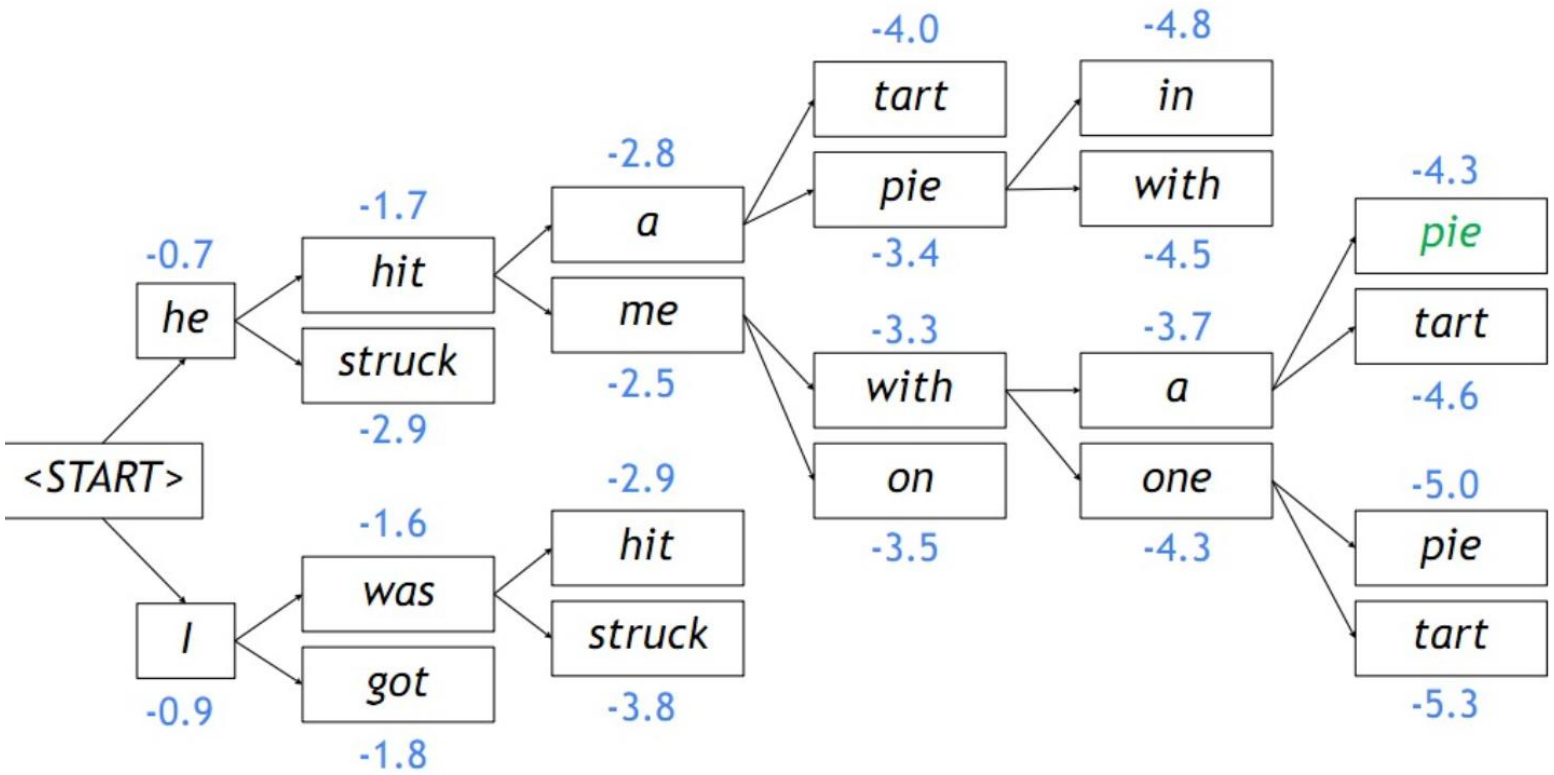

Beam search: tiêu chí dừng

Trong greedy decoding, chúng ta sẽ giải mã cho đến khi gặp <END>

- Ví dụ : <START> he hit me with a pie <END>

Trong beam search decoding, các giả thuyết khác nhau có thể dẫn đến <END> tokens ở các bước khác nhau.

- Khi giả thuyết sinh ra <END>, thì giả thuyết đó hoàn thành.
- Đặt nó sang một bên và tiếp tục tìm kiếm giả thuyết khác sử dụng beam search.

Quá trình dừng lại khi:

- Đạt đến giới hạn thời gian T, hoặc
- Khi đã hoàn thành đủ k giả thuyết.

Chiến lược lấy mẫu (Sampling)

Lấy mẫu ngẫu nhiên (Random Sampling): Chọn từ tiếp theo dựa theo phân phối xác suất có điều kiện: $w_t \sim P(w|w_{1:t-1})$

Nhiệt độ (Temperature): Hạ nhiệt độ (T → 0) làm phân phối xác suất $P(w_t|w_{1:t-1})$ trở nên sắc nét hơn (chênh lệch lớn hơn).

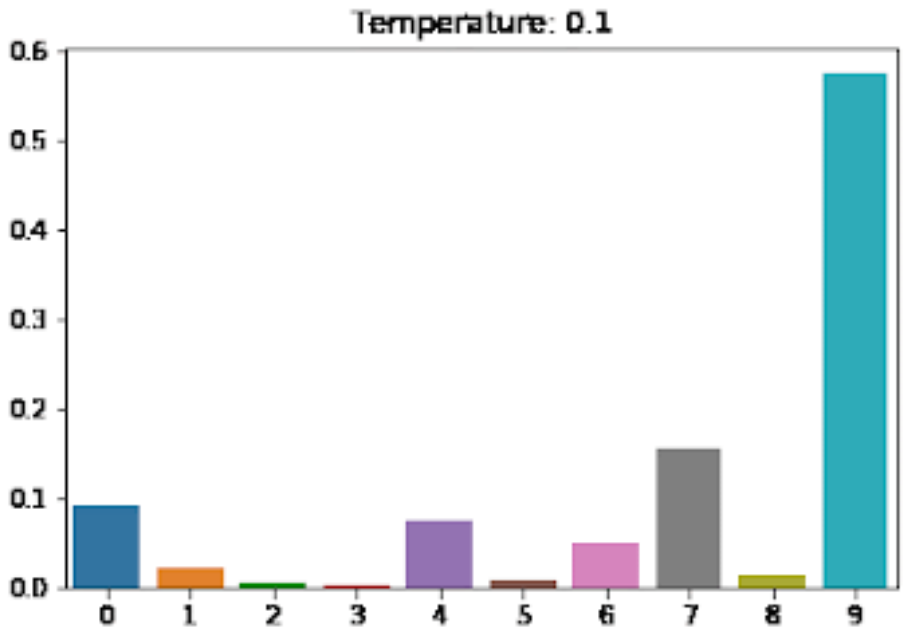

Top-k sampling

Lọc ra K từ có khả năng xuất hiện cao nhất và phân phối lại khối lượng xác suất giữa chúng

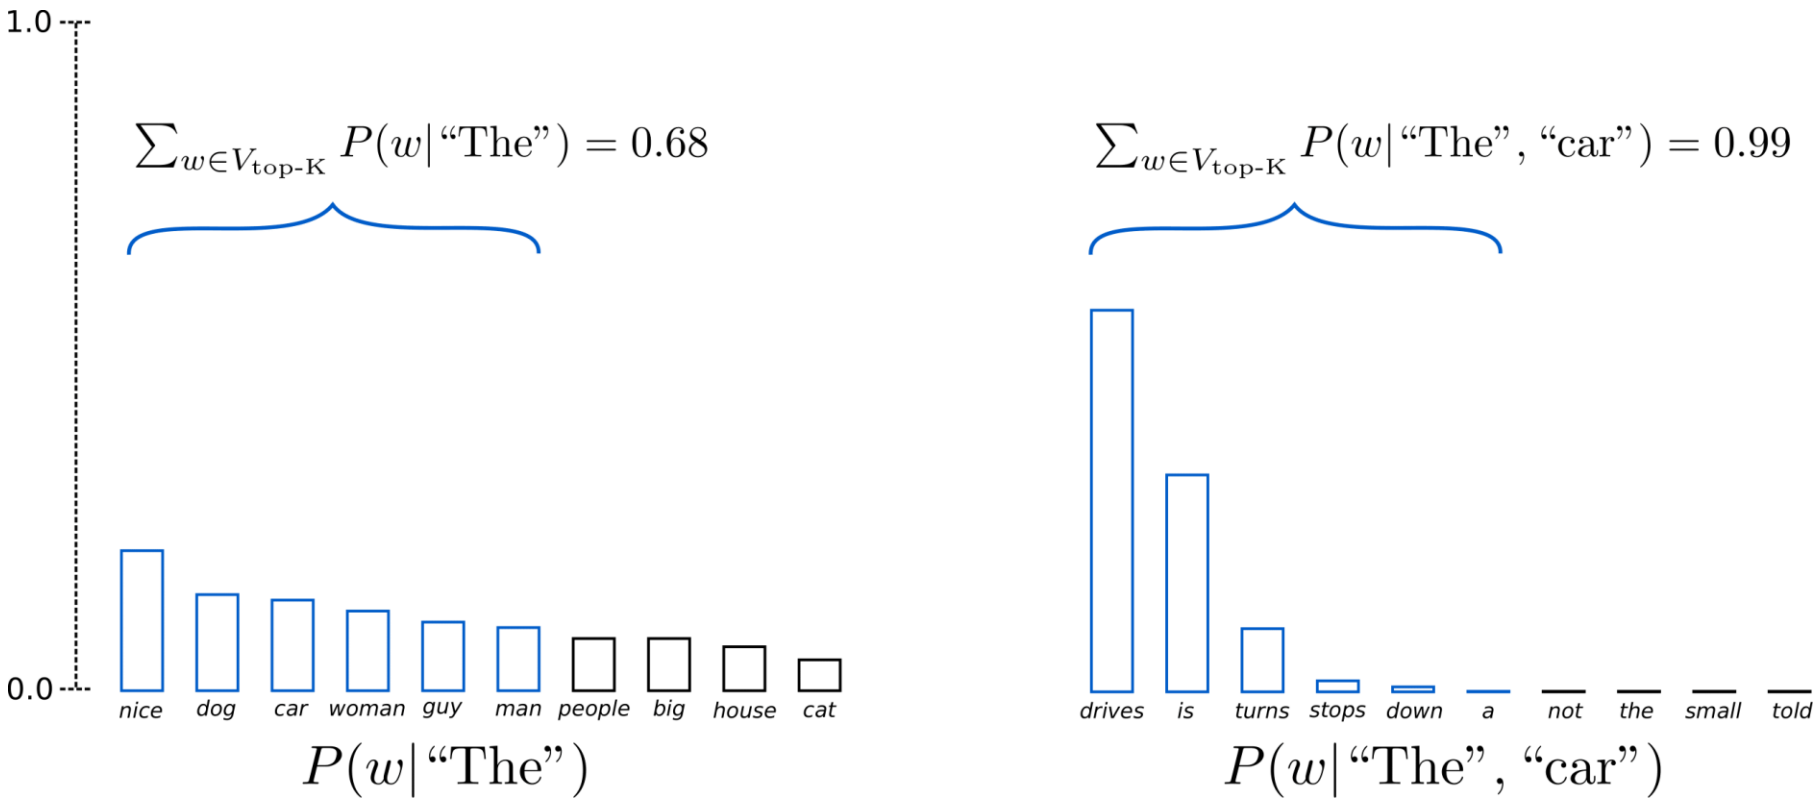

Top-p sampling
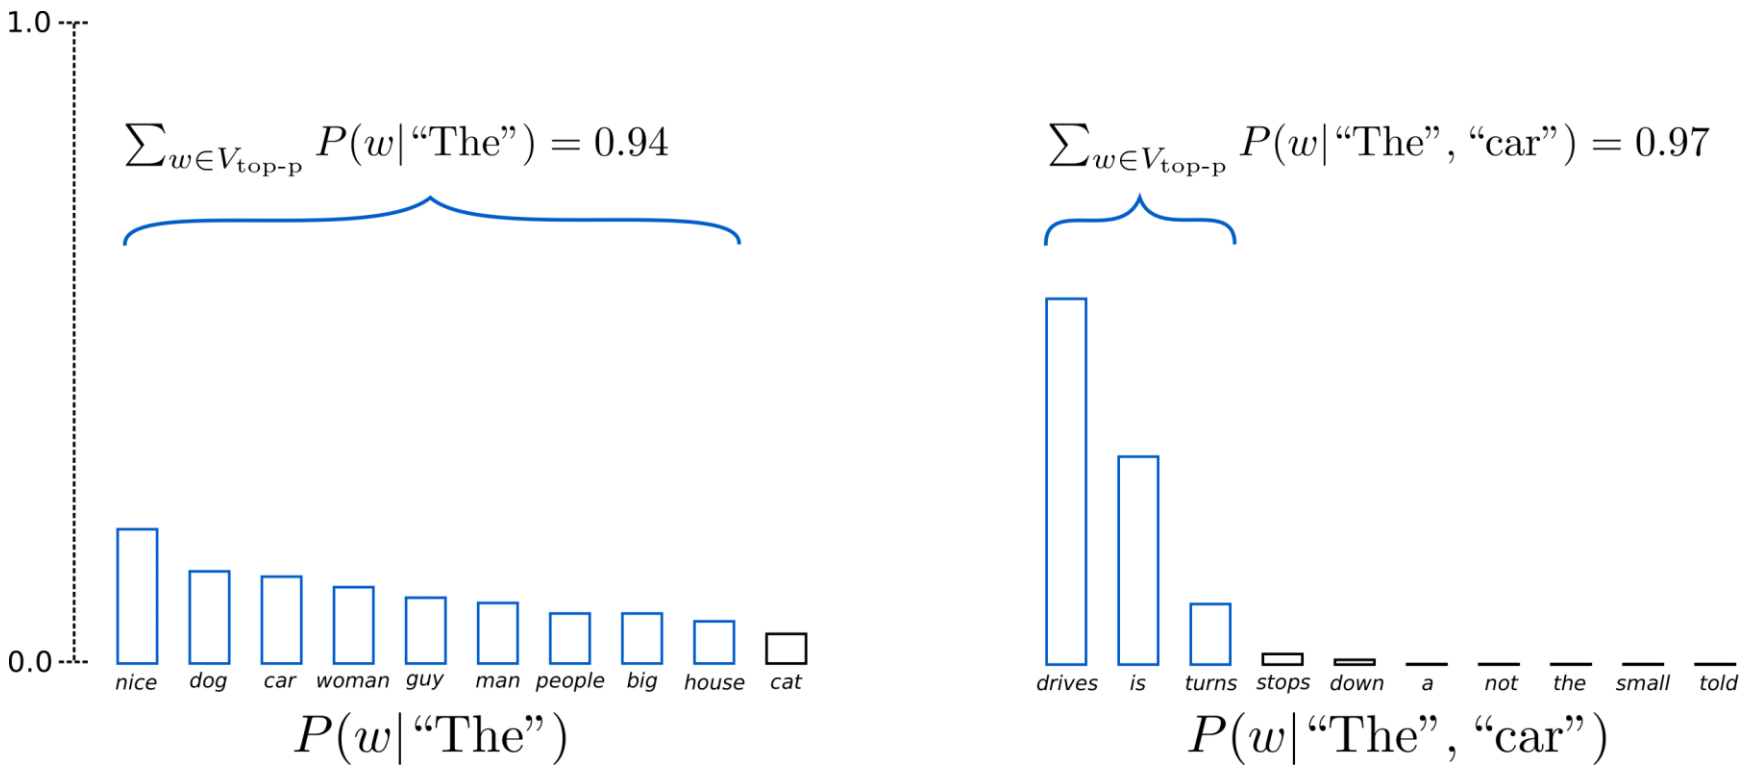
Chọn từ tập hợp nhỏ nhất các từ mà tổng xác suất tích lũy của chúng vượt quá giá trị p