Học viện
Công nghệ Bưu chính Viễn thông

KHOA TRÍ TUỆ NHÂN TẠO
Faculty of Artificial Intelligence

Bài 7: Ngữ nghĩa từ vựng

Giảng viên: ThS. Võ Ngọc Bích Uyên

Nội dung

- Ngữ nghĩa từ vựng (Lexical Semantics)
- Ràng buộc về lựa chọn (Selectional Restrictions)
- Khai thác tri thức với WordNet
- Phân giải nhập nhằng từ (Word Sense Disambiguation - WSD)
- Học máy với ngữ nghĩa
- WSD trong tìm kiếm thông tin

Ngữ nghĩa từ vựng (Lexical Sentiment)

- Ngữ nghĩa nghiên cứu ý nghĩa của các phát biểu dạng ngôn ngữ
- Nghĩa từ vựng (Lexical semantics) nghiên cứu:
  - quan hệ từ vựng: sự liên hệ về mặt ngữ nghĩa giữa các từ
  - ràng buộc về lựa chọn: cấu trúc liên hệ ngữ nghĩa bên trong của từng từ
  - bao gồm lý thuyết về:
    - phân loại và phân rã nghĩa của từ
    - sự giống và khác trong cấu trúc từ vựng – ngữ nghĩa giữa các ngôn ngữ
    - quan hệ nghĩa của từ với cú pháp và ngữ nghĩa của câu.

Các ứng dụng

- Tóm tắt văn bản
- Phân loại văn bản
- Phân tích quan điểm
- Quảng cáo hướng ngữ cảnh
- Đối sánh văn bản
- Máy tìm kiếm
- Hệ thống hội thoại (dialogue system)
- Hệ thống hỏi đáp (question answering)
- ...

Nghĩa của từ (Word Senses)

- Nghĩa của từ (Word Sense): đại diện cho một khía cạnh riêng biệt trong tổng thể ý nghĩa của một từ.
- Một từ có thể có nhiều ý nghĩa khác nhau tùy thuộc vào ngữ cảnh được sử dụng trong câu. Ví dụ:
    - We went to see a **play** at the theater (vở kịch)
    - The children went out to **play** in the park (chơi đùa).

Từ đồng âm (Homonymy)

- **Từ đồng âm (Homonymy):** là những từ trùng nhau về hình thức ngữ âm nhưng khác nhau về nghĩa
  - Từ đồng âm, đồng tự (Homograph): các từ với cùng cách viết nhưng có nghĩa khác nhau. Ví dụ:
    - dove - dive into water, white bird
    - saw
  - Từ đồng âm, không đồng tự (Homophone): các từ có cách viết khác nhau nhưng có cùng âm. Ví dụ: see, sea; meat, meet

Phân loại từ đồng âm tiếng Việt

- Đồng âm từ với từ, gồm:
  - Đồng âm từ vựng: Tất cả các từ đều thuộc cùng một từ loại. Ví dụ:
    - đường1 (đắp đường) - đường2 (đường phèn).
    - đường kính1 (đường để ăn) - đường kính2 (…của đường tròn).
    - cất1 (cất vó) - cất2 (cất tiền vào tủ) - cất3 (cất hàng) - cất4 (cất rượu)
  - Đồng âm từ vựng-ngữ pháp: Các từ trong nhóm đồng âm với nhau chỉ khác nhau về từ loại. Ví dụ:
    - chỉ1 (cuộn chỉ) - chỉ2 (chỉ tay năm ngón) - chỉ3 (chỉ còn có dăm đồng).
    - câu1 (nói vài câu) - câu2 (rau câu) - câu3 (chim câu) - câu4 (câu cá).
- Đồng âm từ với tiếng: các đơn vị khác nhau về cấp độ; kích thước ngữ âm của chúng đều không vượt quá một tiếng. Ví dụ:
  - Con trai Văn Cốc lên dốc bắn cò, đứng lăm le cười khanh khách.
    Con gái Bát *Tràng bán* hàng *thịt* ếch ngồi châu chẫu nói ương ương

Từ đa nghĩa (Polysemy), đồng nghĩa (Synonymy)

- Từ đa nghĩa (Polysemy): một từ nhiều nghĩa, biểu thị những đặc điểm, thuộc tính khác nhau của một đối tượng, hoặc biểu thị những đối tượng khác nhau của thực tại. Ví dụ:
    - đi : việc dịch chuyển bằng hai chi dưới
    - đi: một người nào đó đã chết
- Đồng nghĩa (Synonymy): là những từ tương đồng với nhau về nghĩa, khác nhau về âm thanh. Ví dụ:
    - cố, gắng
    - car, automobile

Từ trái nghĩa (Antonymy) & Quan hệ bao hàm

- Từ trái nghĩa (Antonymy): Nghĩa đối lập nhau xét trên một đặc điểm. Thể hiện sự đối lập nhị phân hoặc hai đầu của thang đo. Ví dụ:
    - dark/light, hot/cold.
- Quan hệ bao hàm: Thượng danh & Hạ danh:
    - Thượng danh (Hypernym): Nghĩa rộng hơn, bao quát hơn (VD: animal là thượng danh của cat).
    - Hạ danh (Hyponym): Nghĩa hẹp hơn, cụ thể hơn (VD: car là hạ danh của vehicle).

Ràng buộc về lựa chọn: Mã hóa ngữ nghĩa trong văn phạm

- Vị từ (động từ) biểu diễn các ràng buộc về mặt ngữ nghĩa qua tham số
  - read (human subject, textual object)
  - eat (animate subject)
  - kill (animate object)
- Sử dụng vị từ để phân giải nhập nhằng
- Ví dụ "dish":
  - cái đĩa để ăn
  - món ăn
  - phương tiện liên lạc

Ví dụ về từ “dish”

- Not unexpectedly, wives, whether working or nonworking, did by far the most - about 80% of the shopping, laundry and cooking, and about two-thirds of housecleaning, washing dishes, child care, and family paper work.
- In her tiny kitchen at home, Ms. Chen works efficiently, stir-frying several simple dishes, including braised pig‘s ears and chicken livers with green peppers.
- Installation of satellite dishes, TVs and videocassette equipment will cost the company about 20,000 per school, Mr Whittle said.

Ràng buộc lựa chọn

- Văn phạm phi ngữ cảnh có thể đưa vào các ràng buộc lựa chọn
  - tạo ontology (VD: người, động vật)
  - ràng buộc về luật

    VD: VP → V(giết) NP(động vật)
  - ràng buộc về dịch nghĩa

    VD: ăn([sinh vật sống], [thức ăn])

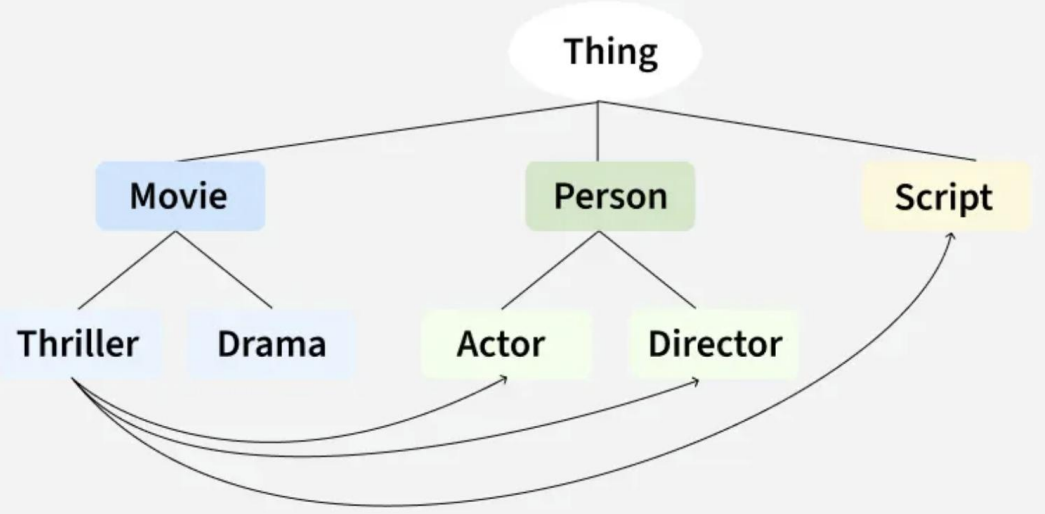

- Nhược điểm: Cách viết này không tổng quát
  - không đủ thông tin
  - không sử dụng được với các trường hợp không liệt kê trong văn phạm

Khai thác quan hệ từ vựng – WordNet

- Từ điển đồng nghĩa: gồm từ đồng nghĩa (Synonyms) và trái nghĩa (Antonyms)
- WordNet [www.globalwordnet.org]:
  - Là CSDL từ vựng khổng lồ xây dựng mạng lưới quan hệ giữa các từ.
  - Tiếng Anh, có khoảng 120.000 danh từ, 22.000 động từ, 30.000 tính từ,...
  - Tổ chức thông tin theo ý nghĩa thay vì hình thức của từ
  - WordNet cho các ngôn ngữ khác: Tây Ban Nha, Tiệp, Hà Lan, Pháp, Đức, Ý, Bồ Đào Nha, Thụy Điển, Basque, Estonian.
  - WordNet đang được làm cho các tiếng: Bulgary, Đan mạch, Hy lạp, Hebrew, Hindi, Cannada, Latvian, Moldavy, Romany, Nga, Slovenian, Tamil, Thái lan, Thổ Nhĩ Kỳ, Ireland, Nauy, Ba tư, Iran.

Tập từ đồng nghĩa (Synonym Sets – Synsets)

- Từ có nhập nhằng.
- Các nút trong WordNet biểu diễn cho các tập từ đồng nghĩa (synonym sets), mỗi synset đại diện cho 1 khái niệm.
    - VD: Khái niệm “một người dễ bị lợi dụng” (fool) có synset = {chump, fish, fool, gull, mark, patsy, fall guy, sucker, schlemiel, shlemiel, soft touch, mug}

Các quan hệ khác trong WordNet

- Các từ nối theo chiều dọc biểu diễn quan hệ thượng danh (hypernymy) – hạ danh (holonymy), theo chiều ngang biểu diễn quan hệ bộ phận meronymy (part_of) và toàn thể holonymy (has_part).
- Mỗi nghĩa của từ được painbiểu diễn bằng 1 số synset.

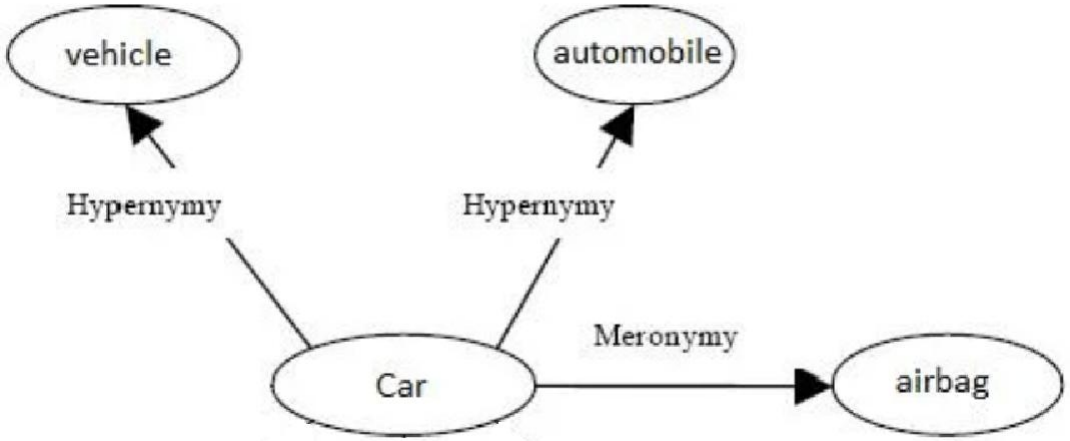

Phân giải nhập nhằng sử dụng quan hệ từ vựng

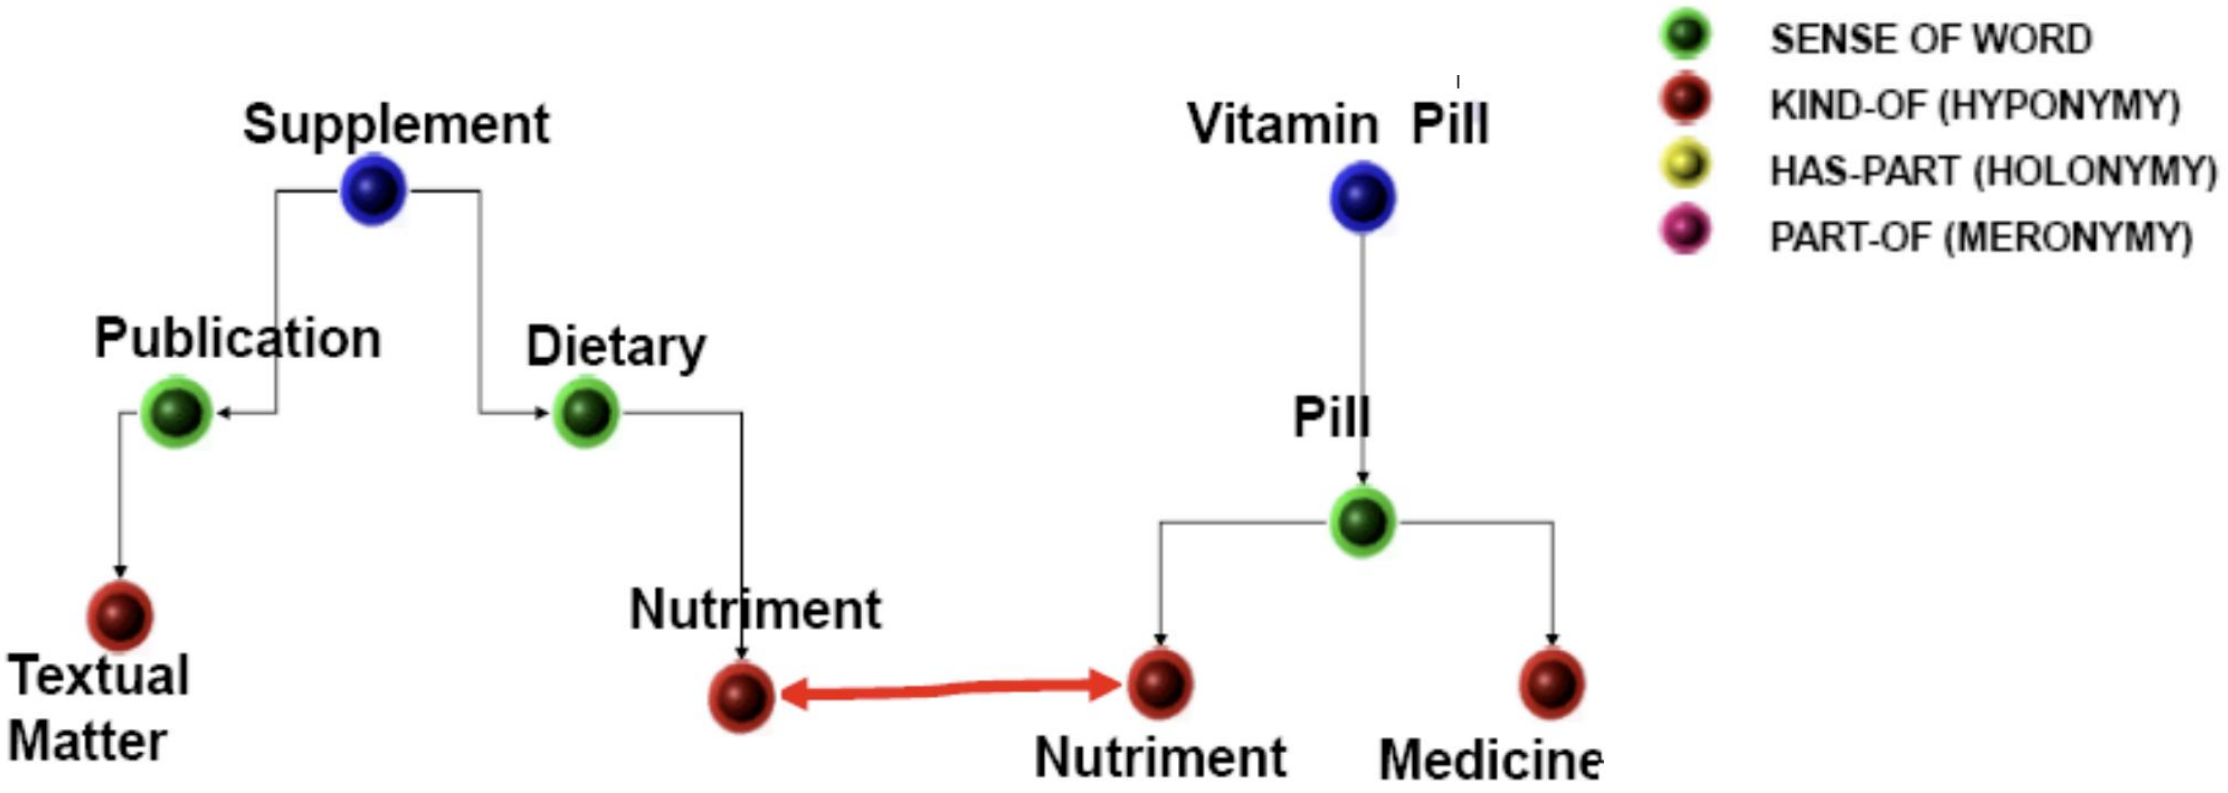

Đo quan hệ từ vựng

Đếm số cạnh/đỉnh trên đồ thị:

- khoảng cách giữa 2 từ tỉ lệ nghịch với quan hệ ngữ nghĩa giữa chúng
- Nếu giữa 2 từ có nhiều đường đi, chọn đường ngắn nhất

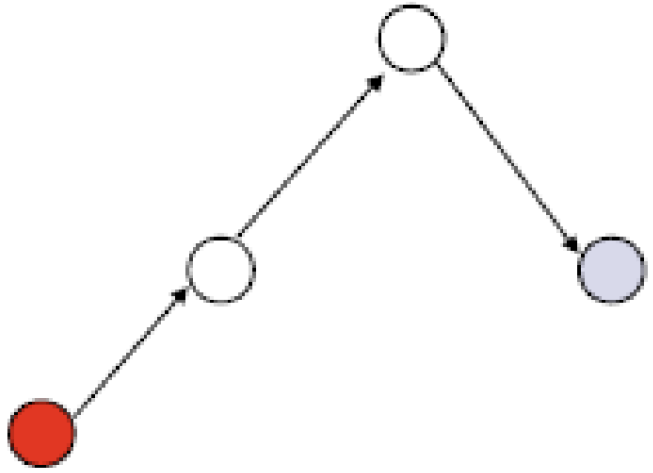

số cạnh = 3

số nút = 4

Cặp từ nào gần nhau hơn?

- cá heo và cá?
- cá và cá hồi?

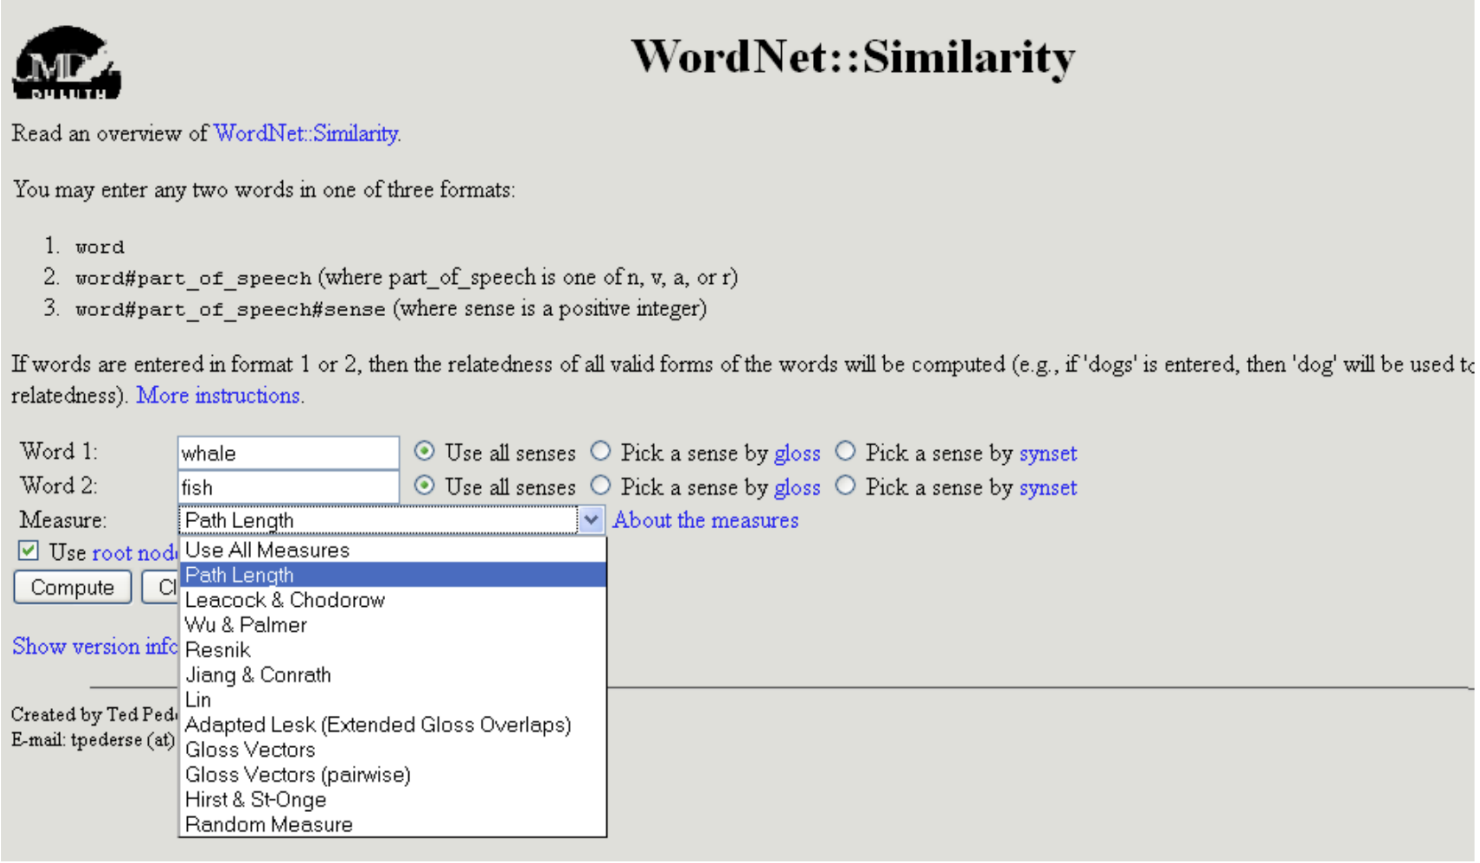

WordNet Similarity Metrics: http://marimba.d.umn.edu/cgi-bin/similarity/similarity.cgi

Phân giải nhập nhằng và đếm cạnh

- whale#n#1: 1 người rất lớn (về kích thước hoặc phẩm chất)
- fish#n#3: (thiên văn học) người được sinh khi mặt trời ở vì sao Pisces

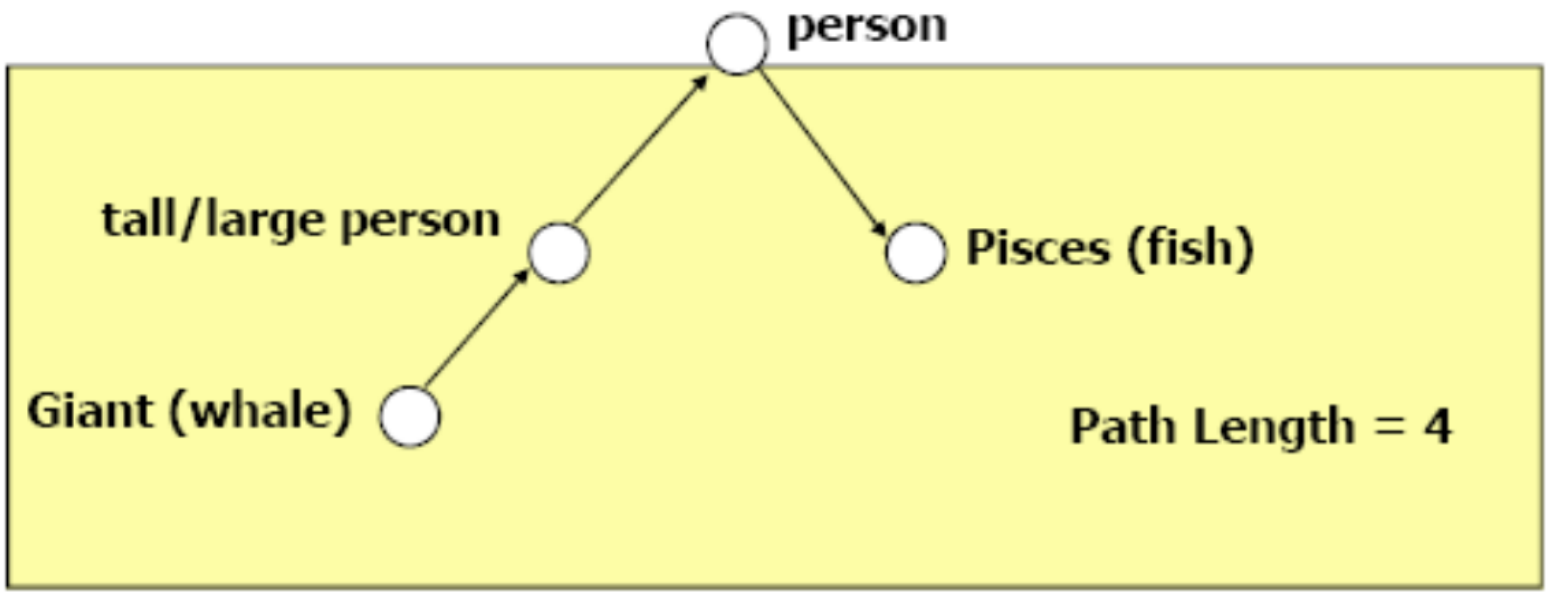

Phân giải nhập nhằng và đếm cạnh

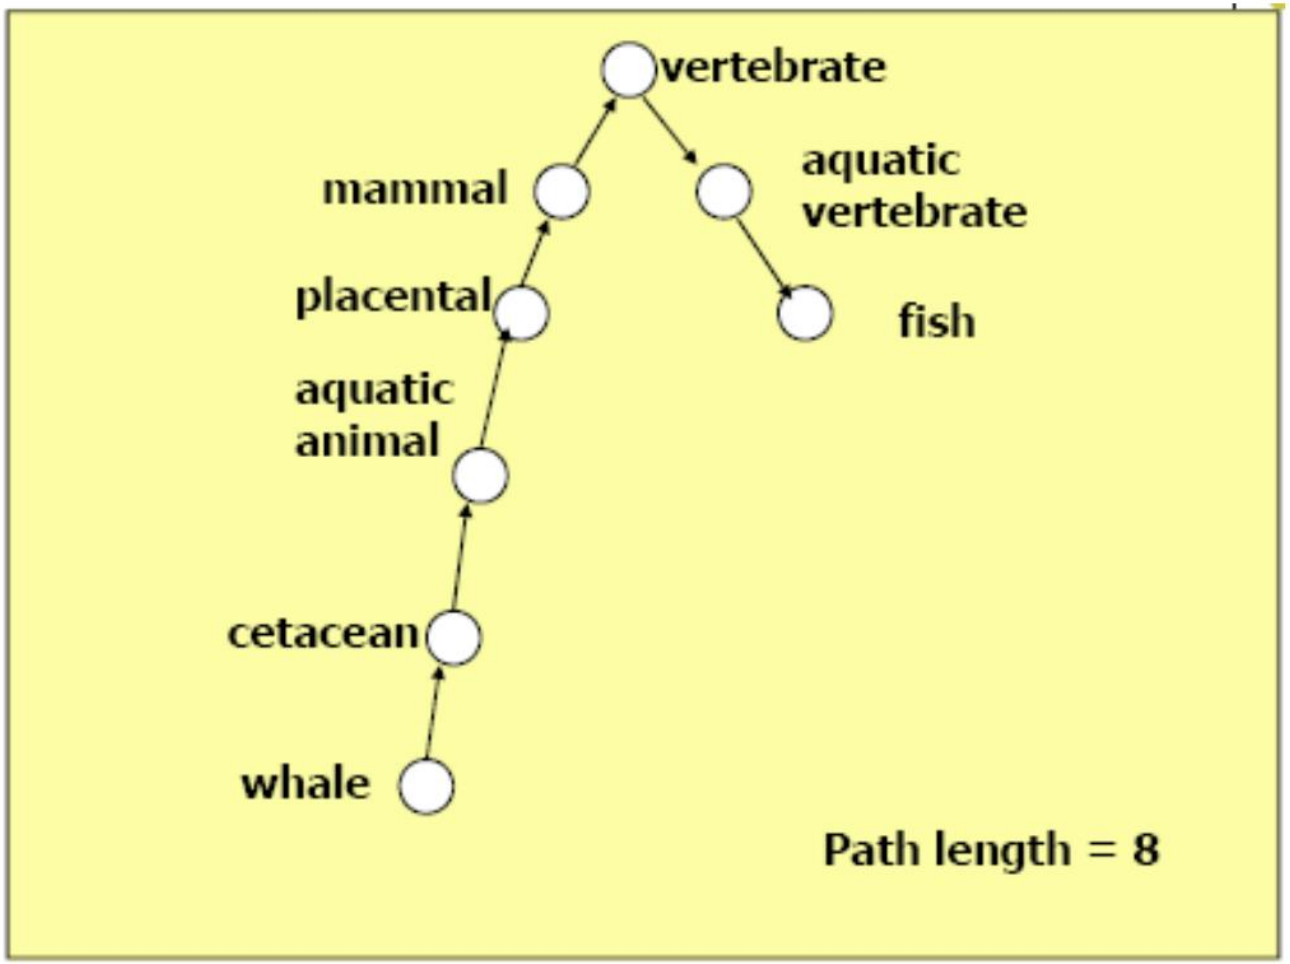

Nhược điểm của WordNet

Độ đo quan hệ ngữ nghĩa WordNet dựa trên các giả thiết sau:

- Mọi cạnh trong đồ thị có độ dài bằng nhau
- Các nhánh trong đồ thị có cùng độ đậm đặc
- Tồn tại tất cả các quan hệ ngoại động từ

→ không đáng tin cậy

Nhược điểm của WordNet

- Thiếu sắc thái, ví dụ như các từ đồng nghĩa: “cố”, “cố gắng”, “gắng”, “nỗ lực” được xem là có mức độ như nhau.
- Thiếu từ mới hoặc ý nghĩa mới (không thể cập nhật): tày, khê, chưa đủ wow,…
- Chủ quan, phụ thuộc vào người tạo.
- Yêu cầu nhiều công sức tạo ra và cập nhật để thích ứng.
- Khó đo chính xác khoảng cách về nghĩa giữa các từ.

Phân giải nhập nhằng từ (Word Sense Disambiguation – WSD)

- Định nghĩa: Là quá trình xác định (giải nghĩa) ý nghĩa chính xác của một từ đa nghĩa trong một ngữ cảnh cụ thể.
- Các biến thể bài toán WSD:
  - Lexical sample task: Tập trung phân giải một tập nhỏ các từ mục tiêu đã chọn trước.
  - All-words task: Phân giải toàn bộ mọi từ có trong một văn bản (tương tự việc gán nhãn từ loại nhưng phức tạp hơn do mỗi từ có bộ nhãn nghĩa riêng).

Các phương pháp tiếp cận WSD

Có 4 cách tiếp cận chính:

- Dựa trên từ điển và tri thức (Dictionary-based).
- Học máy có giám sát (Supervised methods).
- Học bán giám sát (Semi-supervised / Bootstrapping).
- Học không giám sát (Unsupervised methods).

Cách tiếp cận dựa trên từ điển

- Các từ điển điện tử (Lesk ‘86)
  - Cho biết ý nghĩa của các từ trong ngữ cảnh cụ thể (vd., I’ve often caught bass while out at sea)
    - Nghĩa 1 (Âm nhạc): A musical instrument with a low pitch.
    - Nghĩa 2 (Sinh học): A type of fish that lives in the sea.
  - So sánh sự chồng chéo của các định nghĩa về nghĩa của từ (nghĩa 1: 0 từ, nghĩa 2: 1 từ khớp với định nghĩa “sea”)
  - Chọn nghĩa trùng nhau nhiều nhất => bass: “cá vược”
- Hạn chế: đường dẫn đến từ ngắn → mở rộng cho các từ liên quan

Cách tiếp cận học máy

- Học việc phân loại để gán từ với một trong các nghĩa của nó
  - Tích lũy tri thức từ tập ngữ liệu có hoặc không gán nhãn
  - Con người chỉ can thiệp vào tập ngữ liệu gán nhãn và lựa chọn tập đặc trưng sử dụng trong việc huấn luyện
- Vào: vectơ đặc trưng
  - đích (từ cần phân giải nhập nhằng)
  - nội dung (các đặc trưng có thể dùng để tiên đoán nghĩa đúng)
- Ra: các luật phân loại cho văn bản mới

Các đặc trưng sử dụng trong WSD

- Các thẻ POS của từ và các từ lân cận
- Các từ lân cận (có thể lấy gốc từ hoặc không)
- Dấu chấm, viết hoa, định dạng
- PTCP bộ phận để xác định vai trò ngữ pháp và quan hệ giữa chúng
- Các thông tin về đồng xuất hiện:
    - Từ và các từ lân cận của nó có thường đồng xuất hiện không
- Đồng xuất hiện của các từ láng giềng
    - Ví dụ: sea có thường xuyên xuất hiện với bass không

Ví dụ

- Tôi ăn cơm với cá.
  - DT ĐgT DT GT DT
  - (C (CN (DT Tôi)) (VN (ĐgN (ĐgN (ĐgT ăn) (DT cơm)) (GN (GT với) (DT cá)))))
- Em bé chỉ thích ăn kẹo thôi.
  - DT TT TT ĐgT DT PT
  - (C (CN (DT Em bé)) (VN (TN (TN (TT chỉ) (TN (TT thích) (ĐgN (ĐgT ăn) (DT kẹo)))) (PT thôi))))
- Nó ăn nhiều hoa hồng quá.
  - ĐaT ĐgT TT DT TT
  - (C (CN (ĐaT Nó)) (VN (ĐgN (ĐgN (ĐgT ăn) (TT nhiều) (DT hoa hồng)) (TT quá))))

Các kiểu phân loại

Naïve Bayes: Nghĩa tốt nhất là nghĩa có khả năng xảy ra nhất với 1 đầu vào cho trước

$$\hat{s} = \underset{s \in S}{\operatorname{argmax}}\, p(s|V), \text{ hoặc } \underset{s \in S}{\operatorname{argmax}} \frac{p(V|s)p(s)}{p(V)}$$

- trong đó s là 1 trong các nghĩa và V là vector đầu vào của các đặc trưng.
- Chỉ có ít dữ liệu có thông tin vector kết hợp với nghĩa.
- Giả sử các đặc trưng là độc lập, p(V|s) là tích xác suất của các đặc trưng

$$p(V|s) = \prod_{j=1}^{n} p(v_j|s)$$

- $p(V)$ giống nhau với mọi $\hat{s}$ (không ảnh hưởng đến xếp hạng cuối cùng).

Các kiểu phân loại

Naïve Bayes: Nghĩa tốt nhất là nghĩa có khả năng xảy ra nhất với 1 đầu vào cho trước

- Khi đó

$$\hat{s} = \underset{s \in S}{\operatorname{argmax}}\, p(s) \prod_{j=1}^{n} p(v_j|s)$$

- P(s) là xác suất tiền nghiệm của mỗi nghĩa = xác suất của mỗi nghĩa trong tập dữ liệu gán nhãn
- P(v,s) = đếm số lần xuất hiện của bass đi với sea.

Học máy xác định tập từ đồng nghĩa

Phương pháp phân tích ngữ nghĩa tiềm ẩn: LSA (Latent Semantic Analysis)

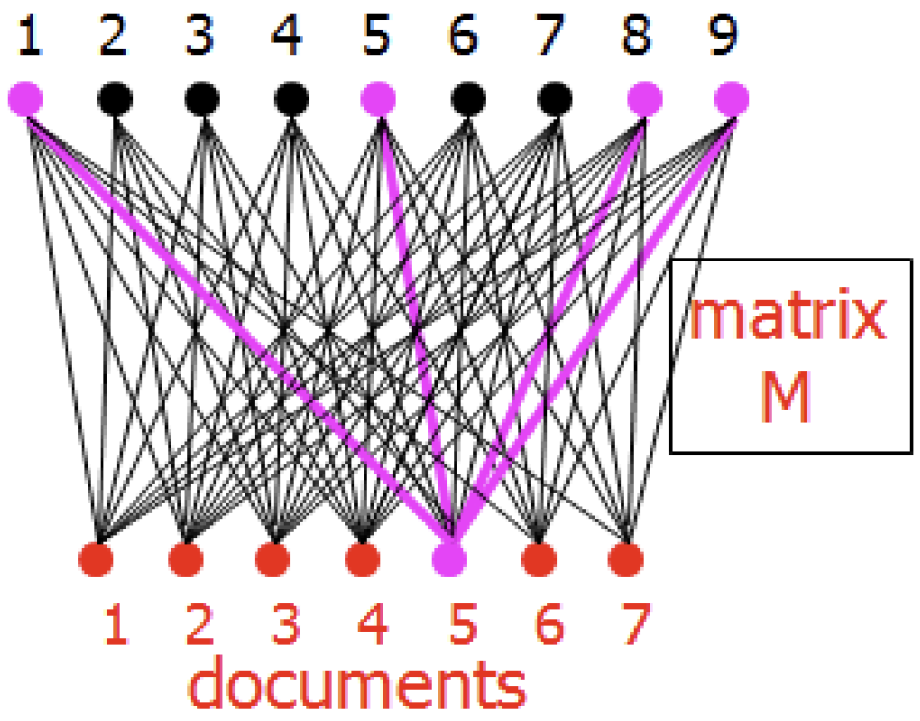

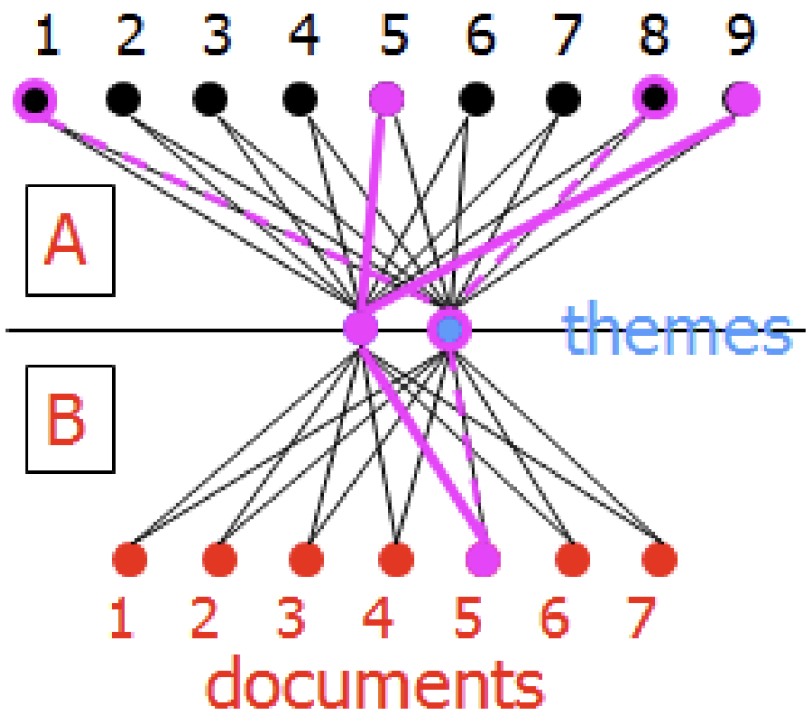

Học máy xác định tập từ đồng nghĩa

Phương pháp phân tích ngữ nghĩa tiềm ẩn:

- LSA (Latent Semantic Analysis) là một kỹ thuật giảm chiều dữ liệu sử dụng SVD để chuyển đổi ma trận từ-văn bản thành một không gian ngữ nghĩa thấp chiều, giúp tìm ra mối liên hệ giữa các từ đồng nghĩa và ngữ cảnh ẩn.

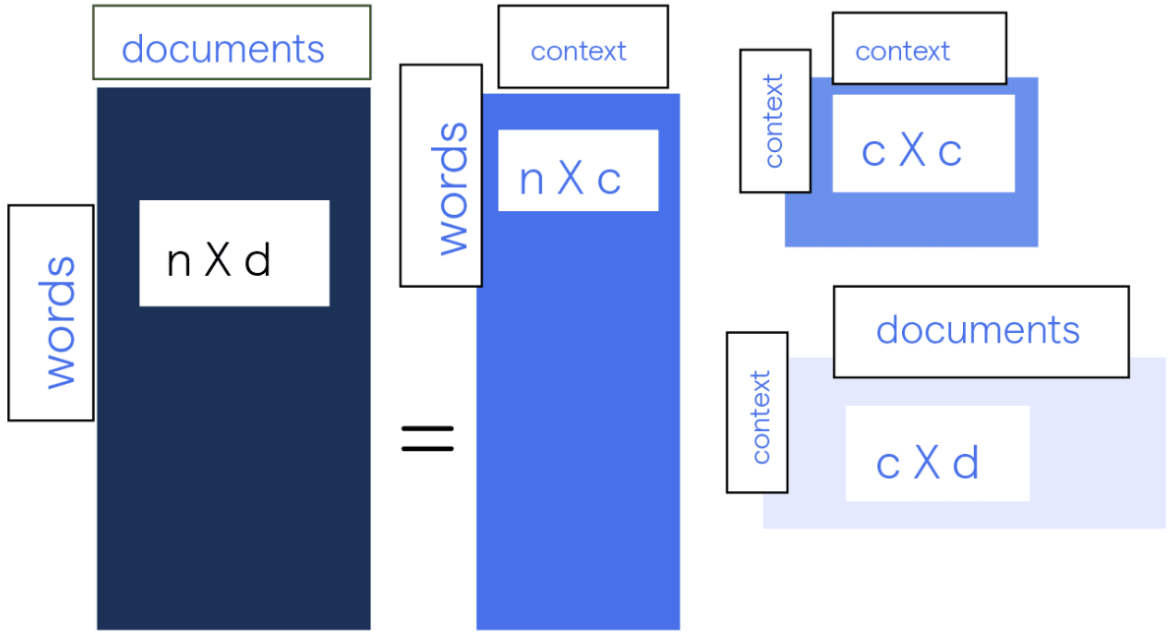

Học máy xác định tập từ đồng nghĩa

Phương pháp phân tích ngữ nghĩa tiềm ẩn:

- LDA (Latent Dirichlet Allocation) là một mô hình xác suất thống kê giúp tự động phân loại các từ ngữ trong một tập hợp văn bản thành các chủ đề ẩn (latent topics) dựa trên sự phân phối Dirichlet của chúng.

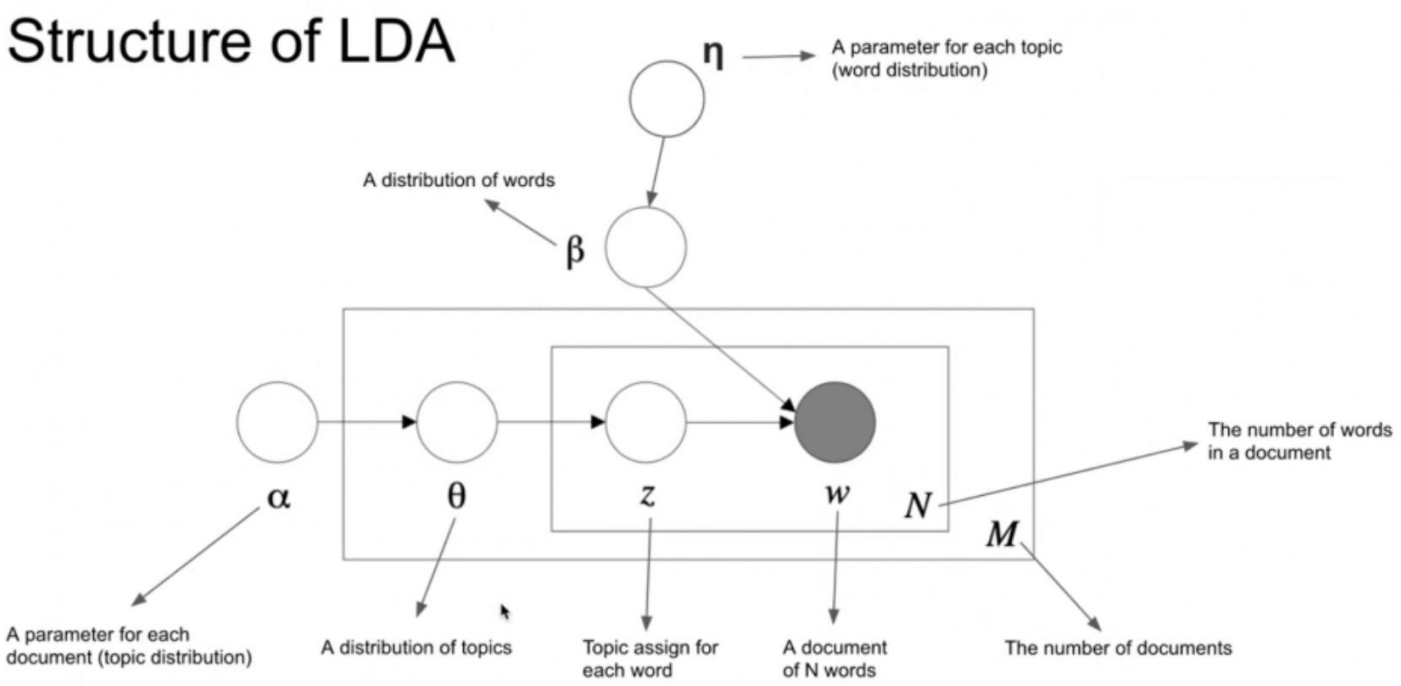

Học máy xác định từ đồng nghĩa

- Word embedding: các kỹ thuật học mô hình ngôn ngữ và học đặc trưng với mỗi từ/cụm từ được biểu diễn bởi 1 vector các số thực trong không gian từ vựng
- Gensim, Fasttext: word2vec, doc2vec

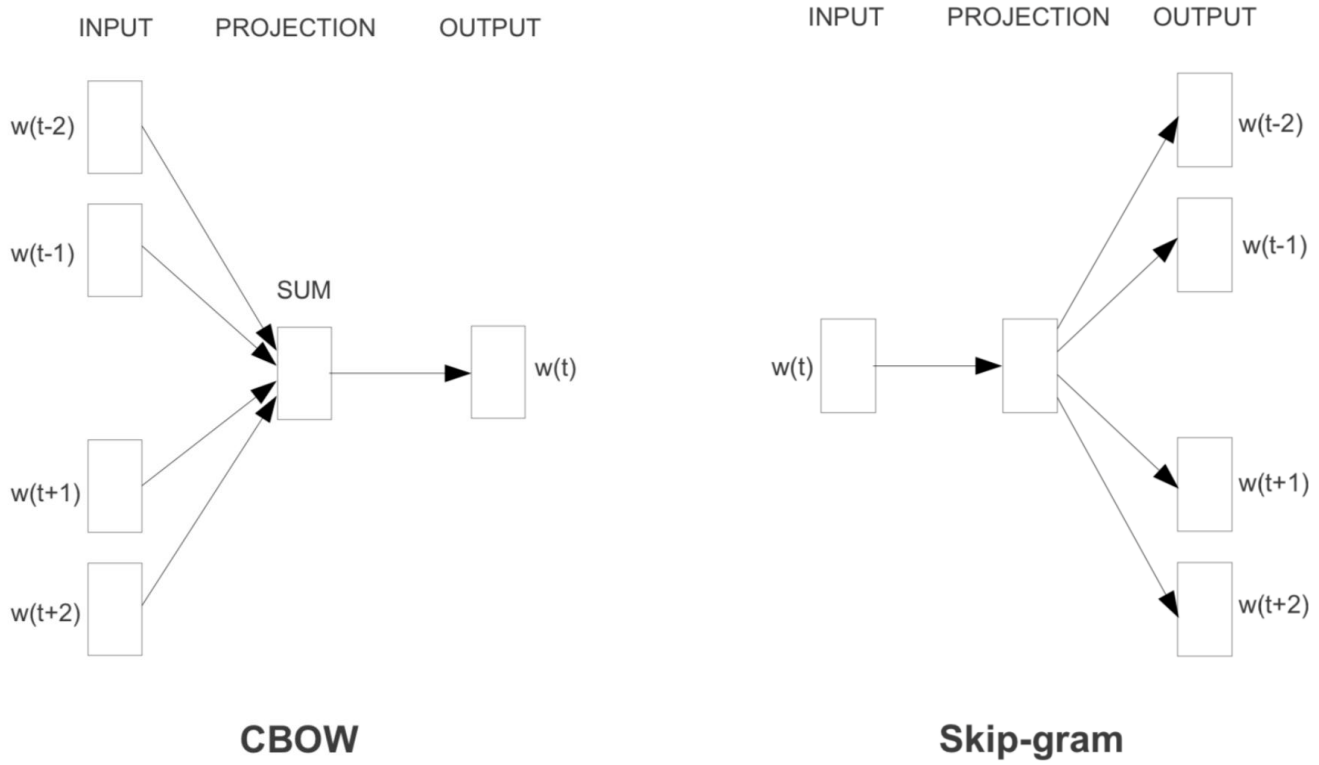

WSD và IR

- IR (Information Retrieval) : tìm kiếm thông tin
- Motivation
  - Đồng âm = Bank (ngân hàng, bờ sông)
  - Đa nghĩa = Bat ((câu lạc bộ chơi cricket), (cây vợt nhỏ có tay cầm dài để chơi bóng))
  - Đồng nghĩa = doctor, doc, physician, MD, medico
- Những vấn đề trên ảnh hưởng đến IR như thế nào?
  - Đồng âm và đa nghĩa có xu hướng giảm độ chính xác
  - Đồng nghĩa: giảm độ phủ

2 ứng dụng của WSD trong IR

- Tìm kiếm dựa trên câu truy vấn (Voorhees, 1998):
  - Sử dụng WSD để mở rộng câu truy vấn: phân giải nhập nhằng câu query và bổ sung vào các từ có nghĩa rộng hơn.
  - Sử dụng WSD để đánh chỉ số khái niệm: phân giải nhập nhằng tập tài liệu và xây dựng chỉ số cho tập synset thay vì cho tập từ gốc
  - Mô hình không gian vector: tìm độ tương đồng cosin giữa câu truy vấn và mỗi vector tài liệu
- Đánh chỉ số khái niệm
  - Trong các thí nghiệm, vector dựa trên nghĩa thực hiện kém hơn vector dựa trên từ gốc
  - Lý do: lỗi phân giải nhập nhằng
    - trong thu thập văn bản, và
    - các câu query ngắn do thiếu nội dung

2 ứng dụng của WSD trong IR

- Mở rộng query
  - Không khả quan
  - Nhưng, phân giải nhập nhằng và mở rộng truy vấn thủ công đem lại kết quả tốt
- Ví dụ:
  - furniture: table, chair, board, refectory(specialisations)
  - “Chỉ có một vài từ vựng liên quan là có ích trong việc mở rộng câu truy vấn, vì đường dẫn lớp cha giữa các từ trong WordNet không phải lúc nào cũng đem lại 1 mở rộng truy vấn 1 cách hữu ích”

Độ chính xác của WSD và IR

- Tập dữ liệu đánh giá WSD: SensEval và SemCor
- Cách khác để tạo ra dữ liệu gán nhãn: Pseudowords
  - Lấy 2 từ (ngẫu nhiên) có cùng từ loại, và thay thế cả 2 bằng 1 từ nhân tạo. Ví dụ, 'door' và 'banana' có thể thay thế trong tập ngữ liệu bằng từ 'donana'.
  - Độ chính xác của WSD: xác định được mỗi trường hợp của donana cụ thể là 'door‘ hay 'banana'. (Yarowsky, 1993)
- (Sanderson, 1997) công bố: thêm nhập nhằng vào các query và kết quả ít có ảnh hưởng đến độ chính xác của việc tìm kiếm so với ảnh hưởng của lỗi phân giải nhập nhằng trong tập kết quả
  - chỉ có lỗi phân giải nhập nhằng mức thấp (< 10%) mới tốt hơn phiên bản IR đơn giản dựa trên từ gốc.

Độ chính xác của WSD và IR

- Tại sao đa nghĩa/đồng âm không phải vấn đề lớn như ta nghĩ?
  - Tác động của sự đồng xuất hiện từ truy vấn: các từ trong câu truy vấn tự nó đã phân giải nhập nhằng
  - Sự phân bố ngữ nghĩa: áp dụng cho các miền ứng dụng cụ thể

Độ chính xác của WSD và IR

Từ đồng nghĩa có ảnh hưởng lớn hơn:

- Gonzalo et al. (1998; 1999): sử dụng SemCor (tập ngữ liệu Brown với các thẻ nghĩa của WordNet) cho thấy nếu phân giải nhập nhằng có độ chính xác = 100%
    - Đánh chỉ số nghĩa (vd synset number) có độ chính xác IR = 62%
    - Đánh chỉ số nghĩa của từ (vd canine1) có độ chính xác IR = 53.2%
    - Đánh chỉ số từ gốc có độ chính xác IR = 48%
- Gonzalo et al. cho thấy độ chính xác tối thiểu 90% với WSD cho IR là quá cao. Gần 60% từ giả không hoạt động giông như từ có nhập nhằng thật.