Học viện Công nghệ Bưu chính Viễn thông
Khoa Công nghệ thông tin 1

HỆ KHUYẾN NGHỊ

Gợi ý dựa trên lọc cộng tác nâng cao

Dao Thi Thuy Quynh

Deep Matrix Factorization

- Biểu diễn user là vector của các item
- Biểu diễn item là vector của các user
- Sử dụng mạng MLP để học các tầng biểu diễn của user và item
- Kết hợp biểu diễn của user và item để đưa ra điểm phù hợp

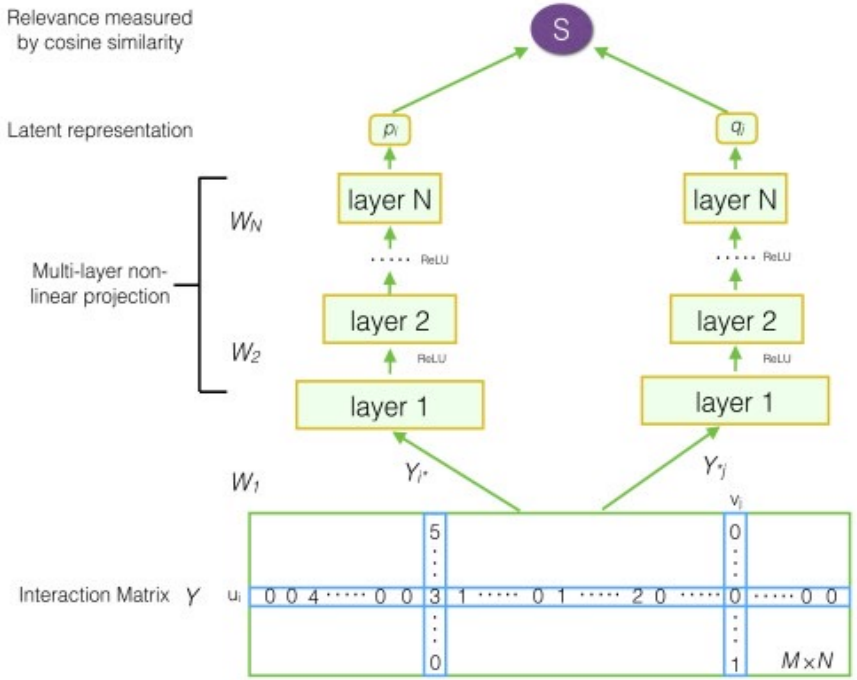

Deep matrix factorization

Minh họa kết quả: DMF

Datasets	Metrics	Methods				DMF	
		ItemPop	ItemKNN	eALS	NeuMF-p	DMF-2-ce	DMF-2-nce
ML100k	NDCG	0.231	0.334	0.356	0.395	0.405	0.409
	HR	0.406	0.600	0.621	0.670	0.679	0.687
ML1m	NDCG	0.263	0.372	0.425	0.440	0.442	0.451
	HR	0.472	0.637	0.709	0.722	0.720	0.732
Amusic	NDCG	0.242	0.345	0.374	0.371	0.403	0.397
	HR	0.423	0.493	0.521	0.527	0.570	0.563
Amovie	NDCG	0.386	0.403	0.455	0.512	0.533	0.550
	HR	0.620	0.652	0.693	0.739	0.765	0.773

LightGCN (He et.al 2020)

- Tương tác của user-item có thể biểu diễn thành đồ thị 2 phía (user-item bipartite graph).
- Sử dụng đồ thị có thể bắt được tương tác bậc cao hơn (high-order connectivity)

E.g., why u_1 may like i_4?

- $u_1 \leftarrow i_2 \leftarrow u_2 \leftarrow i_4$
- $u_1 \leftarrow i_3 \leftarrow u_3 \leftarrow i_4$

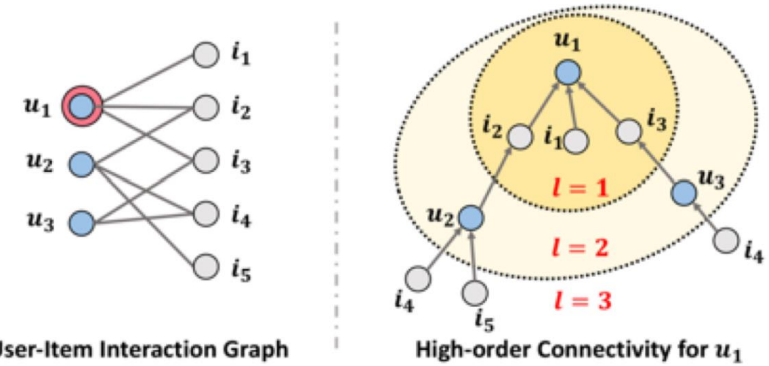

Graph convolutional network (GCN)

- Mạng đồ thị tích GCN là một công cụ hiệu quả để học biểu diễn cho dữ liệu dạng đồ thị.
- Xem xét một đồ thị $G = (V, E)$ trong đó V là tập các đỉnh và E là tập cạnh của đồ thị.
- Đặt A ($A \in R^{V \times V}$) là ma trận kề của đồ thị G và X ($X \in R^{V \times M}$) là ma trận biểu diễn cho các đỉnh mà mỗi hàng X_i ($i \in \{1, \dots, V\}$) là một vectơ M-chiều biểu diễn cho đỉnh thứ i.
- Mạng đồ thị tích chập học L tầng biểu diễn ẩn của các đỉnh trong đồ thị
- Biểu diễn của các đỉnh h_l ở tầng thứ l được tính thông qua lần lượt hai bước: Bước tổng hợp (aggregation) và biến đổi (transformation).

Graph convolutional network (GCN)

- Tại bước tổng hợp, biểu diễn của một đỉnh được tổng hợp từ biểu diễn của các đỉnh có cạnh nối với nó và thông tin từ chính đỉnh đó.

$$\bar{h}_l = \widetilde{D}^{-\frac{1}{2}}\tilde{A}\widetilde{D}^{-\frac{1}{2}}h_{l-1}$$

- Sau đó, bước biến đổi cho phép chuyển đổi biểu diễn của các đỉnh.

$$h_l = f(\bar{h}_l W_l)$$

- trong đó, $\tilde{A} = A + I_V$ (I_V là ma trận đơn vị), $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$, W_l là ma trận trọng số của tầng thứ l, $h_0 = X$ và hàm hoạt động f là hàm ReLU.
- Chúng ta có thể gộp 2 bước:

$$h_l = f\left(\widetilde{D}^{-\frac{1}{2}}\tilde{A}\widetilde{D}^{-\frac{1}{2}}h_{l-1}W_l\right)$$

Có thể đặt thêm bias:

$$H^{(l+1)} = \sigma(\tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2}H^{(l)}W^{(l)})$$

Sử dụng GCN cho lọc cộng tác

- Xây dựng đồ thị đỉnh là user và item, cạnh là tương tác của user-item
- Sử dụng mạng GCN để học biểu diễn cho các đỉnh là user (U) và item (I)

$$(U, I) = GCN(User - item\ graph)$$

- Mức độ yêu thích của user j cho item v được tính như sau:

$$R_{jv} = U_j^T I_v$$

LightGCN

- LightGCN dựa vào thực nghiệm để đưa ra một số lược giảm của GCN gốc cho gợi ý:
  - Loại bỏ biến đổi phi tuyến
  - Không sử dụng activation phi tuyến
  - Loại bỏ liên kết tự kết nối của đỉnh tới chính nó

LightGCN

- LightGCN thực hiện các bước như sau:
  - Lấy thông tin láng giềng

$$\mathbf{e}_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|}\sqrt{|\mathcal{N}_i|}} \mathbf{e}_i^{(k)},$$

$$\mathbf{e}_i^{(k+1)} = \sum_{u \in \mathcal{N}_i} \frac{1}{\sqrt{|\mathcal{N}_i|}\sqrt{|\mathcal{N}_u|}} \mathbf{e}_u^{(k)}.$$

  - Kết hợp tuyến tính biểu diễn các layers k

$$\mathbf{e}_u = \sum_{k=0}^{K} \alpha_k \mathbf{e}_u^{(k)}; \quad \mathbf{e}_i = \sum_{k=0}^{K} \alpha_k \mathbf{e}_i^{(k)},$$

  - Loại bỏ liên kết tự kết nối của đỉnh tới chính nó

$$\mathbf{E}^{(k+1)} = (\mathbf{D}^{-\frac{1}{2}}\mathbf{A}\mathbf{D}^{-\frac{1}{2}})\mathbf{E}^{(k)}$$

  - Với R là interaction matrix và

$$\mathbf{A} = \begin{pmatrix} \mathbf{0} & \mathbf{R} \\ \mathbf{R}^T & \mathbf{0} \end{pmatrix}$$

LightGCN

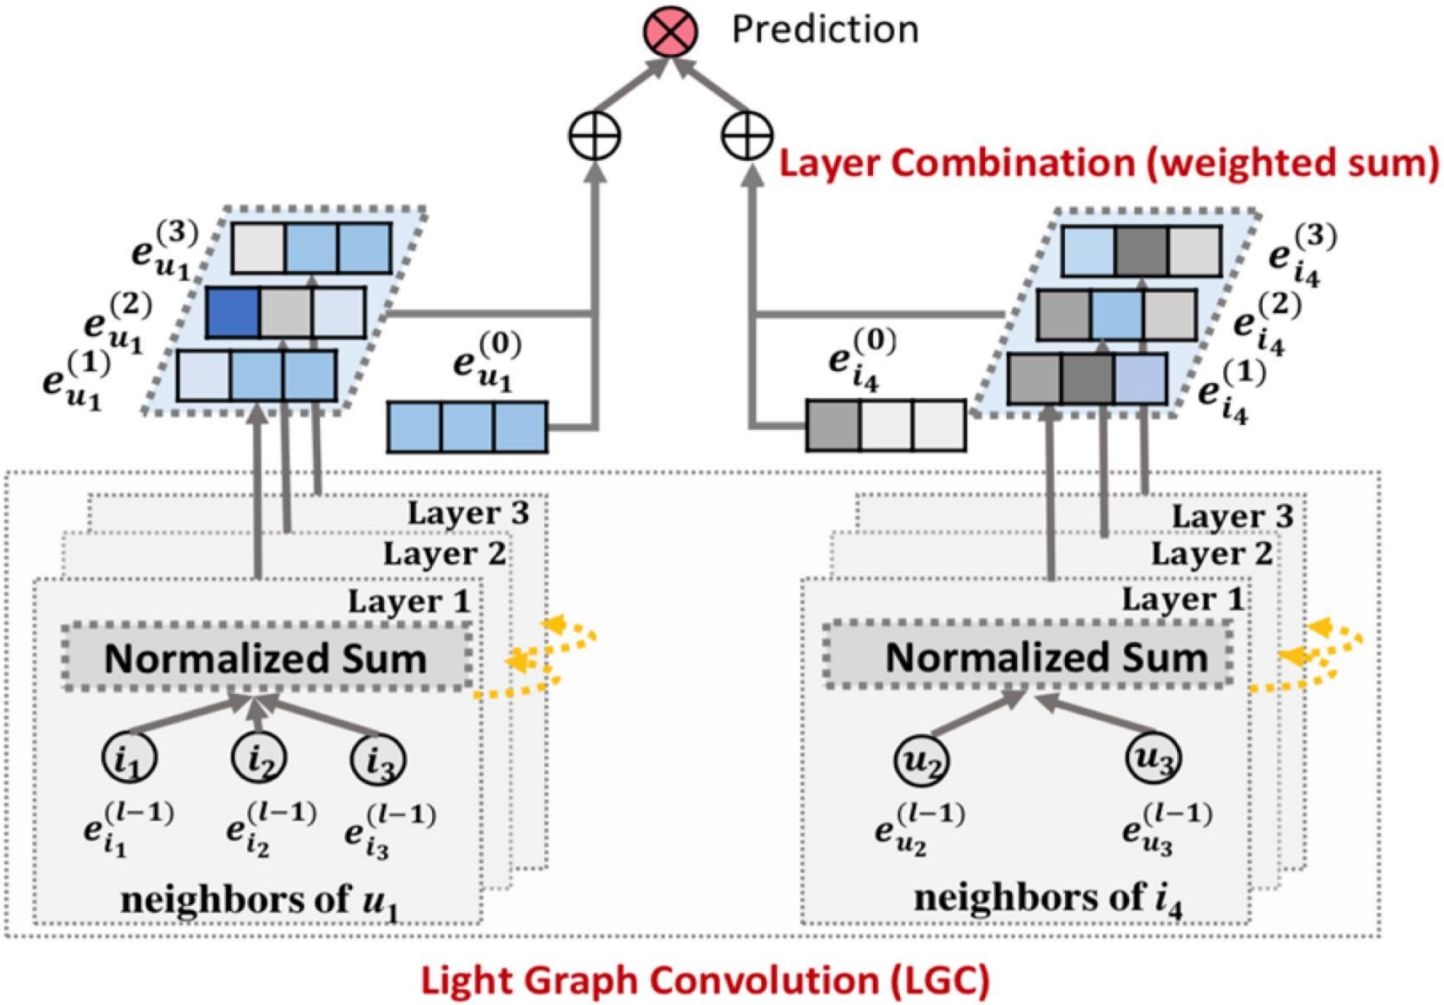
Prediction
Layer Combination (weighted sum)
$e_{u_1}^{(3)}$
$e_{u_1}^{(2)}$
$e_{u_1}^{(1)}$
$e_{u_1}^{(0)}$
$e_{i_4}^{(0)}$
$e_{i_4}^{(3)}$
$e_{i_4}^{(2)}$
$e_{i_4}^{(1)}$
Layer 3
Layer 2
Layer 1
Normalized Sum
i_1
i_2
i_3
$e_{i_1}^{(l-1)}$
$e_{i_2}^{(l-1)}$
$e_{i_3}^{(l-1)}$
neighbors of u_1
Layer 3
Layer 2
Layer 1
Normalized Sum
u_2
u_3
$e_{u_2}^{(l-1)}$
$e_{u_3}^{(l-1)}$
neighbors of i_4
Light Graph Convolution (LGC)

Minh họa hiệu quả: LightGCN

Table 2: Statistics of the experimented data.

Dataset	User #	Item #	Interaction #	Density
Gowalla	29, 858	40, 981	1, 027, 370	0.00084
Yelp2018	31, 668	38, 048	1, 561, 406	0.00130
Amazon-Book	52, 643	91, 599	2, 984, 108	0.00062

Dataset	Gowalla		Yelp2018		Amazon-Book	
Method	**recall**	**ndcg**	**recall**	**ndcg**	**recall**	**ndcg**
NGCF	0.1570	0.1327	0.0579	0.0477	0.0344	0.0263
Mult-VAE	0.1641	0.1335	0.0584	0.0450	0.0407	0.0315
GRMF	0.1477	0.1205	0.0571	0.0462	0.0354	0.0270
GRMF-norm	0.1557	0.1261	0.0561	0.0454	0.0352	0.0269
LightGCN	**0.1830**	**0.1554**	**0.0649**	**0.0530**	**0.0411**	**0.0315**

Dữ liệu explicit và implicit feedback

- Dữ liệu explicit feedback (ratings, purchas, like)
  - Dữ liệu quý giá, thể hiện sở thích của user
  - Thưa, ít, khó thu thập
  - Khó khăn khi học các mô hình
- Dữ liệu implicit feedback (click, view)
  - Dữ liệu nhiều, dễ thu thập
  - Phản ánh tiềm ẩn mức độ ưa thích của người dùng
  - Có thể có nhiễu

Weighted Matrix Factorization

- Weighted Matrix Factorization (Yifan Hu el at -2008)
- Dữ liệu tiềm ẩn: số lần xem một video, thời lượng xem một video, lịch sử mua sắm,… của người dùng.
  - ❖ Dữ liệu tương tác tường minh cho ta biết sở thích người dùng (like, dislike). Tương tác ẩn, dữ liệu tương tác tiềm ẩn thì đều là các phản hồi tích cực.
    - ➢ VD: r_{ui} cho biết số lần u xem toàn bộ một bộ phim i. Khi $r_{ui} = 0.7$, tức u đã xem 70% video.
    - ➢ Các tương tác tiềm ẩn có các mức độ khác nhau.

Weighted Matrix Factorization

- Sử dụng có dữ liệu implicit
  - ❖ Đưa dữ liệu tiềm ẩn về dạng tương tác nhị phân:

$$p_{ui} = \begin{cases} 1 & r_{ui} > 0 \\ 0 & r_{ui} = 0 \end{cases}$$

  - ❖ Dữ liệu tiềm ẩn có các mức độ khác nhau, sử dụng trọng số thể hiện độ tin cậy: $c_{ui} = 1 + \alpha r_{ui}$
  - ❖ Hàm mục tiêu: $\min_{x_\star, y_\star} \sum_{u,i} c_{ui}(p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$
  - ❖ Công thức nghiệm (hồi quy tuyến tính):

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$y_i = (X^T C^i X + \lambda I)^{-1} X^T C^i p(i)$$

Bayesian Personalized Ranking

- Bayesian Personalized Ranking (Rendle el at -2009)
- Đưa ra một danh sách có xếp hạng các sản phẩm cho mỗi người dùng.
  - ❖ Thứ tự này có thể suy ra từ nhóm hành vi tiềm ẩn của người dùng.
  - ❖ Tiếp cận theo cặp item, khác so với phương pháp MF truyền thống.
  - ❖ Dữ liệu tiềm ẩn:
    - Dữ liệu quan sát được là positive.
    - Các cặp user-item không quan sát được: có thể thực sự không thích (negative), chưa biết (missing value).

Bayesian Personalized Ranking

- MF truyền thống: Dự đoán giá trị $\hat{x}_{ui}$ thể hiện mức độ ưa thích của u cho i.

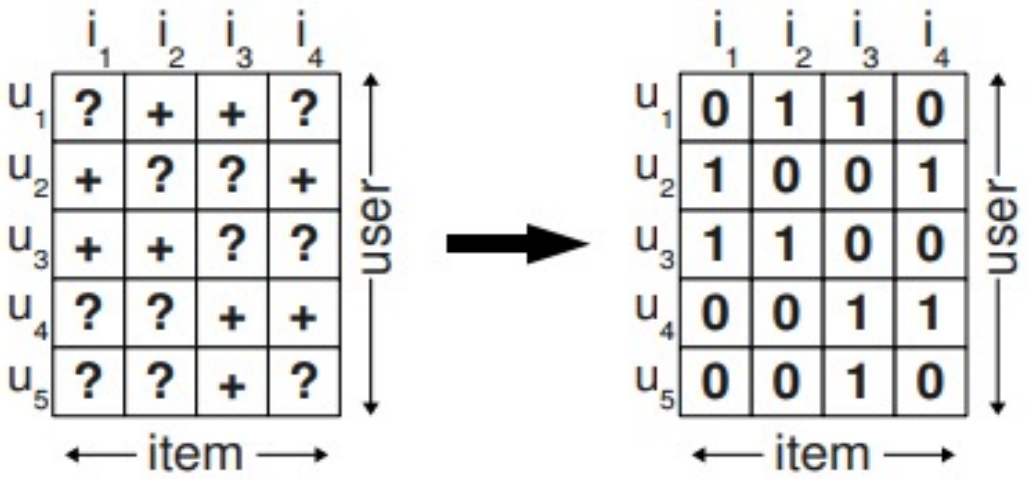

Bayesian Personalized Ranking

Mối quan hệ thứ tự $i >_u j$ giữa các cặp sản phẩm:

- (+): u ưa thích sản phẩm i hơn j.
- (-): u ưa thích sản phẩm j hơn i.

❖ Mỗi u, xác định thứ tự sản phẩm theo thứ tự sẽ được yêu thích bởi u. Xác suất hậu nghiệm:

Θ: tham số của mô hình.

$$p(\Theta | i >_u j) \propto p(i >_u j | \Theta) p(\Theta)$$

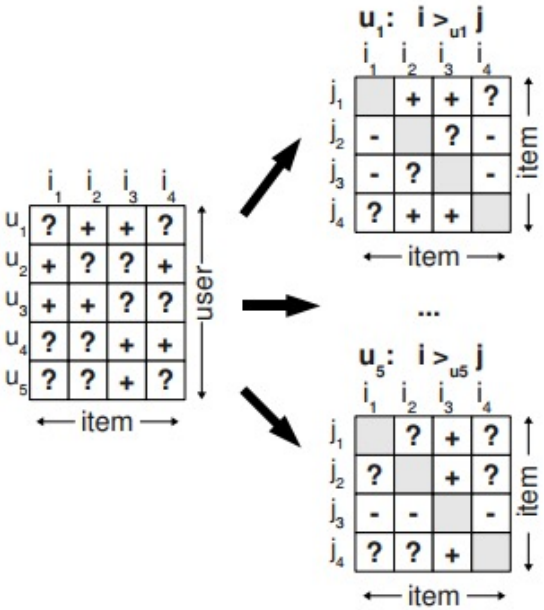

Bayesian Personalized Ranking

- Sử dụng hàm sigmoid để mô hình hóa xác suất u thích sản phẩm i hơn j.

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

❖ r_{uij} mô tả sự khác nhau giữa dự đoán cho sản phẩm và sản phẩm j:

$$p(i >_u j|\Theta) = \sigma\left(\hat{r}_{uij}(\Theta)\right)$$

$$\hat{r}_{uij} = \hat{r}_{ui} - \hat{r}_{uj}$$

$$= x_u y_i^T - x_u y_j^T$$

Bayesian Personalized Ranking (Rendle el at -2009)

- Hàm mục tiêu

$$
\begin{aligned}
BPR - Opt &= \prod_{u,i,j} p(i >_u j|\Theta)p(\Theta) \\
&= ln\Big(\prod_{u,i,j} p(i >_u j|\Theta)p(\Theta)\Big) \\
&= \sum_{u,i,j} ln\sigma\big(\hat{r}_{ui} - \hat{r}_{uj}\big) + lnp(\Theta) \\
&= \sum_{u,i,j} ln\sigma\big(\hat{r}_{ui} - \hat{r}_{uj}\big) - \lambda_\Theta \|\Theta\|^2 \\
&= \sum_{u,i,j} ln\sigma\big(\hat{r}_{ui} - \hat{r}_{uj}\big) - \frac{\lambda_\Theta}{2}\|x_u\|^2 - \frac{\lambda_\Theta}{2}\|y_i\|^2 - \frac{\lambda_\Theta}{2}\|y_j\|^2 \\
&= \sum_{u,i,j} ln\sigma\big(x_u y_i^T - x_u y_j^T\big) - \frac{\lambda_\Theta}{2}\|x_u\|^2 - \frac{\lambda_\Theta}{2}\|y_i\|^2 - \frac{\lambda_\Theta}{2}\|y_j\|^2 \\
&= \sum_{u,i,j} ln\frac{1}{1+e^{-(x_u y_i^T - x_u y_j^T)}} - \frac{\lambda_\Theta}{2}\|x_u\|^2 - \frac{\lambda_\Theta}{2}\|y_i\|^2 - \frac{\lambda_\Theta}{2}\|y_j\|^2
\end{aligned}
$$

Bayesian Personalized Ranking

- Loss:

$$argmin_{x_u,y_i,y_j} \sum_{u,i,j} -ln \frac{1}{1+e^{-(x_u y_i^T - x_u y_j^T)}} + \frac{\lambda_\Theta}{2}\|x_u\|^2 + \frac{\lambda_\Theta}{2}\|y_i\|^2 + \frac{\lambda_\Theta}{2}\|y_j\|^2$$

❖Cập nhật tham số:

$$\frac{\partial}{\partial x_u} = \frac{1}{1+e^{(x_u y_i^T - x_u y_j^T)}} \cdot (y_j - y_i) + \lambda x_u$$

$$\frac{\partial}{\partial y_i} = \frac{1}{1+e^{(x_u y_i^T - x_u y_j^T)}} \cdot -x_u + \lambda y_i$$

$$\frac{\partial}{\partial y_j} = \frac{1}{1+e^{(x_u y_i^T - x_u y_j^T)}} \cdot x_u + \lambda y_j$$

Sử dụng đồng thời Implicit và explicit feedback

- Co-rating [Nathan et al 2010]: Sử dụng cả dữ liệu implicit Y và explicit X:

$$\arg\min_{U,V} \mathcal{L}_E(U,V) + \eta \cdot \mathcal{L}_I(U,V) + \lambda \cdot \mathcal{R}(U,V)$$

$$\mathcal{L}_E(U,V) = \sum_{(u,i)\in S^*} (x_{ui} - \mathbf{u}_i^\top \mathbf{v}_u)^2$$

$$\mathcal{L}_I(U,V) = \sum_{u=1}^{n} \sum_{i=1}^{m} (y_{ui} - \mathbf{u}_i^\top \mathbf{v}_u)^2$$

$$\mathcal{R}(U,V) = \|U\|_F^2 + \|U\|_F^2$$

Sử dụng trọng số eta thể hiện mức độ quan trọng giữa các tương tác ẩn và tường minh.

Neural Multi-Task Recommendation

- Có R loại hành vi khác nhau biểu diễn cho R loại tương tác.
  - ❖ Mỗi loại hành vi được biểu diễn dưới dạng ma trận cỡ MxN, với giá trị mỗi phần tử là giá trị nhị phân.
  - ❖ Các loại hành vi có tính thứ tự từ thấp đến cao, trong đó hành vi cuối cùng được gọi là hành vi mục tiêu.

Neural Multi-Task Recommendation

- Mã hóa được tính thứ tự của hành vi bằng:

  Hành vi loại sau phụ thuộc vào hành vi loại trước:

$$\hat{y}_{ui}^{R} = \sigma(\hat{y}_{ui}^{R-1} + f_{\Theta}^{R}(\mathbf{p}_u, \mathbf{q}_i) + b_i^R),$$

$$\cdots\cdots$$

$$\hat{y}_{ui}^{2} = \sigma(\hat{y}_{ui}^{1} + f_{\Theta}^{2}(\mathbf{p}_u, \mathbf{q}_i) + b_i^2),$$

$$\hat{y}_{ui}^{1} = \sigma(f_{\Theta}^{1}(\mathbf{p}_u, \mathbf{q}_i) + b_i^1),$$

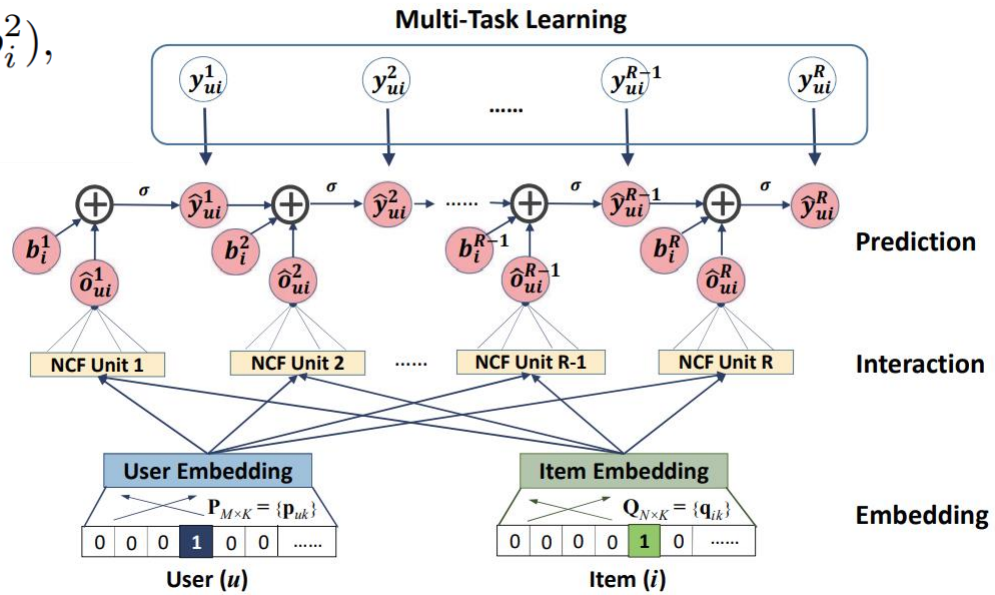

Neural Multi-Task Recommendation

- Hàm lỗi để học cho tất cả các mô hình con, mỗi mô hình con để tối ưu cho 1 loại hành vi:

$$L = -\sum_{r=1}^{R} \lambda_r \Big(\sum_{(u,i)\in\mathcal{Y}_r^+} \log \hat{y}_{ui}^r + \sum_{(u,i)\in\mathcal{Y}_r^-} \log(1-\hat{y}_{ui}^r) \Big)$$

❖ λr trọng số biểu diễn mức độ ảnh hưởng của từng loại hành vi.

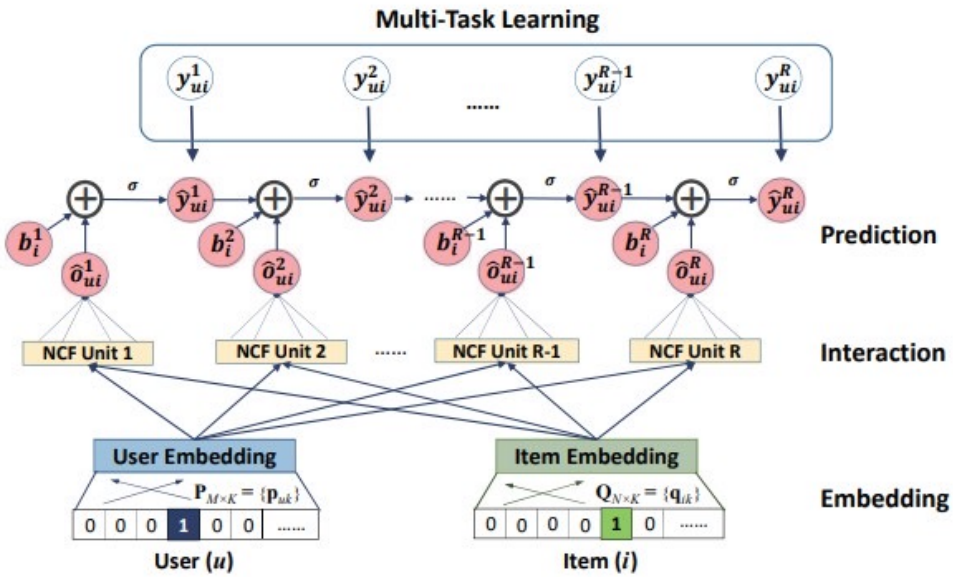

Implict to Explict model

- Mô hình hóa tính thứ tự của hành vi người dùng.
  - Tầng cuối cùng trong mô hình tương tác tiềm ẩn làm đầu vào cho tầng khác với giá trị đầu ra dự đoán điểm cho tương tác hành vi rõ ràng.
  - ITE-one hot: vector đầu vào là vector one hot mã hóa định danh cho người dùng, sản phẩm.

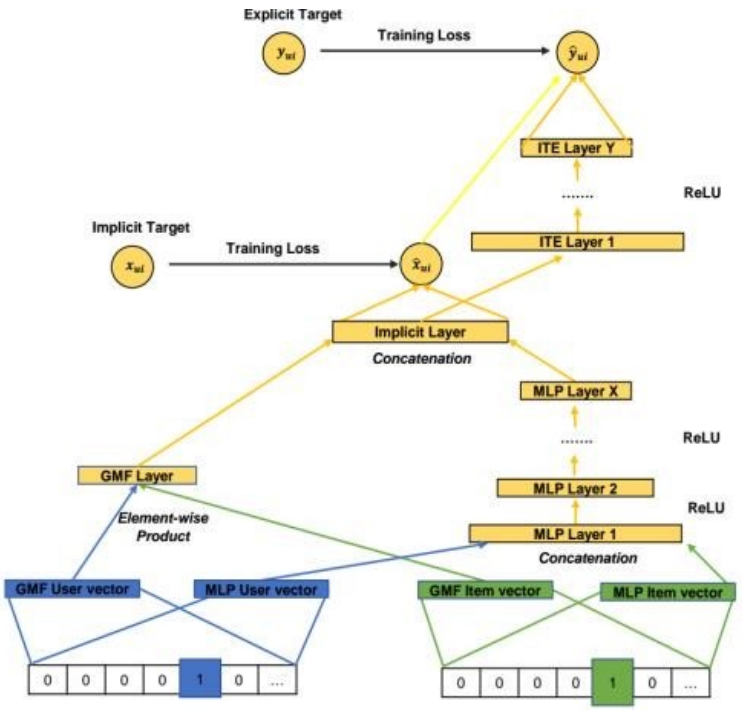

Implict to Explict model

- Các công thức biểu diễn:

$$\phi^{GMF} = \mathbf{p}_u^G \odot \mathbf{q}_i^G,$$

$$\phi^{MLP} = a_X(\mathbf{W}_X^T(a_{X-1}(...a_2(\mathbf{W}_2^T \begin{bmatrix} \mathbf{p}_u^M \\ \mathbf{q}_i^M \end{bmatrix} + \mathbf{b}_2)...)) + \mathbf{b}_X),$$

$$\phi^I = \begin{bmatrix} \phi^{GMF} \\ \phi^{MLP} \end{bmatrix},$$

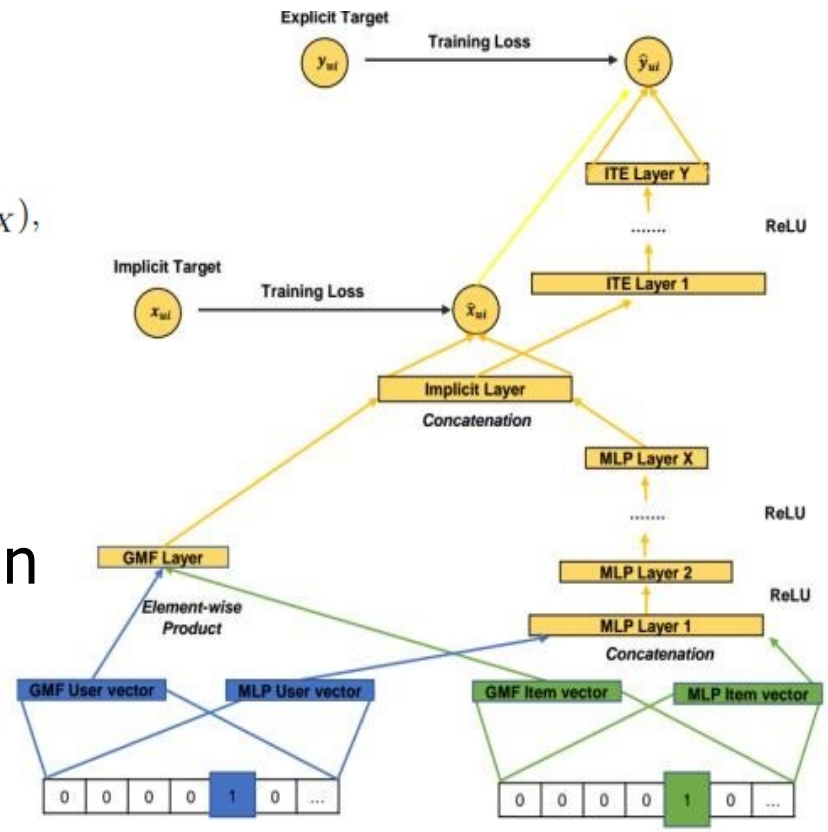

- φ^I :vector đầu ra cuối cùng của mô hình con trong dự đoán tương tác tiềm ẩn.

Implict to Explict model

- Các công thức biểu diễn:

$$\hat{x}_{ui} = a_{out}(\mathbf{h}_I^T \phi^I),$$
$$\phi^{ITE} = c_Y(\mathbf{V}_Y^T(c_{Y-1}(...c_2(\mathbf{V}_2^T \phi^{ITE} + \mathbf{d}_2)...)) + \mathbf{d}_Y),$$
$$\hat{y}_{ui} = c_{out}(\mathbf{h}_E^T \phi^{ITE})$$

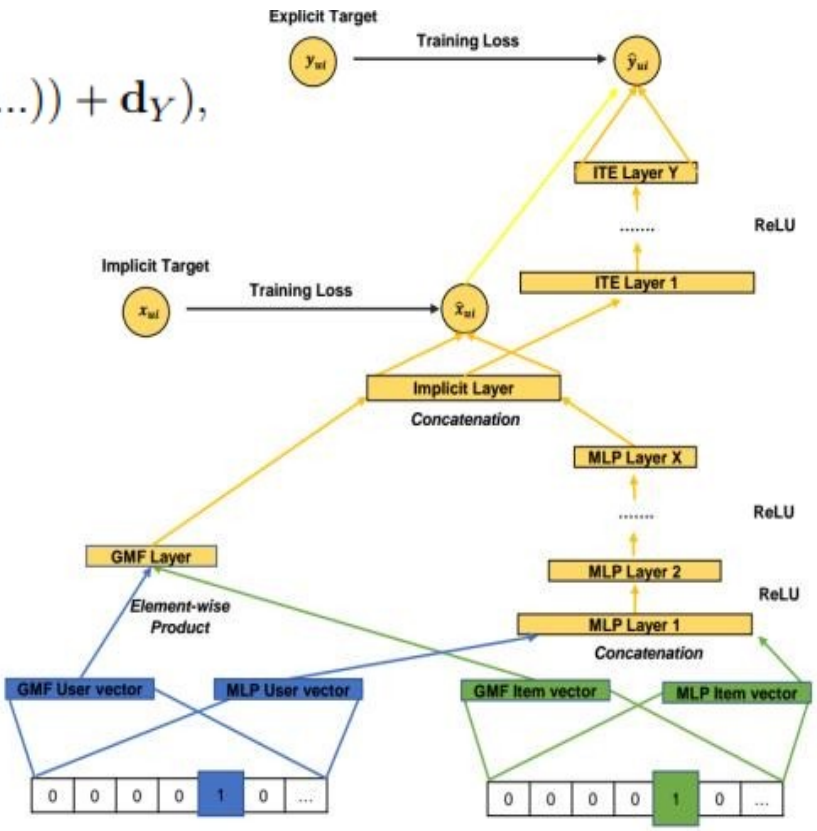

- φ^{ITE} :vector đầu ra cuối cùng của mô hình ở tầng cuối cùng trong các tầng đẩy thông qua ITE.
- $\hat{x}_{ui}$, $\hat{y}_{ui}$ các giá trị dự đoán của hành vi tiềm ẩn và rõ ràng, a với c là hàm sigmoid.

Implict to Explict model

- Công thức dự đoán mô hình:

$$\phi^I = f^I(\mathbf{u}, \mathbf{i}),$$
$$\hat{x}_{ui} = a_{out}(\mathbf{h}_I^T \phi^I),$$
$$\hat{y}_{ui} = f^{ITE}(\phi^I)$$

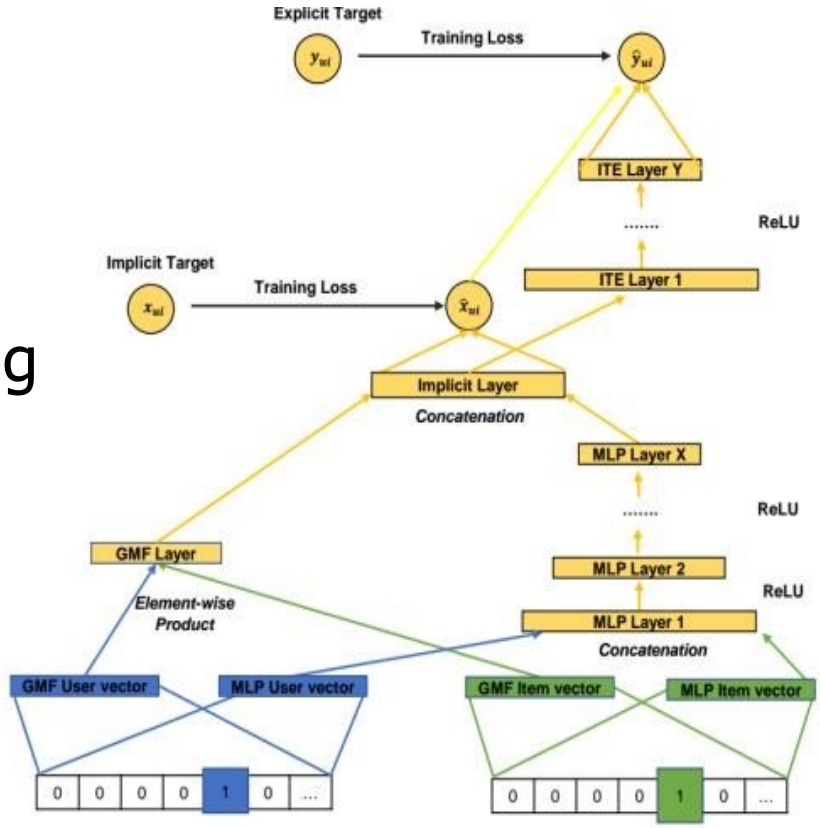

❖ Điểm số dự đoán cho tương tác người dùng, sản phẩm:

$$\hat{r}_{ui} = \hat{x}_{ui}\hat{y}_{ui}$$

Implict to Explict model

- Hàm mục tiêu: $\mathcal{L} = \eta\mathcal{L}_I(\hat{x}, x) + \mathcal{L}_E(\hat{y}, y) + \lambda\mathcal{R}(u, i)$

  - $\mathcal{L}_I, \mathcal{L}_E$ hàm lỗi của hành vi tường ẩn và rõ ràng.

$$\mathcal{L}_I = \sum_{(u,i)\in\mathcal{X}^+\cup\mathcal{X}^-} x_{ui}\log\hat{x}_{ui} + (1 - x_{ui})\log(1 - \hat{x}_{ui})$$

$$\mathcal{L}_E = \sum_{(u,i)\in\mathcal{Y}^+\cup\mathcal{Y}^-} y_{ui}\log\hat{y}_{ui} + (1 - y_{ui})\log(1 - \hat{y}_{ui})$$
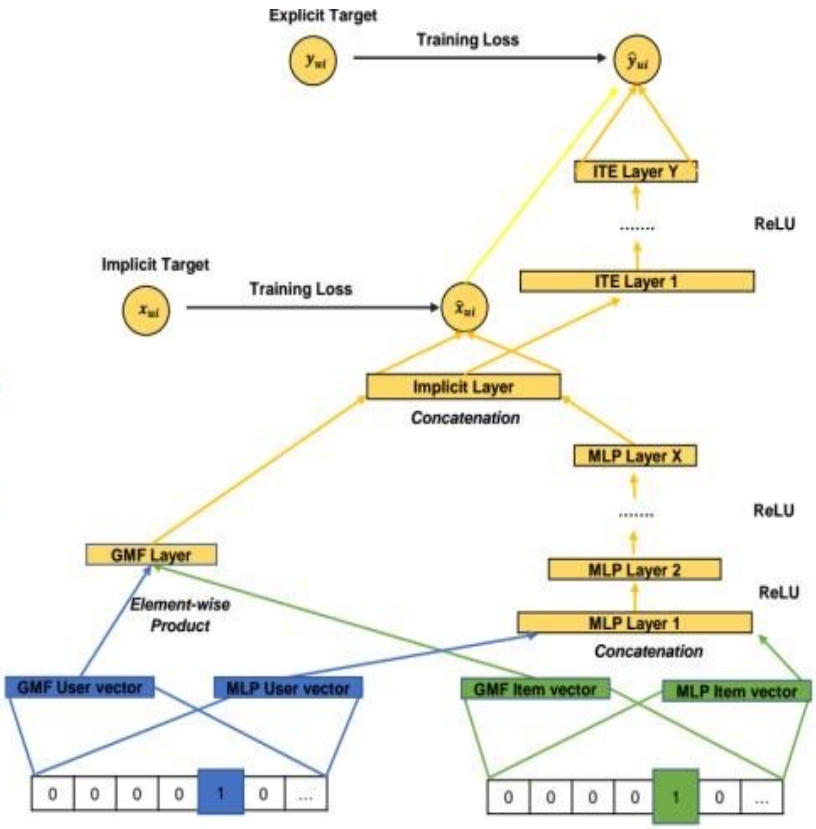
$$\mathcal{R}(u, i) = \sum_u ||\mathbf{p_u}||_2^2 + \sum_i ||\mathbf{q_i}||_2^2$$