Học viện Công nghệ Bưu chính Viễn thông
Khoa Công nghệ thông tin 1

HỆ KHUYẾN NGHỊ

Gợi ý dựa trên nội dung

Dao Thi Thuy Quynh

Gợi ý dựa trên nội dung

- Trong khi các phương pháp lọc cộng tác không yêu cầu bất kỳ thông tin nào về các items:
  - Tuy nhiên, có thể hiệu quả hơn khi khai thác các thông tin này
  - E.g: Gợi ý tiểu thuyết giả tưởng cho những người đã từng thích tiểu thuyết giả tưởng
- Chúng ta cần:
  - Thông tin về các items có sẵn như thể loại ("nội dung"- content)
  - Một số loại user profile mô tả những gì user thích (xu hướng/sở thích)
- Nhiệm vụ:
  - Học xu hướng sở thích của user
  - Xác định/gợi ý các items tương đồng với sở thích của user

"Nội dung- content" là gì?

- Hầu hết các kỹ thuật gợi ý dựa trên nội dung được áp dụng để gợi ý 'text documents'.
  - Ví dụ như các trang web hoặc tin tức.
- Nội dung của các items được biểu diễn dưới dạng 'text documents'.
  - Bằng những mô tả bằng văn bản về các đặc điểm cơ bản của chúng.
  - **Có cấu trúc:** Mỗi item được biểu diễn với cùng một tập các thuộc tính (attributes)

Title	Genre	Author	Type	Price	Keywords
The Night of the Gun	Memoir	David Carr	Paperback	29.90	Press and journalism, drug addiction, personal memoirs, New York
The Lace Reader	Fiction, Mystery	Brunonia Barry	Hardcover	49.90	American contemporary fiction, detective, historical
Into the Fire	Romance, Suspense	Suzanne Brockmann	Hardcover	45.90	American fiction, murder, neo-Nazism

- Phi cấu trúc: mô tả tự do (free-text), mô tả tự do bằng văn bản. Ví dụ: tóm tắt nôi dung sách, review phim, mô tả sản phẩm trên shopee. Dùng NLP (TF-IDF, embedding để có vector, dùng consione simmilarity tính độ tương tự)

Biểu diễn nội dung

- Nội dung được sử dụng để biểu diễn cho item và user
  - **Item representation**

Title	Genre	Author	Type	Price	Keywords
The Night of the Gun	Memoir	David Carr	Paperback	29.90	Press and journalism, drug addiction, personal memoirs, New York
The Lace Reader	Fiction, Mystery	Brunonia Barry	Hardcover	49.90	American contemporary fiction, detective, historical
Into the Fire	Romance, Suspense	Suzanne Brockmann	Hardcover	45.90	American fiction, murder, neo-Nazism

  - **User profile**

Title	Genre	Author	Type	Price	Keywords
…	Fiction	Brunonia, Barry, Ken Follett	Paperback	25.65	Detective, murder, New York

Độ tương đồng của item với user

- Các cách tiếp cận cơ bản
  - Tính mức độ tương đồng của một 'unseen item' với một user dựa trên sự trùng lặp từ khóa (e.g. sử dụng Dice coefficient)

- **Item representation**

Title	Genre	Author	Type	Price	Keywords
The Night of the Gun	Memoir	David Carr	Paperback	29.90	Press and journalism, drug addiction, personal memoirs, New York
The Lace Reader	Fiction, Mystery	Brunonia Barry	Hardcover	49.90	American contemporary fiction, detective, historical
Into the Fire	Romance, Suspense	Suzanne Brockmann	Hardcover	45.90	American fiction, murder, neo-Nazism

- **User profile**

Title	Genre	Author	Type	Price	Keywords
...	Fiction	Brunonia, Barry, Ken Follett	Paperback	25.65	Detective, murder, New York

$$\frac{2 \times |keywords(b_i) \cap keywords(b_j)|}{|keywords(b_i)| + |keywords(b_j)|}$$

$keywords(b_j)$ mô tả Book b_j bởi một tập các keywords

  - Hoặc sử dụng và kết hợp nhiều số liệu

Biểu diễn TF-IDF cho mô tả dạng văn bản

- Biểu diễn từ khóa một cách đơn giản gặp nhiều vấn đề
  - Đặc biệt trong quá trình tự động trích xuất vì
    - không phải mọi 'từ' đều có tầm quan trọng như nhau
    - văn bản dài thường dễ trùng lặp với user profile
- Tiêu chuẩn đánh giá: TF-IDF (term frequency – inverse document frequency)
  - Mã hóa các 'text document' trong không gian Euclid đa chiều
    - Sửu dụng vector trọng số
  - TF: **Đo lường tần suất xuất hiện (mật độ) của một thuật ngữ trong 1 văn bản**
    - giả định rằng các thuật ngữ quan trọng thường xuất hiện thường xuyên
    - chuẩn hóa phải được thực hiện khi tính đến độ dài của văn bản
  - IDF: **Mục đích nhằm giảm trọng số của các thuật ngữ xuất hiện trong tất cả các văn bản**

TF- IDF (2)

- Từ khóa i và văn bản j
- $TF(i,j)$
  - "term frequency" của từ khóa i trong văn bản j
- $IDF(i)$
  - "inverse document frequency" tính bởi: $\boldsymbol{IDF(i) = log\frac{N}{n(i)}}$
    - N : số lượng tất cả các văn bản được đề xuất
    - $n(i)$: số lượng các văn bản từ N văn bản có từ khóa i xuất hiện
- $TF - IDF$
  - Được tính bởi công thức: $\boldsymbol{TF\text{-}IDF(i,j) = TF(i,j) * IDF(i)}$

Ví dụ TF- IDF

- Term frequency:
  - Mỗi văn bản là một "count vector" trong không gian $\mathbb{N}^{|v|}$

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	157	73	0	0	0	0
Brutus	4	157	0	1	0	0
Caesar	232	227	0	2	1	1
Calpurnia	0	10	0	0	0	0
Cleopatra	57	0	0	0	0	0
mercy	1.51	0	3	5	5	1
worser	1.37	0	1	1	1	0

Vector v với số chiều $|v| = 7$

Example taken from http://informationretrieval.org

Ví dụ TF- IDF

- Kết hợp trọng số bởi TF-IDF
  - Mỗi văn bản bây giờ được biểu diễn bằng một vector các giá trị thực với trọng số xác định bởi $TF\text{-}IDF \in \mathbb{R}^{|v|}$

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	157	73	0	0	0	0
Brutus	4					
Caesar	232					
Calpurnia	0					
Cleopatra	57					
mercy	1.51					
worser	1.37					

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	5.25	3.18	0	0	0	0.35
Brutus	1.21	6.1	0	1	0	0
Caesar	8.59	2.54	0	1.51	0.25	0
Calpurnia	0	1.54	0	0	0	0
Cleopatra	2.85	0	0	0	0	0
mercy	1.51	0	1.9	0.12	5.25	0.88
worser	1.37	0	0.11	4.15	0.25	1.95

Example taken from http://informationretrieval.org

Cải thiện không gian vector

- Các vectơ thường dài và thưa
- Loại bỏ “stop words”
  - Các từ xuất hiện hầu hết trong mọi văn bản.
  - ví dụ: "a", "the", "on", …
- Sử dụng “stemming”
  - Nhằm mục đích thay thế các biến thể của các từ bằng từ gốc chung
  - ví dụ: "went" - "go", "stemming" - "stem", …
- Giảm kích thước
  - chỉ sử dụng n từ tiêu biểu nhất để loại bỏ "nhiễu" khỏi dữ liệu. Ví dụ. Top 100 từ
- Sử dụng kiến thức từ vựng, các phương pháp phức tạp hơn để trích chọn đặc trưng
  - Xóa các từ không thuộc lĩnh vực

Cải thiện không gian vector

- Phát hiện các cụm từ dưới dạng thuật ngữ
  - Mô tả tốt cho một văn bản hơn là chỉ dùng các từ đơn lẻ
  - e.g. "United Nations"
- Các hạn chế
  - Không cung cấp thông tin về ngữ nghĩa

Độ tương đồng Cosine

- Độ tương đồng giữa các vector: độ tương đồng Cosine (góc)
  - Tính toán dựa trên góc giữa các vectors

$$sim\left(\vec{a},\vec{b}\right)=\frac{\vec{a}\cdot\vec{b}}{|\vec{a}|*|\vec{b}|}$$

- $\vec{a}$ = vector TF-IDF của **user profile** (hoặc item A)
- $\vec{b}$ = vector TF-IDF của **item chưa xem** (hoặc item B)

Tính cosine → **xếp hạng item theo độ giống user**

Gợi ý items

- Phương pháp đơn giản: láng giềng gần nhất
  - Tập văn bản D đã được đáng giá bởi user (thích/không thích): Tường minh, ngầm ẩn
  - Tìm n láng giềng gần nhất trong D của một item i
  - Sử dụng thước đo độ tương đồng (như độ đo cosine) để nắm bắt độ tương đồng giữa hai văn bản
  - Sử dụng các láng giếng này để đánh giá cho i
    - e.g. $k = 5$ items tương tự i nhất.
      4 trong k được thích bởi user đang xem xét => item i cũng có thể được thích bởi user này
  - Biến:
    - Thay đổi kích thước vùng lân cận k
    - Tăng/giảm ngưỡng độ đo tương đồng để ngăn hệ thống gợi ý ra các items mà user đã biết đến

Gợi ý items

```
Item i (chưa xem)
        ↓
Tính similarity với các item trong D
        ↓
Chọn k item giống nhất
        ↓
Xem user thích/không thích các item đó
        ↓
Suy ra user có thích item i không
```

Gợi ý items

- Phù hợp để mô hình hóa short-term interests / follow-up stories
- Được sử dụng kết hợp với phương pháp khác để mô hình hóa các xu hướng dài hạn
- Chất lượng truy hồi phụ thuộc vào khả năng cá nhân để tạo ra các truy vấn với từ khóa phù hợp.

❑Truy xuất dựa trên truy vấn: Phương pháp Rocchio

- Hê thống SMART: users được phép đánh giá (thích hợp/ không thích hợp) các tài liệu đã truy xuất (phản hồi)
- Sau đó, hệ thống sẽ học một nguyên mẫu của các văn bản có thích hợp/ không thích hợp
- Các truy vấn sau đó sẽ tự động được mở rộng với các điều khoản / trọng số của các văn bản thích hợp

Gợi ý items

- Tư tưởng của gợi ý dựa trên nội dung:
  - Biểu diễn của item là biểu diễn từ đặc trưng trên nội dung (khác với lọc cộng tác, biểu diễn của item được học từ ma trận tương tác)
  - Học biểu diễn của user theo biểu diễn của nội dung của item (giúp hiểu được user thích các thuộc tính của item như thế nào)
  - Tính độ tương đồng user và item

Phương pháp Rocchio

- Tập các văn bản D^+ (được thích) và D^- (không được thích)
  - Tính toán vectơ nguyên mẫu cho các danh mục này.

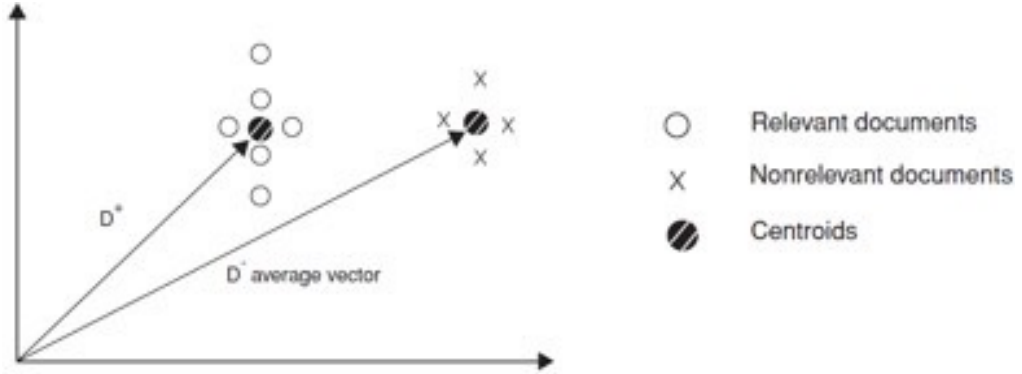

- Tính toán truy vấn đã sửa đổi Qi+1 từ truy vấn hiện tại Qi :

$$Q_{i+1} = \alpha * Q_i + \beta\left(\frac{1}{|D^+|}\sum_{d^+\in D^+} d^+\right) - \gamma\left(\frac{1}{|D^-|}\sum_{d^-\in D^-} d^-\right)$$

- α, β, γ sử dụng để "fine-tune" phản hồi
  - α trọng số cho truy vấn gốc
  - β trọng số cho phản hồi tích cực
  - γ trọng số cho phản hồi tiêu cực

- Thường chỉ sử dụng các phản hồi tích cực vì chúng có giá trị hơn các phản hồi tiêu cực.

Những thách thức của phương pháp Rocchio

- Số lượng xếp hạng items là cần thiết để xây dựng mô hình
  - Có thể được tự động hóa bằng cách cố gắng nắm bắt các đánh giá "implicit" của user (như click vào văn bản)
  - Pseudo relevance Feedback: Giả sử rằng n tài liệu đầu tiên phù hợp nhất để truy vấn. Tập D^- không được sử dụng cho đến khi có phản hồi tiêu cực.
- Cần có sự tương tác của user trong giai đoạn truy xuất
  - Tinh chỉnh truy vấn tương tác có thể tạo ra cơ hội mới trong việc thu thập thông tin
  - Giúp user biết được từ nào nên được sử dụng để có thể nhận thông tin mong muốn

Phương pháp xác suất

- Gợi ý giống như bài toán phân loại văn bản cổ điển
- Tiếp cận đơn giản:
    - 2 lớp: 0/1
    - Biểu diễn văn bản dưới dạng logic 0/1
    - Tính xác xuất để văn bản đó là 0 hoặc 1 dựa vào định lý Bayes

Doc-ID	recommender	intelligent	learning	school	Label
1	1	1	1	0	1
2	0	0	1	1	0
3	1	1	0	0	1
4	1	0	1	1	1
5	0	0	0	1	0
6	1	1	0	0	?

$$
\begin{aligned}
& P(X|Label = 1) \\
&= P(recommender = 1|Label = 1) \\
&\times P(intelligent = 1|Label = 1) \\
&\times P(learning = 0|Label = 1) \\
&\times P(school = 0|Label = 1) \\
&= {}^{3}/_{3} \times {}^{2}/_{3} \times {}^{1}/_{3} \times {}^{2}/_{3} \approx 0.149
\end{aligned}
$$

Phân loại tuyến tính

- Hầu hết các phương pháp học đều nhằm mục đích tìm các hệ số của một mô hình tuyến tính
- Bộ phân loại đơn giản trong không gian hai chiều, có thể được biểu diễn dưới dạng một đường thẳng phân tách
  - Đường phân tách có dạng $\boldsymbol{w_1x_1 + w_2x_2 = b}$
    - x_1 và x_2 tương ứng với vector biểu diễn của một tài liệu (e.g. trọng số TF IDF)
    - w_1, w_2 và b là các tham số phải học
    - Phân loại một văn bản bằng cách kiểm tra $w_1x_1 + w_2x_2 > b$
  - Trong không gian n chiều, hàm phân loại có dạng $\vec{w}^T\vec{x} = b$
  - Các phương pnap khác:
    - Phân loại Naive Bayes, phương pháp Rocchio, giải thuật Windrow-Hoff, Support vector machines

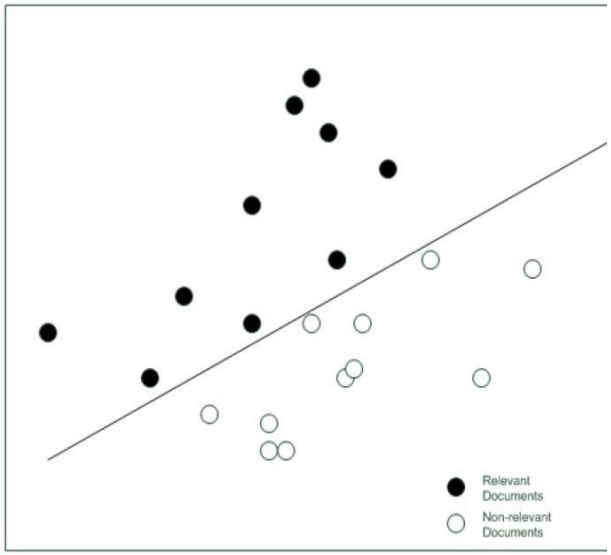

Cải tiến

- Lưu ý: Sự độc lập có điều kiện của các sự kiện trên thực tế không được quan tâm
  - "New York", "Hong Kong"
  - Tuy nhiên, vẫn có thể đạt được độ chính xác tốt
- Cách biểu diễn logic 0/1 đơn giản
  - Vị trí các từ là độc lập
  - Mất mát số lượng từ khóa
- Các phương pháp xác suất phức tạp hơn
  - e.g., ước tính xác suất của từ v xuất hiện trong văn bản của lớp C bằng tần suất tương đối của v trong tất cả các văn bản cùng lớp
- Sử dụng các thuật toán phân loại tuyến tính khác (học máy)
  - Support Vector Machines, ..
- Sử dụng các phương pháp truy xuất thông tin khác (được sử dụng bởi các công cụ tìm kiếm ...)

Các mô hình quyết định rõ ràng

- Cây quyết định cho bài toán gợi ý
  - các nút bên trong được gán nhãn bằng các đặc trưng của item (từ khóa)
  - được sử dụng để phân chia các ví dụ thử nghiệm
    - sự tồn tại hay không tồn tại của một từ khóa
  - trong cài đặt cơ bản, chỉ có hai lớp xuất hiện tại các nút lá
    - thích hoặc không thích
  - cây quyết định có thể tự động được xây dựng từ dữ liệu huấn luyện
  - hoạt động tốt nhất với số lượng đặc trưng ít
  - sử dụng các đặc trưng "meta" như tên tác giả, thể loại, ... thay vì TF-IDF.

Các mô hình quyết định rõ ràng (2)

- Nguyên tắc quy nạp
  - xây dựng trên giải thuật RIPPER
  - hiệu suất tốt so với các phương pháp phân loại khác
    - kĩ thuật hậu cắt tỉa- postprunning của RIPPER
    - mở rộng cho phân loại e-mail

      xem xét đến cấu trúc của văn bản

- Ưu điểm chính:
  - các quy tắc quyết định được sử dụng làm cơ sở để tạo ra các giải thích cho gợi ý
  - kiến thức trong các lĩnh vực đã có có thể được tích hợp vào các mô hình

Trích chọn đặc trưng

- Là quá trình chọn ra một tập con các đặc trưng sẵn có
- Tồn tại các chiến lược khác nhau giúp chọn ra các đặc trưng để sử dụng
  - dựa trên kiến thức lĩnh vực và thông tin từ vựng WordNet (Pazzani và Billsus 1997)
  - dựa trên tần suất để loại bỏ các từ xuất hiện "quá hiếm" hoặc "quá thường xuyên" (Chakrabarti 2002)
- Không thích hợp cho tập văn bản lớn
  - Tốt để đánh giá tầm quan trong của các đặc trưng riêng lẻ (từ khóa) một cách độc lập và xây dựng một
    danh sách các từ khóa "tốt" đã được xếp hạng.
- Đánh giá khả năng sử dụng của các từ khóa: e.g. X^2, đo thông tin qua lại hoặc chỉ số phân loại
  Fisher.

Hạn chế của gợi ý dựa trên nội dung

- Chỉ sử dụng từ khóa có thể không đủ để đánh giá chất lượng / mức độ thích hợp của một văn bản hoặc trang web
  - tính cập nhật, khả năng sử dụng, tính thẩm mỹ, phong cách viết
  - nội dung cũng có thể bị hạn chế / quá ngắn
  - nội dung có thể không thể trích xuất tự động (đa phương tiện)
- Đòi hỏi giai đoạn tăng tốc
  - Vẫn yêu cầu một số dữ liệu huấn luyện
  - Web 2.0: sử dụng các nguồn khác để học xu hướng user
- Chuyên môn hóa quá mức
  - Các thuật toán có xu hướng đề xuất "các thứ giống nhau"
  - Hoặc: các items mới khá giống nhau

Kết luận

- Ngược lại với các phương pháp lọc cộng tác, các kỹ thuật dựa trên nội dung không yêu cầu cộng đồng user để hoạt động
- Các phương pháp tiếp cận ở trên nhằm mục đích học một mô hình của xu hướng user dựa trên phản hồi explicit hoặc implicit
  - Suy luận từ phản hồi ngầm của hành vi user có thể khó khăn
- Các đánh giá cho thấy rằng hệ gợi ý có thể đạt được độ chính xác cao với sự trợ giúp của các kỹ
  thuật máy học
  - Các kĩ thuật này không yêu cầu cộng đồng user.
- Danh sách gợi ý chứa quá nhiều mục tương đồng
  - Tất cả các kỹ thuật học đều yêu cầu một lượng dữ liệu huấn luyện nhất định
  - Một số phương pháp học có xu hướng "overfit"
- Hệ thống dựa trên nội dung thuần túy hiếm khi được tìm thấy trong môi trường thương mại