Học viện
Công nghệ Bưu chính Viễn thông

PHÂN TÍCH DỮ LIỆU CHUỖI THỜI GIAN

Mô hình thống kê

Nội dung

- Mô hình hồi qui tuyến tính (linear regression)
- Mô hình tự hồi qui (autoregression)
- Mộ hình trung bình động (moving average)
- Mô hình tự hồi qui véc tơ (vector autoregression)
- Bộ lọc Kalman
- Mô hình Markov ẩn (hidden Markov model)
- Mô hình Bayes cho dữ liệu chuỗi thời gian

Mô hình hồi qui tuyến tính

- **Hồi qui tuyến tính (linear regression)**: mô hình hoá mối quan hệ giữa biến phụ thuộc (Y_t) và một/tập hợp biến độc lập (X).
  - Công thức tổng quát:

$$Y_t = \beta_0 + \beta_1 X_{1,t} + \beta_2 X_{2,t} + \cdots + \beta_k X_{k,t} + \epsilon_t$$

    - β_i : hệ số hồi qui.
    - ϵ_t : nhiễu (sai số).
  - Hồi qui tuyến tính là công cụ cơ bản để phân tích chuỗi thời gian.
  - Thích hợp để:
    - Dự báo xu hướng,
    - mùa vụ,
    - ảnh hưởng biến ngoài.

Mô hình hồi qui tuyến tính

- **Hồi qui tuyến tính cho Chuỗi thời gian**
  - **Ví dụ minh họa –** Dự báo doanh số bán hàng theo thời gian.
    - Dữ liệu: Doanh số tháng (Y), chi tiêu quảng cáo (X), và chỉ số thời gian (t).
    - Mô hình hồi qui:

$$Sales_t = \beta_0 + \beta_1 t + \beta_2 Advertising_t + \epsilon_t$$

- Nếu $\beta_1 > 0$: xu hướng tăng theo thời gian.
- Nếu $\beta_2 > 0$: chi tiêu quảng cáo làm tăng doanh số.

Mô hình hồi qui tuyến tính

- **Hồi qui tuyến tính cho Chuỗi thời gian**
  - **Ví dụ minh họa** – Dự báo doanh số
    - Dữ liệu giả định:

Tháng	Quảng cáo (triệu)	Doanh số (nghìn sp)
1	10	200
2	12	230
3	15	260
4	20	310
5	22	330
6	25	370

Mô hình hồi qui tuyến tính

- **Hồi qui tuyến tính (linear regression)**: mô hình hoá mối quan hệ giữa biến phụ thuộc (Y_t) và một/tập hợp biến độc lập (X).
  - Công thức tổng quát:

$$Y_t = \beta_0 + \beta_1 X_{1,t} + \beta_2 X_{2,t} + \cdots + \beta_k X_{k,t} + \epsilon_t$$

    - β_i : hệ số hồi qui.
    - ϵ_t : nhiễu (sai số).
  - Dữ liệu có **thứ tự thời gian**. Có thể chứa:
    - Xu hướng (trend)
    - Mùa vụ (seasonality)
    - Tự tương quan (autocorrelation)

→hồi qui tuyến tính cần được điều chỉnh để xử lý các đặc thù này.

Mô hình hồi qui tuyến tính

➢ Hồi qui tuyến tính cho Chuỗi thời gian

- **Ý tưởng xử lý đặc thù:** Biến phụ thuộc tại thời điểm *t* được giải thích bởi:
  - Biến giải thích ngoài (external regressors).
  - Các giá trị quá khứ của chính chuỗi (lagged variables).
- Ví dụ mô hình:

$$Y_t = \beta_0 + \beta_1 t + \beta_2 D_{season} + \beta_3 Y_{t-1} + \epsilon_t$$

  - t : chỉ số thời gian (xu hướng).
  - D_{season} : biến giả cho mùa vụ.
  - Y_{t-1} : giá trị trễ.

Mô hình hồi qui tuyến tính

➢ **Ưu và nhược điểm**

- **Ưu điểm:**
  - Dễ hiểu, trực quan.
  - Giải thích rõ tác động của biến độc lập.
- **Nhược điểm:**
  - Giả định tuyến tính, không phù hợp với quan hệ phi tuyến.
  - Dễ bị **tự tương quan phần dư** (residual autocorrelation).
  - Không xử lý tốt dữ liệu không dừng (non-stationary).

→Cần mở rộng (ARIMA, ARIMAX, VAR...) để xử lý tính chất động và phụ thuộc thời gian của dữ liệu.

Mô hình hồi qui tuyến tính

➢ Hồi qui tuyến tính cho Chuỗi thời gian

- **Bàn luận thêm** về tính tuyến tính trong các mô hình hồi quy và trong các mô hình chuỗi thời gian
  - Như chúng ta đã biết trong các mô hình hồi quy chính quy có dạng: $y = f(x_1, x_2, \ldots, x_p, \beta_0, \beta_1, \ldots, \beta_p) + \varepsilon$. Một số mô hình có thể chuyển về dạng hồi quy tuyến tính.
    Ví dụ như $y = \beta_0 + \beta_1 x_1^2 + \varepsilon$ khi đặt $w = x_1^2$
  - Tính tuyến tính trong bối cảnh chuỗi thời gian hoàn toàn khác so với tính tuyến tính trong bối cảnh hồi quy, vì ở đây nó có nghĩa là tính tuyến tính trong các biến giải thích $(x_{t-1}, x_{t-2}, \ldots)$ chứ không phải trong các tham số mô hình. Hầu hết các mô hình chuỗi thời gian đều không tuyến tính về các tham số. Đây là một trong những khó khăn khi nghiên cứu chuỗi thời gian.

Mô hình hồi qui tuyến tính

➢ Hồi qui tuyến tính cho Chuỗi thời gian

- **Bàn luận thêm** về mô hình "tĩnh" và "động"
  - Các mô hình hồi quy truyền thống có dạng: $y = f(x_1, x_2, \ldots, x_p, \beta_0, \beta_1, \ldots, \beta_p) + \varepsilon$ áp dụng cho dữ liệu chuỗi thời gian được coi là mô hình tĩnh, tức là chúng không động.
    - Chúng phụ thuộc vào biến ε_t, biến này biểu diễn nhiễu động tác động đến hệ thống tại thời điểm t, nhưng hiệu ứng của nó không mở rộng đến chu kỳ thời gian $(t + 1)$
    - ε_{t+1} và ε_t không tương quan với với nhau theo định nghĩa của quá trình nhiễu trắng

    =>nên các hệ thống như vậy không có bộ nhớ, theo nghĩa là chúng hoàn toàn "quên" các nhiễu động đã xảy ra trong quá khứ, do đó các hệ thống như vậy được gọi là "hệ thống tĩnh".

Mô hình hồi qui tuyến tính

➢ Hồi qui tuyến tính cho Chuỗi thời gian

- **Bàn luận thêm** về mô hình "tĩnh" và "động"
  - Các mô hình ngẫu nhiên chuỗi thời gian phụ thuộc vào lịch sử của chuỗi (y_{t-k}) hoặc vào các nhiễu loạn đã xảy ra trong quá khứ (ε_{t-k}) hoặc vào cả hai là mô hình động. Ba nhóm chính:
    - Mô hình tự hồi quy: Ví dụ: $y_t = \beta_0 + \beta_1 y_{t-1} + \varepsilon_t$
      ε_{t-1} ảnh hưởng tới y_t thông qua y_{t-1}
    - Mô hình trung bình động: hệ thống tại thời điểm t có liên hệ trực tiếp với các nhiễu loạn đã xảy ra trong quá khứ.
      Ví dụ: $y_t = \beta_0 + \varepsilon_t + \beta_1 \varepsilon_{t-1}$; $t = 1.2. \dots . n$
    - Mô hình chuỗi thời gian ngẫu nhiên bao gồm cả phần tự hồi quy và phần trung bình động.
      Ví dụ: $y_t = \beta_0 + \beta_1 y_{t-1} + \varepsilon_t + \beta_2 \varepsilon_{t-1}$

Mô hình hồi qui tuyến tính

➢ Quá trình Ngẫu nhiên Tuyến tính

- Các mô hình động giả định sự hiện diện của một dạng tự tương quan cụ thể giữa các quan sát của chuỗi thời gian thuộc về các quá trình tuân theo hành vi của các mô hình đó. Điều này có thể gây ra một số khó khăn khi xử lý các chuỗi thời gian này, đặc biệt nếu hệ số tự tương quan lớn.
- Các nhà khoa học khám phá khả năng nghiên cứu các quá trình như vậy thông qua một quy trình đơn giản hơn. **Wold (1938)** đã công bố lý thuyết của mình, chỉ ra rằng:

"Mọi quá trình dừng đều có thể được biểu thị dưới dạng một tổ hợp tuyến tính của các biến ngẫu nhiên không tương quan với giá trị trung bình bằng không và phương sai σ^2 không đổi"

Mô hình hồi qui tuyến tính

➢ Quá trình Ngẫu nhiên Tuyến tính

- Quá trình ngẫu nhiên $\{y_t\}$ được gọi là quá trình tuyến tính tổng quát nếu có thể biểu diễn nó dưới dạng:

$$y_t = \mu + \varepsilon_t + \psi_1\varepsilon_{t-1} + \psi_2\varepsilon_{t-2} + \cdots, t = 0, \pm 1, \pm 2, \ldots$$

$$y_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$$

Trong đó $\{\varepsilon_t\}$ là quá trình nhiễu trắng, μ là hằng số và $\{\psi_t\}$ là một chuỗi các giá trị cố định.

Mô hình hồi qui tuyến tính

➢ Quá trình Ngẫu nhiên Tuyến tính

- Quá trình tuyến tính tổng quát

$$y_t = \mu + \varepsilon_t + \psi_1\varepsilon_{t-1} + \psi_2\varepsilon_{t-2} + \cdots \quad ,t = 0, \pm 1, \pm 2, \ldots$$

là dừng nếu một trong các điều kiện sau được thỏa mãn:

  - $\psi_1, \psi_2, \ldots$ là hữu hạn.
  - $\sum_{i=0}^{\infty} \psi_i^2 < \infty$, điều này đảm bảo phương sai là hữu hạn.

- ❑ Nếu quá trình là dừng thì μ được coi là trung bình của quá trình, ngược lại, nó chỉ được coi là một điểm tham chiếu.
- ❑ Một số mô hình sẽ giả sử $\mu = 0$, và trong trường hợp $\mu \neq 0$, chúng ta sẽ giả sử y_t biểu diễn chuỗi ban đầu sau khi trừ đi hằng số μ.
- ❑ Một số mô hình có nhiễu ε_t với kì vọng khác 0, chúng ta có thể đưa về nhiễu trắng $w_t = \varepsilon_t - E[\varepsilon_t]$ (phần dư sẽ cộng vào μ).

Mô hình hồi qui tuyến tính

➢ Quá trình Ngẫu nhiên Tuyến tính

- Quá trình tuyến tính tổng quát

$$y_t = \mu + \varepsilon_t + \psi_1\varepsilon_{t-1} + \psi_2\varepsilon_{t-2} + \cdots \quad ,t = 0, \pm 1, \pm 2, \ldots$$

  - Trong một số điều kiện nhất định, chúng ta có thể biểu diễn quá trình tuyến tính tổng quát theo dạng sau:

$$y_t = \varepsilon_t + \pi_1 y_{t-1} + \pi_2 y_{t-2} + \cdots.$$

$$(1 - \pi_1 \mathrm{B} - \pi_2 \mathrm{B}^2 - \pi_2 \mathrm{B}^2 - \cdots) y_t = \varepsilon_t$$

$$\pi(B) = (1 - \pi_1 \mathrm{B} - \pi_2 \mathrm{B}^2 - \pi_2 \mathrm{B}^2 - \cdots) = 1 - \sum_{i=1}^{\infty} \pi_i \mathrm{B}^{\mathrm{i}}$$

$$\pi(B) y_t = \varepsilon_t$$

Mô hình hồi qui tuyến tính

➢ Quá trình Ngẫu nhiên Tuyến tính

- Quá trình tuyến tính tổng quát

$$y_t = \mu + \varepsilon_t + \psi_1\varepsilon_{t-1} + \psi_2\varepsilon_{t-2} + \cdots \quad ,t = 0, \pm 1, \pm 2, \ldots$$

  - Trong một số điều kiện nhất định, chúng ta có thể biểu diễn quá trình tuyến tính tổng quát theo dạng sau:

$$y_t = \varepsilon_t + \psi_1\varepsilon_{t-1} + \psi_2\varepsilon_{t-2} + \cdots.$$

$$y_t = (1 + \psi_1 B + \psi_2 B^2 + \psi_2 B^2 + \cdots)\varepsilon_t$$

$$\psi(B) = \sum_{i=0}^{\infty} \psi_i B^i \ ; \quad \psi_0 = 1$$

$$y_t = \psi(B)\varepsilon_t$$

Mô hình hồi qui tuyến tính

➢ Quá trình Ngẫu nhiên Tuyến tính

- Ví dụ: $y_t = \varepsilon_t + 0.5\, y_{t-1}$

$$y_{t-1} = \varepsilon_{t-1} + 0.5\, y_{t-2}$$

$$y_{t-2} = \varepsilon_{t-2} + 0.5\, y_{t-3}$$

$$y_{t-3} = \varepsilon_{t-3} + 0.5\, y_{t-4}$$

$$\begin{aligned} y_t &= \varepsilon_t + 0.5\,[\varepsilon_{t-1} + 0.5\, y_{t-2}\,] \\ &= \varepsilon_t + 0.5\,\varepsilon_{t-1} + (0.5)^2\, y_{t-2} \\ &= \varepsilon_t + 0.5\,\varepsilon_{t-1} + (0.5)^2\,\varepsilon_{t-2} + (0.5)^3\, y_{t-3} \\ &= \varepsilon_t + 0.5\,\varepsilon_{t-1} + (0.5)^2\,\varepsilon_{t-2} + (0.5)^3\,\varepsilon_{t-3} \\ &\quad + (0.5)^4\, y_{t-4} \end{aligned}$$

Mô hình hồi qui tuyến tính

➢ Quá trình Ngẫu nhiên Tuyến tính

- Ví dụ: $y_t = \varepsilon_t - 0.3\,\varepsilon_{t-1}$

$$\varepsilon_t = y_t + 0.3\,\varepsilon_{t-1}$$

$$\varepsilon_{t-1} = y_{t-1} + 0.3\,\varepsilon_{t-2}$$

$$\varepsilon_{t-2} = y_{t-2} + 0.3\,\varepsilon_{t-3}$$

$$\varepsilon_{t-3} = y_{t-3} + 0.3\,\varepsilon_{t-4}$$

$$\begin{aligned}\varepsilon_t &= y_t + 0.3\,[y_{t-1} + 0.3\,\varepsilon_{t-2}\,] \\ &= y_t + 0.3\,y_{t-1} + (0.3)^2\,\varepsilon_{t-2} \\ &= y_t + 0.3\,y_{t-1} + (0.3)^2\,y_{t-2} + (0.3)^3\,\varepsilon_{t-3}\end{aligned}$$

$$y_t = \varepsilon_t - 0.3\,y_{t-1} - (0.3)^2\,y_{t-2} - (0.3)^3\,y_{t-3} - (0.3)^4\,\varepsilon_{t-4}$$

Mô hình tự hồi qui

- **Autoregression (AR)**: Mô hình trong đó giá trị hiện tại (Y_t) được mô tả như một hàm tuyến tính của các giá trị trong quá khứ của chính nó.

Công thức tổng quát (mô hình AR(p)):

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t$$

- c : hằng số.
- ϕ_i : hệ số hồi qui (tác động của giá trị quá khứ).
- ϵ_t : nhiễu trắng (white noise).

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

$$y_t = \phi_1 y_{t-1} + \epsilon_t$$

Mô hình này có dạng hồi quy giá trị của chuỗi tại thời điểm t trên giá trị của chuỗi tại thời điểm $t-1$ và giá trị hiện tại của nhiễu trắng.

- Nếu $|\phi_1| < 1$: chuỗi dần ổn định (stationary).
- Nếu $\phi_1 > 0$: có xu hướng nối tiếp cùng chiều.
- Nếu $\phi_1 < 0$: có dao động lên xuống (zig-zag).

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc một: AR(1)

$$y_t = \phi_1 y_{t-1} + \epsilon_t$$

- Điều kiện dừng:
  - Khi nói đến các điều kiện dừng, tức là các điều kiện mà mô hình phải thỏa mãn để có thể viết mô hình theo công thức nhiễu trắng. Chúng ta sẽ ký hiệu các giá trị quá khứ của chuỗi như sau:

$$y_{t-1} = \phi_1\, y_{t-2} + \varepsilon_{t-1}$$
$$y_{t-2} = \phi_1\, y_{t-3} + \varepsilon_{t-2}$$
$$\vdots$$
$$y_{t-k} = \phi_1\, y_{t-k-1} + \varepsilon_{t-k}$$

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc một: AR(1)

$$y_t = \phi_1 y_{t-1} + \epsilon_t$$

- Điều kiện dừng:
  - Thay lần lượt vào công thức AR(1) ta thu được:

$$y_t = \varepsilon_t + \phi_1[\phi_1 y_{t-2} + \varepsilon_{t-1}] = \varepsilon_t + \phi_1\varepsilon_{t-1} + \phi_1^2 y_{t-2}$$

$$= \varepsilon_t + \phi_1\varepsilon_{t-1} + \phi_1^2\,\varepsilon_{t-2} + \phi_1^3 y_{t-3}$$

$$= \varepsilon_t + \phi_1\varepsilon_{t-1} + \phi_1^2\,\varepsilon_{t-2} + \cdots + \phi_1^{k-1}\,\varepsilon_{t-k+1} + \phi_1^k y_{t-k}$$

$$= \sum_{j=0}^{k-1} \phi_1^j\,\varepsilon_{t-j} + \phi_1^k y_{t-k}$$

if $|\phi_1| < 1$, and $k \longrightarrow \infty$

$\phi_1^k y_{t-k} \rightarrow 0$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

$$y_t = \phi_1 y_{t-1} + \epsilon_t$$

Mô hình AR (1) có thể được viết dưới dạng:

$$\phi(B) y_t = \varepsilon_t$$

Trong đó, $\phi(B) = 1 - \phi_1 B$ được gọi là toán tử tự hồi quy, hoặc hàm đặc trưng của mô hình.

- Điều kiện dừng: $|\phi_1| < 1$

  Nếu $|\phi_1| < 1$ thì nghiệm của phương trình đặc trưng $\phi(B) = 0$ phải nằm ngoài đường tròn đơn vị, tức là nghiệm phải thỏa mãn $|B| > 1$.

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

$$y_t = \phi_1 y_{t-1} + \epsilon_t$$

- Giá trị trung bình

$$E(y_t) = \phi_1 E(y_{t-1}) + 0$$

$$E(y_t)(1 - \phi_1) = 0 \Rightarrow E(y_t) = 0$$

- Phương sai

$$var(y_t) = \phi_1^2 var(y_{t-1}) + var(\varepsilon_t)$$

  - Khi điều kiện dừng thỏa mãn: $|\phi_1| < 1$

$$var(y_t) = var(y_{t-1}) = \gamma(0)$$

$$\gamma(0) = \frac{\sigma^2}{(1 - \phi_1^2)}$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

$$y_t = \phi_1 y_{t-1} + \epsilon_t$$

- Hàm tự tương quan (ARF) với $|\phi_1| < 1$

$$\gamma(1) = cov\,(y_t, y_{t-1}) = cov(\phi_1 y_{t-1} + \varepsilon_t\,, y_{t-1})$$
$$= \phi_1 cov(y_{t-1}\,, y_{t-1}) + cov(\,\varepsilon_t, y_{t-1})$$
$$= \phi_1 \gamma(0) + 0$$

$$\gamma(k) = \phi_1 \gamma(k-1)$$
$$\rho(k) = \phi_1 \rho(k-1),\ k = 1,2,\ldots$$

$$\boxed{\rho(k) = \phi_1^2 \rho(k-2) = \phi_1^3 \rho(k-3) = \cdots = \phi_1^k \rho(0) = \phi_1^k}$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

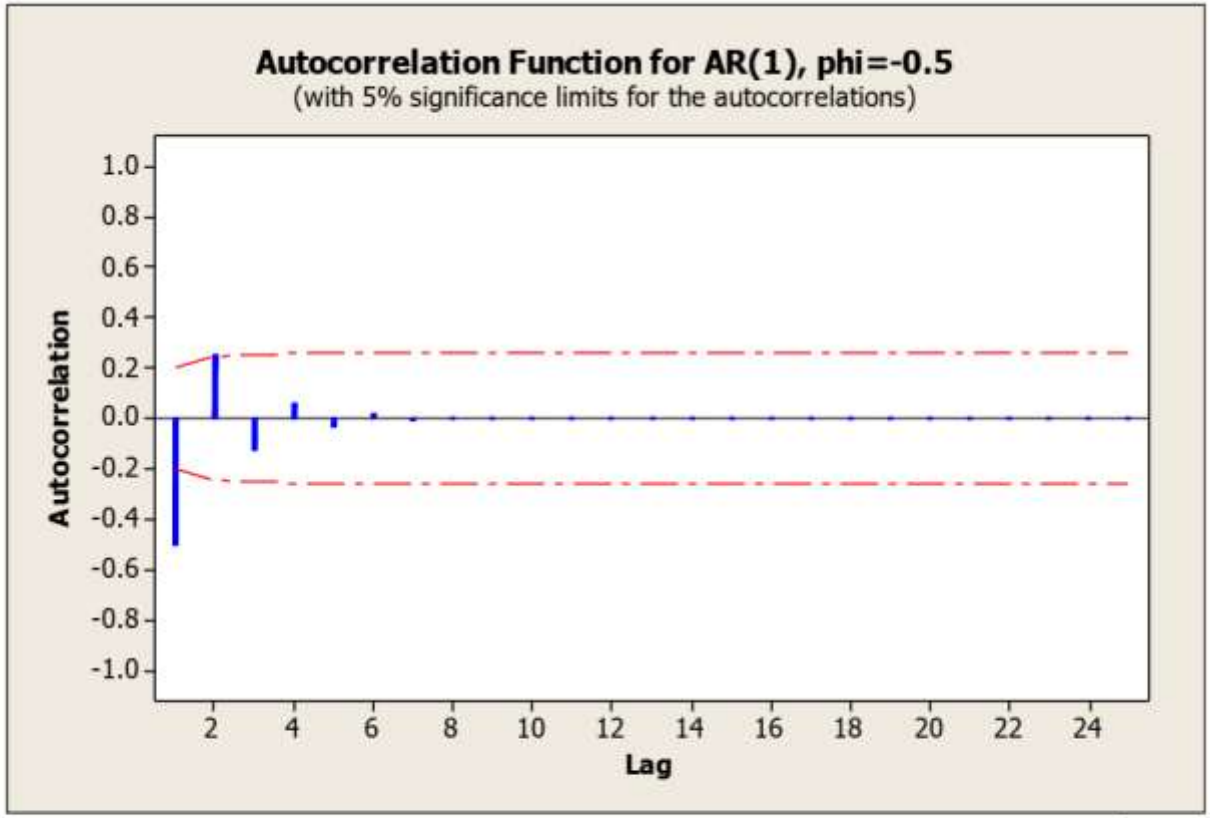

ACF for AR(1) model with $\phi_1 = -0.5$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

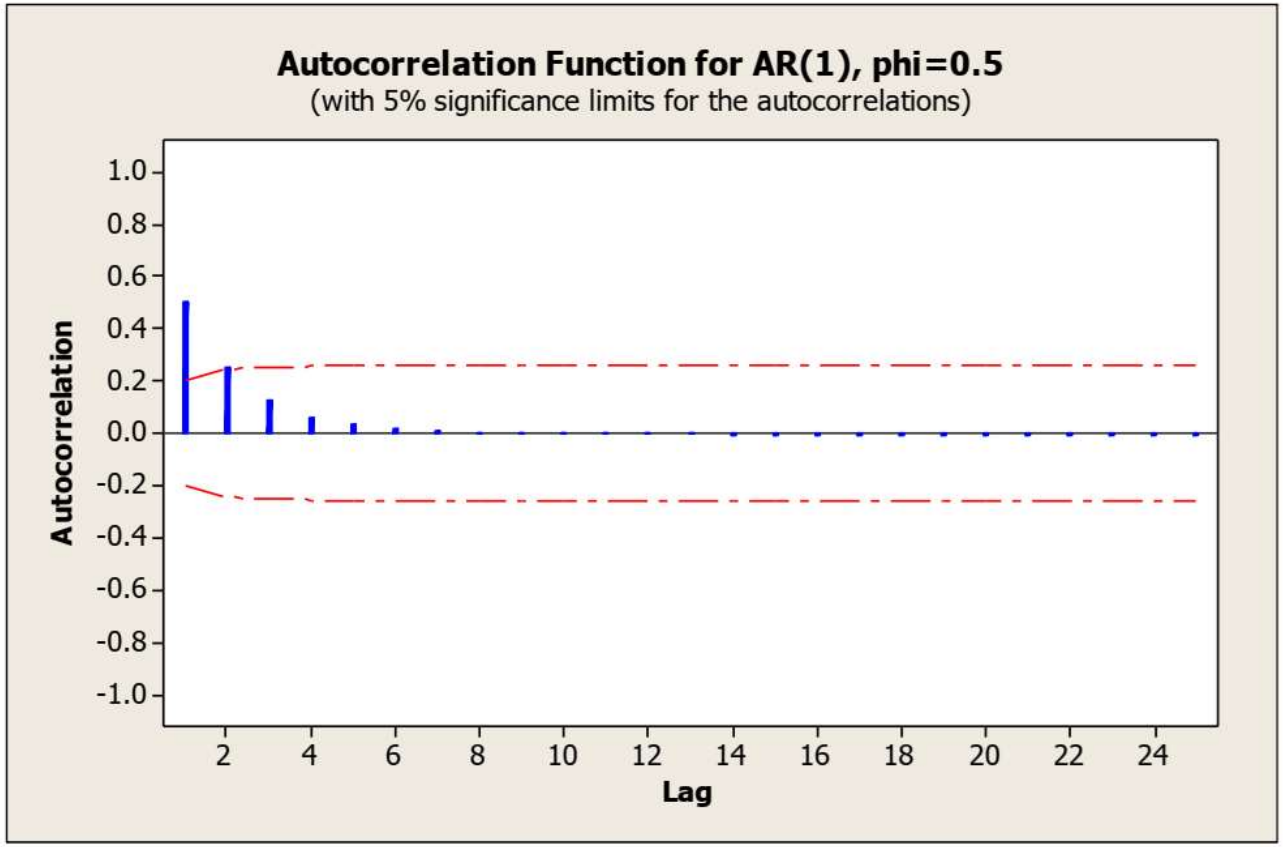

ACF for AR(1) model with $\phi_1 = 0.5$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

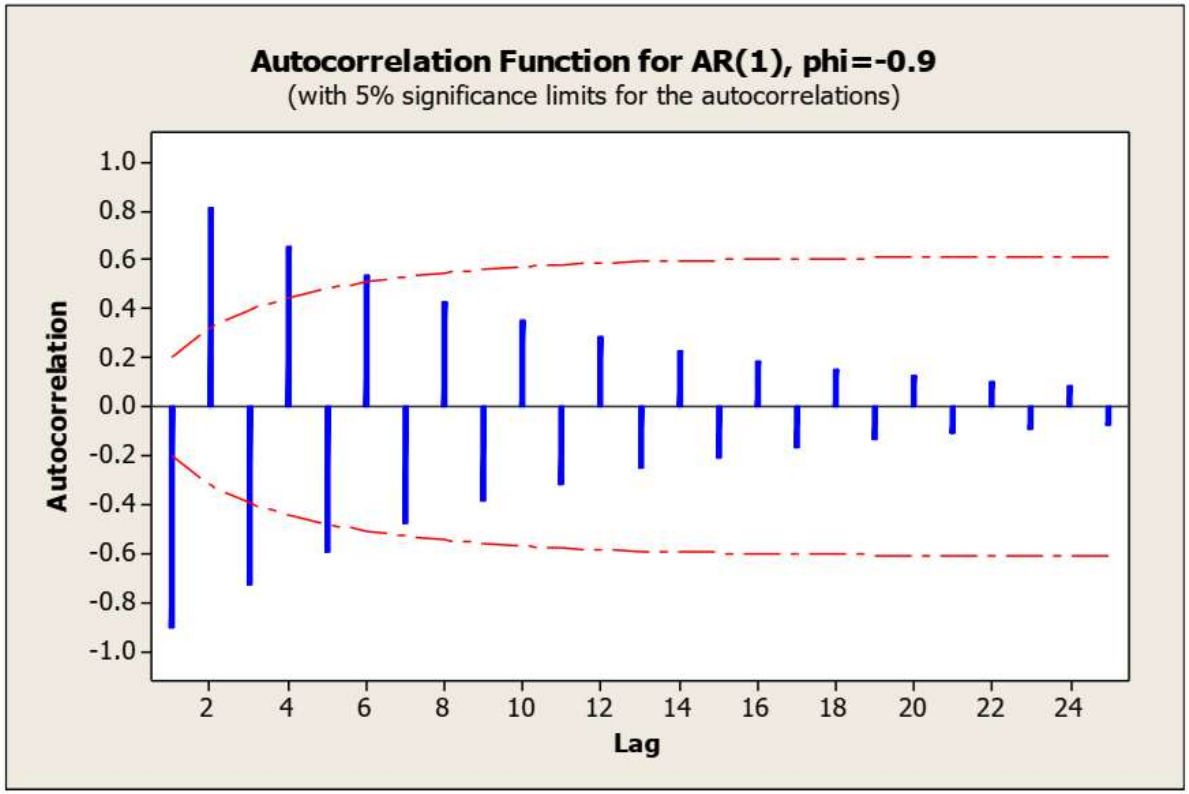

ACF for AR(1) model with $\phi_1 = -0.9$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

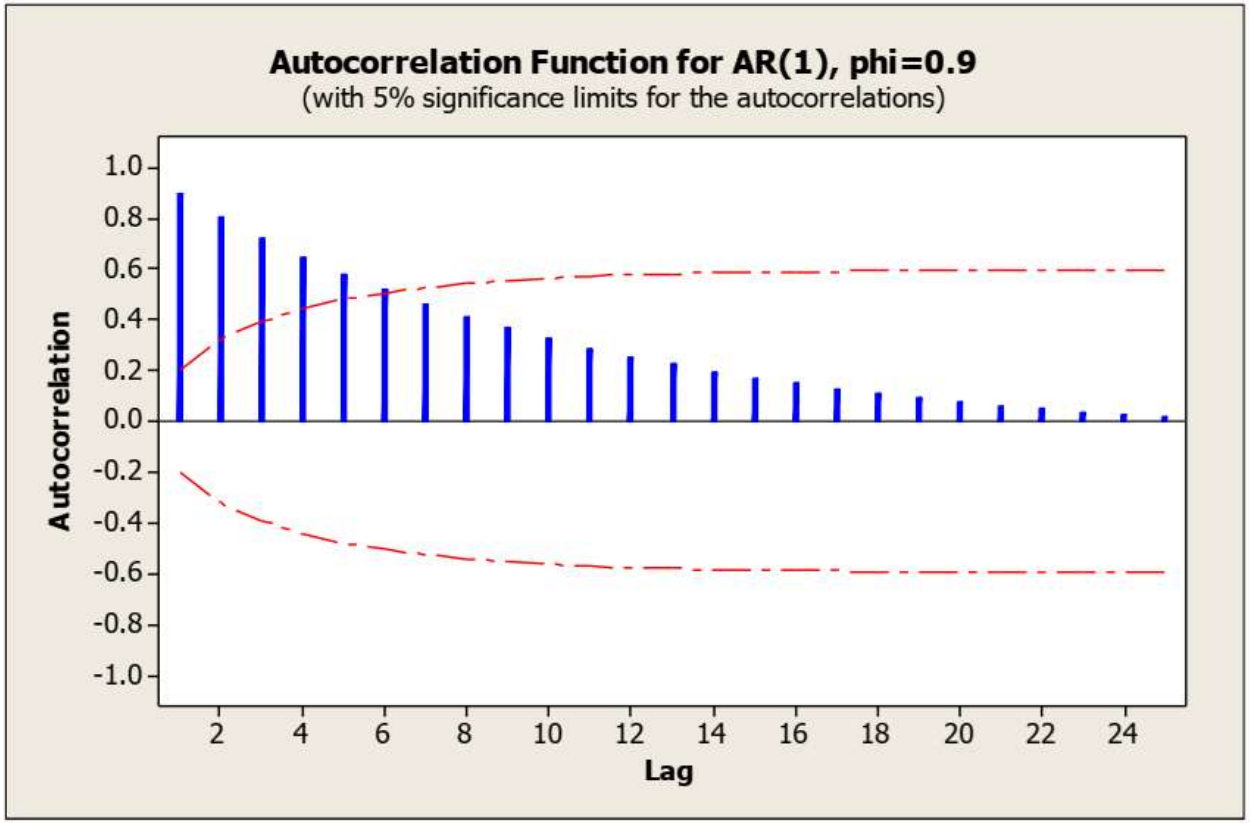

ACF for AR(1) model with $\phi_1 = 0.9$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

Áp dụng công thức tính PACF ta thu được

$$\phi_{00} = 1.$$

$$\phi_{11} = \rho_1 = \phi^1 = \phi.$$

$$\phi_{22} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\begin{vmatrix} 1 & \phi \\ \phi & \phi^2 \end{vmatrix}}{\begin{vmatrix} 1 & \phi \\ \phi & 1 \end{vmatrix}} = \frac{\phi^2 - \phi^2}{1 - \phi^2} = 0$$

$$\phi_{kk} = \begin{cases} 1. & k = 0 \\ \phi. & k = 1 \\ 0. & k \geq 2 \end{cases}$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

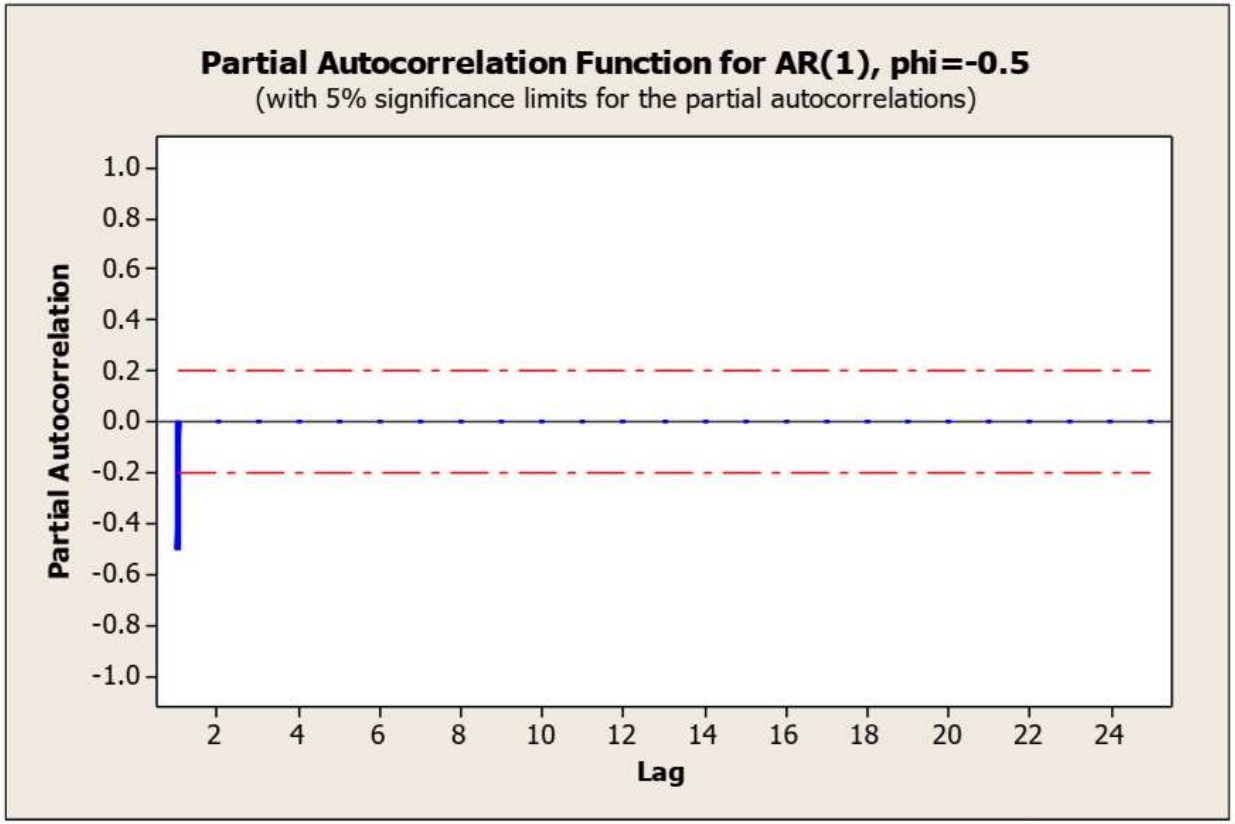

PACF for AR(1) model when $\phi < 0$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc một: AR(1)**

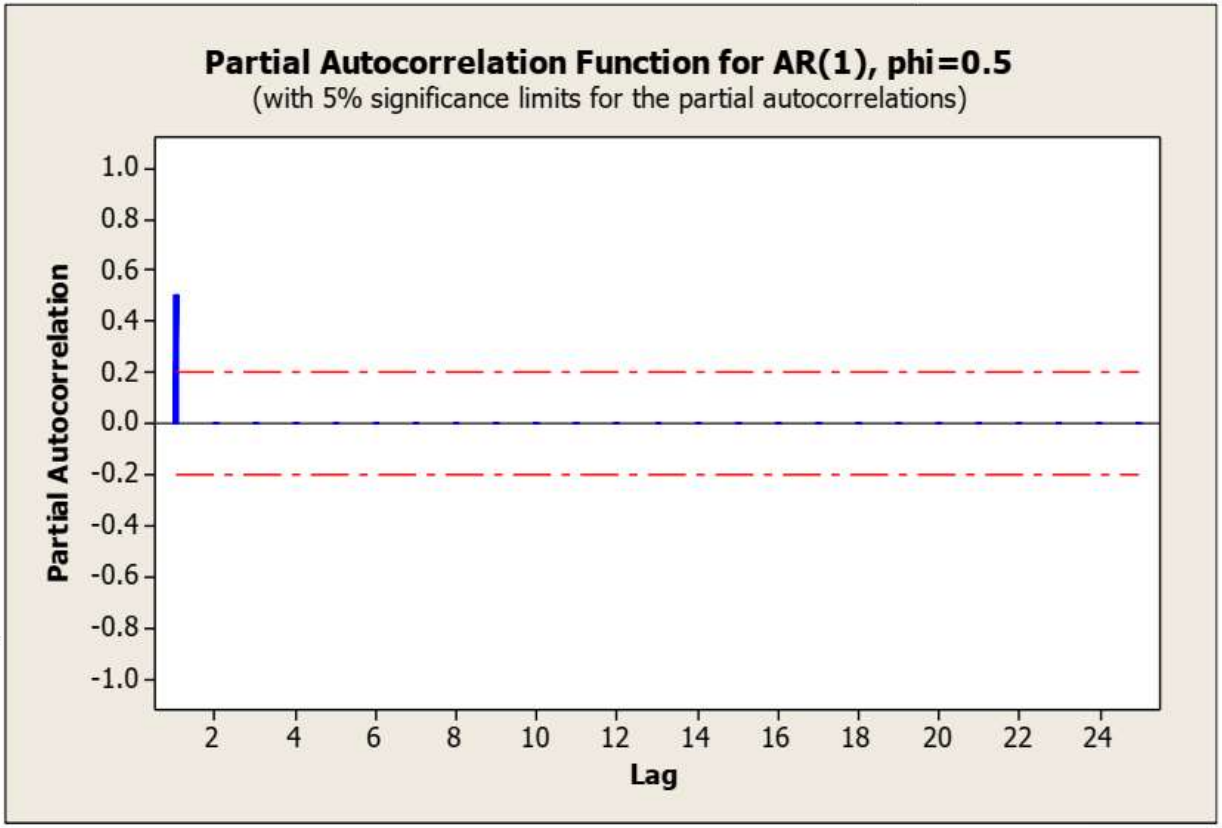

PACF for AR(1) model when $\phi > 0$

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc một: AR(1)

- Một số ví dụ của mô hình AR(1):
  - nếu chúng ta giả sử y_t đại diện cho dân số của một quốc gia nhất định tại một năm nhất định, thì nó bằng phân số ϕ_1 (tỷ lệ những người vẫn còn sống) nhân với dân số của năm trước y_{t-1} , cộng thêm một thành phần ngẫu nhiên ε_t (đại diện cho công dân mới của quốc gia đó).
  - Một ví dụ khác, y_t có thể đại diện cho số người thất nghiệp tại một tháng nhất định, thì nó bằng phân số ϕ_1 (tỷ lệ những người vẫn còn thất nghiệp) nhân với số người thất nghiệp trong tháng trước y_{t-1} , cộng thêm một thành phần ngẫu nhiên ε_t (đại diện cho những người mới thất nghiệp đang tìm việc).

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc một: AR(1)

- Một số ví dụ của mô hình AR(1):
  - Dạng tổng quát của mô hình AR(1) khi giá trị trung bình của mô hình khác 0, tức là khi $E[y_t] = \mu$

$$y_t - \mu = \phi_1(y_{t-1} - \mu) + \varepsilon_t$$

$$y_t = \delta + \phi_1 y_{t-1} + \varepsilon_t$$

$$\text{where } \delta = \mu(1 - \phi_1)$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- Áp dụng toán tử dịch chuyển ngược, chúng ta có thể viết lại mô hình dưới dạng:

$$(1 - \phi_1 B - \phi_2 B^2) y_t = \delta + \varepsilon_t$$

$$y_t = (1 - \phi_1 B - \phi_2 B^2)^{-1} \delta + (1 - \phi_1 B - \phi_2 B^2)^{-1} \varepsilon_t$$

$$y_t = \mu_Y + \psi(B)\varepsilon_t$$

$$\psi(\mathrm{B}) = (1 - \phi_1 B - \phi_2 B^2)^{-1}$$

$$y_t = \mu_Y + (1 + \psi_1 B + \psi_2 B^2 + \psi_3 B^3 + \cdots)\varepsilon_t$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

$$y_t = \mu_Y + \psi(B)\varepsilon_t \quad \text{với} \quad \psi(\mathrm{B}) = (1 - \phi_1 B - \phi_2 B^2)^{-1}$$

$$(1 + \psi_1 B + \psi_2 B^2 + \cdots)(1 - \phi_1 B - \phi_2 B^2) = 1$$

$$B^1: \psi_1 - \phi_1 = 0 \qquad \Rightarrow \psi_1 = \phi_1$$

$$B^2: \psi_2 - \phi_1\psi_1 - \phi_2 = 0 \qquad \Rightarrow \psi_2 = \phi_1\psi_1 + \phi_2 = {\phi_1}^2 + \phi_2$$

$$B^3: \psi_3 - \phi_1\psi_2 - \phi_2\psi_1 = 0 \Rightarrow \psi_3 = \phi_1\psi_2 + \phi_2\psi_1$$

$$B^4: \psi_4 - \phi_1\psi_3 - \phi_2\psi_2 = 0 \Rightarrow \psi_4 = \phi_1\psi_3 + \phi_2\psi_2$$

$$\boxed{\psi_j = \phi_1\psi_{j-1} + \phi_2\psi_{j-2} \;.j \geq 2}$$

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc hai: AR(2)

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- Điều kiện dừng:
  - Phương trình đặc trưng $1 - \phi_1 B - \phi_2 B^2 = 0$
  - Giả sử

$$1 - \phi_1 B - \phi_2 B^2 = (1 - G_1 B)(1 - G_2 B)$$

  - G_1^{-1} và G_2^{-1} là nghiệm thực hoặc phức
  - Hệ dừng khi

$$|G_1^{-1}| > 1 \qquad |G_2^{-1}| > 1$$

❑ Lưu ý: $x = a + ib$ thì $|x| = \sqrt{a^2 + b^2}$

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc hai: AR(2)

- Điều kiện dừng:
  - Ví dụ:

$$y_t = 0.8y_{t-1} - 0.15y_{t-2} + \epsilon_t$$

$$(1 - 0.8B + 0.15B^2) = (1 - 0.5B)(1 - 0.3B) = 0$$

$$G_1^{-1} = \frac{1}{0.5} = 2$$

$$G_2^{-1} = \frac{1}{0.3} = 3.33$$

so this model is stationary

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc hai: AR(2)

- Điều kiện dừng:
  - Ví dụ:

$$y_t = 1.5y_{t-1} - 0.5y_{t-2} + \epsilon_t$$

$$(1 - 1.5B + 0.5B^2) = (1 - B)(1 - 0.5B) = 0$$

$$G_1^{-1} = 1$$

so this model is not stationary

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc hai: AR(2)

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- Điều kiện dừng:
  - Phương trình đặc trưng $1 - \phi_1 B - \phi_2 B^2 = 0$
  - Điều kiện đủ để phương trình đặc trưng có nghiệm nằm ngoài vòng tròn đơn vị là

$$-1 < \phi_2 < 1$$
$$\phi_1 + \phi_2 < 1$$
$$\phi_2 - \phi_1 < 1$$

❑ Ta nói rằng quá trình AR(2) là dừng nếu các điều kiện trên được thỏa mãn. Và nếu bất kỳ điều kiện nào trong số đó không được thỏa mãn, thì quá trình không dừng.

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- ARF

$$\gamma_k = E[y_t y_{t-k}] = \phi_1 E[y_{t-1} y_{t-k}] + \phi_2 E[y_{t-2} y_{t-k}] + E[\varepsilon_t y_{t-k}]$$

$$E[\varepsilon_t y_{t-k}] = \begin{cases} \sigma_\varepsilon^2 & , k = 0 \\ 0 & , k = 1,2,3 \end{cases}$$

$$\gamma_0 = \phi_1 \gamma_{-1} + \phi_2 \gamma_{-2} + \sigma_\varepsilon^2 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \sigma_\varepsilon^2$$

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}. \; k > 0$$

  - Phương trình Yule-Walker

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- ARF
  - Áp dụng phương trình Yule-Walker cho mô hình AR(2) dừng

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$$

    - Với k = 1

$$\rho_1 = \phi_1 \rho_0 + \phi_2 \rho_1$$

$$\rho_1 (1 - \phi_2) = \phi_1 \Rightarrow \rho_1 = \frac{\phi_1}{(1 - \phi_2)}$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- ARF
  - Áp dụng phương trình Yule-Walker cho mô hình AR(2) dừng

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$$

    - Với k = 2

$$\rho_2 = \phi_1 \rho_1 + \phi_2 \rho_0 \Longrightarrow \rho_2 = \frac{{\phi_1}^2}{(1-\phi_2)} + \phi_2$$

$$\rho_2 = \frac{{\phi_1}^2 + \phi_2 - {\phi_2}^2}{(1-\phi_2)}$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- ARF
  - ACF phụ thuộc vào giá trị nghiệm củaphương trình đặc trưng:
    - Nếu nghiệm là số thực, thì ACF giảm theo hàm mũ.
    - Nếu nghiệm là số phức, thì ACF giảm theo dạng sóng sin

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

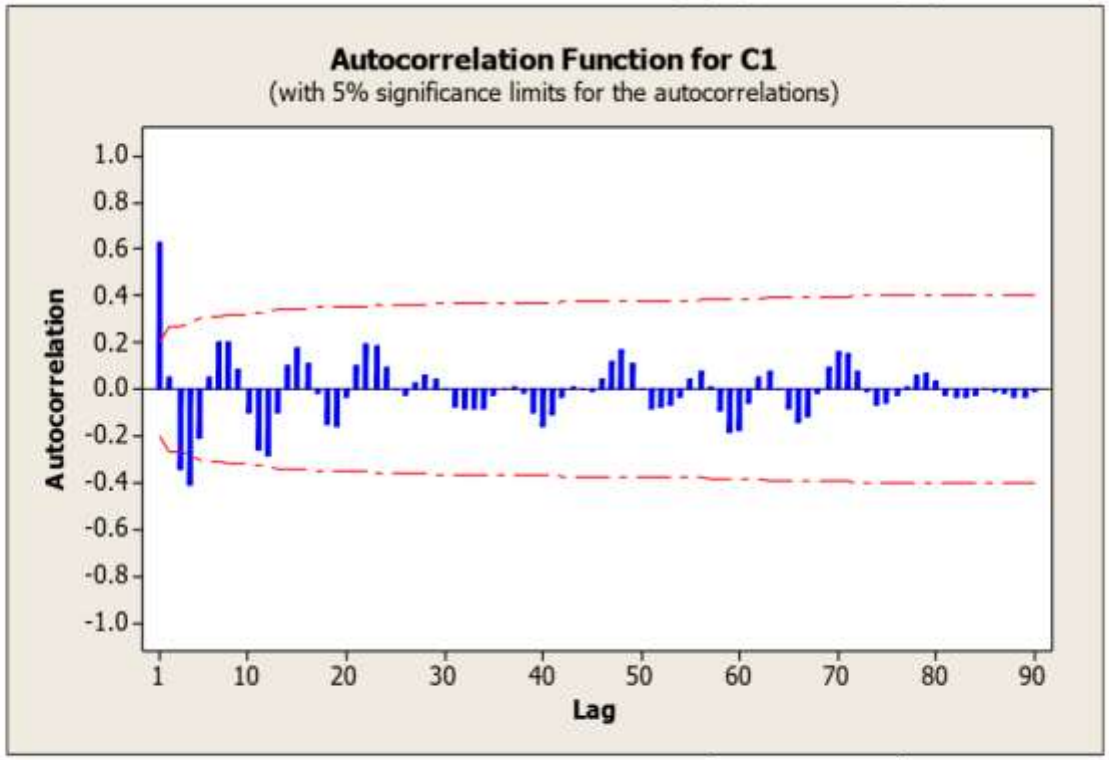

ACF for AR(2) model when $\phi_1 = 1. \phi_2 = -0.5$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

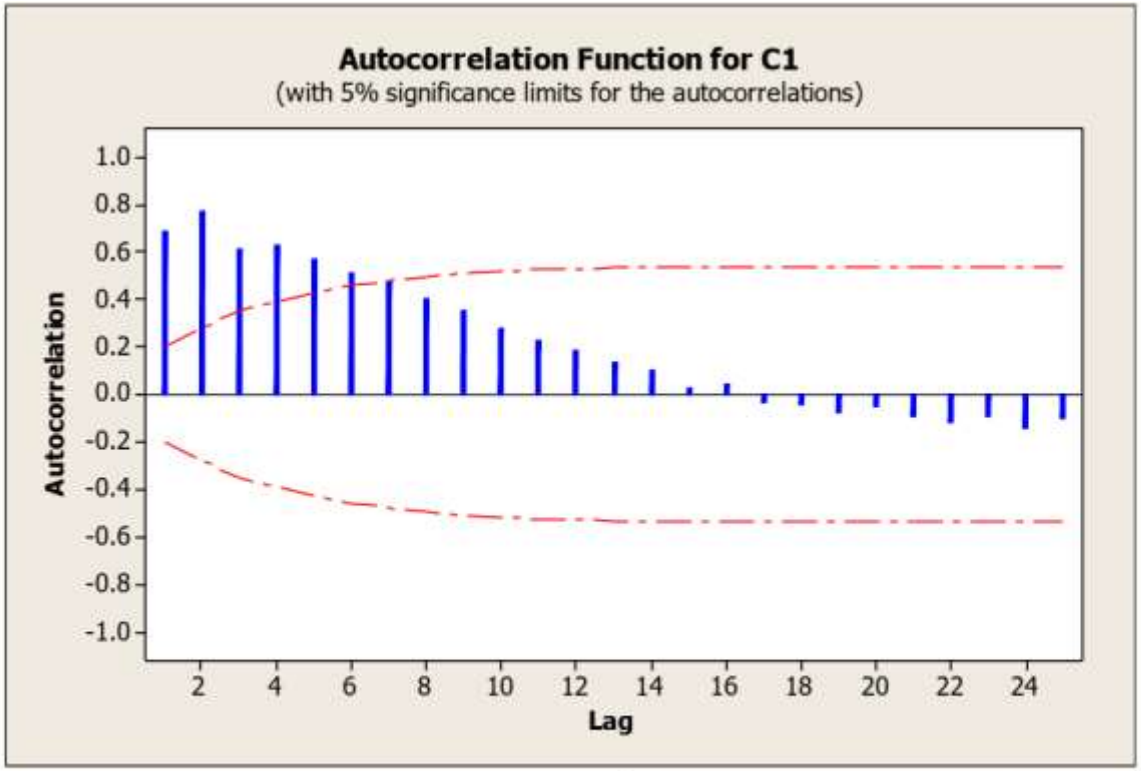

ACF for AR(2) model when $\phi_1 = 0.4. \phi_2 = 0.5$

Mô hình tự hồi qui

➢ Mô hình tự hồi quy bậc hai: AR(2)

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- PARF: áp dụng công thức, ta thu được

$$\phi_{00} = 1. \qquad \phi_{11} = \rho_1 = \frac{\phi_1}{(1-\phi_2)}.$$

$$\phi_{22} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$$

$$\phi_{33} = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_1 = \phi_1\rho_0 + \phi_2\rho_1 \\ \rho_1 & 1 & \rho_2 = \phi_1\rho_1 + \phi_2\rho_0 \\ \rho_2 & \rho_1 & \rho_3 = \phi_1\rho_2 + \phi_2\rho_1 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_2 & \rho_1 & 1 \end{vmatrix}} = \frac{0}{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_2 & \rho_1 & 1 \end{vmatrix}} = 0$$

$$\phi_{kk} = \begin{cases} 1. & k = 0 \\ \rho_1. & k = 1 \\ \dfrac{\rho_2 - \rho_1^2}{1 - \rho_1^2}. & k = 2 \\ 0. & k \geq 3 \end{cases}$$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

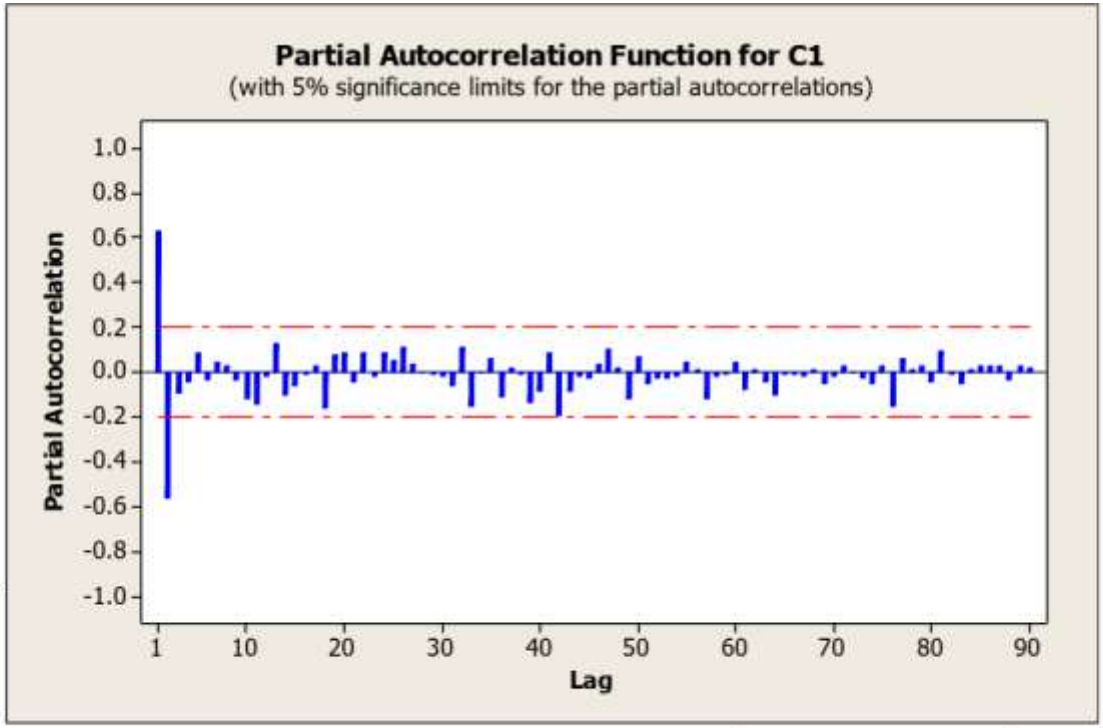

PACF for AR(2) model when $\phi_1 = 1. \phi_2 = -0.5$

Mô hình tự hồi qui

- **Mô hình tự hồi quy bậc hai: AR(2)**

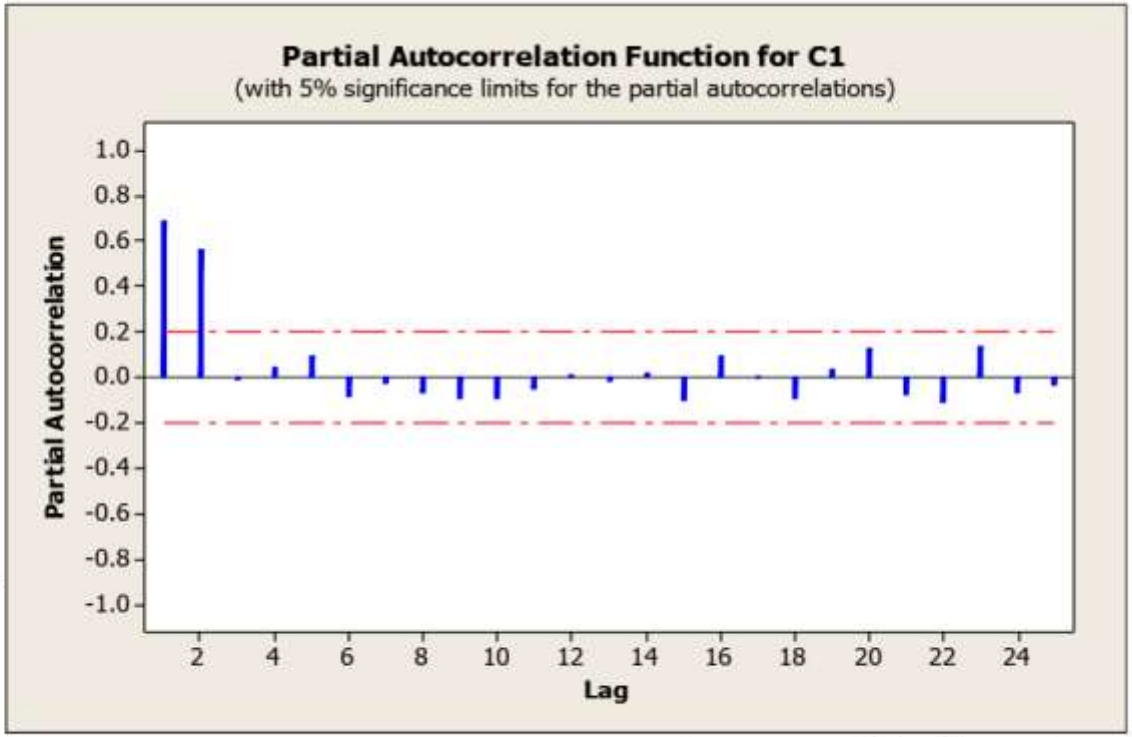

PACF for AR(2) model when $\phi_1 = 0.4 \,.\, \phi_2 = 0.5$

Mô hình tự hồi qui

- **Công thức tổng quát: Mô hình AR(p)**:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t$$

- Áp dụng toán tử dịch chuyển ngược

$$(1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi^p B^p)\, y_t = \delta + \varepsilon_t$$

$$\phi(B)\, y_t = \delta + \varepsilon_t$$

Các mô hình AR(p) có thể dừng hoặc khôngtùy thuộc vào giá trị của các hệ số ϕi, tuy nhiên, có thểchứng minh rằng nếu các nghiệm của hàm đặc trưng $\phi(B) = 0$nằm ngoài vòng tròn đơn vị, thì mô hình là dừng.

Mô hình tự hồi qui

- **Công thức tổng quát: Mô hình AR(p)**:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t$$

- Hàm tự tương quan của mô hình AR(p) có thể được chứng minh là thỏa mãn phương trình sai phân sau:

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \cdots + \phi_p \rho_{k-p} \quad .k \geq 1$$

  - ACF mở rộng vô hạn và bao gồm hỗn hợp các hàm mũ hoặc hàm sóng sin suy giảm. Vì vậy, hàm ACF luôn là một chỉ báo tốt cho thấy liệu một chuỗi trong các ứng dụng thực tế có thể được mô hình hóa bằng các mô hình tự hồi quy hay không.
  - Tuy nhiên, nó không đủ để xác định bậc p của tự hồi quy, vì vậy chúng ta phải xem xét PACF, là điểm cắt sau bậc p.

Mô hình tự hồi qui

➢ **Công thức tổng quát: Mô hình AR(p)**:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t$$

- **Ước lượng tham số:** Các hệ số ϕ_i thường được ước lượng bằng:
  - Phương pháp bình phương tối thiểu (OLS).
  - Phương pháp cực đại khả năng (MLE).
  - Công cụ: Python (statsmodels), R.
- **Ứng dụng**
  - Dự báo tài chính: giá cổ phiếu, lãi suất.
  - Kinh tế vĩ mô: GDP, CPI.
  - Khí tượng: nhiệt độ, lượng mưa.

❑ Ví dụ: Dự báo Y_{t+1} dựa trên các giá trị quá khứ $Y_t, Y_{t-1}, \ldots$.

Mô hình tự hồi qui

- **Tính chất của mô hình AR**
  - **Ưu điểm:**
    - Đơn giản, dễ hiểu.
    - Hiệu quả khi chuỗi có tính tự tương quan.
  - **Hạn chế:**
    - Chỉ sử dụng thông tin nội tại (không tính đến biến ngoài).
    - Cần chuỗi **stationary**.

Mô hình tự hồi qui

➢ **Nhận xét**

- Mô hình AR là nền tảng cơ bản trong phân tích chuỗi thời gian. Đây là cơ sở của nhiều mô hình hiện đại trong time series.
- Dễ áp dụng, nhưng cần kiểm tra tính dừng của dữ liệu.
- Thường được dùng như bước đầu tiên trước khi chuyển sang ARMA/ARIMA/VAR.
- Kết hợp AR với:
  - MA → ARMA.
  - Sai phân → ARIMA.
  - Biến ngoài → ARIMAX.

Mô hình trung bình động

- **Moving Average (MA)**: Mô hình trong đó giá trị hiện tại (Y_t) được mô tả dựa trên nhiễu trắng hiện tại và các nhiễu trắng trong quá khứ.
  - Ý tưởng: Giá trị hôm nay không chỉ ngẫu nhiên mà còn chịu ảnh hưởng từ "cú sốc" (shock/sai số) của những ngày trước.
  - **Công thức tổng quát: Mô hình MA(q)**:

$$Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q}$$

    - μ : giá trị trung bình.
    - θ_i : hệ số MA (tác động của nhiễu quá khứ).
    - ϵ_t : nhiễu trắng (white noise).

Mô hình trung bình động

- **Moving Average (MA):**
  - Lưu ý: Chúng ta đã đề cập trước đó rằng bất kỳ quá trình tuyến tính dừng nào cũng có thể được viết dưới dạng:

$$y_t = \varepsilon_t + \sum_{j=1}^{\infty} \psi_j \, \varepsilon_{t-j} \; ; \; where \sum_j \psi_j^{\,2} < \infty$$

  - Trên thực tế, nhiều hiện tượng trong kinh tế học hoặc khoa học xã hội có thể được biểu diễn (có thể sau phép sai phân thứ nhất hoặc thứ hai) theo cùng cách trên
  - Các mô hình MA luôn dừng bất kể giá trị tham số là bao nhiêu, vì số lượng giá trị ψ khác không trong biểu diễn quy trình tuyến tính bị giới hạn.
  - Đôi khi, cần phải biểu diễn các mô hình này bằng cách sử dụng các giá trị quá khứ của chuỗi, điều này có nghĩa là chúng ta sử dụng công thức khả nghịch (xem phần sau).

Mô hình trung bình động

- **Trung bình động bậc nhất: MA(1)**

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

  - Mô hình MA(1) được coi là một trong những mô hình phân tích chuỗi thời gian quan trọng được sử dụng trong việc mô hình hóa hàng tồn kho, kiểm soát chất lượng, nhiệt độ, tỷ lệ ô nhiễm và các chỉ số kinh tế chung sau khi bị ảnh hưởng bởi các nhiễu loạn đột ngột từ bên trong hệ thống như đình công của công nhân, hoặc từ bên ngoài hệ thống như chiến tranh hoặc thiên tai, v.v.
  - Như đã đề cập trước đó, mô hình MA(1) luôn dừng, bất kể giá trị của tham số là bao nhiêu.

Mô hình trung bình động

- **Trung bình động bậc nhất: MA(1)**

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

- Mô hình này có thể được viết ngắn gọn như sau:

$$y_t = \theta(B)\varepsilon_t$$

Trong đó $\theta(B) = 1 + \theta_1 B$ còn được gọi là toán tử trung bình động, nó liên kếtquy trình $\{y_t\}$ làm đầu ra với quy trình $\{\varepsilon_t\}$ làm đầu vào.

Mô hình trung bình động

➢ **Trung bình động bậc nhất: MA(1)**

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

- Giá trị trung bình $E(y_t) = 0$
- Hàm tự hiệp phương sai (auto-covariance)

$$\begin{aligned} var(y_t) = \gamma(0) &= var(\varepsilon_t + \theta_1 \varepsilon_{t-1}) \\ &= var(\varepsilon_t) + {\theta_1}^2 \, var(\varepsilon_{t-1}) \\ &= \sigma_\varepsilon^2 (1 + {\theta_1}^2) \end{aligned}$$

Mô hình trung bình động

➢ Trung bình động bậc nhất: MA(1)

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

- Hàm tự hiệp phương sai

$$\gamma(1) = cov\,(y_t, y_{t-1}) = cov(\varepsilon_t + \theta_1\varepsilon_{t-1}, \varepsilon_{t-1} + \theta_1\varepsilon_{t-2})$$

$$= \theta_1 cov(\varepsilon_{t-1}, \varepsilon_{t-1}) \quad = \theta_1\sigma_\varepsilon^2$$

$$\gamma(2) = cov\,(y_t . y_{t-2}) = cov(\varepsilon_t + \theta_1\varepsilon_{t-1} . \varepsilon_{t-2} + \theta_1\varepsilon_{t-3}) = 0$$

$$\gamma(3) = \gamma(4) = \cdots = 0$$

$$\gamma(k) = \begin{cases} \sigma_\varepsilon^2(1 + \theta_1{}^2) & k = 0 \\ \theta_1\sigma_\varepsilon^2 & k = 1 \\ 0 & k = 2, 3, \ldots \end{cases}$$

Mô hình trung bình động

➢ Trung bình động bậc nhất: MA(1)

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

- Hàm tự tương quan

$$\rho(k) = \begin{cases} 1 & k = 0 \\ \dfrac{\theta_1}{(1+\theta_1{}^2)} & k = 1 \\ 0 & k = 2, 3, \ldots \end{cases}$$

Mô hình trung bình động

➢ Trung bình động bậc nhất: MA(1)

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

- Hàm tự tương quan cục bộ

$$\phi_{00} = 1$$

$$\phi_{11} = \rho_1 = \frac{\theta_1}{1+\theta_1^2}$$

$$\phi_{22} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 0 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{0-{\rho_1}^2}{1-{\rho_1}^2} = \frac{-\theta_1^2}{1+\theta_1^2+\theta_1^4} = \frac{-\theta_1^2(1-\theta_1^2)}{1-\theta_1^6}$$

Mô hình trung bình động

- **Trung bình động bậc hai: MA(2)**

$$y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$$

- Mô hình này có thể được viết ngắn gọn như sau:

$$y_t = \theta(B)\epsilon_t$$

Trong đó $\theta(B) = 1 + \theta_1 B + \theta_2 B^2$.

- Giá trị trung bình:

$$E[y_t] = E[\epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}] = 0$$

Mô hình trung bình động

- **Trung bình động bậc hai: MA(2)**

$$y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$$

- Hàm tự hiệp phương sai (auto-covariance)

$$\begin{aligned}
\gamma(0) &= Var[y_t] = Var[\epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}] \\
&= (1 + \theta_1^2 + \theta_2^2)\sigma^2 \\
\gamma(1) &= Cov[\epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}, \epsilon_{t-1} + \theta_1 \epsilon_{t-2} + \theta_2 \epsilon_{t-3}] \\
&= \theta_1(1 + \theta_2)\sigma^2
\end{aligned}$$

$$\gamma(k) = \begin{cases} \sigma^2(1 + \theta_1^2 + \theta_2^2), & k = 0 \\ \sigma^2\theta_1(1 + \theta_2), & k = 1 \\ \theta_2\sigma^2, & k = 2 \\ 0, & k = 3, 4, \ldots \end{cases}$$

Mô hình trung bình động

- **Trung bình động bậc hai: MA(2)**

$$y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$$

- Hàm tự tương quan

$$\rho(k) = \begin{cases} 1, & k = 0 \\ \frac{\theta_1(1+\theta_2)}{1+\theta_1^2+\theta_2^2}, & k = 1 \\ \frac{\theta_2}{1+\theta_1^2+\theta_2^2}, & k = 2 \\ \theta_2 \sigma^2, & k = 2 \\ 0, & k = 3, 4, \ldots \end{cases}$$

Mô hình trung bình động

- **Trung bình động bậc q: MA(q)**

$$y_t = \epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2} + \cdots + \theta_q\epsilon_{t-q}$$

- Mô hình này có thể được viết ngắn gọn như sau:

$$y_t = \theta(B)\epsilon_t$$

Trong đó $\theta(B) = 1 + \theta_1 B + \theta_2 B^2 + \ldots + \theta_q B^q$.

- Giá trị trung bình: $E[y_t] = 0$
- Hàm tự hiệp phương sai: $\gamma(0) = (1 + \theta_1^2 + \cdots + \theta_q^2)\sigma$
- Hàm tự tương quan:

$$\rho(k) = \begin{cases} 1, & k = 0 \\ \frac{\theta_k + \theta_1\theta_{k+1} + \cdots + \theta_{q-k}\theta_q}{1 + \theta_1^2 + \cdots + \theta_q^2}, & k = 1, 2, \ldots, q \\ 0, & k > q \end{cases}$$

Mô hình trung bình động

- **Tính chất của mô hình MA**
  - **Ưu điểm:**
    - Hiệu quả trong mô tả dữ liệu có cấu trúc nhiễu.
    - Đảm bảo tính dừng tự nhiên (stationary).
  - **Hạn chế:**
    - Không tận dụng trực tiếp thông tin của giá trị trong quá khứ (chỉ dùng thông tin từ nhiễu).
    - Khó xác định bậc (q) tối ưu.

Mô hình trung bình động

- **Ước lượng tham số**
  - Các hệ số (\theta_i) thường được ước lượng bằng:
    - **Phương pháp bình phương tối thiểu phi tuyến (Nonlinear Least Squares)**.
    - **Phương pháp cực đại khả năng (MLE)**.
  - Công cụ: Python (statsmodels), R.

Mô hình trung bình động

➢ **Ứng dụng**

- Mô hình MA mô tả chuỗi thời gian bằng tác động của các cú sốc quá khứ.
  - **Kinh tế - tài chính**: mô hình hoá biến động lợi nhuận, tỷ giá.
  - **Dự báo ngắn hạn** khi dữ liệu chứa nhiều nhiễu ngẫu nhiên.
- Đơn giản nhưng mạnh mẽ để phân tích dữ liệu có yếu tố ngẫu nhiên.
- Thường dùng kết hợp với AR trong các mô hình phức tạp hơn (ARMA/ARIMA).

Mô hình ARMA (Autoregressive Moving Average)

➢ Khái niệm cơ bản

- **ARMA** = AR + MA.

  Kết hợp cả hai yếu tố: Autoregressive Moving Average = Autoregression + Moving Average
  - **AR**: Giá trị hiện tại phụ thuộc vào các giá trị trong quá khứ.
  - **MA**: Giá trị hiện tại phụ thuộc vào các cú sốc (nhiễu trắng) trong quá khứ.
- Phù hợp cho các chuỗi thời gian **dừng (stationary)**.

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(p, q)**:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2} - \cdots - \theta_q \epsilon_{t-q}$$

- c : hằng số.
- ϕ_i : hệ số AR.
- θ_i : hệ số MA.
- ϵ_t : nhiễu trắng.

Mô hình ARMA (Autoregressive Moving Average)

➢ Tính khả nghịch (Invertibility)

- Trong phân tích chuỗi thời gian, đặc biệt với mô hình Moving Average (MA) hoặc ARMA, invertibility (khả nghịch) là tính chất cho phép viết mô hình MA dưới dạng mô hình AR vô hạn.
  - Nói cách khác: chuỗi trắng (white noise) có thể được biểu diễn lại từ dữ liệu quan sát thông qua một chuỗi AR vô hạn.
  - Điều này giúp ước lượng thông số dễ dàng hơn và mô hình duy nhất (unique).

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(p, q)**:

$$y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2} - \cdots - \theta_q \epsilon_{t-q}$$

- Chúng ta có thể viết ARMA(p,q) lại thành dạng sau

$$\phi(B) y_t = \theta(B) \varepsilon_t$$

$\phi(B)$: the auto-regressive operator

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$$

$\theta(B)$: the moving average operator

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q$$

Mô hình ARMA (Autoregressive Moving Average)

➢ Tính khả nghịch (Invertibility)

- **Ví dụ mô hình MA(1)**

$$y_t = \epsilon_t - \theta_1 \epsilon_{t-1}$$

  - ϵ_t là white noise

$$\varepsilon_t = y_t + \theta_1 \varepsilon_{t-1}$$
$$\varepsilon_{t-1} = y_{t-1} + \theta_1 \varepsilon_{t-2}$$
$$\varepsilon_{t-2} = y_{t-2} + \theta_1 \varepsilon_{t-3}$$
$$\varepsilon_{t-k} = y_{t-k} + \theta_1 \varepsilon_{t-k-1}$$

$$\varepsilon_t = y_t + \theta_1 y_{t-1} + \theta_1^2 y_{t-2} + \theta_1^3 y_{t-3} + \cdots + \theta_1^k y_{t-k} + \theta_1^{k+1} \varepsilon_{t-k-1}$$

Nếu $|\theta_1| < 1$, $(\theta_1^{k+1} \varepsilon_{t-k-1})$ → 0 as k → ∞

Mô hình ARMA (Autoregressive Moving Average)

➢ Tính khả nghịch (Invertibility)

- **Ví dụ mô hình MA(1)**

$$y_t = \epsilon_t - \theta_1 \epsilon_{t-1}$$

  - ϵ_t là white noise
  - MA(1) là **khả nghịch** nếu tồn tại dãy $\{\phi_j\}$sao cho:

$$\epsilon_t = y_t + \sum_{j=1}^{\infty} \phi_j \, y_{t-j}$$

  - Điều kiện: $|\theta_1| < 1$
  - Khi invertible, bạn có thể tái tạo lại chuỗi nhiễu trắng ϵ_ttừ dữ liệu quan sát y_t.

Mô hình ARMA (Autoregressive Moving Average)

➢ Tính khả nghịch (Invertibility)

- **Ví dụ mô hình MA(1)**

$$y_t = \epsilon_t - \theta_1 \epsilon_{t-1}$$

  - ϵ_t là white noise

  - MA(1) là **không khả nghịch** nếu tồn tại dãy $\{\phi_j\}$sao cho:

$$\epsilon_t = y_t + \sum_{j=1}^{\infty} \phi_j \, y_{t-j}$$

    - Nếu $|\theta_1| \geq 1$, không thể biểu diễn MA(1) dưới dạng AR vô hạn → hai bộ tham số khác nhau có thể sinh cùng dữ liệu → không xác định duy nhất.

Mô hình ARMA (Autoregressive Moving Average)

➢ **Tính khả nghịch (Invertibility)**

- Đảm bảo mô hình duy nhất: Không invertible → cùng chuỗi dữ liệu có thể được mô phỏng bởi nhiều bộ θ_i khác nhau.
- Ước lượng thông số dễ dàng: Invertibility giúp phép ước lượng Maximum Likelihood hội tụ tốt.
- Dễ dàng dự báo (forecasting): Khi MA invertible, bạn có thể viết dưới dạng AR vô hạn → dự báo nhiều bước.

Mô hình ARMA (Autoregressive Moving Average)

➢ Tính khả nghịch và tính dừng

Tính chất	Mô hình áp dụng	Ý nghĩa
Stationarity	AR(p)	Các nghiệm đa thức AR phải nằm ngoài vòng tròn đơn vị
Invertibility	MA(q)	Các nghiệm đa thức MA phải nằm ngoài vòng tròn đơn vị

- **Stationarity** → AR có thể viết dưới dạng MA vô hạn
- **Invertibility** → MA có thể viết dưới dạng AR vô hạn

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(p, q)**:

$$y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2} - \cdots - \theta_q \epsilon_{t-q}$$

- Chúng ta có thể viết ARMA(p,q) lại thành dạng sau

$$\phi(B) y_t = \theta(B) \varepsilon_t$$

$\phi(B)$: the auto-regressive operator

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$$

$\theta(B)$: the moving average operator

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q$$

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(p, q)**: $\phi(B)y_t = \theta(B)\varepsilon_t$
  - y_t có thể được viết dưới dạng một quá trình trung bình động vô hạn, và trong trường hợp này, chúng ta yêu cầu các nghiệm của phương trình đặc trưng $\phi(B) = 0$, nằm ngoài đường tròn đơn vị như một điều kiện dừng cho mô hình này

$$y_t = \frac{\theta(B)}{\phi(B)}\varepsilon_t = \psi(B)\varepsilon_t$$

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(p, q)**: $\phi(B)y_t = \theta(B)\varepsilon_t$
  - ε_t có thể được viết dưới dạng một quá trình tự hồi quy vô hạn, và trong trường hợp này, chúng ta yêu cầu các nghiệm của phương trình đặc trưng $\theta(B)$=0, nằm ngoài đường tròn đơn vị như một điều kiện khả nghịch cho mô hình này..

$$\varepsilon_t = \frac{\phi(B)}{\theta(B)} y_t = \Pi(B)\, y_t$$

$$\Pi(B) = \psi^{-1}(B)$$

$$\Pi(B)\psi(B) = 1$$

Mô hình ARMA (Autoregressive Moving Average)

➢ **Ưu điểm và hạn chế**

- **Ưu điểm:**
  - Kết hợp được cả AR và MA → mô tả linh hoạt hơn.
  - Phù hợp cho chuỗi dừng.
- **Hạn chế:**
  - Khó chọn bậc (p, q) tối ưu.
  - Không áp dụng trực tiếp cho chuỗi không dừng.

→Nền tảng quan trọng cho mô hình **ARIMA** (khi chuỗi không dừng).

Mô hình ARMA (Autoregressive Moving Average)

- **Ước lượng tham số**
  - Dùng phương pháp **MLE (Maximum Likelihood Estimation)** hoặc **Least Squares**.
  - Công cụ: Python (statsmodels), R.

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(1, 1)**:

$$y_t = \phi_1 y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$
$$(1-\phi_1 B) y_t = (1-\theta_1 B)\varepsilon_t$$

- Quá trình ARMA(1,1) là dừng nếu $|\phi_1| < 1$, trong trường hợp này, nó có thể được biểu thị dưới dạng một quá trình trung bình động vô hạn, như sau:

$$y_t = \psi(B)\varepsilon_t$$

$$\psi(B) = \frac{(1-\theta_1 B)}{(1-\phi_1 B)}$$

$$\Longrightarrow (1-\phi_1 B)\psi(B) = (1-\theta_1 B)$$

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(1, 1):**

$$(1-\phi_1 B)(1+\psi_1 B+\psi_2 B^2+\cdots)=(1-\theta_1 B)$$

$$\psi_1-\phi_1=-\theta_1 \quad \Rightarrow \psi_1=\phi_1-\theta_1$$

$$\psi_2-\phi_1\psi_1=0 \quad \Rightarrow \psi_2=\phi_1\psi_1=\phi_1(\phi_1-\theta_1)$$

$$\psi_3-\phi_1\psi_2=0 \quad \Rightarrow \psi_3=\phi_1\psi_2=\phi_1^2\psi_1=\phi_1^2(\phi_1-\theta_1)$$

$$\psi_j=\phi_1\psi_{j-1}=\phi_1{}^{j-1}(\phi_1-\theta_1)$$

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(1, 1)**:

$$y_t = \phi_1 y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$
$$(1-\phi_1 B) y_t = (1-\theta_1 B)\varepsilon_t$$

- Quá trình ARMA(1,1) là khả nghịch nếu $|\theta_1| < 1$, trong trường hợp này, nó có thể được biểu thị dưới dạng một quá trình tự hồi quy vô hạn, như sau:

$$\varepsilon_t = \Pi(B) y_t$$

$$\Pi(B) = \frac{(1-\phi_1 B)}{(1-\theta_1 B)}$$

$$\Longrightarrow (1-\theta_1 B)\Pi(B) = (1-\phi_1 B)$$

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(1, 1):**

$$(1-\theta_1 B)(1+\pi_1 B+\pi_2 B^2+\cdots) = (1-\phi_1 B)$$

$$\pi_1 = \phi_1 - \theta_1$$

$$\pi_2 = \theta_1 \pi_1 = (\phi_1 - \theta_1)$$

$$\pi_3 = \theta_1^2 \pi_2 = \theta_1^2 (\phi_1 - \theta_1)$$

$$\pi_j = \phi_1 \pi_{j-1} = \theta_1{}^{j-1} (\phi_1 - \theta_1)$$

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(1, 1)**:

$$y_t = \phi_1 y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

- Giá trị trung bình:

$$E(y_t) = \phi_1 E(y_{t-1}) + 0 = 0$$

- Hàm tự hiệp phương sai:

$$var(y_t) = \gamma(0) = \phi_1^2 \gamma(0) + \sigma_\varepsilon^2 + \theta_1^2 \sigma_\varepsilon^2 - 2\phi_1\theta_1\sigma_\varepsilon^2$$

$$\gamma(0) = \frac{\sigma_\varepsilon^2(1 + \theta_1^2 - 2\phi_1\theta_1)}{1 - \phi_1^2}$$

$$\gamma(1) = \frac{\sigma_\varepsilon^2(\phi_1 - \theta_1)(1 - \phi_1\theta_1)}{1 - \phi_1^2}$$

$$\gamma(k) = \phi_1 \gamma(k-1), \text{ k = 2, 3, …}$$

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(1, 1)**:
  - Ví dụ: $y_t = 0.5y_{t-1} + \varepsilon_t + 0.9\varepsilon_{t-1}$

$$\phi_1 = 0.5,\ \theta_1 = -0.9$$

$$\rho(1) = \frac{(0.5 + 0.9)(1 + 0.45)}{1 + 0.9^2 - 2(0.5)(0.91)} = 0.75$$

$$\rho(2) = \phi_1^{2-1}\rho(1) = (0.5)(0.75) = 0.375$$

$$\rho(3) = \phi_1^{3-1}\rho(1) = (0.5^2)(0.75) = 0.1875$$

$$\rho(4) = \phi_1^{4-1}\rho(1) = (0.5^3)(0.75) = 0.09375$$

$$\rho(5) = \phi_1^{5-1}\rho(1) = (0.5^4)(0.75) = 0.046875$$

Mô hình ARMA (Autoregressive Moving Average)

- **Mô hình ARMA(1, 1)**:

$$y_t = \phi_1 y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

- PACF:

$$\phi_{00} = 1\,.$$

$$\phi_{11} = \rho_1 = \frac{(1-\phi_1\theta_1)(\phi_1-\theta_1)}{1-2\phi_1\theta_1+{\theta_1}^2}$$

$$\phi_{22} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\rho_2 - {\rho_1}^2}{1-\rho_1}$$

$$\phi_{33} = \frac{\rho_3 - \phi_{21}\rho_2 - \phi_{22}\rho_1}{1 - \phi_{21}\rho_1 - \phi_{22}\rho_2}$$

$$\phi_{21} = \phi_{11} - \phi_{22}\phi_{11}$$

Mô hình ARIMA (Integrated Autoregressive Moving Average)

- Hầu hết các chuỗi thời gian thực tế xuất hiện trong các ứng dụng thực tế trong nhiều lĩnh vực kiến thức đều không dừng ở giá trị trung bình, và do đó, chúng ta phải sử dụng phép biến đổi sai phân để làm cho chúng dừng.
  - Giả sử d là bậc nhỏ nhất của các hiệu số cần thiết để làm cho chuỗi dừng. Các mô hình mô tả các quá trình này là quá trình trung bình động tự hồi quy tích hợp.
  - Ký hiệu là ARIMA(p, d, q), để phân biệt chúng với các mô hình ARMA(p, q) dừng.

Mô hình ARIMA (Integrated Autoregressive Moving Average)

- Một quá trình $\{y_t\}$ là một quá trình ARIMA(p, d, q) nếu có thể biểu diễn nó dưới dạng:

$$\phi(B)\nabla^d y_t = \theta(B)\varepsilon_t$$

  - $\phi(B) = \left(1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p\right)$
  - $\theta(B) = \left(1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q\right)$
  - $\nabla^d = (1 - B)^d$

Sử dụng phép biến đổi $z_t = \nabla^d y_t$, ta thu được ARMA(p,q)

$$\phi(B)\, z_t = \theta(B)\varepsilon_t$$

Mô hình ARIMA (Integrated Autoregressive Moving Average)

- Ví dụ: Dạng của mô hình ARIMA(1.1.1)

$$(1-\phi_1 B)(1-B)y_t = (1-\theta_1 B)\varepsilon_t$$

$$z_t = (1-B)y_t \;\; = y_t - y_{t-1}$$

$$(1-\phi_1 B)z_t = (1-\theta_1 B)\varepsilon_t$$

$$z_t = \phi_1 z_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

$$y_t - y_{t-1} = \phi_1(y_{t-1} - y_{t-2}) + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

$$y_t = (1+\phi_1)y_{t-1} - \phi_1 y_{t-2} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

Ước tính tham số

- Chúng ta sẽ giả định rằng bậc của mô hình ARMA(p,q) đã được xác định, tức là chúng ta đã xác định được giá trị của p và q. Do đó, chúng ta cần ước tính giá trị của các tham số σ_ε^2, $\boldsymbol{\phi}$ và $\boldsymbol{\theta}$. Trong phần tiếp theo, chúng ta sẽ thảo luận một số phương pháp:
  - Phương pháp Mô men
  - Phương pháp bình phương nhỏ nhất

Ước tính tham số

- **Phương pháp Mô men:** Phương pháp này được coi là đơn giản nhất trong số các phương pháp ước lượng, trong đó, các mô men mẫu (sample moments) được cân bằng với các mô men lý thuyết tương ứng, và bằng cách giải các phương trình thu được, ta có thể thu được các ước lượng cần thiết.
  - Mô hình AR(1): Theo lý thuyết, $\rho_1 = \phi_1$ và ρ_1 có thể ước tính bằng hệ số tự tương quan mẫu r_1, do đó phương pháp ước tính mô men cho ϕ_1 là:

$$\hat{\phi}_1 = r_1$$

Ước tính tham số

- **Phương pháp Mô men:**
  - Mô hình AR(2): Chúng ta có thể sử dụng phương trình Yule-Walker

$$\rho_K = \phi_1\rho_{K-1} + \phi_2\rho_{K-2} + \cdots + \phi_P\rho_{K-P}$$

có hai tham số, chúng ta cần hai phương trình sau:

$$\rho_1 = \phi_1 + \phi_2\rho_1$$

$$\rho_2 = \phi_1\rho_1 + \phi_2$$

thay ρ_1 bằng r_1 và ρ_2 bằng r_2 , và giải các phương trình này, chúng ta thu được:

$$\hat{\phi}_1 = \frac{r_1(1-r_2)}{1-r_1^2} \qquad \hat{\phi}_2 = \frac{r_2 - r_1^2}{1-r_1^2}$$

Ước tính tham số

- **Phương pháp Mô men:**
  - Mô hình MA(1): Chúng ta có thể sử dụng phương trình

$$\rho_1 = -\frac{\theta}{1+\theta^2}$$

và thay ρ_1 bằng r_1

$$r_1 = -\frac{\theta}{1+\theta^2} \longrightarrow r_1\theta^2 + \theta + r_1 = 0$$

$$\hat{\theta} = \frac{-1 \pm \sqrt{1-4r_1^2}}{2r_1}$$

Đối với các mô hình MA bậc cao hơn, các giải pháp sẽ phức tạp hơn.

Ước tính tham số

- **Phương pháp Mô men:**
  - Ước tính phương sai nhiễu trắng

    Đối với bất kỳ mô hình ARMA(p, q) dừng nào, $\gamma_0 = Var[y_t]$ đượcước tính bằng cách sử dụng phương sai mẫu của chuỗi thời gian y_t:

$$S^2 = \frac{\sum_{i=1}^{n}(y_t - \bar{y})^2}{n-1}$$

    sau đó chúng ta sử dụng mối quan hệ giữaσ_ε^2và các tham số θ hoặc ϕ để có đượcσ_ε^2 cho bất kỳ mô hình nào.

Ước tính tham số

- **Phương pháp Mô men:**
  - Ước tính phương sai nhiễu trắng
    - AR(p):

$$\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \cdots + \phi_p\gamma_p + \sigma_\varepsilon^2$$

$$\rho_k = \frac{\gamma_k}{\gamma_0} \Rightarrow \gamma_k = \gamma_0\rho_k$$

$$\gamma_0 = \phi_1\gamma_0\rho_1 + \phi_2\gamma_0\rho_2 + \cdots + \phi_p\gamma_0\rho_p + \sigma_\varepsilon^2$$

$$\sigma_\varepsilon^2 = \left(1 - \phi_1\rho_1 - \phi_2\rho_2 - \cdots - \phi_p\rho_p\right)\gamma_0$$

$$\hat{\sigma}_\varepsilon^2 = (1 - \hat{\phi}_1 r_1 - \hat{\phi}_2 r_2 - \cdots - \hat{\phi}_p r_p)S^2$$

- p = 1: $\hat{\sigma}_\varepsilon^2 = (1 - r_1^2)S^2$
- p = 2: $\hat{\sigma}_\varepsilon^2 = (1 - \hat{\phi}_1 r_1 - \hat{\phi}_2 r_2)S^2$

Ước tính tham số

- **Phương pháp Mô men:**
  - Ước tính phương sai nhiễu trắng
    - AR(2): Giả sử chúng ta đã quan sát một chuỗi thời gian y_t có kích thước n = 121 mẫu, và chúng ta đã ước tính các hệ số tự tương quan mẫu r_1 = 0,936 và r_2 = 0,802. Giá trị trung bình của chuỗi μ = 5,1069, và $\gamma_0 = Var[y_t] = S^2$= 1,99487.

$$\hat{\phi}_1 = \frac{r_1(1-r_2)}{1-r_1^2} = \frac{0.936(1-0.802)}{1-0.936^2} = 1.50$$

$$\hat{\phi}_2 = \frac{r_2-r_1^2}{1-r_1^2} = \frac{0.802-0.936^2}{1-0.936^2} = -0.598$$

Ước tính tham số

- **Phương pháp Mô men:**
  - Ước tính phương sai nhiễu trắng
    - AR(2): Giả sử chúng ta đã quan sát một chuỗi thời gian y_t có kích thước n = 121 mẫu, và chúng ta đã ước tính các hệ số tự tương quan mẫu r_1 = 0,936 và r_2 = 0,802. Giá trị trung bình của chuỗi μ = 5,1069, và $\gamma_0 = Var[y_t] = S^2$= 1,99487.

$$y_t - 5.1069 = 1.5(y_{t-1} - 5.1069) + 0.598(y_{t-2} - 5.1069) + \varepsilon_t$$

$$y_t = -5.6074 + 1.5y_{t-1} + 0.598y_{t-2} + \varepsilon_t$$

$$\hat{\sigma}_\varepsilon^2 = [1 - \hat{\phi}_1 r_1 - \hat{\phi}_2 r_2]S^2$$

$$= [1 - 1.50 \times 0.936 - (-0.598)0.802]1.99487 = 0.388$$

Ước tính tham số

- **Phương pháp Mô men:**
  - Ước tính phương sai nhiễu trắng
    - MA(p):

$$\gamma_0 = \sigma_\varepsilon^2 \left(1 + \theta_1^2 + \cdots + \theta_q^2\right)$$

$$\hat{\sigma}_\varepsilon^2 = \frac{S^2}{(1 + \hat{\theta}_1^2 + \hat{\theta}_2^2 + \cdots + \hat{\theta}_q^2)}$$

- p = 1:

$$\hat{\sigma}_\varepsilon^2 = \frac{S^2}{(1+\hat{\theta}_1^2)} \quad \text{where} \quad \hat{\theta} = \frac{-1+\sqrt{1-4r_1^2}}{2r_1}$$

Ước tính tham số

- Phương pháp bình phương nhỏ nhất
  - AR(1): Mô hình có dạng như sau

$$y_t - \mu = \phi(y_{t-1} - \mu) + \varepsilon_t$$

$$\varepsilon_t = (y_t - \mu) - \phi(y_{t-1} - \mu)$$

Hàm cần tối ưu

$$S(\phi, \mu) = \sum_{t=2}^{n} \varepsilon_t^2 = \sum_{t=2}^{n} [(y_t - \mu) - \phi(y_{t-1} - \mu)]^2$$

Ước tính tham số

- Phương pháp bình phương nhỏ nhất
  - AR(1): Hàm cần tối ưu

$$S(\phi,\mu)=\sum_{t=2}^{n}\varepsilon_t^2=\sum_{t=2}^{n}[(y_t-\mu)-\phi(y_{t-1}-\mu)]^2$$

$$\frac{\partial S}{\partial \mu}=\sum_{t=2}^{n}2[(y_t-\mu)-\phi(y_{t-1}-\mu)](-1+\phi)=0$$

$$\hat{\mu}=\frac{\sum_{t=2}^{n}y_t-\phi\sum_{t=2}^{n}y_{t-1}}{(n-1)(1-\phi)}$$

large n, $\sum_{t=2}^{n}\frac{y_t}{n-1}\approx\sum_{t=2}^{n}\frac{y_{t-1}}{n-1}\approx\bar{y}$ $\Rightarrow$ $\hat{\mu}\approx\frac{\bar{y}-\phi\bar{y}}{1-\phi}=\frac{\bar{y}(1-\phi)}{1-\phi}=\bar{y}$

Ước tính tham số

- Phương pháp bình phương nhỏ nhất
  - AR(1): Hàm cần tối ưu

$$S(\phi,\mu)=\sum_{t=2}^{n}\varepsilon_t^2=\sum_{t=2}^{n}[(y_t-\mu)-\phi(y_{t-1}-\mu)]^2$$

$$\frac{\partial S(\phi,\bar{y})}{\partial\phi}=-\sum_{t=2}^{n}2[(y_t-\bar{y})-\phi(y_{t-1}-\bar{y})](y_{t-1}-\bar{y})=0$$

$$\hat{\phi}=\frac{\sum_{t=2}^{n}(y_t-\bar{y})(y_{t-1}-\bar{y})}{\sum_{t=2}^{n}(y_{t-1}-\bar{y})^2}$$

Ước tính tham số

- Phương pháp bình phương nhỏ nhất
  - MA(1): Mô hình có dạng như sau

$$\varepsilon_t = y_t + \theta\varepsilon_{t-1}$$

$$\varepsilon_1 = y_1$$
$$\varepsilon_2 = y_2 + \theta\varepsilon_1 = y_2 + \theta y_1$$
$$\varepsilon_3 = y_3 + \theta\varepsilon_2 = y_3 + \theta y_2 + \theta^2 y_1$$
$$\vdots$$
$$\varepsilon_n = y_n + \theta y_{n-1} + \cdots + \theta^{n-1} y_1$$

Hàm cần tối ưu

$$S(\theta) = \sum_{t=1}^{n} \varepsilon_t^2 = \sum_{t=1}^{n} (y_n + \theta y_{n-1} + \cdots + \theta^{n-1} y_1)^2$$

Mô hình tự hồi qui véc tơ (Vector Autoregression)

- Trong thế giới thực, chúng ta thường gặp một số chuỗi thời gian song song được cho là có liên quan với nhau. Chúng ta có thể mô hình AR(p) cho trường hợp nhiều biến. Điểm hấp dẫn của mô hình này là nó đảm bảo rằng các biến vừa ảnh hưởng lẫn nhau vừa bị ảnh hưởng. Lưu ý rằng phép vi phân có thể được áp dụng như trong các mô hình khác trước đây nếu chuỗi không dừng.
- **Ví dụ:** $\begin{cases} x_t = c_1 + a_{11}x_{t-1} + a_{12}y_{t-1} + \varepsilon_{1,t} \\ y_t = c_2 + a_{21}x_{t-1} + a_{22}y_{t-1} + \varepsilon_{2,t} \end{cases}$
  - x_t: giá hàng hoá
  - y_t: nhu cầu tiêu thụ
  - Mô hình tự ước lượng các mối quan hệ này.
    - a_{12}: tác động **nhu cầu → giá**
    - a_{21}: tác động **giá → nhu cầu**

Mô hình tự hồi qui véc tơ (Vector Autoregression)

- **Các lĩnh vực dùng VAR**
  - Kinh tế: GDP, lạm phát, lãi suất
  - Năng lượng: giá điện, nhu cầu, nhiệt độ
  - ML / kiểm soát: nhiều sensor trong hệ điều khiển
- Dùng VAR khi:
  - Có nhiều chuỗi thời gian có liên hệ lẫn nhau.
  - Phân tích tác động lan truyền (dynamic interactions).
  - Khi không chắc biến nào phụ thuộc vào biến nào — VAR không cần giả định trước quan hệ nhân quả cứng nhắc.

Mô hình tự hồi qui véc tơ (Vector Autoregression)

- **Vector Autoregression (VAR)** là mô hình mở rộng của **Autoregression (AR)** từ **một chuỗi** sang **nhiều chuỗi thời gian**.
  - AR: dự đoán y_t dựa vào các giá trị quá khứ của chính nó.
  - VAR: dự đoán **vector** các biến $(y_{1,t}, y_{2,t}, \ldots, y_{k,t})$dựa vào **các giá trị quá khứ của chính tất cả chúng**.

  Nghĩa là **biến này có thể giải thích biến kia**, không còn phân tích đơn lẻ.
  - Cho vector biến quan sát: $\boldsymbol{Y}_t = [y_{1,t} \quad y_{2,t} \quad \cdots \quad y_{k,t}]^T$.
  - VAR(p): $\boldsymbol{Y}_t = \boldsymbol{c} + \boldsymbol{A}_1\boldsymbol{Y}_{t-1} + \boldsymbol{A}_2\boldsymbol{Y}_{t-2} + \cdots + \boldsymbol{A}_p\boldsymbol{Y}_{t-p} + \boldsymbol{\varepsilon}_t$
    - **c**: hằng số
    - $\boldsymbol{A}_i$: hệ số
    - p: độ trễ
    - $\boldsymbol{\varepsilon}_t$: nhiễu trắng

Mô hình tự hồi qui véc tơ (Vector Autoregression)

➢ Các bước xây dựng mô hình VAR

- **(1) Kiểm tra tính dừng (stationarity):** VAR yêu cầu dữ liệu **dừng**. Nếu không: dùng differencing, log, detrend, seasonal adjust…
- **(2) Chọn độ trễ p** sao chomô hình đủ linh hoạt để nắm bắt động học, nhưng không quá phức tạp gây overfitting.
- **(3) Ước lượng các ma trận A_i**: Thường dùng **phương pháp tổng bình phương nhỏ nhất** vì mô hình phân rã gồm $k$phương trình tuyến tính.
- **(4) Kiểm tra tính ổn định của mô hình:** Eigenvalues của companion matrix phải nằm trong vòng tròn đơn vị.
- **(5) Dự báo (Forecast)** $\widehat{Y}_{t+1} = c + A_1 Y_t + \cdots + A_p Y_{t-p+1}$

Mô hình tự hồi qui véc tơ (Vector Autoregression)

➢ Kiểm tra tính ổn định của mô hình

- **Companion matrix** (ma trận đồng hành) là một cách **biểu diễn VAR(p) thành VAR(1)** bằng cách mở rộng vector trạng thái. Điều này rất quan trọng vì **tính ổn định của VAR** được kiểm tra bằng **eigenvalues** của ma trận này.
- Mô hình VAR(p):

$$\boldsymbol{Y}_t = \boldsymbol{c} + \boldsymbol{A}_1\boldsymbol{Y}_{t-1} + \boldsymbol{A}_2\boldsymbol{Y}_{t-2} + \cdots + \boldsymbol{A}_p\boldsymbol{Y}_{t-p} + \boldsymbol{\varepsilon}_t$$

khó phân tích trực tiếp vì có nhiều độ trễ.

Chúng ta biến nó thành dạng **VAR(1)**:

$$\boldsymbol{Z}_t = \boldsymbol{C} + \mathbf{A}\boldsymbol{Z}_{t-1} + \boldsymbol{e}_t$$

Trong đó **A** là *companion matrix*.

$$\boldsymbol{Z}_t = \begin{bmatrix} \boldsymbol{Y}_t^T & \boldsymbol{Y}_{t-1}^T & \dots & \boldsymbol{Y}_{t-p+1}^T \end{bmatrix}^T, \boldsymbol{C} = [\boldsymbol{c}^T \quad \boldsymbol{c}^T \quad \dots \quad \boldsymbol{c}^T]^T,$$

$$\boldsymbol{e}_t = \begin{bmatrix} \boldsymbol{\varepsilon}_t^T & \boldsymbol{\varepsilon}_{t-1}^T & \dots & \boldsymbol{\varepsilon}_{t-p+1}^T \end{bmatrix}^T$$

Mô hình tự hồi qui véc tơ (Vector Autoregression)

➢ **Kiểm tra tính ổn định của mô hình**

- **Companion matrix** (ma trận đồng hành)

$$\boldsymbol{A} = \begin{bmatrix} \boldsymbol{A}_1 & \boldsymbol{A}_2 & \cdots & \boldsymbol{A}_{p-1} & \boldsymbol{A}_p \\ \boldsymbol{I}_k & \boldsymbol{0} & \boldsymbol{0} & \boldsymbol{0} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{I}_k & \boldsymbol{0} & \boldsymbol{0} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{0} & \ddots & \boldsymbol{0} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{0} & \boldsymbol{0} & \boldsymbol{I}_k & \boldsymbol{0} \end{bmatrix}$$

$\boldsymbol{I}_k$: ma trận đơn vị kxk chiều

- Mô hình VAR(p) ổn định khi tất cả trị riêng của ma trận đồng hành phải nằm trong vòng tròn đơn vị.

$$|\lambda_i| < 1$$

Mô hình tự hồi qui véc tơ (Vector Autoregression)

➢ Kiểm tra tính ổn định của mô hình

- **Ví dụ:** Mô hình VAR(2)

$$\boldsymbol{A}_1 = \begin{bmatrix} 0.5 & 0.1 \\ -0.2 & 0.4 \end{bmatrix}, \boldsymbol{A}_2 = \begin{bmatrix} 0.2 & 0 \\ 0 & 0.1 \end{bmatrix}. \Rightarrow \mathbf{A} = \begin{bmatrix} \boldsymbol{A}_1 & \boldsymbol{A}_2 \\ \boldsymbol{I}_2 & \mathbf{0} \end{bmatrix} = \begin{bmatrix} 0.5 & 0.1 & 0.2 & 0 \\ -0.2 & 0.4 & 0 & 0.1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}.$$

- Tính eigenvalues của **A** ta được bốn nghiệm:
  $\lambda_1 = 0.66406738 + 0.05041982\, i$, $\lambda_2 = 0.66406738 - 0.05041982\, i$,
  $\lambda_3 = -0.24111967, \lambda_4 = -0.18701509$
- Các module (độ lớn) của chúng là:
  $|\lambda_1| = |\lambda_2| \approx 0.66597871, |\lambda_3| \approx 0.24111967, |\lambda_4| \approx 0.18701509$
- Vì tất cả các $|\lambda| < 1$, companion matrix có mọi trị riêng nằm trong vòng tròn đơn vị → **VAR(2) này là ổn định**

Mô hình không gian trạng thái

- **Khái niệm:** Các mô hình không gian trạng thái (state-space model) đặt ra một hệ thống mà trạng thái thực sự không thể được đo lường trực tiếp mà chỉ có thể suy ra từ những gì có thể đo lường được. Các mô hình không gian trạng thái cũng dựa trên việc xác định động lực của một hệ thống, chẳng hạn như trạng thái thực sự của hệ thống tiến hóa theo thời gian như thế nào, cả do động lực nội tại và các lực bên ngoài tác động lên hệ thống.
  - Mô hình không gian trạng thái cho phép thay đổi hệ số và tham số theo thời gian, nghĩa là nó cho phép thay đổi hành vi theo thời gian. Chúng tôi không áp đặt điều kiện tính dừng cho dữ liệu khi sử dụng mô hình không gian trạng thái.

Mô hình không gian trạng thái

- Chúng ta sẽ nghiên cứu các phương pháp dựa trên không gian trạng thái sau:
  - Bộ lọc Kalman áp dụng cho mô hình Gauss tuyến tính
  - Mô hình Markov ẩn
  - Chuỗi thời gian cấu trúc Bayes
- Các mô hình không gian trạng thái có thể được sử dụng cho cả ứng dụng xác định và ngẫu nhiên, và có thể áp dụng cho cả dữ liệu lấy mẫu liên tục và dữ liệu lấy mẫu rời rạc. Chúng ta sẽ phân tích dữ liệu lấy mẫu rời rạc, loại dữ liệu phổ biến nhất trong các ứng dụng thực tế.

Kalman Filter

- **Bộ lọc Kalman** là một phương pháp được phát triển tốt và triển khai rộng rãi để kết hợp thông tin mới từ chuỗi thời gian và kết hợp thông tin đó một cách thông minh với thông tin đã biết trước đó để ước tính trạng thái cơ bản.
  - Nó tương đối dễ tính toán và không yêu cầu lưu trữ dữ liệu quá khứ để đưa ra ước tính hiện tại hoặc dự báo tương lai.
  - Bộ lọc Kalman là thuật toán **ước lượng trạng thái động** của một hệ thống **tuyến tính**, **nhiễu Gaussian**, dựa trên:
    - mô hình động học (vật lý / kinh tế / hệ thống điều khiển),
    - quan sát nhiễu (đo lường không hoàn hảo),
    - thông tin ở các thời điểm trước.

Kalman Filter

- Bộ lọc Kalman = bộ ước tính Bayesian đệ quy cho mô hình tuyến tính Gaussian.
  - Nó giúp tìm: $\hat{x}_t \approx x_t$
    trong khi hệ thống có nhiễu và đo lường không chính xác.
  - Kalman Filter hoạt động trên mô hình dạng không gian trạng thái (state-space), gồm 2 phương trình:
    - Phương trình trạng thái (state equation)
    - Phương trình quan sát (measurement equation)

Kalman Filter tìm cách kết hợp thông minh giữa:

- dự đoán (từ mô hình),
- và quan sát thực tế (nhiễu).

Kalman Filter

- Bộ lọc Kalman = bộ ước tính Bayesian đệ quy cho mô hình tuyến tính Gaussian.
  - **Phương trình trạng thái (state equation)**

$$x_t = Fx_{t-1} + Bu_t + w_t$$

    - x_t: vector trạng thái (ẩn)
    - F: ma trận chuyển trạng thái
    - u_t: đầu vào điều khiển
    - w_t: nhiễu hệ thống (process noise), $w_t \sim \mathcal{N}(0, Q)$
  - **Phương trình quan sát (measurement equation)**

$$y_t = Hx_t + v_t$$

    - y_t: quan sát đo được
    - H: ma trận quan sát
    - v_t: nhiễu đo lường (measurement noise), $v_t \sim \mathcal{N}(0, R)$

Kalman Filter

- Bộ lọc Kalman = bộ ước tính Bayesian đệ quy cho mô hình tuyến tính Gaussian.
  - Ở mỗi thời điểm, Kalman Filter làm 2 bước:
    - Bước 1 — Dự đoán (Predict)
    - Bước 2 — Cập nhật (Update)
  - **Bước 1 — Dự đoán (Predict)**

    Từ trạng thái quá khứ:

$$\hat{x}_{t|t-1} = F\hat{x}_{t-1|t-1} + Bu_t$$

    Dự đoán sai số:

$$P_{t|t-1} = FP_{t-1|t-1}F^\top + Q$$

Kalman Filter

- Bộ lọc Kalman = bộ ước tính Bayesian đệ quy cho mô hình tuyến tính Gaussian.
  - **Bước 2 — Cập nhật (Update)**

    Dựa vào quan sát mới y_t:
    - **Tính "độ lợi Kalman" (Kalman Gain)**

      $$K_t = P_{t|t-1}H^\top(HP_{t|t-1}H^\top + R)^{-1}$$

      Nó quyết định: Tin vào mô hình nhiều hơn (K nhỏ) hay tin vào đo lường nhiều hơn (K lớn)
    - **Cập nhật ước lượng trạng thái**

      $$\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t(y_t - H\hat{x}_{t|t-1})$$

      - $y_t - H\hat{x}_{t|t-1}$ là sai lệch giữa đo thật và dự đoán.
      - Cập nhật sai số ước lượng: $P_{t|t} = (I - K_tH)P_{t|t-1}$

      Sau bước này, có trạng thái ước lượng tốt nhất tại thời điểm t.

Kalman Filter

- Tầm quan trọng của bộ lọc Kalman:
  - Nhiều mô hình time series thực chất là state-space
  - Nó xử lý missing data rất tốt: Không cần interpolation.
  - Nó cho phép dự báo mượt (smoothing): Ngoài filter (online), còn có Kalman Smoother (RTS) để ước lượng dùng toàn bộ dữ liệu.

Kalman Filter

- **Kalman Filter khái quát ARIMA / local level / trend model:**
  - Local Level Model:

$$x_t = x_{t-1} + w_t,$$
$$y_t = x_t + v_t$$

  - Local Linear Trend:

$$\mu_t = \mu_{t-1} + \beta_{t-1} + w_{1t}$$
$$\beta_t = \beta_{t-1} + w_{2t}$$
$$y_t = \mu_t + v_t$$

Kalman Filter

- **Kalman Filter khái quát ARIMA / local level / trend model:**
  - ARIMA(1,0,0) = AR(1): $y_t = \phi y_{t-1} + \varepsilon_t, \varepsilon_t \sim N(0, \sigma^2)$
    Ta đặt trạng thái ẩn là chính giá trị AR(1):
    $$x_t = \phi x_{t-1} + w_t, w_t \sim N(0, \sigma^2)$$
    $$y_t = x_t$$
  - ARIMA(0,1,1): $\Delta y_t = y_t - y_{t-1} = \theta \varepsilon_{t-1} + \varepsilon_t$
    Đây chính là Local Level Model trong cấu trúc chuỗi thời gian:
    $$x_t = x_{t-1} + w_t$$
    $$y_t = x_t + v_t$$

Kalman Filter

- Ví dụ **ARIMA(1,0,0):** Giả sử ta có chuỗi:

$$y_t = 0.7y_{t-1} + \varepsilon_t, \varepsilon_t \sim N(0,1)$$

Ban đầu: $\hat{y}_0 = 0,\ \ P_0 = 10$

- **Kalman Predict:**

$$\hat{y}_{t|t-1} = 0.7\ \hat{y}_{t-1|t-1}$$
$$P_{t|t-1} = 0.7^2 P_{t-1|t-1} + 1$$

- **Kalman Update:**
  - Innovation: $\nu_t = \hat{y}_{t|t} - \hat{y}_{t|t-1}$
  - Kalman Gain: $K_t = \frac{P_{t|t-1}}{P_{t|t-1}+0} = 1$ (nhiễu đo lường = 0 trong AR)

→ Với AR(1), Kalman Filter **giảm đúng** thành recursion AR(1) cổ điển.

Mô hình Markov ẩn

- Mô hình Markov ẩn (Hidden Markov Models - HMM) là một phương pháp đặc biệt hữu ích để mô hình hóa chuỗi thời gian
  - Đây là một phương pháp học không giám sát trong phân tích chuỗi thời gian, nghĩa là không có mẫu đúng được gắn nhãn để huấn luyện.
  - Tương tự như bộ lọc Kalman, HMM giả định một hệ thống trong đó có những trạng thái không thể quan sát trực tiếp.
  - quá trình Markov nghĩa là nó "không có bộ nhớ" theo nghĩa xác suất của các sự kiện trong tương lai chỉ có thể được tính toán đầy đủ khi biết trạng thái hiện tại của hệ thống. Nghĩa là, việc biết trạng thái hiện tại và các trạng thái trước đó của hệ thống cũng không hữu ích hơn việc chỉ biết trạng thái hiện tại của hệ thống.

Mô hình Markov ẩn

- **Hidden Markov Model (HMM)** là mô hình thống kê trong đó:
  - có một chuỗi các trạng thái ẩn (hidden states) mà ta không quan sát trực tiếp.
  - mỗi trạng thái ẩn sẽ sinh ra quan sát (observations) mà ta có thể nhìn thấy.
- Quá trình Markov thường được mô tả dưới dạng ma trận. Một HMM gồm 3 thành phần chính:
  - Ma trận chuyển trạng thái (Transition matrix) - ***A***

$$P(z_t = j \mid z_{t-1} = i)$$

  - Phân phối phát ra (Emission distribution) - ***B***

$$P(x_t \mid z_t)$$

  - Phân phối khởi tạo trạng thái

$$\pi_i = P(z_1 = i)$$

Mô hình Markov ẩn

- Một HMM gồm 3 thành phần chính:
  - Ma trận chuyển trạng thái (Transition matrix): $\boldsymbol{A} = [A_{ij}]$
    - Ma trận chuyển trạng thái mô tả: Xác suất chuyển từ trạng thái ẩn này sang trạng thái ẩn khác theo thời gian. Giả sử có K trạng thái ẩn $z_t \in \{1, 2, \dots, K\}$,khi đó:

$$A_{ij} = P(z_{t+1} = j \mid z_t = i)$$

      - Mỗi hàng là tổng bằng 1 (xác suất).
      - $\boldsymbol{A}$ là ma trận $K \times K$.
    - Ví dụ: Trạng thái ẩn gồm S_1(nắng) và S_2 (mưa)

$$A = \begin{bmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{bmatrix}$$

      - Nếu hôm nay nắng, 80% ngày mai vẫn nắng, 20% mưa.
      - Nếu hôm nay mưa, 30% cơ hội mai nắng, 70% mưa.

Mô hình Markov ẩn

- Một HMM gồm 3 thành phần chính:
  - Ma trận phát ra (Emission Matrix): $\boldsymbol{B} = [B_{ij}]$
    - Mỗi trạng thái ẩn sẽ **phát ra quan sát** (emit observation). Ma trận phát ra xác định: Xác suất một trạng thái ẩn sinh ra một quan sát cụ thể.
    - Nếu có: K trạng thái ẩn và M loại quan sát rời rạc
      Thì:

$$B_{ik} = P(x_t = o_k \mid z_t = i)$$

  - Ví dụ: Ta quan sát mặt đất: $o_1(wet)$ và $o_2(dry)$

$$B = \begin{bmatrix} 0.1 & 0.9 \\ 0.8 & 0.2 \end{bmatrix}$$

    - $P(wet \mid sunny) = 0.1$:hiếm khi mặt đất ướt khi trời nắng,
    - $P(wet \mid rain) = 0.8$:mặt đất ướt là chuyện bình thường

Mô hình Markov ẩn

- Một HMM gồm 3 thành phần chính:
  - **Phân phối khởi tạo**, ký hiệu là:

$$\pi = (\pi_1, \pi_2, \ldots, \pi_K)$$

    - là xác suất ban đầu cho biết tại thời điểm t = 1, hệ thống đang ở trạng thái ẩn nào.

      Nói cách khác:

$$\pi_i = P(z_1 = i)$$

    - HMM có nhiều trạng thái ẩn (regimes). Nhưng khi bắt đầu quan sát chuỗi tại thời điểm 1, ta không biết hệ thống đang ở trạng thái nào.

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Đánh giá (Evaluation): Tính xác suất chuỗi quan sát

$$P(x_1, \dots, x_T)$$

→ dùng thuật toán Forward–Backward.

  - Giải mã (Decoding): Tìm chuỗi trạng thái ẩn tối ưu

$$z_1, z_2, \dots, z_T$$

→ dùng Viterbi algorithm.

  - Ước lượng tham số (Learning): Tìm A, B, π từ dữ liệu quan sát

    → dùng Baum–Welch (EM algorithm).

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Forward–Backward là thuật toán **suy diễn xác suất** trong **HMM**. Mục tiêu chính: Tính xác suất "ẩn" tại mỗi thời điểm — tức là

$$P(z_t = \mathrm{i} \mid O, \theta)$$

trong đó O là chuỗi quan sát.

  - Forward Pass (Thuật toán alpha) ta tính xác suất quan sát tính đến thời điểm t, và hiện đang ở trạng thái i.

$$\alpha_t(i) = P(o_1, o_2, \ldots, o_t, z_t = i)$$

    - Khởi tạo: $\alpha_1(i) = \pi_i b_{i1}$
    - Đệ quy: $\alpha_t(i) = b_{it} \sum_{j=1}^{N} \alpha_{t-1}(j) A_{ji}$
    - Kết thúc: $P(O \mid \theta) = \sum_{i=1}^{N} \alpha_T(i)$

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Forward–Backward
    - Backward Pass (Thuật toán beta): nếu tại thời điểm t đang ở trạng thái i → xác suất để sinh ra phần còn lại của chuỗi quan sát

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \ldots, o_T \mid q_t = i)$$

      - Khởi tạo: $\beta_T(i) = 1$
      - Đệ quy: $\beta_t(i) = \sum_{j=1}^{N} a_{ij}\, b_{j,t+1} \beta_{t+1}(j)$

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Forward–Backward
    - Khi có alpha và beta, ta có thể tính:
      - Posterior state probability: xác suất trạng thái tại thời điểm t là $\gamma_t(i) = P(q_t = i \mid O) = \frac{\alpha_t(i)\beta_t(i)}{P(O)}$

        Đây là lượng quan trọng dùng để: Gán trạng thái mềm (soft assignments), tính kỳ vọng trong Baum–Welch
      - **Joint probability giữa hai thời điểm liên tiếp**

$$\xi_t(i, j) = P(q_t, = i q_{t+1} = j \mid O)$$

$$\xi_t(i, j) = \frac{\alpha_t(i)\, a_{ij}\, b_j(o_{t+1})\, \beta_{t+1}(j)}{P(O)}$$

Đây là lượng dùng để ước lượng lại ma trận chuyển

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Baum–Welch algorithm: Chúng ta có thể sử dụng thuật toán Baum Welch để ước tính các tham số của Mô hình Markov ẩn
    - Nếu biết chuỗi trạng thái ẩn $z_1, z_2, \dots, z_T$, ta có thể:
      - đếm số lần đi từ trạng thái i → j → cập nhật A
      - đếm số lần trạng thái i phát ra quan sát o → cập nhật B
    - Nhưng ta **không biết** trạng thái ẩn. Thay vì đếm thật, ta **đếm theo xác suất** (kỳ vọng). Baum–Welch algorithm là 1 phiên bản của EM (Expectation–Maximization) algorithm dùng để ước lượng các tham số của HMM khi các trạng thái ẩn không đo được mà chỉ có dữ liệu quan sát $x_1, x_2, \dots, x_T$

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Baum–Welch algorithm:
    - Chúng ta đơn giản hóa nhiệm vụ bằng cách áp dụng thuật toán Expectation–maximization (EM) như sau:
      1. Khởi tạo ngẫu nhiên các biến xác suất phát xạ.
      2. Tính xác suất của mỗi quan sát khả dĩ, giả sử các giá trị xác suất phát xạ.
      3. Sử dụng các giá trị của quan sát để tạo ra ước tính tốt hơn về các biến xác suất phát xạ.
      4. Lặp lại bước 2 và 3 cho đến khi đạt được sự hội tụ.

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Baum–Welch algorithm: lặp đi lặp lại 2 bước:
    - E-step: tính kỳ vọng số lần chuyển / phát ra. Tính:
      - $\gamma_t(i)$— kỳ vọng "ở trạng thái i"
      - $\xi_t(i,j)$— kỳ vọng "chuyển từ i sang j"

      Dựa trên forward–backward.
    - M-step: cập nhật tham số dựa trên kỳ vọng đó.
      - Cập nhật phân phối khởi tạo: $\pi_i = \gamma_1(i)$
      - Cập nhật ma trận chuyển trạng thái: $A_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$
      - Cập nhật ma trận phát ra: $B_{ik} = \frac{\sum_{t:x_t=o_k} \gamma_t(i)}{\sum_{t=1}^{T} \gamma_t(i)}$

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Viterbi algorithm.
    - Sau khi các tham số của quy trình HMM đã được ước tính, như thông qua thuật toán Baum Welch, câu hỏi tiếp theo được quan tâm là chuỗi trạng thái cơ bản nào có khả năng xảy ra nhất với chuỗi thời gian đo được của các giá trị quan sát được.
    - Thuật toán Viterbi được đảm bảo cung cấp cho bạn giải pháp tốt nhất cho câu hỏi bạn đang đặt ra.
      - Do đây là một thuật toán quy hoạch động được thiết kế để khám phá đầy đủ phạm vi các phép khớp khả thi bằng cách lưu các nghiệm vào các phần của một đường dẫn,
      - khi đường dẫn được kéo dài, không cần phải tính toán lại tất cả các đường dẫn khả thi (đã được tính rồi).

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Viterbi algorithm: là thuật toán dùng để tìm chuỗi trạng thái ẩn có xác suất cao nhất trong mô hình HMM. Tức là "Chuỗi trạng thái ẩn nào có khả năng nhất đã sinh ra chuỗi quan sát O?"
    - Thuật toán dùng Dynamic Programming và dựa trên hai ý tưởng:
      - Tính xác suất tốt nhất để đến mỗi trạng thái tại thời điểm t.
      - Lưu lại đường đi tốt nhất dẫn đến trạng thái đó
    - Ta tính xác suất lớn nhất của mọi chuỗi trạng thái có thể kết thúc ở i tại thời điểm t

$$\delta_t(i) = \max_{z_1,\dots,z_{t-1}} P(z_1, \dots, z_{t-1}, z_t = i, o_1 \dots o_t)$$

Và trạng thái trước đó tốt nhất dẫn đến i

$$\psi_t(i) = argmax_j \, \delta_{t-1}(j) a_{ji}$$

Mô hình Markov ẩn

- Ba bài toán kinh điển trong HMM
  - Viterbi algorithm:
    - Công thức thuật toán
      - Bước 1 — Khởi tạo: $\delta_1(i) = \pi_i B_{i1}$

        $\psi_1(i) = 0$
      - Bước 2 — Đệ quy: Với mỗi thời điểm t ≥ 2:

        $$\delta_t(i) = \max_j \ [\delta_{t-1}(j) a_{ji}]\, b_i(o_t)$$

        $$\psi_t(i) = \arg\max_j \ [\delta_{t-1}(j) a_{ji}]$$
      - Bước 3 — Kết thúc: $P^* = \max_i \ \delta_T(i)$

        $q_T^* = \arg\max_i \ \delta_T(i)$
      - Bước 4 — Truy vết ngược từ T về 1: $q_{t-1}^* = \psi_t(q_t^*)$

        →thu được chuỗi trạng thái tối ưu.

Chuỗi thời gian cấu trúc Bayes

- Chuỗi thời gian cấu trúc Bayes (Bayesian structural time series - BSTS) cung cấp một cách để sử dụng các thành phần có sẵn để xây dựng các mô hình phức tạp hơn, có thể phản ánh các sự kiện đã biết hoặc các giả thuyết thú vị về một hệ thống. Sau đó, chúng ta có thể thiết kế cấu trúc, sử dụng các kỹ thuật điều chỉnh mạnh mẽ để ước tính các tham số cho mô hình đã xây dựng trong trường hợp dữ liệu của chúng ta, và xem liệu mô hình có thực hiện tốt việc mô tả và dự đoán hành vi của hệ thống hay không.

Chuỗi thời gian cấu trúc Bayes

- Trong chuỗi thời gian cấu trúc Bayes, xác suất của mô hình được cập nhật dần khi quan sát dữ liệu mới. Trong cách tiếp cận Bayes, bạn luôn có:
  - Prior: niềm tin ban đầu về tham số mô hình
  - Likelihood: mô hình sinh dữ liệu
  - Posterior: niềm tin đã cập nhật khi thấy dữ liệu
- Bayes đặc biệt phù hợp trong chuỗi thời gian vì:
  - dữ liệu đến theo từng thời điểm
  - hệ thống có thể thay đổi theo thời gian
  - bạn cần dự đoán và cập nhật liên tục

Chuỗi thời gian cấu trúc Bayes

- Chuỗi thời gian cấu trúc Bayes: xác suất của mô hình được cập nhật dần khi quan sát dữ liệu mới.
  - Ví dụ: **Bayesian ARIMA có mô hình g**iống hệt ARIMA nhưng ϕ, θ, σ^2 được coi là ngẫu nhiên
    - Công thức cơ bản:

$$p(\phi,\theta \mid y_{1:T}) = \frac{p(y_{1:T} \mid \phi,\theta)\, p(\phi,\theta)}{p(y_{1:T})}$$

Chuỗi thời gian cấu trúc Bayes

- Chuỗi thời gian cấu trúc Bayes: xác suất của mô hình được cập nhật dần khi quan sát dữ liệu mới.
  - Có bốn bước để điều chỉnh mô hình BSTS, được thực hiện theo thứ tự sau:
    1. Một mô hình cấu trúc được xác định, bao gồm việc xác định các giá trị tiên nghiệm.
    2. Bộ lọc Kalman được áp dụng để cập nhật các ước tính trạng thái dựa trên dữ liệu quan sát được.
    3. Phương pháp spike-and-slab (đặt độ ưu tiên lên các tham số của mô hình hồi quy) được sử dụng để thực hiện lựa chọn biến trong mô hình cấu trúc.
    4. Trung bình mô hình Bayesian được áp dụng để kết hợp các kết quả nhằm mục đích tạo ra dự báo.